«Спуск с Эвереста»
Оракульная сложность выпуклой оптимизации при (L_0, L_1)-гладкости

Михаил Рудоманов▲
МФТИ
Москва, Россия
rudomanov.ma@phystech.edu

Иван Фомин▲
Яндекс
Москва, Россия
fomin.iva2017@gmail.com

Александр Владимирович Гасников
Университет Иннополис
Иннополис, Россия
gasnikov@yandex.ru

Федор Сергеевич Стонякин
МФТИ
Москва, Россия
КФУ им. В. И. Вернадского
Симферополь, Россия
fedyor@mail.ru

▲Равный вклад.

Аннотация. Для выпуклых (L_0, L_1)-гладких функций кривизна может расти вместе с нормой градиента. Поэтому даже при $\|x^0 - x^*\| \le R$ градиент и невязка по функции в начальной точке могут быть экспоненциально большими по $L_1 R$, и оценка $\sqrt{L_0 R^2/\varepsilon}$, известная для ускоренного метода на функциях с липшицевым градиентом, уже не описывает сложность задачи. Мы находим оракульную сложность этого класса для произвольных детерминированных методов первого порядка: при $L_0 R^2/\varepsilon \ge 1$ оптимальное число обращений к оракулу N удовлетворяет соотношению $1 + N = \widetilde{\Theta}\big(\sqrt{L_0 R^2/\varepsilon} + L_1 R\big)$. Верхняя оценка имеет вид $O\big(\sqrt{L_0 R^2/\varepsilon} + (1 + L_1 R)\log(2 + L_1 R)\big)$: метод сначала проходит режим больших градиентов за $O(1 + L_1 R)$ итераций с неточным одномерным поиском, а затем работает обычный ускоренный метод с постоянным шагом. Нижняя оценка получена с помощью цепочек и принципа ортогональной инвариантности на функциях, сопряжённых к сильно выпуклым функциям на многограннике. Если начальная невязка не больше 4ε, то оптимальная оценка принимает вид $1 + N = \widetilde{\Theta}\big(\sqrt{L_0 R^2/\varepsilon} + (L_1 R)^{2/3}\big)$.

Ключевые слова: (L_0, L_1)-гладкость, обобщённая гладкость, выпуклая оптимизация, оракульная сложность, нижние оценки, ускоренные методы, неточный одномерный поиск, методы первого порядка.

Использование языковых моделей. При получении теоретических результатов настоящей работы использовались модели *Codex Astra 6* и *Claude Opus 5.5*. Они также применялись при подготовке и вёрстке рукописи и для перевода исходного текста на английский язык. Каждая строка текста отредактирована и проверена авторами. Ответственность за корректность всех математических утверждений, доказательств и выводов несут исключительно авторы работы.

1 Введение

Мы рассматриваем задачу безусловной выпуклой оптимизации

$$f(x) \to \min_{x \in \mathbb{R}^d},$$

где $f : \mathbb{R}^d \to \mathbb{R}$ — выпуклая дифференцируемая (L_0, L_1)-гладкая функция, достигающая минимума f^* в некоторой точке[1] x^*. О начальной точке x^0 известно лишь, что $\|x^0 - x^*\| \le R$.

Для выпуклых задач с L-липшицевым градиентом расстояние R до точки минимума ограничивает начальную невязку по функции величиной $LR^2/2$ и задаёт сложность градиентных методов — классические оценки LR^2/ε и $\sqrt{LR^2/\varepsilon}$. При обобщённой гладкости это уже не так. Для дважды непрерывно дифференцируемых функций класс (L_0, L_1)-гладких выпуклых функций с параметрами $L_0, L_1 > 0$ задаётся условием

$$0 \preceq \nabla^2 f(x) \preceq \big(L_0 + L_1 \|\nabla f(x)\|\big) I,$$

то есть кривизне разрешено расти вместе с нормой градиента. Эта модель была предложена для объяснения успеха методов с клиппингом градиента (Zhang et al., 2020b,a) и с тех пор стала одним из стандартных предположений в анализе методов первого порядка.

Условие (L_0, L_1)-гладкости было предложено на основе экспериментальных наблюдений при обучении нейронных сетей. В экспериментах с языковой моделью на основе LSTM была обнаружена положительная корреляция между локальной константой гладкости и нормой градиента, что послужило основанием для введения модели с зависимостью $L_0 + L_1\|\nabla f(x)\|$ (Zhang et al., 2020b). Аналогичная зависимость наблюдалась при обучении трансформеров (Crawshaw et al., 2022).

Условие (L_0, L_1)-гладкости не требует выпуклости функции. В частности, ему удовлетворяют многочлены одной переменной степени не ниже третьей при подходящем выборе констант L_0, L_1 (Zhang et al., 2020b). Кроме того, соответствующая оценка гессиана выполняется для некоторых задач распределённо-робастной оптимизации после перехода к двойственной переменной и введения штрафа, при определённых предположениях о функции потерь и дивергенции (Jin et al., 2021, Chen et al., 2023).

В отличие от функций с липшицевым градиентом, расстояние до точки минимума уже не ограничивает невязку по функции квадратичной величиной: в точке на расстоянии R от минимума невязка может достигать $(L_0/L_1^2)\big(e^{L_1 R} - L_1 R - 1\big)$, то есть быть экспоненциально большой по $L_1 R$, и эта оценка достигается (лемма A.2). Поэтому, прежде чем метод попадёт в область малых градиентов, где работает привычная теория задач с липшицевым градиентом, ему приходится пройти область больших градиентов. Сколько обращений к оракулу это стоит наилучшему методу первого порядка, если о начальной точке известно только расстояние R? В этой работе мы даём ответ: с точностью до логарифмических множителей эта цена равна $L_1 R$.

Обозначения. Через $\varepsilon > 0$ обозначается требуемая точность решения задачи по функции: метод должен выдать точку $\hat{x}$, для которой $f(\hat{x}) - f^* \le \varepsilon$. Знак $\|\cdot\|$ всюду означает евклидову норму вектора и спектральную норму матрицы, $[x, y]$ — отрезок с концами $x, y \in \mathbb{R}^d$, $B(x, r)$ — замкнутый шар радиуса r с центром x, КБШ — неравенство Коши–Буняковского–Шварца. Сумму первых k членов последовательности мы обозначаем соответствующей заглавной буквой: например, $A_k = a_1 + \cdots + a_k$ и $A_0 = 0$.

Основной результат. Мы рассматриваем произвольные детерминированные методы первого порядка: методу разрешено запрашивать градиент в любых точках и выдавать любую точку, а учитывается каждое обращение к оракулу. Мы доказываем, что наименьшее число обращений N, при котором существует детерминированный метод первого порядка, решающий задачу для всех функций класса во всех размерностях, удовлетворяет

[1] Точка минимума, вообще говоря, не единственна. Множество $X^* = \arg\min f$ выпукло и замкнуто, поэтому условие ниже равносильно $\operatorname{dist}(x^0, X^*) \le R$, и под x^* можно понимать ближайшую к x^0 точку минимума.

неравенствам[2]

$$1 + N \geq \frac{1}{29}\Big[1 + \sqrt{\frac{L_0 R^2}{\varepsilon}} + \frac{L_1 R}{\sqrt{\log(2 + L_1 R)}}\Big],$$
$$1 + N \leq 5\sqrt{\frac{L_0 R^2}{\varepsilon}} + C\,(1 + L_1 R)\log(2 + L_1 R)$$

с абсолютной константой C (теоремы 3.7 и 4.10). Таким образом, оптимальная сложность равна $\sqrt{L_0 R^2/\varepsilon} + L_1 R$ с точностью до логарифмических множителей, причём логарифмы стоят только при $L_1 R$. Метод верхней оценки использует только градиенты. Нижняя оценка остаётся верной и для методов, которые вместе с градиентом получают значение функции.

Верхняя и нижняя оценки. Верхняя оценка получена методом из двух этапов. На первом этапе метод SHERPA проходит режим больших градиентов за $O(1 + L_1 R)$ итераций. Это ускоренный метод с неточным одномерным поиском ICEPICK, построенный по схеме оценивающих последовательностей Нестерова (Nesterov, 2018). На втором этапе работает обычный ускоренный метод с постоянным шагом $1/(2L_0)$, анализ которого мы берём из работы Tyurin (2026). Используемый вариант этого метода мы называем CRUISE. Нижняя оценка получена по классической схеме: цепочка и принцип ортогональной инвариантности (Nemirovsky and Yudin, 1983, Nesterov, 2018, Carmon et al., 2020).

Ограниченная начальная невязка. Если дополнительно известно, что $f(x^0) - f^* \leq 4\varepsilon$, то сложность падает до

$$1 + N = \widetilde{\Theta}\Big(\sqrt{\frac{L_0 R^2}{\varepsilon}} + (L_1 R)^{2/3}\Big)$$

(приложение B). Противоречия с основным результатом нет: наихудшие функции, на которых получено слагаемое $L_1 R$, имеют огромную начальную невязку и в класс с ограниченной невязкой не входят. Этот режим может быть полезен для схем с рестартами: каждый следующий запуск метода начинается из точки, в которой невязка по функции уже ограничена постоянным кратным точности, требуемой от этого запуска, поэтому стоимость одного запуска определяется показателем $2/3$, а не 1.

Связанные работы. Обобщение, в котором $L_0 + L_1\|\nabla f(x)\|$ заменяется произвольной функцией $\ell(\|\nabla f(x)\|)$, изучалось в работах Li et al. (2023), Tyurin (2025). Мы ограничиваемся аффинным случаем. Гарантии сходимости градиентных методов в выпуклом случае получены в работах Gorbunov et al. (2025), Vankov et al. (2025), Lobanov et al. (2025), ускоренные методы рассматривались в работах Gorbunov et al. (2025), Vankov et al. (2025), Tyurin (2026), Borodich and Kovalev (2026). Нижние оценки для функций с липшицевым градиентом и произвольных методов первого порядка обсуждаются, например, в работе Guzmán and Nemirovski (2015). Сводная таблица известных верхних оценок для выпуклого случая приведена в приложении D.

Сравнение с известными результатами. Известные оценки для выпуклого детерминированного случая, не использующие оценку начальной невязки, содержат либо член $(L_1 R)^2$ или выше, либо множитель, равный логарифму отношения начальной невязки

[2]Здесь и далее нижние оценки доказаны при $L_0 R^2 \geq \varepsilon$.

$f(x^0) - f^*$ к ε или к L_0/L_1^2 (таблица 2). На классе, заданном только радиусом, этот множитель может иметь порядок $L_1 R$. Например, при $L_1 R \geq 1$ для прохождения режима больших градиентов, то есть для достижения невязки $L_0/(128 L_1^2)$, известные оценки дают $O((L_1 R)^{5/3})$ итераций с точной одномерной минимизацией для метода AGMsDR (Vankov et al., 2025) и $O((L_1 R)^2)$ итераций для предварительного этапа метода из работы Tyurin (2026). Наш первый этап проходит этот режим за $O\big((1 + L_1 R)\log(2 + L_1 R)\big)$ обращений к оракулу при неизвестной начальной невязке. После этого ускоренный метод из работы Tyurin (2026, теорема 3.2) даёт оценку $O\big(1 + \sqrt{L_0 R^2/\varepsilon}\big)$ без логарифмов, и мы используем его на втором этапе. Нижние оценки в обобщённой постановке ранее были известны лишь для конкретных методов, например для градиентного спуска с постоянным шагом (Zhang et al., 2020b, Crawshaw et al., 2022), вариантов AdaGrad (Crawshaw and Liu, 2025) и методов без знания параметров (Hübler et al., 2023), или переносились из подкласса $L_1 = 0$ (Nesterov, 2018). Насколько нам известно, теоремы 4.10 и B.3 — первые нижние оценки для произвольных детерминированных методов, в которых участвует L_1.

Организация. В разделе 2 заданы класс функций и оракульная сложность. В разделе 3 построен метод, дающий верхнюю оценку. В разделе 4 доказана нижняя оценка, совпадающая с верхней асимптотически с точностью до логарифмических множителей. Раздел 5 перечисляет открытые вопросы. Приложение A содержит общие неравенства для функций класса, описанного выше, и доказательства вспомогательных лемм. В приложения вынесены также класс с ограниченной начальной невязкой (приложение B), фиксированная размерность (приложение C) и сводная таблица известных оценок (приложение D).

Таблица 1. Результаты, полученные в нашей работе. Столбец «Условие» задаёт дополнительное ограничение на начальную невязку в определении класса.

Результат	Условие	Ниж.	Верх.	Сложность $1 + N$
Теоремы 3.7, 4.10	нет	✓	✓	$\widetilde{\Theta}\Big(1 + \sqrt{\dfrac{L_0 R^2}{\varepsilon}} + L_1 R\Big)$
Теоремы B.7(а), B.3	$f(x^0) - f^* \leq 4\varepsilon$	✓	✓	$\widetilde{\Theta}\Big(1 + \sqrt{\dfrac{L_0 R^2}{\varepsilon}} + (L_1 R)^{2/3}\Big)$
Теорема B.7(б)	$f(x^0) - f^* \leq \Delta$	✗	✓	$O\Big(\log\Big(2 + \dfrac{L_0 R^2}{\varepsilon} + L_1 R\Big) \times$ $\times\Big[1 + \sqrt{\dfrac{L_0 R^2}{\varepsilon}} + (L_1 R)^{2/3}\log^{2/3}\dfrac{2\Delta}{\varepsilon}\Big]\Big)$

В третьей строке предполагается $\Delta > \varepsilon$. При $\Delta \leq \varepsilon$ достаточно вернуть x^0 без обращений к оракулу.

2 Постановка задачи

В этом разделе вводятся класс функций и оракульная сложность.

Определение 2.1 (класс функций)**.**
Пусть $\ell : [0, \infty) \to (0, \infty)$ — непрерывная неубывающая функция. Через $\mathcal{F}_\ell^d$ обозначается класс выпуклых дифференцируемых функций $f : \mathbb{R}^d \to \mathbb{R}$, для которых при всех $x, y \in \mathbb{R}^d$

$$\|\nabla f(x) - \nabla f(y)\| \leq \ell\Big(\sup_{u \in [x,y]} \|\nabla f(u)\|\Big)\|x - y\|. \tag{2.1}$$

Для $\ell(s) = L_0 + L_1 s$ мы пишем $\mathcal{F}^d_{L_0,L_1}$ и называем функции этого класса (L_0, L_1)-*гладкими*.

Неравенство (2.1) — это условие симметричной (L_0, L_1)-гладкости из работы Gorbunov et al. (2025, предположение 1.3), записанное для произвольной функции ℓ. Оно согласуется с определением ℓ-гладкости в работах Li et al. (2023), Tyurin (2025). При $\ell \equiv L$ получается класс выпуклых функций с L-липшицевым градиентом. Класс $\mathcal{F}^d_\ell$ инвариантен относительно ортогональных преобразований координат, сдвигов аргумента и прибавления константы.

Проверять условие (2.1) непосредственно неудобно. Следующая лемма показывает, что его достаточно проверять вдоль прямых, а для дважды непрерывно дифференцируемых функций оно равносильно привычной оценке гессиана. Её доказательство приведено в приложении A.1.

Лемма 2.2 (характеризация класса)**.**
Пусть функция $f : \mathbb{R}^d \to \mathbb{R}$ выпукла и дифференцируема.

(а) $f \in \mathcal{F}^d_\ell$ тогда и только тогда, когда для любых $x, v \in \mathbb{R}^d$ отображение $t \mapsto \nabla f(x + tv)$ локально абсолютно непрерывно на $\mathbb{R}$ и при почти всех t

$$\Big\| \frac{d}{dt} \nabla f(x + tv) \Big\| \le \ell\big(\|\nabla f(x + tv)\|\big)\|v\|. \tag{2.2}$$

(б) Если $f \in C^2(\mathbb{R}^d)$, то $f \in \mathcal{F}^d_\ell$ тогда и только тогда, когда при всех x

$$0 \preceq \nabla^2 f(x) \preceq \ell\big(\|\nabla f(x)\|\big) I. \tag{2.3}$$

Сдвигом аргумента можно добиться равенства $x^0 = 0$, что мы и предполагаем. Рассматриваются два класса задач.

- ▷ $\mathcal{P}_\mathrm{R}$ — все функции $f \in \mathcal{F}^d_{L_0,L_1}$, $d \ge 1$, имеющие точку минимума x^* с $\|x^*\| \le R$ (*класс, заданный только радиусом*).
- ▷ $\mathcal{P}_\Delta$ — функции из $\mathcal{P}_\mathrm{R}$, для которых дополнительно $f(0) - f^* \le \Delta$ (*класс с ограниченной начальной невязкой*).

Метод *решает* класс за N обращений к оракулу в размерности d, если на выходе $f(\hat{x}) - f^* \le \varepsilon$ для всех функций класса на $\mathbb{R}^d$. *Оракульная сложность* $\mathcal{N}(\mathcal{P})$ класса $\mathcal{P}$ — наименьшее N, при котором для каждой размерности d найдётся метод, решающий все задачи класса в этой размерности не более чем за N обращений. Точная модель детерминированного метода нужна для нижней оценки и приведена в разделе 4. Нас интересует прежде всего сложность $\mathcal{N}(\mathcal{P}_\mathrm{R})$, класс $\mathcal{P}_\Delta$ рассматривается в приложении B.

3 Верхняя оценка

В этом разделе построен метод, на котором достигается верхняя оценка сложности класса $\mathcal{P}_\mathrm{R}$. Метод состоит из двух этапов.

- ▷ *Первый этап* (метод SHERPA) проходит режим больших градиентов. Начиная из точки x^0, он находит точку x', для которой

$$\begin{aligned} f(x') - f^* &\le \frac{L_0}{128 L_1^2}, \\ \|x' - x^*\| &\le R. \end{aligned} \tag{3.1}$$

Это ускоренный метод, построенный по схеме оценивающих последовательностей Нестерова (Nesterov, 2018, §2.2), с неточным одномерным поиском.

▷ *Второй этап* (метод CRUISE) запускается из точки x'. В окрестности такой точки функция класса ведёт себя как функция с $2L_0$-липшицевым градиентом, и работает обычный ускоренный метод с постоянным шагом $1/(2L_0)$, анализ которого мы берём из работы Tyurin (2026).

Подразделы 3.1–3.6 посвящены первому этапу, подраздел 3.7 — второму, в подразделе 3.8 доказана итоговая оценка. Всюду в разделе $f \in \mathcal{F}^d_{L_0,L_1}$, а x^* — точка минимума функции f. Доказательства вспомогательных лемм вынесены в приложение A.

3.1 Лемма о спуске

Первая лемма — аналог классической леммы о спуске (Nesterov, 2018, лемма 1.2.3). Шаг градиентного спуска делается с длиной, вычисленной по локальной константе гладкости $L_0 + L_1\|\nabla f(y)\|$.

Лемма 3.1 (лемма о спуске)**.** ▼
Для любой точки $y \in \mathbb{R}^d$ точка

$$y^+ = y - \frac{\nabla f(y)}{4\big(L_0 + L_1\|\nabla f(y)\|\big)}$$

удовлетворяет неравенствам

$$f(y^+) \le f(y) - \frac{5\|\nabla f(y)\|^2}{24\big(L_0 + L_1\|\nabla f(y)\|\big)},$$
$$\|y^+ - x^*\|^2 \le \|y - x^*\|^2 - \frac{\|\nabla f(y)\|^2}{24\big(L_0 + L_1\|\nabla f(y)\|\big)^2}.$$

Доказательство леммы 3.1 приведено в приложении A.3. Длина такого шага не больше $1/(4L_1)$. На таком расстоянии локальная константа гладкости меняется не более чем в $e^{1/4}$ раз (лемма A.1), поэтому функция ведёт себя как функция с липшицевым градиентом.

3.2 Неравенство в точке минимума

При $G \ge 0$ введём функцию

$$\Phi(G) = \frac{L_0}{L_1^2}\Big[\Big(1 + \frac{L_1 G}{L_0}\Big)\log\Big(1 + \frac{L_1 G}{L_0}\Big) - \frac{L_1 G}{L_0}\Big]. \tag{3.2}$$

Она выпукла, $\Phi(0) = 0$ и

$$\begin{aligned} \Phi'(G) &= \frac{1}{L_1}\log\Big(1 + \frac{L_1 G}{L_0}\Big), \\ \Phi''(G) &= \frac{1}{L_0 + L_1 G}. \end{aligned} \tag{3.3}$$

При малых G функция $\Phi(G)$ ведёт себя как $G^2/(2L_0)$, а при больших — как $(G/L_1)\log(L_1 G/L_0)$.

Обычное неравенство выпуклости в точке минимума утверждает, что касательная к графику функции, проведённая в точке y, проходит в точке x^* не выше значения f^*. В классе $\mathcal{F}^d_{L_0,L_1}$ касательная проходит ниже f^* по крайней мере на $\Phi(\|\nabla f(y)\|)$.

Лемма 3.2 (неравенство в точке минимума)**.** ▼
Для любой точки $y \in \mathbb{R}^d$

$$f(y) + \langle \nabla f(y), x^* - y \rangle + \Phi\big(\|\nabla f(y)\|\big) \le f^*.$$

Доказательство леммы 3.2 приведено в приложении A.4. Для дважды непрерывно дифференцируемых функций это частный случай неравенства из работы Vankov et al. (2025, лемма 2.7). Благодаря слагаемому $\Phi(\|\nabla f(y)\|)$ методу первого этапа не нужна оценка начальной невязки по функции.

3.3 Неточный одномерный поиск

Ускоренному методу на каждой итерации нужна точка y на отрезке $[v, x]$, в которой одновременно $f(y) \le f(x)$ и мала величина $\langle \nabla f(y), y - v \rangle$. Точная одномерная минимизация дала бы $\langle \nabla f(y), y - v \rangle \le 0$, но за конечное число обращений к оракулу она не гарантируется. Достаточно метода деления отрезка пополам с заранее известным числом шагов (алгоритм 1). Мы называем этот метод ICEPICK (Inexact Convex Edge Probing by Interval Cutting with Known Query Bound).

Алгоритм 1 ICEPICK: неточный одномерный поиск

Вход: точки $v, x \in \mathbb{R}^d$, числа $r, \delta > 0$, натуральное число m

Запросить $\nabla f(v)$ и $\nabla f(x)$
если $r\|\nabla f(v)\| \le \delta$ **то** ▷ критерий остановки
  вернуть $y = v$
иначе если $r\|\nabla f(x)\| \le \delta$ **то** ▷ критерий остановки
  вернуть $y = x$
иначе если $\langle \nabla f(v), x - v \rangle \ge 0$ **то**
  вернуть $y = v$
иначе если $\langle \nabla f(x), x - v \rangle \le 0$ **то**
  вернуть $y = x$
конец если
$t_- = 0$, $t_+ = 1$
для $j = 1, \dots, m$ **выполнять**
  $t = (t_- + t_+)/2$, запросить $\nabla f\big(v + t(x - v)\big)$
  если $r\|\nabla f(v + t(x - v))\| \le \delta$ **то** ▷ критерий остановки
    вернуть $y = v + t(x - v)$
  иначе если $\langle \nabla f(v + t(x - v)), x - v \rangle = 0$ **то**
    вернуть $y = v + t(x - v)$
  иначе если $\langle \nabla f(v + t(x - v)), x - v \rangle < 0$ **то**
    $t_- = t$
  иначе
    $t_+ = t$
  конец если
конец для
вернуть $y = v + t_+(x - v)$

Лемма 3.3 (неточный одномерный поиск). ▼
Пусть $r, \delta > 0$, точки v и x лежат в шаре $B(x^*, r)$, а натуральное число m удовлетворяет условию

$$2^m \geq 128\Big(1 + \frac{L_0 r^2}{\delta} + L_1 r\Big)^2. \tag{3.4}$$

Тогда алгоритм 1 делает не более $m+2$ обращений к оракулу в точках отрезка $[v, x]$ и возвращает точку $y \in [v, x]$, для которой выполнено одно из двух условий.

(а) Сработал критерий остановки. Тогда $f(y) - f^* \leq \delta$.

(б) Выполнены неравенства

$$\begin{aligned} f(y) &\leq f(x), \\ \langle \nabla f(y), y - v \rangle &\leq \frac{\|\nabla f(y)\|^2}{16\big(L_0 + L_1 \|\nabla f(y)\|\big)}. \end{aligned} \tag{3.5}$$

Доказательство леммы 3.3 приведено в приложении A.5. Число шагов m логарифмически зависит от $L_0 r^2/\delta$ и $L_1 r$. Именно отсюда возникает логарифмический множитель в верхней оценке. Алгоритм 1 использует только градиенты: значения функции ему не нужны.

3.4 Метод первого этапа

Метод первого этапа SHERPA (Smoothness-aware High-gradient Escape with Radius-Preserving Acceleration, алгоритм 2) устроен как ускоренный метод с оценивающими последовательностями (Nesterov, 2018, §2.2) и близок к методу AGMsDR (Vankov et al., 2025, алгоритм 1). Он поддерживает две последовательности точек: x^k с убывающими значениями функции и v^k, по которой строится оценка функции снизу. Здесь и далее сумма первых k членов последовательности обозначается соответствующей заглавной буквой: $A_k = a_1 + \cdots + a_k$, $A_0 = 0$. Коэффициент $a_k > 0$ определяется уравнением

$$a_k^2 = \frac{A_{k-1} + a_k}{7\big(L_0 + L_1 \|\nabla f(y^k)\|\big)} + \frac{a_k \, \Phi\big(\|\nabla f(y^k)\|\big)}{\|\nabla f(y^k)\|^2}. \tag{3.6}$$

Это квадратное уравнение относительно a_k с единственным положительным корнем. Без последнего слагаемого оно совпадает с обычным правилом выбора коэффициентов ускоренного метода, в котором константа Липшица градиента заменена на $7(L_0 + L_1 \|\nabla f(y^k)\|)$. Последнее слагаемое отвечает добавке Φ из леммы 3.2. Оно увеличивает коэффициент на итерациях с большим градиентом.

Из уравнения (3.6) и неравенства $A_{k-1} \geq 0$ следуют два свойства коэффициентов:

$$\begin{aligned} a_k &\leq A_k, \\ a_k^2 &\geq \frac{A_k}{7\big(L_0 + L_1 \|\nabla f(y^k)\|\big)}. \end{aligned} \tag{3.7}$$

На каждой итерации алгоритм 1 делает не более $m+2$ обращений к оракулу, а точки x^k и v^k вычисляются без обращений. Поэтому K итераций стоят не более $K(m+2)$ обращений. Значения функции методу не нужны.

3.5 Невязка и расстояние до точки минимума

Следующая лемма одновременно ограничивает невязку по функции, сумму квадратов норм градиентов с весами и расстояние от точки v^k до точки минимума.

Алгоритм 2 SHERPA (первый этап): ускоренный метод с неточным одномерным поиском

Вход: начальная точка x^0, параметры L_0, L_1, R, причём $L_1 R \geq 1$

$m = \left\lceil \log_2\bigl(128(1 + 128L_1^2R^2 + L_1R)^2\bigr) \right\rceil$, $K = \lceil 60L_1R \rceil$

$v^0 = x^0$, $A_0 = 0$

для $k = 1, \ldots, K$ **выполнять**

  y^k — результат алгоритма 1 на отрезке $[v^{k-1}, x^{k-1}]$ с $r = R$, $\delta = L_0/(128L_1^2)$ и m

  если сработал критерий остановки **то**

    вернуть y^k

  конец если

  a_k — положительный корень уравнения (3.6), $A_k = A_{k-1} + a_k$

  $x^k = y^k - \dfrac{\nabla f(y^k)}{4(L_0 + L_1\|\nabla f(y^k)\|)}$

  $v^k = v^{k-1} - a_k \nabla f(y^k)$

конец для

вернуть x^K

Лемма 3.4. ▼
Пусть $\|x^0 - x^*\| \leq R$, а итерации $1, \ldots, k$ алгоритма 2 прошли без срабатывания критерия остановки. Тогда

$$A_k\bigl(f(x^k) - f^*\bigr) + \frac{1}{2}\sum_{i=1}^{k} a_i^2 \|\nabla f(y^i)\|^2 + \frac{1}{2}\|v^k - x^*\|^2 \leq \frac{R^2}{2}, \tag{3.8}$$

и все точки x^i, v^i, y^i, $i \leq k$, лежат в шаре $B(x^*, R)$.

Доказательство. Индукция по k. При $k = 0$ неравенство (3.8) совпадает с условием $\|x^0 - x^*\| \leq R$. Пусть утверждение верно для $k - 1$.

▷ *Итерация корректна.* По предположению индукции точки v^{k-1} и x^{k-1} лежат в шаре $B(x^*, R)$. Шар выпукл, поэтому отрезок $[v^{k-1}, x^{k-1}]$ и точка y^k лежат в нём, и лемма 3.3 применима. Критерий остановки не сработал, поэтому выполнены неравенства (3.5). Вместе с леммой 3.1 они дают $x^k \in B(x^*, R)$ и

$$\begin{aligned} &f(y^k) \leq f(x^{k-1}), \\ &\langle \nabla f(y^k), y^k - v^{k-1} \rangle \leq \frac{\|\nabla f(y^k)\|^2}{16\bigl(L_0 + L_1\|\nabla f(y^k)\|\bigr)}, \\ &f(x^k) \leq f(y^k) - \frac{5\|\nabla f(y^k)\|^2}{24\bigl(L_0 + L_1\|\nabla f(y^k)\|\bigr)}. \end{aligned} \tag{3.9}$$

▷ *Расстояние.* Так как $v^k = v^{k-1} - a_k \nabla f(y^k)$,

$$\begin{aligned} &\frac{1}{2}\|v^k - x^*\|^2 - \frac{1}{2}\|v^{k-1} - x^*\|^2 \\ &\qquad = a_k \langle \nabla f(y^k), y^k - v^{k-1} \rangle - a_k \langle \nabla f(y^k), y^k - x^* \rangle + \frac{1}{2} a_k^2 \|\nabla f(y^k)\|^2. \end{aligned} \tag{3.10}$$

Оценим первые два слагаемых справа:

$$\begin{aligned} a_k\langle \nabla f(y^k), y^k - v^{k-1}\rangle &\underset{(3.9)}{\leq} \frac{a_k\|\nabla f(y^k)\|^2}{16\big(L_0 + L_1\|\nabla f(y^k)\|\big)}, \\ -a_k\langle \nabla f(y^k), y^k - x^*\rangle &\underset{\text{лемма 3.2}}{\leq} -a_k\big(f(y^k) - f^*\big) - a_k\Phi\big(\|\nabla f(y^k)\|\big). \end{aligned}$$

▷ *Невязка.* Так как $A_k = A_{k-1} + a_k$,

$$\begin{aligned} &A_k\big(f(x^k) - f^*\big) - A_{k-1}\big(f(x^{k-1}) - f^*\big) \\ &\quad\underset{(3.9)}{\leq} A_k\big(f(y^k) - f^*\big) - \frac{5A_k\|\nabla f(y^k)\|^2}{24\big(L_0 + L_1\|\nabla f(y^k)\|\big)} - A_{k-1}\big(f(y^k) - f^*\big) \\ &\quad= a_k\big(f(y^k) - f^*\big) - \frac{5A_k\|\nabla f(y^k)\|^2}{24\big(L_0 + L_1\|\nabla f(y^k)\|\big)}. \end{aligned}$$

▷ *Сумма.* Умножив уравнение (3.6) на $\|\nabla f(y^k)\|^2$, получаем

$$a_k\Phi\big(\|\nabla f(y^k)\|\big) = a_k^2\|\nabla f(y^k)\|^2 - \frac{A_k\|\nabla f(y^k)\|^2}{7\big(L_0 + L_1\|\nabla f(y^k)\|\big)}.$$

Сложим (3.10), две оценки его слагаемых и оценку невязки, затем подставим это равенство:

$$\begin{aligned} &\Big[A_k\big(f(x^k) - f^*\big) + \frac{1}{2}\|v^k - x^*\|^2\Big] - \Big[A_{k-1}\big(f(x^{k-1}) - f^*\big) + \frac{1}{2}\|v^{k-1} - x^*\|^2\Big] \\ &\quad\leq \Big(\frac{a_k}{16} - \frac{5A_k}{24}\Big)\frac{\|\nabla f(y^k)\|^2}{L_0 + L_1\|\nabla f(y^k)\|} - a_k\Phi\big(\|\nabla f(y^k)\|\big) + \frac{1}{2}a_k^2\|\nabla f(y^k)\|^2 \\ &\quad= \Big(\frac{a_k}{16} - \frac{5A_k}{24} + \frac{A_k}{7}\Big)\frac{\|\nabla f(y^k)\|^2}{L_0 + L_1\|\nabla f(y^k)\|} - \frac{1}{2}a_k^2\|\nabla f(y^k)\|^2 \\ &\quad\underset{(3.7)}{\leq} -\frac{A_k\|\nabla f(y^k)\|^2}{336\big(L_0 + L_1\|\nabla f(y^k)\|\big)} - \frac{1}{2}a_k^2\|\nabla f(y^k)\|^2 \leq -\frac{1}{2}a_k^2\|\nabla f(y^k)\|^2. \end{aligned}$$

Прибавив это неравенство к неравенству (3.8) для $k-1$, получаем (3.8) для k. Из него следует $\|v^k - x^*\| \leq R$, что замыкает индукцию. □

3.6 Число итераций первого этапа

Начальная невязка неизвестна и может быть экспоненциально большой по L_1R, поэтому оценка числа итераций через неё бесполезна. Вместо неё работают две суммы, которые ограничивает лемма 3.4: веса A_K и сумма квадратов $a_i^2\|\nabla f(y^i)\|^2$. Итерации с очень большим градиентом увеличивают вторую сумму, поэтому их мало. На остальных итерациях вес A_i не слишком мал, и число таких итераций оценивается так же, как в ускоренном методе для функций с липшицевым градиентом.

Лемма 3.5 (число итераций первого этапа)**.**
Пусть $\|x^0 - x^*\| \leq R$ и $L_1R \geq 1$. Если K итераций алгоритма 2 прошли без срабатывания критерия остановки и

$$f(x^K) - f^* > \frac{L_0}{128L_1^2},$$

то $K < 60L_1R$.

Доказательство.

▷ *Две суммы.* По лемме 3.4 и условию на невязку

$$\begin{aligned} &L_0 A_K < 64 L_1^2 R^2, \\ &\sum_{i=1}^{K} a_i^2 \|\nabla f(y^i)\|^2 \le R^2. \end{aligned} \tag{3.11}$$

▷ *Оценки для одной итерации.* Из неравенств (3.7)

$$\begin{aligned} \sqrt{L_0 A_i} - \sqrt{L_0 A_{i-1}} = \frac{\sqrt{L_0}\, a_i}{\sqrt{A_i} + \sqrt{A_{i-1}}} &\underset{A_{i-1} \le A_i}{\ge} \frac{\sqrt{L_0}\, a_i}{2\sqrt{A_i}} \\ &\underset{(3.7)}{\ge} \frac{1}{2\sqrt{7}} \sqrt{\frac{L_0}{L_0 + L_1 \|\nabla f(y^i)\|}}, \\ L_0 A_i = \frac{L_0 A_i^2}{A_i} &\underset{(3.7)}{\ge} \frac{L_0 a_i^2}{A_i} \\ &\underset{(3.7)}{\ge} \frac{L_0}{7\big(L_0 + L_1 \|\nabla f(y^i)\|\big)}. \end{aligned} \tag{3.12}$$

Разделим уравнение (3.6) на a_i и умножим на $L_1 \|\nabla f(y^i)\|$:

$$L_1 a_i \|\nabla f(y^i)\| = \frac{L_1 \Phi(\|\nabla f(y^i)\|)}{\|\nabla f(y^i)\|} + \frac{A_i}{7a_i} \cdot \frac{L_1 \|\nabla f(y^i)\|}{L_0 + L_1 \|\nabla f(y^i)\|}. \tag{3.13}$$

Оба слагаемых справа неотрицательны. По определению (3.2)

$$\begin{aligned} \frac{L_1 \Phi(\|\nabla f(y^i)\|)}{\|\nabla f(y^i)\|} &= \Big(1 + \frac{L_0}{L_1 \|\nabla f(y^i)\|}\Big) \log\Big(1 + \frac{L_1 \|\nabla f(y^i)\|}{L_0}\Big) - 1 \\ &\ge \log\Big(1 + \frac{L_1 \|\nabla f(y^i)\|}{L_0}\Big) - 1. \end{aligned} \tag{3.14}$$

Умножив (3.13) на $7a_i/A_i$ и сложив с первым неравенством (3.12), получаем

$$\begin{aligned} &2\sqrt{7}\Big(\sqrt{L_0 A_i} - \sqrt{L_0 A_{i-1}}\Big) + \Big(\frac{7 L_1 a_i^2 \|\nabla f(y^i)\|}{A_i}\Big)^{2/3} \\ &\quad \ge \Big(\frac{L_0}{L_0 + L_1 \|\nabla f(y^i)\|}\Big)^{1/2} + \Big(\frac{L_1 \|\nabla f(y^i)\|}{L_0 + L_1 \|\nabla f(y^i)\|}\Big)^{2/3} \\ &\quad \underset{(a)}{\ge} \frac{L_0}{L_0 + L_1 \|\nabla f(y^i)\|} + \frac{L_1 \|\nabla f(y^i)\|}{L_0 + L_1 \|\nabla f(y^i)\|} = 1. \end{aligned} \tag{3.15}$$

Здесь (a) — неравенства $t^{1/2} \ge t$ и $t^{2/3} \ge t$ при $0 \le t \le 1$.

▷ *Итерации с большим произведением* $L_1 a_i \|\nabla f(y^i)\|$. Пусть J — множество номеров $i \le K$, для которых $L_1 a_i \|\nabla f(y^i)\| \ge \sqrt{L_1 R}$. По второму неравенству (3.11)

$$|J|\, L_1 R \le \sum_{i \in J} L_1^2 a_i^2 \|\nabla f(y^i)\|^2 \le L_1^2 R^2,$$

то есть $|J| \le L_1 R$.

▷ *Остальные итерации.* Пусть I — множество остальных номеров. Если оно пусто, то $K = |J| \le L_1 R$. Иначе для $i \in I$ по (3.13) и (3.14)

$$\log\Big(1 + \frac{L_1 \|\nabla f(y^i)\|}{L_0}\Big) - 1 \le L_1 a_i \|\nabla f(y^i)\| < \sqrt{L_1 R},$$

и второе неравенство (3.12) даёт

$$L_0 A_i \geq \frac{1}{7}\Bigl(1 + \frac{L_1\|\nabla f(y^i)\|}{L_0}\Bigr)^{-1} > \frac{1}{7}e^{-\sqrt{L_1 R}-1}.$$

Пусть j — наименьший номер из I. Веса A_i возрастают, поэтому при $i > j$ имеем $A_{i-1} > 0$ и

$$\frac{a_i}{A_i} \leq -\log\Bigl(1 - \frac{a_i}{A_i}\Bigr) = \log\frac{A_i}{A_{i-1}}.$$

Вместе с неравенством $a_j \leq A_j$ это даёт

$$\begin{aligned}\sum_{i\in I}\frac{a_i}{A_i} &\leq 1 + \log\frac{A_K}{A_j} \underset{(3.11)}{<} 1 + \log\bigl(448 L_1^2 R^2 e^{\sqrt{L_1 R}+1}\bigr)\\ &= \sqrt{L_1 R} + 2 + \log 448 + 2\log(L_1 R)\\ &\underset{(б)}{<} 5\sqrt{L_1 R} + \frac{9}{2} \underset{L_1 R \geq 1}{\leq} \frac{19}{2}\sqrt{L_1 R}.\end{aligned}$$

Здесь (б) — неравенства $\log 448 < 13/2$ и $\log t \leq 2\sqrt{t} - 2$ при $t \geq 1$. Сложим неравенства (3.15) по $i \in I$. Первые слагаемые в сумме не больше $2\sqrt{7}\sqrt{L_0 A_K} < 16\sqrt{7} L_1 R$. Ко вторым применим неравенство Гёльдера с показателями 3 и 3/2:

$$\begin{aligned}|I| &< 16\sqrt{7} L_1 R + 7^{2/3}\sum_{i\in I}\bigl(L_1 a_i \|\nabla f(y^i)\|\bigr)^{2/3}\Bigl(\frac{a_i}{A_i}\Bigr)^{2/3}\\ &\leq 16\sqrt{7} L_1 R + 7^{2/3}\Bigl(\sum_{i\in I} L_1^2 a_i^2 \|\nabla f(y^i)\|^2\Bigr)^{1/3}\Bigl(\sum_{i\in I}\frac{a_i}{A_i}\Bigr)^{2/3}\\ &\underset{(3.11)}{<} 16\sqrt{7} L_1 R + 7^{2/3}(L_1 R)^{2/3}\Bigl(\frac{19}{2}\sqrt{L_1 R}\Bigr)^{2/3}\\ &= \Bigl(16\sqrt{7} + \Bigl(\frac{133}{2}\Bigr)^{2/3}\Bigr) L_1 R\\ &\underset{(в)}{<} 59 L_1 R.\end{aligned}$$

Здесь (в) — неравенства $16\sqrt{7} < 42{,}4$ и $(133/2)^{2/3} < 16{,}5$, равносильные $1792 < 42{,}4^2$ и $133^2 < 4 \cdot 16{,}5^3$.

▷ *Итог.* Каждая итерация попадает ровно в одно из множеств J и I, поэтому

$$K = |J| + |I| < L_1 R + 59 L_1 R = 60 L_1 R. \qquad \square$$

3.7 Второй этап

На втором этапе работает ускоренный градиентный метод с постоянным шагом $1/(2L_0)$ (Tyurin, 2026, алгоритм 1) (алгоритм 3). По структуре он близок к методу подобных треугольников (Gasnikov and Nesterov, 2018). Используемый вариант мы называем CRUISE (Constant-step Refinement Using Inertia in Smooth Environments). Это название варианта ускоренного метода из работы Tyurin (2026) с начальной точкой, найденной на первом этапе, а не новый метод, разработанный авторами настоящей статьи. На каждой итерации вычисляется один новый градиент.

Алгоритм 3 CRUISE (второй этап): ускоренный метод с постоянным шагом из работы Tyurin (2026)

Вход: начальная точка x', параметры L_0, L_1, R, число итераций N

$y^0 = w^0 = x'$, $\Gamma_0 = L_0/(64L_1^2R^2)$

для $k = 0, \dots, N-1$ **выполнять**

  $\lambda_k = \sqrt{\Gamma_k/(2L_0)}$

  $y^{k+1} = \dfrac{1}{1+\lambda_k}\Big(y^k + \lambda_k w^k - \dfrac{\nabla f(y^k)}{2L_0}\Big)$

  $w^{k+1} = w^k - \dfrac{\lambda_k}{\Gamma_k}\nabla f(y^{k+1})$

  $\Gamma_{k+1} = \Gamma_k/(1+\lambda_k)$

конец для

вернуть y^N

Предложение 3.6 (второй этап)**.**
Пусть $L_1R \geq 1$, а точка x' удовлетворяет условиям

$$f(x') - f^* \leq \frac{L_0}{128L_1^2},$$
$$\|x' - x^*\| \leq R.$$

Тогда точки алгоритма 3 при всех $k \geq 1$ удовлетворяют неравенству

$$f(y^k) - f^* \leq \frac{18L_0R^2}{k^2}.$$

В частности, при

$$N = \left\lceil \sqrt{\frac{18L_0R^2}{\varepsilon}} \right\rceil \tag{3.16}$$

алгоритм находит точку с невязкой по функции не больше ε, сделав не более

$$5\sqrt{\frac{L_0R^2}{\varepsilon}} + 2$$

обращений к оракулу.

Доказательство. Это теорема 3.2 из работы Tyurin (2026) для $\ell(s) = L_0 + L_1 s$ с параметром точности, равным удвоенной правой части первого неравенства (3.1). Проверим её условия.

▷ Автор работы Tyurin (2026) формулирует результат для дважды дифференцируемых функций, но отмечает (там же, после леммы 2.2), что вместо оценки гессиана достаточно неравенства

$$\|\nabla f(z) - \nabla f(y)\| \leq \big(L_0 + L_1\|\nabla f(y)\|\big)\frac{e^{L_1\|z-y\|} - 1}{L_1}.$$

Для нашего класса это лемма A.1(б).

▷ Функция из условия теоремы 3.2 строго возрастает на $[0, \infty)$, поскольку при $t > 0$

$$\frac{d}{dt}\,\frac{t^2}{2(L_0 + 4L_1t)} = \frac{t(L_0 + 2L_1t)}{(L_0 + 4L_1t)^2} > 0.$$

▷ Условие теоремы 3.2 на параметр точности выполнено с равенством:

$$\ell\Big(8\sqrt{\ell(0)\,\frac{L_0}{64L_1^2}}\Big) = L_0 + 8L_1\sqrt{\frac{L_0^2}{64L_1^2}} = 2L_0 = 2\ell(0).$$

▷ В теореме 3.2 начальная точка ускоренного метода получена градиентным спуском, но в доказательстве (там же, приложение E.1, формула (32)) используются только два её свойства (3.1). Для точки x' они выполнены по условию.

▷ Число предварительных итераций в теореме 3.2 равно нулю:

$$\frac{\Gamma_0}{8L_0} = \frac{1}{512L_1^2R^2} \le \frac{4}{9},$$

поэтому

$$\max\Big\{1 + \frac{1}{2}\log_{3/2}\frac{\Gamma_0}{8L_0},\ 0\Big\} = 0.$$

Теорема 3.2 даёт оценку из формулировки предложения. При N из (3.16) её правая часть для $k = N$ не больше ε. Алгоритм вычисляет градиенты в точках $y^0, \dots, y^N$, поэтому число $N+1$ его обращений к оракулу удовлетворяет неравенству

$$N + 1 \le \sqrt{\frac{18L_0R^2}{\varepsilon}} + 2 \le 5\sqrt{\frac{L_0R^2}{\varepsilon}} + 2.$$

□

3.8 Итоговая оценка

Теорема 3.7 (верхняя оценка для класса, заданного только радиусом)**.**
Для любых $L_0, L_1, R, \varepsilon > 0$

$$\mathcal{N}(\mathcal{P}_{\mathrm{R}}) \le 5\sqrt{\frac{L_0R^2}{\varepsilon}} + 240\,(1 + L_1R)\log_2\big(64(1 + L_1R)\big) + 2.$$

Метод, на котором достигается эта оценка, использует только градиенты и числа L_0, L_1, R, ε. Значение f^*, оценка начальной невязки и значения функции ему не нужны.

Доказательство.

▷ *Сведение к случаю* $L_1R \ge 1$. Если $L_1R < 1$, то класс $\mathcal{F}^d_{L_0,L_1}$ содержится в классе $\mathcal{F}^d_{L_0,1/R}$. Тогда во всех параметрах обоих этапов заменим L_1 на $1/R$. После замены $K = 60$ и $m = 22$, поэтому первый этап делает не больше $60 \cdot 24 = 240\log_2 64$ обращений к оракулу, что не превосходит $240(1 + L_1R)\log_2\big(64(1 + L_1R)\big)$. Далее $L_1R \ge 1$.

▷ *Первый этап.* Запустим алгоритм 2. Число m в нём удовлетворяет условию (3.4) с $r = R$ и $\delta = L_0/(128L_1^2)$. Пусть x' — возвращённая точка. Докажем, что для неё выполнены неравенства (3.1). Если на итерации k сработал критерий остановки, то первое из них даёт лемма 3.3. Кроме того, x' лежит на отрезке $[v^{k-1}, x^{k-1}]$, концы которого по лемме 3.4 лежат в шаре $B(x^*, R)$. Иначе выполнены все $K \ge 60L_1R$ итераций, и первое неравенство даёт лемма 3.5, а второе — лемма 3.4.

▷ *Число обращений на первом этапе.* Оно не больше $K(m+2)$. При $L_1R \ge 1$

$$K \le 60L_1R + 1 \le 60(1 + L_1R),$$
$$m + 2 \underset{\text{(a)}}{\le} \log_2\big(2^{21}L_1^2R^2(1 + L_1R)^2\big) + 3 \le 4\log_2\big(64(1 + L_1R)\big).$$

Здесь (а) — неравенство $1 + 128L_1^2R^2 + L_1R \le 128L_1R(1 + L_1R)$. Значит, первый этап делает не больше $240(1 + L_1R)\log_2\bigl(64(1 + L_1R)\bigr)$ обращений к оракулу.

▷ *Второй этап.* Если ε не меньше правой части первого неравенства (3.1), возвращаем x'. Иначе запускаем из x' алгоритм 3 с числом итераций (3.16). По предложению 3.6 он находит точку с невязкой по функции не больше ε, и число его обращений к оракулу ограничено оценкой из этого предложения.

Складывая число обращений на двух этапах, получаем утверждение теоремы. Оба алгоритма используют только градиенты. □

Итак,

$$\mathcal{N}(\mathcal{P}_{\mathrm{R}}) = O\Bigl(\sqrt{\frac{L_0R^2}{\varepsilon}} + (1 + L_1R)\log(2 + L_1R)\Bigr).$$

Классическое слагаемое входит без логарифма и с константой 5, а логарифмический множитель стоит только при L_1R и возникает из одномерного поиска. В разделе 4 показано, что с точностью до логарифмических множителей эта оценка неулучшаема.

4 Нижняя оценка

Модель оракула. Мы пользуемся стандартной моделью чёрного ящика с оракулом первого порядка (Nemirovsky and Yudin, 1983), (Nesterov, 2018, §1.1.2). На запрос $z \in \mathbb{R}^d$ оракул возвращает пару $(f(z), \nabla f(z))$, другой информации о функции у метода нет. *Детерминированный метод*, делающий N обращений к оракулу в размерности d, задаётся двумя правилами: k-я точка запроса есть произвольная функция предыдущих точек запроса и ответов оракула в них, а выход $\hat{x}$ — произвольная функция всех точек запроса и ответов. Метод знает L_0, L_1, R, ε (и оценку начальной невязки Δ, если она задана), но не знает f^* и x^*. Значения функции в ответе оракула только расширяют возможности метода, поэтому нижние оценки этого раздела тем более верны для методов, получающих лишь градиенты.

Нижняя оценка означает, что для каждого детерминированного метода с меньшим числом обращений к оракулу найдётся функция класса, на выходе которой невязка по функции больше ε. Мы пользуемся классической схемой Nemirovsky and Yudin (1983) в форме, изложенной в работе Carmon et al. (2020). Схема состоит из двух шагов.

▷ *Цепочка.* Строится выпуклая функция на $\mathbb{R}^n$, у которой каждое обращение к оракулу открывает не больше одной новой координаты. Крыловский метод после $n-1$ обращений не выходит из подпространства, где последняя координата равна нулю, а там невязка больше ε.

▷ *Принцип ортогональной инвариантности.* Класс не меняется при ортогональных преобразованиях. Поэтому, поворачивая цепочку в пространстве размерности $2n$, оценку для крыловских методов можно перенести на произвольные детерминированные методы.

Оба шага — общий инструмент, он описан в подразделе 4.1. Там же построены цепочки, сопряжённые к сильно выпуклым функциям на многограннике. Конкретные цепочки различаются наклонами звеньев. В подразделе 4.2 наклоны убывают в геометрической прогрессии, и цепочка содержит почти L_1R звеньев. В приложении B наклоны равны, звеньев порядка $(L_1R)^{2/3}$, зато начальная невязка мала. Классическое слагаемое, не зависящее от L_1, даёт нижняя оценка для функций с L_0-липшицевым градиентом (Nesterov, 2018, теорема 2.1.7), мы её не передоказываем. Основной результат раздела, теорема 4.10, доказан в подразделе 4.3.

4.1 Цепочки и принцип ортогональной инвариантности

Пусть $e_1, \dots, e_n$ — стандартный базис $\mathbb{R}^n$. Положим $\mathcal{K}_0 = \{0\}$ и при $j = 1, \dots, n$

$$\mathcal{K}_j = \operatorname{span}\{e_1, \dots, e_j\}.$$

Определение 4.1 (цепочка)**.**
Дифференцируемая функция $\varphi : \mathbb{R}^n \to \mathbb{R}$ называется *цепочкой*, если при каждом $j = 1, \dots, n$

$$y \in \mathcal{K}_{j-1} \implies \nabla\varphi(y) \in \mathcal{K}_j. \tag{4.1}$$

Это нуль-цепочки из работы Carmon et al. (2020), а $\mathcal{K}_j$ играют роль крыловских подпространств. Метод назовём *крыловским*, если каждая точка запроса и выход лежат в линейной оболочке уже полученных градиентов. Такой метод после $n-1$ обращений к цепочке не выходит из $\mathcal{K}_{n-1}$.

Цепочки на многограннике. Квадратичная цепочка не использует L_1. Чтобы получить слагаемое с $L_1 R$, нужна цепочка, кривизна которой растёт вместе с градиентом. Мы строим её как функцию, сопряжённую к сильно выпуклой функции H на многограннике: чем меньше модуль сильной выпуклости H, тем больше кривизна сопряжённой функции. При постоянном модуле градиент сопряжённой функции липшицев с обратной константой (Nesterov, 2018, теорема 6.1.1). Следующая лемма разрешает модулю зависеть от точки.

Лемма 4.2 (гладкость сопряжённой функции)**.**
Пусть $K \subset \mathbb{R}^n$ — непустой выпуклый компакт, функция H непрерывна на K, и для любых $z, z' \in K$ её сужение на отрезок $[z, z']$ сильно выпукло с модулем

$$\frac{1}{L_0 + L_1 \max\{\|z\|, \|z'\|\}}.$$

Тогда при любом $\sigma \in \mathbb{R}^n$ функция

$$\varphi(y) = \max_{z \in K} \big\{ \langle y + \sigma, z \rangle - H(z) \big\}$$

выпукла и дифференцируема, её градиент $\nabla\varphi(y)$ — единственная точка максимума $z(y)$, и при всех y, y'

$$\|\nabla\varphi(y) - \nabla\varphi(y')\| \le \Big(L_0 + L_1 \max\big\{ \|\nabla\varphi(y)\|, \|\nabla\varphi(y')\| \big\} \Big) \|y - y'\|. \tag{4.2}$$

В частности, $\varphi \in \mathcal{F}^n_{L_0, L_1}$.

Модуль убывает с ростом норм концов отрезка. Именно поэтому кривизна φ может расти вместе с градиентом, который лежит в K.

Доказательство.

- ▷ *Градиент.* Обозначим $\Psi_y(z) = \langle y + \sigma, z \rangle - H(z)$. Функция H строго выпукла на каждом отрезке, поэтому Ψ_y имеет на K единственную точку максимума $z(y)$. По теореме Данскина функция φ выпукла, дифференцируема и $\nabla\varphi(y) = z(y)$.
- ▷ *Рост вокруг точки максимума.* Пусть $z = z(y)$, $z' \in K$, $z_t = z + t(z' - z)$, а m — модуль из условия для отрезка $[z, z']$. По условию функция $\Psi_y(z_t)$ остаётся вогнутой

по t после прибавления квадратичного слагаемого с модулем m, поэтому

$$\begin{aligned}\Psi_y(z) &\underset{z=z(y)}{\geq} \Psi_y(z_t)\\ &\underset{\text{(a)}}{\geq} (1-t)\Psi_y(z) + t\Psi_y(z') + \frac{m}{2}t(1-t)\|z'-z\|^2,\end{aligned}$$

где (a) — сильная вогнутость Ψ_y на отрезке $[z, z']$ с модулем m. Вычитая $(1-t)\Psi_y(z)$, деля на t и устремляя t к нулю, получаем

$$\Psi_y(z(y)) - \Psi_y(z') \geq \frac{m}{2}\|z'-z(y)\|^2. \tag{4.3}$$

▷ *Липшицевость градиента.* Пусть $z = z(y)$, $z' = z(y')$, а m — модуль для отрезка $[z, z']$. Сложим (4.3) для пары (y, z') с тем же неравенством для пары (y', z). Значения H сокращаются, и

$$\begin{aligned}m\|z-z'\|^2 &\leq \langle y-y', z-z'\rangle\\ &\underset{\text{КБШ}}{\leq} \|y-y'\|\,\|z-z'\|.\end{aligned}$$

При $z = z'$ неравенство (4.2) очевидно, иначе деление на $m\|z-z'\|$ даёт (4.2). Максимум нормы градиента по концам отрезка не больше его супремума по отрезку, поэтому $\varphi \in \mathcal{F}^n_{L_0,L_1}$. □

Принцип ортогональной инвариантности. Ограничение на метод снимается поворотом цепочки: класс не меняется при ортогональных преобразованиях.

Предложение 4.3 (принцип ортогональной инвариантности)**.**

(a) Пусть $\varphi : \mathbb{R}^n \to \mathbb{R}$ — выпуклая цепочка, $d \geq 2n$, и каждой матрице V размера $d \times n$ с ортонормированными столбцами $v_1, \ldots, v_n$ сопоставлена функция

$$F_V(x) = \varphi(V^\top x).$$

Пусть каждая функция F_V достигает минимума и при некотором $\mathrm{gap} > 0$

$$\langle v_n, x\rangle = 0 \implies F_V(x) - \min F_V \geq \mathrm{gap}. \tag{4.4}$$

Тогда для любого детерминированного метода с $n-1$ обращениями к оракулу в $\mathbb{R}^d$ найдётся V, для которого $F_V(\hat{x}) - \min F_V \geq \mathrm{gap}$.

(б) Пусть цепочка $\varphi \in \mathcal{F}^n_{L_0,L_1}$ имеет точку минимума нормы не больше R и при $y_n = 0$

$$\varphi(y) - \min\varphi \geq \mathrm{gap} > \varepsilon.$$

Тогда $\mathcal{N}(\mathcal{P}_{\mathrm{R}}) \geq n$. Если, кроме того, $\varphi(0) - \min\varphi \leq \Delta$, то $\mathcal{N}(\mathcal{P}_\Delta) \geq n$.

Пункт (a) — принцип ортогональной инвариантности в форме Carmon et al. (2020, §3.3). Векторы v_k выбираются по ходу работы метода ортогонально уже сделанным запросам, поэтому ответы оракула, включая значения функции, не зависят от ещё не выбранных векторов. Квадратичная цепочка для методов, точки которых лежат в линейной оболочке градиентов, разобрана, например, в Гасников (2021, упражнение 1.3). Переход к произвольным детерминированным методам восходит к Nemirovsky and Yudin (1983). Пункт (б) следует из (a) при $d = 2n$.

4.2 Цепочка с геометрически убывающими наклонами

Звенья этой цепочки — аффинные функции координат с наклонами G_i, убывающими в геометрической прогрессии. Благодаря этому сдвиги звеньев почти одинаковы, и в шар радиуса R помещается почти $L_1 R$ звеньев: теряется лишь множитель $\sqrt{\log(L_1 R)}$. Новыми здесь являются выбор функции H, модуль сильной выпуклости которой убывает ровно так, как требует условие (L_0, L_1)-гладкости, и выбор наклонов и сдвигов.

Наклоны и сдвиги. Зафиксируем $n \geq 1$ и при $i = 1, \ldots, n$ положим

$$\begin{aligned} G_i &= \varepsilon L_1 \exp\Bigl((n-i)\sqrt{\frac{\log(4n)}{n}}\Bigr), \\ \sigma_i &= \frac{2}{L_1}\log\Bigl(1 + \frac{L_1 G_1}{L_0}\Bigr) + \frac{2}{L_1} + \frac{4\log(1+\sqrt{n})}{L_1 G_i}\sum_{k=i}^{n} G_k. \end{aligned} \tag{4.5}$$

Наклоны убывают от G_1 до $G_n = \varepsilon L_1$. Из определения сдвигов при $j < l$

$$\begin{aligned} G_j\sigma_j - G_l\sigma_l &= (G_j - G_l)\Bigl[\frac{2}{L_1}\log\Bigl(1 + \frac{L_1 G_1}{L_0}\Bigr) + \frac{2}{L_1}\Bigr] + \frac{4\log(1+\sqrt{n})}{L_1}\sum_{k=j}^{l-1} G_k \\ &\geq (G_j - G_l)\,\frac{2}{L_1}\log\Bigl(1 + \frac{L_1 G_1}{L_0}\Bigr) + \frac{4\log(1+\sqrt{n})}{L_1}\,G_j. \end{aligned} \tag{4.6}$$

Функция на многограннике. Определим многогранник

$$K = \Bigl\{ z \in \mathbb{R}^n : \; z \geq 0, \; \sum_{i=1}^{n} \frac{z_i}{G_i} \leq 1 \Bigr\}$$

и при $p \geq 0$ функцию

$$r(p) = \frac{4}{L_1}\Bigl[\Bigl(p + \frac{1}{\sqrt{n}}\Bigr)\log\bigl(1 + \sqrt{n}\,p\bigr) - p\Bigr].$$

Её производные равны

$$\begin{aligned} r'(p) &= \frac{4}{L_1}\log\bigl(1 + \sqrt{n}\,p\bigr), \\ r''(p) &= \frac{4\sqrt{n}}{L_1\bigl(1 + \sqrt{n}\,p\bigr)}, \end{aligned} \tag{4.7}$$

так что $r(0) = r'(0) = 0$. Для точки $z \in K$ обозначим $Z_n = z_1 + \cdots + z_n$ и положим

$$H(z) = \begin{cases} 2\Phi(Z_n) + Z_n \sum_{i=1}^{n} r\Bigl(\frac{z_i}{Z_n}\Bigr), & Z_n > 0, \\ 0, & z = 0, \end{cases}$$

где Φ — функция (3.2) из раздела 3. Наконец, положим

$$\varphi(y) = \max_{z \in K}\bigl\{\langle y + \sigma, z\rangle - H(z)\bigr\}. \tag{4.8}$$

В вершине $G_i e_i$ многогранника выражение под максимумом равно $G_i(y_i + \sigma_i) - H(G_i e_i)$, то есть i-е звено — аффинная функция с наклоном G_i.

Первое слагаемое H зависит только от суммы координат z и отвечает за рост кривизны вместе с градиентом. Второе слагаемое отвечает за распределение этой суммы по координатам. Производная r в нуле конечна, поэтому далёкие звенья не включаются вовсе.

Лемма 4.4 (принадлежность классу)**.**
Функция H удовлетворяет условию леммы 4.2. Следовательно, $\varphi \in \mathcal{F}^n_{L_0,L_1}$ и её градиент удовлетворяет неравенству (4.2).

Доказательство.

▷ *Непрерывность.* Функция r выпукла и $r(0) = 0$, поэтому на $[0,1]$

$$0 \le r(p) \le p\, r'(p) \le p\, r'(1).$$

Значит, второе слагаемое H не больше $Z_n r'(1)$ и стремится к нулю вместе с Z_n. В остальных точках K непрерывность очевидна.

▷ *Вторая производная вдоль отрезка.* Пусть $z, z' \in K$ различны, $u = z' - z$ и $w = z + tu$, $t \in [0,1]$. Обозначим $W_n = w_1 + \dots + w_n$ и $U_n = u_1 + \dots + u_n$, так что W_n зависит от t и его производная по t равна U_n. Положим

$$p = \frac{w}{W_n}.$$

Координаты, равные нулю в обеих точках, равны нулю на всём отрезке, остальные положительны при $0 < t < 1$. Поэтому на $(0,1)$ функция $t \mapsto H(w)$ дважды непрерывно дифференцируема. Второе слагаемое H — перспектива функции $r(p_1) + \dots + r(p_n)$. Вдоль отрезка

$$\frac{dp}{dt} = \frac{u - pU_n}{W_n},$$
$$\Phi''(W_n) \underset{(3.3)}{=} \frac{1}{L_0 + L_1 W_n},$$

и дифференцирование даёт

$$\frac{d^2}{dt^2} H(w) = \frac{2U_n^2}{L_0 + L_1 W_n} + \sum_{i=1}^n \frac{r''(p_i)}{W_n} (u_i - p_i U_n)^2. \tag{4.9}$$

Вектор p лежит в симплексе, поэтому каждая его координата не больше его нормы и

$$\frac{1}{\sqrt{n}} \le \|p\| \le 1. \tag{4.10}$$

Кроме того, $\|w\| = W_n \|p\|$. Оценим коэффициенты в (4.9):

$$\begin{aligned} \frac{r''(p_i)}{W_n} &\underset{(4.7)}{=} \frac{4\sqrt{n}}{L_1 W_n \left(1 + \sqrt{n}\, p_i\right)} \underset{(4.10)}{\ge} \frac{2}{L_1 W_n \|p\|} \\ &= \frac{2}{L_1 \|w\|} \ge \frac{2}{L_0 + L_1 \|w\|}, \\ \frac{2}{L_0 + L_1 W_n} &\underset{\|p\| \le 1}{\ge} \frac{2\|p\|^2}{L_0 + L_1 W_n \|p\|} = \frac{2\|p\|^2}{L_0 + L_1 \|w\|}. \end{aligned}$$

Подставляя их в (4.9), получаем

$$\begin{aligned} \frac{d^2}{dt^2} H(w) &\ge \frac{2}{L_0 + L_1 \|w\|} \left(\|p\|^2 U_n^2 + \|u - pU_n\|^2 \right) \\ &\underset{(а)}{\ge} \frac{\|u\|^2}{L_0 + L_1 \|w\|} \underset{(б)}{\ge} \frac{\|u\|^2}{L_0 + L_1 \max\{\|z\|, \|z'\|\}}. \end{aligned}$$

Здесь (а) — неравенство $\|u\|^2 \le 2\|pU_n\|^2 + 2\|u - pU_n\|^2$, (б) — выпуклость нормы.

▷ *Вывод.* Сужение H на отрезок минус квадратичное слагаемое из леммы 4.2 имеет на $(0,1)$ неотрицательную вторую производную и непрерывно на $[0,1]$. Значит, оно выпукло, и лемма 4.2 применима. □

Вторая производная слагаемого $2\Phi(Z_n)$ даёт множитель $L_0 + L_1\|z\|$ в модуле сильной выпуклости и, следовательно, рост кривизны φ вместе с градиентом. Множитель $\sqrt{n}$ в функции r согласует второе слагаемое с первым и определяет величину

$$r'(1) = \frac{4}{L_1}\log\bigl(1+\sqrt{n}\bigr),$$

от которой зависит длина цепочки.

Лемма 4.5 (цепочка)**.**
Функция φ — цепочка: если $y \in \mathcal{K}_{j-1}$, то $\nabla\varphi(y) \in \mathcal{K}_j$.

Доказательство. Пусть $y \in \mathcal{K}_{j-1}$, то есть $y_i = 0$ при $i \geq j$, и $z = \nabla\varphi(y)$. Нужно доказать, что $z_l = 0$ при $l > j$. Если $z = 0$, доказывать нечего. Иначе $Z_n > 0$. Пусть p — вектор z, делённый на Z_n.

▷ *Условия оптимальности.* В окрестности z функция H дифференцируема и $\partial_i H(z) = \nu + r'(p_i)$, где

$$\nu = 2\Phi'(Z_n) + \sum_{k=1}^{n}\bigl[r(p_k) - p_k r'(p_k)\bigr].$$

Точка z максимизирует вогнутую функцию на многограннике K. По теореме Каруша–Куна–Таккера найдётся множитель $\lambda \geq 0$ линейного ограничения, задающего K, для которого

$$y_i + \sigma_i - \frac{\lambda}{G_i}\begin{cases} = \nu + r'(p_i), & z_i > 0, \\ \leq \nu, & z_i = 0. \end{cases} \tag{4.11}$$

▷ *Оценка сверху для ν.* Так как $r(p) \leq p\,r'(p)$, имеем $\nu \leq 2\Phi'(Z_n)$. Далее, $Z_n \leq G_1$, поскольку $z \in K$ и все наклоны не больше G_1. Функция Φ' возрастает, поэтому

$$\nu \leq 2\Phi'(G_1) \underset{(3.3)}{=} \frac{2}{L_1}\log\Bigl(1 + \frac{L_1 G_1}{L_0}\Bigr). \tag{4.12}$$

▷ *Оценка снизу для ν.* Так как $0 \leq r'(p_j) \leq r'(1)$ и $y_j = 0$, из (4.11) в обоих случаях

$$-\lambda \leq G_j\nu - G_j\sigma_j + G_j r'(1). \tag{4.13}$$

▷ *Координата l равна нулю.* Так как $y_l = 0$ и $G_j \geq G_l$,

$$\begin{aligned} G_l\Bigl(\sigma_l - \frac{\lambda}{G_l} - \nu\Bigr) &\underset{(4.13)}{\leq} G_l\sigma_l - G_j\sigma_j + G_j r'(1) + (G_j - G_l)\nu \\ &\underset{(4.12)}{\leq} G_l\sigma_l - G_j\sigma_j + G_j r'(1) + (G_j - G_l)\,\frac{2}{L_1}\log\Bigl(1 + \frac{L_1 G_1}{L_0}\Bigr) \\ &\underset{(4.6)}{\leq} 0. \end{aligned}$$

Если бы $z_l > 0$, то по (4.11) левая часть равнялась бы $G_l r'(p_l) > 0$. Значит, $z_l = 0$. □

Лемма 4.6.

(а) $\min \varphi = 0$, и минимум достигается в точке $-\sigma$.
(б) Если $y_n = 0$, то $\varphi(y) \geq 2\varepsilon$.

Доказательство.

(а) Точка $z = 0$ допустима, поэтому $\varphi \geq -H(0) = 0$. С другой стороны, $H \geq 0$, и $\varphi(-\sigma) = \max_K\{-H\} = 0$.
(б) Подставим в (4.8) вершину $G_n e_n$. Функция Φ выпукла, $\Phi(0) = 0$ и Φ' возрастает, поэтому $\Phi(G_n) \leq G_n\Phi'(G_n) \leq G_n\Phi'(G_1)$. Кроме того, $r(1) \leq r'(1)$. Значит,

$$\begin{aligned}\varphi(y) &\geq G_n\sigma_n - 2\Phi(G_n) - G_n r(1)\\ &\geq G_n\sigma_n - \frac{2G_n}{L_1}\log\Bigl(1 + \frac{L_1G_1}{L_0}\Bigr) - G_n\,\frac{4}{L_1}\log\bigl(1+\sqrt{n}\bigr) \underset{(4.5)}{=} \frac{2G_n}{L_1} = 2\varepsilon.\end{aligned}$$ □

Лемма 4.7 (расстояние до точки минимума)**.**

$$L_1\|\sigma\| \leq 2\sqrt{n}\,\log\Bigl(1 + \frac{L_1^2\varepsilon}{L_0}\Bigr) + 9\,n\sqrt{\log(4n)}.$$

Доказательство. Оценим три величины, из которых складываются сдвиги σ_i:

$$\begin{aligned}&2\log\Bigl(1 + \frac{L_1G_1}{L_0}\Bigr) \underset{\text{(a)}}{\leq} 2\log\Bigl(1 + \frac{L_1^2\varepsilon}{L_0}\Bigr) + 2\sqrt{n\log(4n)},\\ &4\log\bigl(1+\sqrt{n}\bigr) \underset{\text{(b)}}{\leq} 2\log(4n),\\ &\sum_{k=i}^{n}\frac{G_k}{G_i} \underset{\text{(c)}}{\leq} 1 + \sqrt{\frac{n}{\log(4n)}}.\end{aligned}$$

Здесь (a) — неравенство $\log(1 + xe^v) \leq \log(1+x) + v$ при $x, v \geq 0$, (b) — неравенство $(1+\sqrt{n})^2 \leq 4n$, (c) — сумма геометрической прогрессии и неравенство $e^{-x}(1+x) \leq 1$. Складывая, получаем для каждой координаты

$$L_1\sigma_i \leq 2\log\Bigl(1 + \frac{L_1^2\varepsilon}{L_0}\Bigr) + 4\sqrt{n\log(4n)} + 2\log(4n) + 2.$$

Все σ_i положительны, поэтому $\|\sigma\| \leq \sqrt{n}\max_i\sigma_i$ и

$$L_1\|\sigma\| \leq 2\sqrt{n}\log\Bigl(1 + \frac{L_1^2\varepsilon}{L_0}\Bigr) + n\sqrt{\log(4n)}\,\Bigl[4 + 2\sqrt{\frac{\log(4n)}{n}} + \frac{2}{\sqrt{n\log(4n)}}\Bigr].$$

Отношение $\log(4n)$ к n убывает и потому не больше $\log 4 < 2$, а $n\log(4n) \geq \log 4 > 1$. Значит, скобка меньше $4 + 2\sqrt{2} + 2 < 9$. □

Теорема 4.8 (нижняя оценка для цепочки с убывающими наклонами)**.**
Пусть натуральное число n удовлетворяет условию

$$2\sqrt{n}\,\log\Bigl(1+\frac{L_1^2\varepsilon}{L_0}\Bigr)+9\,n\sqrt{\log(4n)}\le L_1R. \tag{4.14}$$

Тогда для каждого детерминированного метода с $n-1$ обращениями к оракулу в $\mathbb{R}^{2n}$ найдётся функция $f\in\mathcal{P}_{\mathrm{R}}$ на $\mathbb{R}^{2n}$ с $\min f=0$ и $f(\hat{x})\ge 2\varepsilon$. В частности, $\mathcal{N}(\mathcal{P}_{\mathrm{R}})\ge n$.

Доказательство. Функция φ — выпуклая цепочка из класса $\mathcal{F}^n_{L_0,L_1}$ (леммы 4.4 и 4.5). Её минимум равен нулю и достигается в точке $-\sigma$, а при $y_n=0$ её значение не меньше 2ε (лемма 4.6). Из леммы 4.7 и условия (4.14) следует, что норма σ не больше R. Остаётся применить предложение 4.3(б) с $\mathrm{gap}=2\varepsilon$. □

Начальная невязка этих функций не ограничена величиной 4ε. Подстановка вершины G_1e_1 в (4.8), как в доказательстве леммы 4.6(б), даёт

$$\varphi(0)\ge\frac{2G_1}{L_1}=2\varepsilon\exp\Bigl((n-1)\sqrt{\frac{\log(4n)}{n}}\Bigr),$$

то есть невязка экспоненциально велика по $\sqrt{n\log n}$. Поэтому теорема 4.8 не противоречит верхней оценке со слагаемым $(L_1R)^{2/3}$ на классе $\mathcal{P}_{4\varepsilon}$ (приложение B).

4.3 Основная нижняя оценка

Осталось выбрать длину цепочки, удовлетворяющую условию (4.14).

Лемма 4.9 (выбор длины цепочки)**.**
Если $L_0R^2\ge\varepsilon$ и $L_1R\ge 16$, то

$$1+\mathcal{N}(\mathcal{P}_{\mathrm{R}})\ge\frac{L_1R}{24\sqrt{\log(2+L_1R)}}.$$

Доказательство. Положим

$$n=\Bigl\lfloor\frac{L_1R}{24\sqrt{\log(2+L_1R)}}\Bigr\rfloor.$$

Если $n=0$, утверждение очевидно. Пусть $n\ge 1$. Проверим условие (4.14), оценив два его слагаемых.

▷ *Второе слагаемое.* Число $4n$ меньше $2+L_1R$, поэтому $\log(4n)\le\log(2+L_1R)$ и

$$9n\sqrt{\log(4n)}\le 9n\sqrt{\log(2+L_1R)}\underset{\text{опр. }n}{\le}\frac{3}{8}L_1R.$$

▷ *Первое слагаемое.* Отношение $\log^{3/2}(2+x)$ к x убывает при $x \geq 16$ и в точке 16 меньше трёх восьмых. Поэтому

$$2\sqrt{n}\log\Bigl(1+\frac{L_1^2\varepsilon}{L_0}\Bigr) \underset{L_0R^2\geq\varepsilon}{\leq} 2\sqrt{n}\log\bigl(1+(L_1R)^2\bigr) \underset{1+t^2\leq(2+t)^2}{\leq} 4\sqrt{n}\log(2+L_1R)$$
$$\underset{\text{опр. } n}{\leq} \frac{4}{\sqrt{24}}\,L_1R\sqrt{\frac{\log^{3/2}(2+L_1R)}{L_1R}}$$
$$\underset{L_1R\geq 16}{\leq} \frac{4}{\sqrt{24}}\sqrt{\frac{3}{8}}\,L_1R = \frac{L_1R}{2}.$$

Сумма слагаемых меньше L_1R, и теорема 4.8 даёт

$$1+\mathcal{N}(\mathcal{P}_{\mathrm{R}}) \geq 1+n \geq \frac{L_1R}{24\sqrt{\log(2+L_1R)}}.$$ □

Теорема 4.10 (нижняя оценка для класса, заданного только радиусом)**.**
Если $L_0R^2 \geq \varepsilon$, то

$$1+\mathcal{N}(\mathcal{P}_{\mathrm{R}}) \geq \frac{1}{29}\Bigl[1+\sqrt{\frac{L_0R^2}{\varepsilon}}+\frac{L_1R}{\sqrt{\log(2+L_1R)}}\Bigr]. \tag{4.15}$$

Доказательство. Оценим каждое из трёх слагаемых в скобке через $1+\mathcal{N}(\mathcal{P}_{\mathrm{R}})$.

▷ *Первое.* Очевидно, $1 \leq 1+\mathcal{N}(\mathcal{P}_{\mathrm{R}})$.

▷ *Второе.* Функции с L_0-липшицевым градиентом лежат в классе. Классическая оценка (Nesterov, 2018, теорема 2.1.7) вместе с предложением 4.3 даёт

$$\sqrt{\frac{L_0R^2}{\varepsilon}} \leq 4\bigl(1+\mathcal{N}(\mathcal{P}_{\mathrm{R}})\bigr).$$

▷ *Третье.* При $L_1R \geq 16$ по лемме 4.9 оно не больше $24(1+\mathcal{N}(\mathcal{P}_{\mathrm{R}}))$. При $L_1R < 16$ оно меньше 10, поскольку возрастает по L_1R и

$$\frac{16}{\sqrt{\log 18}} \underset{\log 18>4\log 2}{<} \frac{16}{\sqrt{4\log 2}} \underset{\log 2>2/3}{<} \sqrt{96} < 10.$$

Складывая, получаем, что скобка в (4.15) не больше $29(1+\mathcal{N}(\mathcal{P}_{\mathrm{R}}))$. □

Вместе с теоремой 3.7 при $L_0R^2 \geq \varepsilon$ получаем

$$1+\mathcal{N}(\mathcal{P}_{\mathrm{R}}) = \widetilde{\Theta}\Bigl(1+\sqrt{\frac{L_0R^2}{\varepsilon}}+L_1R\Bigr).$$

Степени в нижней и верхней оценках совпадают, а расхождение сводится к логарифмическим множителям при L_1R.

5 Заключение и открытые вопросы

Большие градиенты и растущая вместе с ними кривизна создают режим, число обращений к оракулу в котором в худшем случае зависит от L_1R и не зависит от ε. Если методу известно только расстояние R, то при $L_0R^2 \geq \varepsilon$ оптимальная сложность среди детерминированных методов первого порядка N удовлетворяет соотношению

$$1+N = \widetilde{\Theta}\Bigl(1+\sqrt{\frac{L_0R^2}{\varepsilon}}+L_1R\Bigr).$$

Иначе говоря, цена прохождения области больших градиентов равна $L_1 R$ с точностью до логарифмических множителей. Если начальная невязка не больше 4ε, эта цена падает до $(L_1 R)^{2/3}$ (приложение B). Открытыми остаются следующие вопросы.

- ▷ *Логарифмические множители.* Между нижней и верхней оценками остаётся множитель порядка $\log^{3/2}(2 + L_1 R)$ при слагаемом $L_1 R$. Множитель $\sqrt{\log(2 + L_1 R)}$ теряется в нижней оценке из-за выбора наклонов и сдвигов цепочки, множитель $\log(2 + L_1 R)$ — в верхней из-за одномерного поиска на первом этапе. Мы не знаем, можно ли пройти режим больших градиентов за $O(1 + L_1 R)$ обращений без одномерного поиска.
- ▷ *Известная оценка невязки.* Для класса $\mathcal{P}_\Delta$, у которого Δ больше 4ε, но меньше правой части оценки (A.3), доказана только верхняя оценка теоремы B.7(б). Совпадающая с ней нижняя оценка по зависимости от Δ неизвестна. Точная зависимость сложности от Δ/ε при $\varepsilon < \Delta < 4\varepsilon$ также не установлена.
- ▷ *Размерность.* Нижние оценки для произвольных методов реализуются в размерности порядка числа обращений, а в фиксированной размерности при фиксированных L_0, L_1 и ε сложность растёт лишь логарифмически по R (приложение C). Промежуточный режим не изучен.
- ▷ *Рандомизированные методы и неточные градиенты.* Все нижние оценки получены для детерминированных методов и точного оракула.

Список литературы

Ekaterina Borodich and Dmitry Kovalev. Nesterov finds GRAAL: Optimal and adaptive gradient method for convex optimization. In *International Conference on Learning Representations*, 2026. URL https://openreview.net/forum?id=vPSiCA3CkD. arXiv:2507.09823v2.

Yair Carmon, John C. Duchi, Oliver Hinder, and Aaron Sidford. Lower bounds for finding stationary points I. *Mathematical Programming*, 184:71–120, 2020.

Ziyi Chen, Yi Zhou, Yingbin Liang, and Zhaosong Lu. Generalized-smooth nonconvex optimization is as efficient as smooth nonconvex optimization. In *Proceedings of the 40th International Conference on Machine Learning*, volume 202 of *PMLR*, pages 5396–5427, 2023.

Michael Crawshaw and Mingrui Liu. Complexity lower bounds of adaptive gradient algorithms for non-convex stochastic optimization under relaxed smoothness, 2025.

Michael Crawshaw, Mingrui Liu, Francesco Orabona, Wei Zhang, and Zhenxun Zhuang. Robustness to unbounded smoothness of generalized signsgd, 2022.

A. V. Gasnikov and Yu. E. Nesterov. Universal method for stochastic composite optimization problems. *Computational Mathematics and Mathematical Physics*, 58(1):48–64, 2018.

Eduard Gorbunov, Nazarii Tupitsa, Sayantan Choudhury, Alen Aliev, Peter Richtárik, Samuel Horváth, and Martin Takáč. Methods for convex (L_0, L_1)-smooth optimization: Clipping, acceleration, and adaptivity. In *International Conference on Learning Representations*, 2025. arXiv:2409.14989.

Branko Grünbaum. Partitions of mass-distributions and of convex bodies by hyperplanes. *Pacific Journal of Mathematics*, 10(4):1257–1261, 1960.

Cristóbal Guzmán and Arkadi Nemirovski. On lower complexity bounds for large-scale smooth convex optimization. *Journal of Complexity*, 31(1):1–14, 2015. doi: 10.1016/j.jco.2014.08.003. URL https://arxiv.org/abs/1307.5001.

Florian Hübler, Junchi Yang, Xiang Li, and Niao He. Parameter-agnostic optimization under relaxed smoothness, 2023.

Jikai Jin, Bohang Zhang, Haiyang Wang, and Liwei Wang. Non-convex distributionally robust optimization: Non-asymptotic analysis. In *Advances in Neural Information Processing Systems*, volume 34, pages 2771–2782, 2021.

Anastasia Koloskova, Hadrien Hendrikx, and Sebastian U. Stich. Revisiting gradient clipping: Stochastic bias and tight convergence guarantees. In *Proceedings of the 40th International Conference on Machine Learning*, volume 202 of *PMLR*, pages 17343–17363, 2023.

Evgeniy Kovalev and Fedor Stonyakin. Normalized first-order methods for convex (l0, l1)-smooth optimization with inexact gradients, 2026.

V. O. Krivchenko. Computer-aided analysis of gradient descent under generalized smoothness. *Doklady Mathematics*, 530(1):5–13, 2026. doi: 10.7868/S3034504926030011. URL https://journals.rcsi.science/2686-9543/article/view/444931.

Haochuan Li, Jian Qian, Yi Tian, Alexander Rakhlin, and Ali Jadbabaie. Convex and non-convex optimization under generalized smoothness. In *Advances in Neural Information Processing Systems*, volume 36, 2023.

Aleksandr Lobanov. A few accelerated algorithms for convex optimization under (H_0, H_1)-smoothness, 2026.

Aleksandr Lobanov, Alexander Gasnikov, Eduard Gorbunov, and Martin Takáč. Linear convergence rate in convex setup is possible! gradient descent method variants under (L_0, L_1)-smoothness. *arXiv preprint arXiv:2412.17050*, 2025. doi: 10.48550/arXiv.2412.17050. URL https://arxiv.org/abs/2412.17050v2. Version 2, 19 February 2025.

A. S. Nemirovsky and D. B. Yudin. *Problem Complexity and Method Efficiency in Optimization*. Wiley-Interscience, New York, 1983.

Yurii Nesterov. *Lectures on Convex Optimization*, volume 137 of *Springer Optimization and Its Applications*. Springer, 2018.

Konstantinos Oikonomidis, Jan Quan, Emanuel Laude, and Panagiotis Patrinos. Nonlinearly preconditioned gradient methods under generalized smoothness, 2025.

R. Tyrrell Rockafellar. *Convex Analysis*. Princeton University Press, 1970.

Yuki Takezawa, Han Bao, Ryoma Sato, Kenta Niwa, and Makoto Yamada. Parameter-free clipped gradient descent meets Polyak. In *Advances in Neural Information Processing Systems*, volume 37, 2024. arXiv:2405.15010.

Alexander Tyurin. Toward a unified theory of gradient descent under generalized smoothness. In *Proceedings of the 42nd International Conference on Machine Learning*, volume 267 of *Proceedings of Machine Learning Research*, pages 60493–60514, 2025. URL https://proceedings.mlr.press/v267/tyurin25a.html.

Alexander Tyurin. Near-optimal convergence of accelerated gradient methods under generalized and (L_0, L_1)-smoothness. In *Proceedings of the 43rd International Conference on Machine Learning*, 2026. arXiv:2508.06884.

Daniil Vankov, Anton Rodomanov, Angelia Nedić, Lalitha Sankar, and Sebastian U. Stich. Optimizing (L_0, L_1)-smooth functions by gradient methods. In *International Conference on Learning Representations*, 2025. arXiv:2410.10800.

Bohang Zhang, Jikai Jin, Cong Fang, and Liwei Wang. Improved analysis of clipping algorithms for non-convex optimization. *Advances in Neural Information Processing Systems*, 33, 2020a.

Jingzhao Zhang, Tianxing He, Suvrit Sra, and Ali Jadbabaie. Why gradient clipping accelerates training: A theoretical justification for adaptivity. In *International Conference on Learning Representations*, 2020b. arXiv:1905.11881.

А. В. Гасников. *Современные численные методы оптимизации. Метод универсального градиентного спуска: учебное пособие. 2-е изд., испр.* МЦНМО, Москва, 2021. ISBN 978-5-4439-4199-8.

A Вспомогательные неравенства

В этом приложении доказаны лемма 2.2 и вспомогательные леммы раздела 3. В подразделе A.1 функция ℓ произвольна, как в определении 2.1. Начиная с подраздела A.2, $f \in \mathcal{F}^d_{L_0,L_1}$, а x^* — точка минимума функции f.

A.1 Характеризация класса

Доказательство леммы 2.2 ▲.

▷ *Необходимость в (а).* Градиент выпуклой дифференцируемой функции непрерывен (Rockafellar, 1970, теорема 25.5), поэтому на каждом шаре он ограничен некоторым числом M. Если отрезок $[x, y]$ лежит в таком шаре, то по (2.1)

$$\|\nabla f(x) - \nabla f(y)\| \le \ell(M)\|x - y\|.$$

Значит, отображение $t \mapsto \nabla f(x + tv)$ липшицево на каждом отрезке, а потому локально абсолютно непрерывно и дифференцируемо при почти всех t. В такой точке t применим (2.1) к точкам $x + tv$ и $x + (t + h)v$, разделим на $|h|$ и устремим h к нулю. В силу непрерывности ∇f и ℓ получим (2.2).

▷ *Достаточность в (а).* Пусть $v = y - x$. По формуле Ньютона–Лейбница и монотонности ℓ

$$\begin{aligned}\|\nabla f(y) - \nabla f(x)\| &\le \int_0^1 \ell\big(\|\nabla f(x + tv)\|\big)\|v\|\,dt \\ &\le \ell\Big(\sup_{u\in[x,y]} \|\nabla f(u)\|\Big)\|x - y\|.\end{aligned}$$

▷ *Утверждение (б).* Для $f \in C^2$ производная отображения $t \mapsto \nabla f(x + tv)$ равна $\nabla^2 f(x+tv)v$ и непрерывна по t. Поэтому условие (2.2) при почти всех t равносильно неравенству

$$\|\nabla^2 f(x)v\| \le \ell\big(\|\nabla f(x)\|\big)\|v\|$$

при всех x и v. Гессиан выпуклой функции класса C^2 — симметричная неотрицательно определённая матрица, и для неё это неравенство равносильно (2.3). Остаётся применить (а). □

A.2 Скорость изменения градиента

Следующая лемма показывает, что локальная константа гладкости $L_0 + L_1\|\nabla f(y)\|$ при переходе от точки y к точке z меняется не более чем в $e^{L_1\|z-y\|}$ раз. Остальные оценки приложения выводятся из этого факта.

Лемма A.1 (следствия леммы Гронуолла)**.**
Для любых точек $y, z \in \mathbb{R}^d$ выполнены неравенства

(а) $$L_0 + L_1\|\nabla f(z)\| \le \big(L_0 + L_1\|\nabla f(y)\|\big)e^{L_1\|z-y\|},$$

(б) $$\|\nabla f(z) - \nabla f(y)\| \le \big(L_0 + L_1\|\nabla f(y)\|\big)\frac{e^{L_1\|z-y\|} - 1}{L_1},$$

(в) $$0 \le f(z) - f(y) - \langle\nabla f(y), z - y\rangle \le \big(L_0 + L_1\|\nabla f(y)\|\big)\frac{e^{L_1\|z-y\|} - 1 - L_1\|z - y\|}{L_1^2}.$$

Доказательство. Будем следить за градиентом в точках $y + t(z-y)$, $t \in [0,1]$.

▷ *Интегральное неравенство.* По лемме 2.2(а) отображение $t \mapsto \nabla f(y + t(z-y))$ абсолютно непрерывно, и при почти всех t норма его производной не больше $(L_0 + L_1\|\nabla f(y + t(z-y))\|)\|z-y\|$. Поэтому при всех $t \in [0,1]$

$$\|\nabla f\big(y + t(z-y)\big) - \nabla f(y)\| \le \|z-y\| \int_0^t \Big(L_0 + L_1\|\nabla f\big(y + \tau(z-y)\big)\|\Big) d\tau. \quad \text{(A.1)}$$

По неравенству треугольника отсюда следует

$$\begin{aligned} &L_0 + L_1\|\nabla f\big(y + t(z-y)\big)\| \\ &\quad \le L_0 + L_1\|\nabla f(y)\| + L_1\|z-y\| \int_0^t \Big(L_0 + L_1\|\nabla f\big(y + \tau(z-y)\big)\|\Big) d\tau. \end{aligned}$$

▷ *Лемма Гронуолла.* Левая часть последнего неравенства непрерывна по t, и по лемме Гронуолла в интегральной форме

$$L_0 + L_1\|\nabla f\big(y + t(z-y)\big)\| \le \big(L_0 + L_1\|\nabla f(y)\|\big) e^{L_1\|z-y\|t}.$$

При $t = 1$ это утверждение (а).

▷ *Приращение градиента.* Подставим эту оценку в (A.1):

$$\begin{aligned} \|\nabla f\big(y + t(z-y)\big) - \nabla f(y)\| &\le \big(L_0 + L_1\|\nabla f(y)\|\big)\|z-y\| \int_0^t e^{L_1\|z-y\|\tau} d\tau \\ &= \big(L_0 + L_1\|\nabla f(y)\|\big) \frac{e^{L_1\|z-y\|t} - 1}{L_1}. \end{aligned}$$

При $t = 1$ это утверждение (б).

▷ *Приращение функции.* Левое неравенство в (в) — это выпуклость функции f. Для правого

$$\begin{aligned} f(z) - f(y) - \langle \nabla f(y), z-y\rangle &= \int_0^1 \langle \nabla f\big(y + t(z-y)\big) - \nabla f(y), z-y\rangle \, dt \\ &\underset{\text{(б)}}{\le} \big(L_0 + L_1\|\nabla f(y)\|\big)\|z-y\| \int_0^1 \frac{e^{L_1\|z-y\|t} - 1}{L_1} \, dt \\ &= \big(L_0 + L_1\|\nabla f(y)\|\big) \frac{e^{L_1\|z-y\|} - 1 - L_1\|z-y\|}{L_1^2}. \end{aligned}$$

Во втором переходе использованы неравенство КБШ и утверждение (б). □

Для дважды непрерывно дифференцируемых функций неравенства (б) и (в) получены в работе Vankov et al. (2025, лемма 2.5). Из неравенства $e^x - 1 - x \le x^2 e^x/2$ при $x \ge 0$ и утверждения (в) следует

$$f(z) \le f(y) + \langle \nabla f(y), z-y\rangle + \frac{\big(L_0 + L_1\|\nabla f(y)\|\big) e^{L_1\|z-y\|}}{2} \|z-y\|^2. \quad \text{(A.2)}$$

На расстояниях порядка $1/L_1$ это обычное неравенство для функций с липшицевым градиентом (Nesterov, 2018, лемма 1.2.3) с константой, пропорциональной $L_0 + L_1\|\nabla f(y)\|$.

A.3 Лемма о спуске

Доказательство леммы 3.1 ▲.

▷ *Убывание функции.* Так как $L_0 + L_1\|\nabla f(y)\| \geq L_1\|\nabla f(y)\|$, длина шага

$$\|y^+ - y\| = \frac{\|\nabla f(y)\|}{4\big(L_0 + L_1\|\nabla f(y)\|\big)}$$

не больше $1/(4L_1)$, и множитель $e^{L_1\|y^+-y\|}$ в (A.2) не больше $e^{1/4}$. Поэтому

$$\begin{aligned} f(y^+) &\underset{\text{(A.2)}}{\leq} f(y) - \frac{\|\nabla f(y)\|^2}{4\big(L_0 + L_1\|\nabla f(y)\|\big)} + \frac{e^{1/4}\|\nabla f(y)\|^2}{32\big(L_0 + L_1\|\nabla f(y)\|\big)} \\ &= f(y) - \Big(\frac{1}{4} - \frac{e^{1/4}}{32}\Big)\frac{\|\nabla f(y)\|^2}{L_0 + L_1\|\nabla f(y)\|} \\ &\underset{\text{(а)}}{\leq} f(y) - \frac{5\|\nabla f(y)\|^2}{24\big(L_0 + L_1\|\nabla f(y)\|\big)}. \end{aligned}$$

Здесь (а) — неравенство $e^{1/4} < 4/3$, которое следует из $e^t \leq 1/(1-t)$ при $0 \leq t < 1$.

▷ *Убывание расстояния до точки минимума.* Имеем

$$\begin{aligned} \langle \nabla f(y), y - x^*\rangle &\underset{\text{(б)}}{\geq} f(y) - f^* \underset{\text{(в)}}{\geq} f(y) - f(y^+) \\ &\underset{\text{(г)}}{\geq} \frac{5\|\nabla f(y)\|^2}{24\big(L_0 + L_1\|\nabla f(y)\|\big)}, \end{aligned}$$

где (б) — выпуклость, (в) — неравенство $f(y^+) \geq f^*$, (г) — уже доказанное убывание функции. Раскрывая квадрат нормы и подставляя эту оценку, получаем

$$\begin{aligned} \|y^+ - x^*\|^2 &= \|y - x^*\|^2 - \frac{\langle \nabla f(y), y - x^*\rangle}{2\big(L_0 + L_1\|\nabla f(y)\|\big)} + \frac{\|\nabla f(y)\|^2}{16\big(L_0 + L_1\|\nabla f(y)\|\big)^2} \\ &\leq \|y - x^*\|^2 - \frac{5\|\nabla f(y)\|^2}{48\big(L_0 + L_1\|\nabla f(y)\|\big)^2} + \frac{3\|\nabla f(y)\|^2}{48\big(L_0 + L_1\|\nabla f(y)\|\big)^2}. \end{aligned}$$

□

A.4 Оценки в окрестности точки минимума

В точке минимума градиент равен нулю, поэтому лемма A.1 при $y = x^*$ даёт оценку роста функции при удалении от точки минимума.

Лемма A.2 (рост вокруг точки минимума)**.**
Для любой точки $x \in \mathbb{R}^d$

$$\begin{aligned} \|\nabla f(x)\| &\leq \frac{L_0}{L_1}\big(e^{L_1\|x-x^*\|} - 1\big), \\ f(x) - f^* &\leq \frac{L_0}{L_1^2}\big(e^{L_1\|x-x^*\|} - 1 - L_1\|x - x^*\|\big). \end{aligned}$$

В частности, если $\|x^0 - x^*\| \leq R$, то

$$f(x^0) - f^* \leq \frac{L_0}{L_1^2}\big(e^{L_1 R} - 1 - L_1 R\big). \tag{A.3}$$

Доказательство. Обе оценки — утверждения (б) и (в) леммы A.1 при $y = x^*$ и $z = x$, поскольку $\nabla f(x^*) = 0$. Правая часть второй оценки возрастает по $\|x - x^*\|$, что даёт (A.3). □

Оценка (A.3) точна. Функция

$$f(x) = \frac{L_0}{L_1^2}\bigl(e^{L_1\|x\|} - 1 - L_1\|x\|\bigr)$$

дважды непрерывно дифференцируема, и

$$\|\nabla f(x)\| = \frac{L_0}{L_1}\bigl(e^{L_1\|x\|} - 1\bigr).$$

При $x \neq 0$ её кривизна вдоль радиуса равна

$$L_0 e^{L_1\|x\|} = L_0 + L_1\|\nabla f(x)\|,$$

а в касательных направлениях кривизна равна

$$\frac{\|\nabla f(x)\|}{\|x\|} = \frac{L_0\bigl(e^{L_1\|x\|} - 1\bigr)}{L_1\|x\|} \leq L_0 e^{L_1\|x\|},$$

поскольку $e^s - 1 \leq se^s$. В нуле гессиан равен $L_0 I$, и обе кривизны стремятся к L_0. По лемме 2.2(б) функция лежит в классе $\mathcal{F}^d_{L_0,L_1}$, а при $\|x^0\| = R$ в (A.3) достигается равенство. Таким образом, начальная невязка по функции может быть экспоненциально большой по $L_1 R$.

Доказательство леммы 3.2 ▲. При $\nabla f(y) = 0$ утверждение совпадает с неравенством выпуклости. Пусть $\nabla f(y) \neq 0$. Сравним касательную в точке y с оценкой роста леммы A.2 в точках луча

$$z_t = x^* + \frac{t\,\nabla f(y)}{\|\nabla f(y)\|},$$

где $t \geq 0$.

▷ *Оценка при фиксированном t.* Так как $\langle \nabla f(y), z_t - x^* \rangle = t\|\nabla f(y)\|$,

$$\begin{aligned} f(y) + \langle \nabla f(y), x^* - y\rangle + t\|\nabla f(y)\| &= f(y) + \langle \nabla f(y), z_t - y\rangle \\ &\underset{\text{(а)}}{\leq} f(z_t) \underset{\text{(б)}}{\leq} f^* + \frac{L_0}{L_1^2}\bigl(e^{L_1 t} - 1 - L_1 t\bigr), \end{aligned}$$

где (а) — выпуклость, (б) — лемма A.2.

▷ *Выбор t.* Положим

$$t = \frac{1}{L_1}\log\Bigl(1 + \frac{L_1\|\nabla f(y)\|}{L_0}\Bigr).$$

Тогда

$$e^{L_1 t} = 1 + \frac{L_1\|\nabla f(y)\|}{L_0},$$

и прямое вычисление по формуле (3.2) даёт

$$t\|\nabla f(y)\| - \frac{L_0}{L_1^2}\bigl(e^{L_1 t} - 1 - L_1 t\bigr) = \Phi\bigl(\|\nabla f(y)\|\bigr).$$

Подставляя это в предыдущую оценку, получаем утверждение леммы. □

Выбранное t максимизирует левую часть последнего равенства, то есть Φ — функция, сопряжённая к функции роста из леммы A.2. Неравенство леммы 3.2 утверждается только в точке x^*: аффинная функция с добавкой Φ не обязана быть минорантой функции f всюду.

A.5 Неточный одномерный поиск

Доказательство леммы 3.3 ▲. Обозначим через $z(t) = v + t(x - v)$ точки отрезка $[v, x]$. Функция $t \mapsto f(z(t))$ выпукла на $[0, 1]$, а её производная $\langle \nabla f(z(t)), x - v\rangle$ не убывает. Для точки $y = z(t)$

$$\langle \nabla f(y), y - v\rangle = t\,\langle \nabla f(z(t)), x - v\rangle.$$

▷ *Критерий остановки.* Если он сработал в точке $z \in [v, x]$, то z лежит в шаре $B(x^*, r)$, и по выпуклости

$$f(z) - f^* \le \langle \nabla f(z), z - x^*\rangle \le r\|\nabla f(z)\| \le \delta.$$

Далее считаем, что критерий остановки не сработал.

▷ *Возврат в концах отрезка.* Если $\langle \nabla f(v), x - v\rangle \ge 0$, то производная неотрицательна на $[0, 1]$. Значит, $f(v) \le f(x)$, а для $y = v$ левая часть второго неравенства (3.5) равна нулю. Если $\langle \nabla f(x), x - v\rangle \le 0$, то для $y = x$ первое неравенство (3.5) очевидно, а левая часть второго неположительна.

▷ *Деление отрезка пополам.* Алгоритм поддерживает неравенства

$$\langle \nabla f(z(t_-)), x - v\rangle < 0 < \langle \nabla f(z(t_+)), x - v\rangle.$$

Если в середине производная равна нулю, то эта середина — точка минимума функции на отрезке, и для неё выполнены оба неравенства (3.5). Иначе после m шагов $t_+ - t_- = 2^{-m}$.

▷ *Убывание для $y = z(t_+)$.* Производная в точке t_+ положительна, поэтому функция не убывает на $[t_+, 1]$, и $f(y) \le f(x)$.

▷ *Погрешность для $y = z(t_+)$.* Расстояние между точками $z(t_+)$ и $z(t_-)$ равно $2^{-m}\|x - v\|$, причём $\|x - v\| \le 2r$. По условию (3.4)

$$L_1\|z(t_+) - z(t_-)\| \le 2^{1-m} L_1 r \le \frac{2L_1 r}{128\big(1 + L_1 r\big)^2} \le \frac{1}{32}.$$

По лемме A.1(б) с базовой точкой $z(t_+)$ и неравенству $e^s - 1 \le se^s$

$$\|\nabla f(z(t_+)) - \nabla f(z(t_-))\| \le 2\big(L_0 + L_1\|\nabla f(y)\|\big)\|z(t_+) - z(t_-)\|.$$

Так как $\langle \nabla f(z(t_-)), x - v\rangle < 0$ и $t_+ \le 1$,

$$\begin{aligned}
\langle \nabla f(y), y - v\rangle &\le t_+ \langle \nabla f(z(t_+)) - \nabla f(z(t_-)), x - v\rangle \\
&\underset{\text{(a)}}{\le} 2r\|\nabla f(z(t_+)) - \nabla f(z(t_-))\| \\
&\le 2^{3-m} r^2 \big(L_0 + L_1\|\nabla f(y)\|\big) \\
&\underset{(3.4)}{\le} \frac{r^2\big(L_0 + L_1\|\nabla f(y)\|\big)}{16\big(1 + L_0 r^2/\delta + L_1 r\big)^2},
\end{aligned}$$

где (a) — неравенства $t_+ \le 1$ и $\|x - v\| \le 2r$.

▷ *Связь с градиентом.* В точке y критерий остановки не выполнен, то есть $r\|\nabla f(y)\| > \delta$. Поэтому

$$\begin{aligned}
\frac{r\big(L_0 + L_1\|\nabla f(y)\|\big)}{\|\nabla f(y)\|} &= \frac{L_0 r}{\|\nabla f(y)\|} + L_1 r \\
&\underset{\text{(б)}}{<} \frac{L_0 r^2}{\delta} + L_1 r < 1 + \frac{L_0 r^2}{\delta} + L_1 r,
\end{aligned}$$

где (б) — неравенство $r\|\nabla f(y)\| > \delta$. Возводя в квадрат и деля на $16(L_0 + L_1\|\nabla f(y)\|)$, получаем

$$\frac{r^2\bigl(L_0 + L_1\|\nabla f(y)\|\bigr)}{16\bigl(1 + L_0 r^2/\delta + L_1 r\bigr)^2} < \frac{\|\nabla f(y)\|^2}{16\bigl(L_0 + L_1\|\nabla f(y)\|\bigr)},$$

и второе неравенство (3.5) выполнено.

▷ *Число обращений.* Алгоритм делает два обращения в концах отрезка и не более m обращений в серединах. □

B Класс с ограниченной начальной невязкой

В основном тексте о начальной точке известно только расстояние R до точки минимума, и начальная невязка по функции может быть экспоненциально большой по $L_1 R$. В этом приложении рассмотрен класс $\mathcal{P}_\Delta$ из раздела 2, в котором начальная невязка ограничена известным числом Δ, и прежде всего случай $\Delta = 4\varepsilon$. Показатель степени при $L_1 R$ в оценке сложности падает при этом с единицы до $2/3$.

Условие $f(x^0) - f^* \le 4\varepsilon$ естественно в схемах с рестартами: каждая фаза стартует из точки, где невязка уже ограничена постоянным кратным точности, требуемой от этой фазы.

Нижняя оценка доказана в подразделе B.1 на цепочке с равными наклонами звеньев. Верхние оценки получены вариантом ускоренного метода раздела 3 с другими способами подсчёта итераций (подразделы B.2–B.4). Итоговые утверждения сформулированы в конце соответствующих подразделов.

B.1 Нижняя оценка: цепочка с равными наклонами

Как и в подразделе 4.2, построим цепочку сопряжением на многограннике и применим лемму 4.2. Здесь наклоны всех звеньев равны, а сдвиги образуют арифметическую прогрессию с шагом $-b$.

Наклон и сдвиги. Зафиксируем $n \ge 1$ и положим

$$\begin{aligned} b &= R\Bigl(\sum_{k=n+1}^{2n} k^2\Bigr)^{-1/2}, \\ \sigma_i &= (2n - i)\, b, \\ G &= \frac{2\varepsilon}{nb}. \end{aligned} \tag{B.1}$$

где $i = 1, \dots, n$. Сумма в определении b лежит между n^3 и $4n^3$.

Функция на многограннике. Пусть функция $r \in C^1([0,1])$ сильно выпукла с некоторым положительным модулем, $r(0) = r'(0) = 0$ и $r'(1) = b$. Рассмотрим многогранник

$$K = \bigl\{z \in \mathbb{R}^n :\ z \ge 0,\ Z_n \le G\bigr\},$$

где $Z_n = z_1 + \dots + z_n$. Для $z \in K$ положим

$$\begin{aligned} p_i &= \frac{z_i}{G}, \\ p_0 &= 1 - \frac{Z_n}{G}, \end{aligned}$$

где $i = 1, \dots, n$. Координата p_0 — остаток до ограничения $Z_n \le G$, она обеспечивает плоское множество точек минимума. Определим функцию на K и сопряжённую к ней:

$$\begin{aligned} H(z) &= G\Big[\sum_{i=0}^{n} r(p_i) - r(1)\Big], \\ \psi(y) &= \max_{z \in K}\big\{\langle y + \sigma, z\rangle - H(z)\big\}. \end{aligned} \tag{B.2}$$

Здесь $H(0) = H(Ge_i) = 0$.

Лемма B.1 (свойства цепочки с равными наклонами)**.**
Функция ψ выпукла, непрерывно дифференцируема, и

(а) её минимум равен нулю, а множество точек минимума равно

$$\big\{y \in \mathbb{R}^n :\ y_i \le -(\sigma_i + b) \text{ при } i = 1, \dots, n\big\}.$$

Ближайшая к нулю точка минимума $-b\,(2n, 2n-1, \dots, n+1)$ имеет норму R,

(б) $\psi(0) = (4 - 2/n)\varepsilon$,

(в) при $y_n = 0$ имеем $\psi(y) \ge 2\varepsilon$,

(г) ψ — цепочка,

(д) $\nabla\psi(y) = z(y) = G\,(p_1, \dots, p_n)$, где $z(y)$ — единственная точка максимума в (B.2).

Доказательство.

▷ *Градиент.* Сильная выпуклость r даёт сильную выпуклость H на K с постоянным модулем. Поэтому точка максимума единственна, и, как в доказательстве леммы 4.2, $\nabla\psi(y) = z(y)$ и градиент непрерывен. Это утверждение (д).

▷ *Условия оптимальности.* Положим $\theta_0 = 0$ и $\theta_i = y_i + \sigma_i$ при $i \ge 1$. Задача максимизации в (B.2) равносильна максимизации

$$\sum_{i=0}^{n} \theta_i p_i - \sum_{i=0}^{n} r(p_i)$$

на симплексе. Перенос веса между двумя положительными координатами и из положительной координаты в нулевую даёт число ν, для которого при $0 \le i \le n$

$$\theta_i \ \begin{cases} = \nu + r'(p_i), & p_i > 0, \\ \le \nu, & p_i = 0. \end{cases} \tag{B.3}$$

Эти условия также достаточны по выпуклости r. Так как $0 \le r'(p_i) \le b$, всегда $\nu \ge \theta_i - b$.

▷ *Утверждение (а).* Точка $z = 0$ допустима, поэтому $\psi \ge 0$. Равенство достигается ровно тогда, когда оптимален вектор $p = e_0$. По (B.3) это равносильно $\nu = -b$ и $\theta_i \le -b$ при $i \ge 1$. Формулы для множества точек минимума и ближайшей к нулю точки следуют из (B.1).

▷ *Утверждение (б).* При $y = 0$ условия (B.3) выполнены для $p = e_1$ и $\nu = \sigma_1 - b = (2n-2)b$: все остальные θ_i, включая $\theta_0 = 0$, не больше ν. Поэтому $\psi(0) = G\sigma_1 = (4 - 2/n)\varepsilon$.

▷ *Утверждение (в).* Подставляя $z = Ge_n$, получаем $\psi(y) \ge G\sigma_n = 2\varepsilon$.

▷ *Утверждение (г).* Если $y_i = 0$ при $i \geq j$, то при $l > j$

$$\theta_l = \sigma_l \leq \sigma_j - b = \theta_j - b \leq \nu.$$

Положительное p_l противоречило бы (B.3), поскольку $r'(p_l) > 0$. Значит, l-я координата градиента Gp_l равна нулю. □

Для проверки условия класса достаточно одномерной оценки кривизны функции r.

Лемма B.2 (условие класса для равных наклонов)**.**
Если r дважды непрерывно дифференцируема на $(0, 1)$ и при $0 < p < 1$

$$r''(p) \geq \frac{G}{L_0 + L_1 G p}, \tag{B.4}$$

то $\psi \in \mathcal{F}^n_{L_0,L_1}$.

Доказательство. Пусть $z, z' \in K$ различны и $u = z' - z$. На интервале $0 < t < 1$ координаты p_i точки $z+tu$ либо положительны, либо тождественно равны нулю. Поэтому

$$\begin{aligned}\frac{d^2}{dt^2} H(z + tu) &= \frac{1}{G}\sum_{i=1}^{n} r''(p_i)u_i^2 + \frac{1}{G} r''(p_0)U_n^2 \\ &\underset{\text{(B.4)}}{\geq} \frac{\|u\|^2}{L_0 + L_1\|z + tu\|} \geq \frac{\|u\|^2}{L_0 + L_1 \max\{\|z\|, \|z'\|\}},\end{aligned}$$

где $U_n = u_1 + \cdots + u_n$. Слагаемые с тождественно нулевыми координатами пропущены. Если $p_0 \equiv 0$, то $U_n = 0$ и последнее слагаемое также отсутствует. Во втором переходе использовано неравенство $Gp_i = (z + tu)_i \leq \|z + tu\|$, в третьем — выпуклость нормы. Интегрирование и непрерывность на концах дают условие леммы 4.2, которая завершает доказательство. □

Квадратичная функция r. Возьмём $r(p) = bp^2/2$. Тогда $r'' = b$. Пусть

$$4n \leq \sqrt{\frac{L_0 R^2}{\varepsilon}}. \tag{B.5}$$

Тогда

$$\begin{aligned}\frac{G}{b} &\underset{\text{(B.1)}}{=} \frac{2\varepsilon}{nR^2} \sum_{k=n+1}^{2n} k^2 \leq \frac{8\varepsilon n^2}{R^2} \\ &\underset{\text{(B.5)}}{\leq} \frac{L_0}{2}.\end{aligned}$$

Следовательно, условие (B.4) выполнено, и градиент функции ψ даже липшицев с константой не больше $L_0/2$.

Логарифмическая функция r. Положим

$$\begin{aligned} r(p) &= \frac{1}{L_1}\Big[(p + \chi)\log\Big(1 + \frac{p}{\chi}\Big) - p\Big], \\ \chi &= \frac{1}{e^{L_1 b} - 1}. \end{aligned} \tag{B.6}$$

Тогда

$$r'(p) = \frac{1}{L_1}\log\Big(1 + \frac{p}{\chi}\Big),$$
$$r''(p) = \frac{1}{L_1(p+\chi)},$$

и $r'(1) = b$. Условие (B.4) выполнено, если $GL_1\chi \le L_0$, поскольку тогда $GL_1(p+\chi) \le L_0 + L_1 G p$. Проверим это при условиях

$$\begin{aligned} &L_1^2\varepsilon \ge L_0, \\ &n \le \Big(\frac{L_1 R}{8\log(2 + L_1^2\varepsilon/L_0)}\Big)^{2/3}. \end{aligned} \tag{B.7}$$

Из (B.1) и (B.7)

$$\begin{aligned} L_1 b &\underset{\text{(B.1)}}{\ge} \frac{L_1 R}{2n^{3/2}} \underset{\text{(B.7)}}{\ge} 4\log\Big(2 + \frac{L_1^2\varepsilon}{L_0}\Big) \\ &\underset{\text{(B.7)}}{\ge} 4\log 3 > 4. \end{aligned}$$

В последнем переходе использовано первое условие (B.7). Поэтому $e^{L_1 b} \ge 2$ и

$$\chi \le 2e^{-L_1 b} \le 2\Big(2 + \frac{L_1^2\varepsilon}{L_0}\Big)^{-2},$$

и

$$\begin{aligned} \frac{GL_1\chi}{L_0} &= \frac{2L_1^2\varepsilon}{nL_1 b\, L_0}\chi \le \frac{4}{nL_1 b}\cdot\frac{L_1^2\varepsilon/L_0}{\big(2 + L_1^2\varepsilon/L_0\big)^2} \\ &\underset{\text{(a)}}{\le} \frac{1}{2nL_1 b} < \frac{1}{2}. \end{aligned}$$

Здесь (a) — неравенство $t/(2+t)^2 \le 1/8$ при $t \ge 0$, равносильное $(t-2)^2 \ge 0$.

Теорема B.3 (нижняя оценка на классе с ограниченной начальной невязкой)**.** Пусть натуральное число n удовлетворяет условию (B.5) или условию (B.7). Тогда для каждого детерминированного метода с $n-1$ обращениями к оракулу в $\mathbb{R}^{2n}$ найдётся функция $f \in \mathcal{P}_{4\varepsilon}$ на $\mathbb{R}^{2n}$, для которой $f^* = 0$, расстояние от нуля до множества точек минимума равно R, $f(0) = (4 - 2/n)\varepsilon$ и $f(\hat{x}) \ge 2\varepsilon$. В частности, $\mathcal{N}(\mathcal{P}_{4\varepsilon}) \ge n$, и при $L_0 R^2 \ge \varepsilon$

$$1 + \mathcal{N}(\mathcal{P}_{4\varepsilon}) \ge \frac{1}{12}\Big[1 + \sqrt{\frac{L_0 R^2}{\varepsilon}} + \Big(\frac{L_1 R}{\log(2 + L_1^2\varepsilon/L_0)}\Big)^{2/3}\Big]. \tag{B.8}$$

Доказательство.

▷ *Наихудшие функции.* Если выполнено условие (B.5), возьмём квадратичную функцию r, иначе — логарифмическую (B.6). В обоих случаях $\psi \in \mathcal{F}^n_{L_0,L_1}$ по лемме B.2, а лемма B.1 даёт остальные условия предложения 4.3(б) с $\mathrm{gap} = 2\varepsilon$ и $\Delta = 4\varepsilon$. По этому предложению для каждого метода найдётся матрица V с ортонормированными столбцами, для которой функция $f(x) = \psi(V^\top x)$ лежит в $\mathcal{P}_{4\varepsilon}$ и $f(\hat{x}) \ge 2\varepsilon$. Остальные свойства f дают утверждения (а) и (б) леммы B.1.

▷ *Случай* $L_1^2\varepsilon \ge L_0$. Для каждого из условий (B.5) и (B.7) возьмём в качестве n целую часть наибольшей допустимой правой части. Если она положительна, первая часть теоремы даёт $\mathcal{N}(\mathcal{P}_{4\varepsilon}) \ge n$, а если равна нулю, это неравенство очевидно. Вместе с неравенством $1 + \lfloor x \rfloor \ge x$ получаем

$$\begin{aligned} 1 + \mathcal{N}(\mathcal{P}_{4\varepsilon}) &\ge 1, \\ 1 + \mathcal{N}(\mathcal{P}_{4\varepsilon}) &\ge \frac{1}{4}\sqrt{\frac{L_0 R^2}{\varepsilon}}, \\ 1 + \mathcal{N}(\mathcal{P}_{4\varepsilon}) &\ge \Big(\frac{L_1 R}{8\log(2 + L_1^2\varepsilon/L_0)}\Big)^{2/3} \\ &= \frac{1}{4}\Big(\frac{L_1 R}{\log(2 + L_1^2\varepsilon/L_0)}\Big)^{2/3}. \end{aligned}$$

Складывая эти неравенства с множителями 1, 4 и 4, получаем, что скобка в (B.8) не больше $9\big(1 + \mathcal{N}(\mathcal{P}_{4\varepsilon})\big)$.

▷ *Случай* $L_1^2\varepsilon < L_0$. Тогда $(L_1 R)^2 < L_0 R^2/\varepsilon$, и при $L_0 R^2 \ge \varepsilon$

$$\begin{aligned} \Big(\frac{L_1 R}{\log(2 + L_1^2\varepsilon/L_0)}\Big)^{2/3} &\underset{\text{(а)}}{\le} (\log 2)^{-2/3}(L_1 R)^{2/3} \underset{\text{(б)}}{<} \frac{3}{2}\Big(\frac{L_0 R^2}{\varepsilon}\Big)^{1/3} \\ &\underset{\text{(в)}}{\le} \frac{3}{2}\sqrt{\frac{L_0 R^2}{\varepsilon}}, \end{aligned}$$

где (а) — неравенство $\log(2 + t) \ge \log 2$, (б) — неравенства $(\log 2)^{-2/3} < 3/2$ и $(L_1 R)^2 < L_0 R^2/\varepsilon$, (в) — условие $L_0 R^2 \ge \varepsilon$. Значит, скобка в (B.8) не больше

$$\begin{aligned} 1 + \frac{5}{2}\sqrt{\frac{L_0 R^2}{\varepsilon}} &\le \big(1 + \mathcal{N}(\mathcal{P}_{4\varepsilon})\big) + 10\big(1 + \mathcal{N}(\mathcal{P}_{4\varepsilon})\big) \\ &= 11\big(1 + \mathcal{N}(\mathcal{P}_{4\varepsilon})\big). \end{aligned}$$

Здесь использованы первые два неравенства из предыдущего случая: они получены без условия на знак $L_1^2\varepsilon - L_0$.

В обоих случаях подходит константа $1/12$. □

Показатель $2/3$ возникает так. Сдвиги $\sigma_i = (2n - i)b$ образуют арифметическую прогрессию с шагом $-b$, поэтому R^2 имеет порядок $b^2 n^3$. Условие класса для логарифмической функции r требует, чтобы $L_1 b$ было не меньше логарифма, как в условии (B.7). Эти две оценки дают длину цепочки порядка $(L_1 R)^{2/3}$ с точностью до логарифма. Начальная невязка меньше 4ε, и теорема B.7(а) ниже показывает, что показатель $2/3$ точен с точностью до логарифмических множителей. Начальная невязка функций теоремы 4.8, напротив, не ограничена равномерно величиной 4ε (см. замечание после неё).

B.2 Вариант метода без поправки

В этом подразделе и далее $f \in \mathcal{F}^d_{L_0,L_1}$, а x^* — точка минимума функции f. Используется вариант алгоритма 2 без добавки Φ, и с начальным весом $a_0 \ge 0$ (алгоритм 4). Положим $A_k = a_0 + a_1 + \dots + a_k$. Коэффициент $a_k > 0$ определяется уравнением

$$32\big(L_0 + L_1\|\nabla f(y^k)\|\big)a_k^2 = A_{k-1} + a_k, \tag{B.9}$$

а число шагов одномерного поиска — условием (3.4).

Алгоритм 4 Вариант метода SHERPA без поправки

Вход: начальная точка x^0, начальный вес $a_0 \geq 0$, числа $r, \delta > 0$, натуральное число m с условием (3.4), число итераций K

$v^0 = x^0$, $A_0 = a_0$
для $k = 1, \ldots, K$ **выполнять**
  y^k — результат алгоритма 1 на отрезке $[v^{k-1}, x^{k-1}]$ с числами r, δ, m
  если сработал критерий остановки **то**
    вернуть y^k
  конец если
  a_k — положительный корень уравнения (B.9), $A_k = A_{k-1} + a_k$
  $x^k = y^k - \dfrac{\nabla f(y^k)}{4(L_0 + L_1\|\nabla f(y^k)\|)}$
  $v^k = v^{k-1} - a_k \nabla f(y^k)$
конец для
вернуть x^K

Лемма B.4.
Пусть $\|x^0 - x^*\| \leq R_0$, начальная невязка $f(x^0) - f^*$ не больше Δ_0 и

$$r^2 \geq R_0^2 + 2a_0\Delta_0.$$

Если первые k итераций алгоритма 4 прошли без срабатывания критерия остановки, то

$$A_k\big(f(x^k) - f^*\big) + \frac{1}{2}\sum_{i=1}^{k} a_i^2 \|\nabla f(y^i)\|^2 + \frac{1}{2}\|v^k - x^*\|^2 \leq \frac{1}{2}R_0^2 + a_0\Delta_0, \tag{B.10}$$

и все точки метода и одномерного поиска лежат в шаре $B(x^*, r)$. Кроме того, при всех $i \leq k$

$$\begin{aligned} f(x^{i-1}) &\geq f(y^i), \\ f(y^i) &\geq f(x^i) + \frac{\|\nabla f(y^i)\|^2}{8\big(L_0 + L_1\|\nabla f(y^i)\|\big)}. \end{aligned} \tag{B.11}$$

Доказательство. Доказательство повторяет доказательство леммы 3.4. При $k = 0$ неравенство (B.10) следует из условий на x^0. Шаг индукции отличается в трёх местах.

- ▷ *Замены.* Вместо леммы 3.2 используется неравенство выпуклости $\langle \nabla f(y^k), y^k - x^* \rangle \geq f(y^k) - f^*$, а лемма 3.3 используется так же. Неравенства (B.11) следуют из неё и леммы 3.1.
- ▷ *Приращение.* С этими заменами оценки расстояния и невязки из доказательства леммы 3.4 дают

$$\begin{aligned} &\Big[A_k\big(f(x^k) - f^*\big) + \frac{1}{2}\|v^k - x^*\|^2\Big] - \Big[A_{k-1}\big(f(x^{k-1}) - f^*\big) + \frac{1}{2}\|v^{k-1} - x^*\|^2\Big] \\ &\quad\leq \Big(\frac{a_k}{16} - \frac{5A_k}{24}\Big)\frac{\|\nabla f(y^k)\|^2}{L_0 + L_1\|\nabla f(y^k)\|} + \frac{1}{2}a_k^2\|\nabla f(y^k)\|^2 \\ &\quad\underset{\text{(B.9)}}{=} \Big(\frac{a_k}{16} - \frac{5A_k}{24} + \frac{A_k}{32}\Big)\frac{\|\nabla f(y^k)\|^2}{L_0 + L_1\|\nabla f(y^k)\|} - \frac{1}{2}a_k^2\|\nabla f(y^k)\|^2 \\ &\quad\underset{\text{(a)}}{\leq} -\frac{1}{2}a_k^2\|\nabla f(y^k)\|^2, \end{aligned}$$

где (a) — неравенства $a_k \le A_k$ и $1/16 - 5/24 + 1/32 < 0$.

▷ *Шар радиуса r.* По неравенству (B.10) и условию леммы

$$\|v^k - x^*\|^2 \le R_0^2 + 2a_0\Delta_0 \le r^2,$$

а точка x^k лежит в шаре по лемме 3.1. □

Из уравнения (B.9) и равенства $A_k = A_{k-1} + a_k$ при каждом $i \ge 1$ следуют соотношения

$$\begin{aligned} a_i^2 &= \frac{A_i}{32\big(L_0 + L_1\|\nabla f(y^i)\|\big)}, \\ \sqrt{A_i} - \sqrt{A_{i-1}} &= \frac{a_i}{\sqrt{A_i} + \sqrt{A_{i-1}}} \underset{A_{i-1}\le A_i}{\ge} \frac{a_i}{2\sqrt{A_i}} \\ &= \frac{1}{2\sqrt{32\big(L_0 + L_1\|\nabla f(y^i)\|\big)}}. \end{aligned} \tag{B.12}$$

Кроме того, при $A_{i-1} > 0$

$$\frac{a_i}{A_i} \le -\log\Big(1 - \frac{a_i}{A_i}\Big) = \log\frac{A_i}{A_{i-1}}. \tag{B.13}$$

B.3 Невязка не больше 4ε: оценка по блокам

Первый способ подсчёта оценивает невязку после блока из N последовательных итераций через невязку в начале блока.

Лемма B.5 (оценка по блокам)**.**
Пусть $\|x^0 - x^*\| \le R$, алгоритм 4 запущен с $a_0 = 0$ и $r = R$, и итерации $k+1, \dots, k+N$, $N \ge 1$, прошли без срабатывания критерия остановки. Тогда

$$f(x^{k+N}) - f^* \le \frac{96L_0R^2}{N^2} + \frac{3072\,L_1^2R^2}{N^3}\big(f(x^k) - f^*\big). \tag{B.14}$$

Доказательство. Все суммы в доказательстве берутся по $i = k+1, \dots, k+N$.

▷ *Невязка через веса.* Имеем

$$\begin{aligned} f(x^{k+N}) - f^* &\underset{\text{(B.10)}}{\le} \frac{R^2}{2A_{k+N}} \le \frac{R^2}{2\big(\sqrt{A_{k+N}} - \sqrt{A_k}\big)^2} \\ &\underset{\text{(B.12)}}{\le} \frac{64R^2}{\Big(\sum_i \big(L_0 + L_1\|\nabla f(y^i)\|\big)^{-1/2}\Big)^2}. \end{aligned}$$

▷ *Неравенство Гёльдера.* С показателями 3/2 и 3

$$\begin{aligned} N &= \sum_i \big(L_0 + L_1\|\nabla f(y^i)\|\big)^{-1/3}\big(L_0 + L_1\|\nabla f(y^i)\|\big)^{1/3} \\ &\le \Big(\sum_i \big(L_0 + L_1\|\nabla f(y^i)\|\big)^{-1/2}\Big)^{2/3}\Big(\sum_i \big(L_0 + L_1\|\nabla f(y^i)\|\big)\Big)^{1/3}. \end{aligned}$$

Подставляя в предыдущую оценку, получаем

$$\begin{aligned} f(x^{k+N}) - f^* &\le \frac{64R^2}{N^3}\sum_i \big(L_0 + L_1\|\nabla f(y^i)\|\big) \\ &= \frac{64L_0R^2}{N^2} + \frac{64L_1R^2}{N^3}\sum_i \|\nabla f(y^i)\|. \end{aligned} \tag{B.15}$$

▷ *Сумма градиентов мала, если мала невязка.* Суммируя неравенства (B.11) по блоку, получаем

$$\sum_i \frac{\|\nabla f(y^i)\|^2}{L_0 + L_1\|\nabla f(y^i)\|} \le 8\big(f(x^k) - f^*\big).$$

По неравенству КБШ

$$\begin{aligned}\Big(\sum_i \|\nabla f(y^i)\|\Big)^2 &\le \sum_i \frac{\|\nabla f(y^i)\|^2}{L_0 + L_1\|\nabla f(y^i)\|} \cdot \sum_i \big(L_0 + L_1\|\nabla f(y^i)\|\big) \\ &\le 8\big(f(x^k) - f^*\big)\Big(NL_0 + L_1 \sum_i \|\nabla f(y^i)\|\Big).\end{aligned}$$

Для неотрицательных чисел из неравенства $s^2 \le c_1 + c_2 s$ следует $s \le \sqrt{c_1} + c_2$: иначе было бы $s^2 > (\sqrt{c_1} + c_2)s \ge c_1 + c_2 s$. Поэтому

$$\sum_i \|\nabla f(y^i)\| \le \sqrt{8NL_0\big(f(x^k) - f^*\big)} + 8L_1\big(f(x^k) - f^*\big).$$

▷ *Подстановка.* Подставим эту оценку в (B.15). Второе слагаемое в (B.15) станет не больше

$$\frac{64L_1R^2}{N^3}\sqrt{8NL_0\big(f(x^k) - f^*\big)} + \frac{512\,L_1^2R^2\big(f(x^k) - f^*\big)}{N^3}.$$

Первое из этих слагаемых равно $2\sqrt{st}$ для чисел

$$\begin{aligned}s &= \frac{32L_0R^2}{N^2}, \\ t &= \frac{256\,L_1^2R^2\big(f(x^k) - f^*\big)}{N^3},\end{aligned}$$

и по неравенству $2\sqrt{st} \le s + t$ не больше $s + t$. Поэтому

$$f(x^{k+N}) - f^* \le \frac{96L_0R^2}{N^2} + \frac{768\,L_1^2R^2\big(f(x^k) - f^*\big)}{N^3}.$$

Так как $768 \le 3072$, получаем (B.14). □

Оценка (B.14) объясняет, откуда берутся два слагаемых: первое — обычная скорость ускоренного метода, второе — цена нелинейности кривизны, пропорциональная невязке в начале блока. Если начальная невязка неизвестна и может быть экспоненциально большой, второе слагаемое бесполезно. Это препятствие обходится двумя способами: добавкой Ф, если известен только радиус (раздел 3), и положительным начальным весом, если известна оценка невязки (следующий подраздел).

B.4 Известная оценка невязки: положительный начальный вес

Пусть $\|x^0 - x^*\| \le R$ и известно число $\Delta > \varepsilon$, для которого $f(x^0) - f^* \le \Delta$. Запустим алгоритм 4 с параметрами

$$\begin{aligned}a_0 &= \frac{R^2}{2\Delta}, \\ r &= \sqrt{2}R, \\ \delta &= \varepsilon.\end{aligned} \tag{B.16}$$

Условие леммы B.4 с $R_0 = R$ и $\Delta_0 = \Delta$ выполнено, поскольку $R^2 + 2a_0\Delta = 2R^2 = r^2$.

Лемма B.6 (подсчёт при положительном начальном весе)**.**
Если K итераций алгоритма 4 с параметрами (B.16) прошли без срабатывания критерия остановки и $f(x^K) - f^* > \varepsilon$, то

$$K < 16\sqrt{\frac{L_0 R^2}{\varepsilon}} + 21\,(L_1 R)^{2/3} \log^{2/3} \frac{2\Delta}{\varepsilon}.$$

Доказательство. Правая часть (B.10) не больше $R^2/2 + R^2/2 = R^2$. Так как $f(x^K) - f^* > \varepsilon$, отсюда

$$\begin{gathered} A_K < \frac{R^2}{\varepsilon}, \\ \sum_{i=1}^{K} a_i^2 \|\nabla f(y^i)\|^2 \le 2R^2. \end{gathered} \tag{B.17}$$

Разделим итерации на две группы: с малым градиентом, $L_1\|\nabla f(y^i)\| \le L_0$, и с большим, $L_1\|\nabla f(y^i)\| > L_0$.

▷ *Итерации с малым градиентом.* Для них $L_0 + L_1\|\nabla f(y^i)\| \le 2L_0$, и по (B.12) каждая такая итерация увеличивает $\sqrt{L_0 A_i}$ не менее чем на $1/16$. Значит, их число не больше

$$16\sqrt{L_0 A_K} \underset{\text{(B.17)}}{<} 16\sqrt{\frac{L_0 R^2}{\varepsilon}}.$$

▷ *Итерации с большим градиентом.* Для них $L_0 + L_1\|\nabla f(y^i)\| < 2L_1\|\nabla f(y^i)\|$, поэтому

$$\begin{aligned} a_i\|\nabla f(y^i)\| &\underset{\text{(B.12)}}{=} \frac{A_i\|\nabla f(y^i)\|}{32\big(L_0 + L_1\|\nabla f(y^i)\|\big)a_i} \\ &> \frac{A_i}{64 L_1 a_i}. \end{aligned}$$

Отсюда и из (B.17)

$$\sum_{L_1\|\nabla f(y^i)\| > L_0} \Big(\frac{A_i}{a_i}\Big)^2 < (64L_1)^2 \cdot 2R^2 = 8192\, L_1^2 R^2.$$

Так как $A_{i-1} \ge a_0 > 0$, по (B.13)

$$\sum_{L_1\|\nabla f(y^i)\| > L_0} \frac{a_i}{A_i} \le \log \frac{A_K}{a_0} \underset{\text{(B.17), (B.16)}}{<} \log \frac{2\Delta}{\varepsilon}.$$

По неравенству Гёльдера с показателями 3 и 3/2 число итераций с большим градиентом равно

$$\begin{aligned} \sum_{L_1\|\nabla f(y^i)\| > L_0} \Big(\frac{A_i}{a_i}\Big)^{2/3} \Big(\frac{a_i}{A_i}\Big)^{2/3} &\le \Big(\sum \Big(\frac{A_i}{a_i}\Big)^2\Big)^{1/3} \Big(\sum \frac{a_i}{A_i}\Big)^{2/3} \\ &< (8192\, L_1^2 R^2)^{1/3} \log^{2/3} \frac{2\Delta}{\varepsilon} \\ &< 21\,(L_1 R)^{2/3} \log^{2/3} \frac{2\Delta}{\varepsilon}. \end{aligned}$$

□

B.5 Итоговые верхние оценки

Теорема B.7 (верхние оценки при ограниченной начальной невязке)**.**
Пусть $f \in \mathcal{F}^d_{L_0,L_1}$, $\|x^0 - x^*\| \le R$ и $\varepsilon > 0$.

(а) Если $f(x^0) - f^* \le 4\varepsilon$, то алгоритм 4 с $a_0 = 0$, $r = R$, $\delta = \varepsilon$,

$$m = \left\lceil \log_2\Big(128\Big(1 + \frac{L_0R^2}{\varepsilon} + L_1R\Big)^2\Big)\right\rceil$$

и числом итераций

$$\begin{aligned} K &= \max\Big\{1, \Big\lceil\sqrt{\frac{192L_0R^2}{\varepsilon}}\Big\rceil, \lceil(24576\,L_1^2R^2)^{1/3}\rceil\Big\} \\ &\le 3 + 14\sqrt{\frac{L_0R^2}{\varepsilon}} + 30(L_1R)^{2/3} \end{aligned}$$

выдаёт точку с невязкой по функции не больше ε, сделав не более $K(m+2)$ обращений к оракулу.

(б) Если известно число $\Delta > \varepsilon$ с $f(x^0) - f^* \le \Delta$, то алгоритм 4 с параметрами (B.16),

$$m = \left\lceil \log_2\Big(128\Big(1 + \frac{2L_0R^2}{\varepsilon} + \sqrt{2}L_1R\Big)^2\Big)\right\rceil$$

и числом итераций

$$K = \left\lceil 16\sqrt{\frac{L_0R^2}{\varepsilon}} + 21\,(L_1R)^{2/3}\log^{2/3}\frac{2\Delta}{\varepsilon}\right\rceil$$

выдаёт такую точку, сделав не более $K(m+2)$ обращений к оракулу. При $\Delta \le \varepsilon$ достаточно вернуть x^0.

В обоих случаях метод использует только градиенты и не использует значение f^*. В случае (а) он не использует и оценку начальной невязки.

Доказательство.

▷ *Пункт (а).* Если сработал критерий остановки, выход корректен по лемме 3.3. Иначе оценка (B.14) с $k = 0$ и $f(x^0) - f^* \le 4\varepsilon$ даёт

$$f(x^K) - f^* \le \frac{96L_0R^2}{K^2} + \frac{3072\,L_1^2R^2\cdot 4\varepsilon}{K^3} \underset{\text{(а)}}{\le} \frac{\varepsilon}{2} + \frac{\varepsilon}{2},$$

где (а) — выбор K. Оценка для K следует из неравенств $\sqrt{192} < 14$ и $24576^{1/3} < 30$.

▷ *Пункт (б).* При $\Delta \le \varepsilon$ возвращаем x^0. Иначе по лемме B.6 после K итераций либо сработал критерий остановки и выход корректен по лемме 3.3, либо $f(x^K) - f^* \le \varepsilon$.

В обоих пунктах число обращений не больше $K(m+2)$. □

Число шагов поиска $m + 2$ растёт лишь логарифмически по L_0R^2/ε и L_1R, поэтому теорема даёт для класса с начальной невязкой не больше 4ε и для класса с известной оценкой начальной невязки Δ соответственно оценки

$$O\Big(\Big[1 + \sqrt{\frac{L_0R^2}{\varepsilon}} + (L_1R)^{2/3}\Big]\log\Big(2 + \frac{L_0R^2}{\varepsilon} + L_1R\Big)\Big),$$
$$O\Big(\Big[1 + \sqrt{\frac{L_0R^2}{\varepsilon}} + (L_1R)^{2/3}\log^{2/3}\frac{2\Delta}{\varepsilon}\Big]\log\Big(2 + \frac{L_0R^2}{\varepsilon} + L_1R\Big)\Big).$$

В случае (б) перед запуском Δ можно заменить на минимум из Δ и правой части (A.3). Вместе с теоремой B.3 первая оценка даёт при $L_0 R^2 \geq \varepsilon$

$$1 + \mathcal{N}(\mathcal{P}_{4\varepsilon}) = \widetilde{\Theta}\Big(1 + \sqrt{\frac{L_0 R^2}{\varepsilon}} + (L_1 R)^{2/3}\Big).$$

Совпадающая с (б) нижняя оценка при Δ между 4ε и правой частью (A.3) неизвестна.

C Фиксированная размерность

Нижние оценки раздела 4 используют растущую размерность. Покажем, что это существенно: в фиксированной размерности метод центров тяжести решает задачу при фиксированной нормированной точности $L_1^2\varepsilon/L_0$ за число обращений, логарифмическое по $L_1 R$.

Функция $t \mapsto e^t - 1 - t$ строго возрастает на $[0, \infty)$ от 0 до $+\infty$. Поэтому однозначно определено число $\rho_\varepsilon > 0$ — радиус шара вокруг точки минимума, в котором оценка роста леммы A.2 не превосходит ε:

$$\frac{L_0}{L_1^2}\big(e^{L_1\rho_\varepsilon} - 1 - L_1\rho_\varepsilon\big) = \varepsilon. \tag{C.1}$$

Предложение C.1 (метод центров тяжести)**.**
Пусть $L_0, L_1, R, \varepsilon > 0$ и размерность d фиксирована. Класс $\mathcal{P}_{\mathrm{R}}$ в размерности d решается методом центров тяжести за

$$1 + \Big\lfloor \frac{d \log\big(2\sqrt{d}\, R/\min\{R, \rho_\varepsilon\}\big)}{-\log(1 - 1/e)} \Big\rfloor \tag{C.2}$$

обращений к оракулу, то есть за

$$O\Big(d \log\Big(2\sqrt{d} \max\Big\{1, \frac{R}{\rho_\varepsilon}\Big\}\Big)\Big)$$

обращений. В размерности $d = 1$ метод деления отрезка пополам использует не более

$$\Big\lceil \max\Big\{\log_2 \frac{R}{\rho_\varepsilon},\, 0\Big\} \Big\rceil \tag{C.3}$$

обращений. Если выход обязан совпадать с точкой обращения к оракулу, достаточно добавить одно обращение.

При фиксированных d и $L_1^2\varepsilon/L_0$ величина $L_1\rho_\varepsilon$ постоянна, и оценка (C.2) имеет порядок $\log(2 + L_1 R)$. Многомерный метод центров тяжести выбирает выход по значениям функции. Метод деления отрезка пополам использует только знаки производной.

Доказательство.

▷ *Шар точек с малой невязкой.* По лемме A.2 для каждого x

$$f(x) - f^* \leq \frac{L_0}{L_1^2}\big(e^{L_1\|x - x^*\|} - 1 - L_1\|x - x^*\|\big). \tag{C.4}$$

Следовательно, в шаре $B(x^*, \min\{R, \rho_\varepsilon\})$ невязка по функции не больше ε.

▷ *Метод центров тяжести.* Без ограничения общности $x^0 = 0$. Начнём с куба $K_0 = [-2R, 2R]^d$. Он содержит шар $B(x^*, \min\{R, \rho_\varepsilon\})$, поскольку $\|x^*\| \leq R$. На

шаге k вычислим центр тяжести c_k многогранника K_{k-1} и обратимся к оракулу в этой точке. Если $\nabla f(c_k) = 0$, то c_k — точка минимума. Иначе положим

$$K_k = K_{k-1} \cap \{z : \ \langle \nabla f(c_k), z - c_k \rangle \le 0\}.$$

После заданного числа шагов вернём точку обращения с наименьшим значением функции. Вычисления центров тяжести между обращениями к оракулу не учитываются.

▷ *Шар сохраняется.* Пусть во всех первых N точках обращения невязка по функции больше ε. Для всякой точки z шара $B(x^*, \min\{R, \rho_\varepsilon\})$ из выпуклости и (C.4)

$$\langle \nabla f(c_k), z - c_k \rangle \le f(z) - f(c_k) < 0.$$

Значит, весь шар сохраняется после каждого отсечения.

▷ *Сравнение объёмов.* По теореме Грюнбаума (Grünbaum, 1960) всякая гиперплоскость, проходящая через центр тяжести выпуклого тела, оставляет в каждом из двух полупространств не менее $1/e$ его объёма. Единичный шар содержит куб $[-1/\sqrt{d}, 1/\sqrt{d}]^d$, поэтому его объём не меньше $(2/\sqrt{d})^d$. Следовательно,

$$\begin{aligned} \Big(\frac{2\min\{R, \rho_\varepsilon\}}{\sqrt{d}}\Big)^d &\underset{\text{(а)}}{\le} \operatorname{vol}(K_N) \\ &\underset{\text{(б)}}{\le} \Big(1 - \frac{1}{e}\Big)^N (4R)^d, \end{aligned}$$

где (а) — сохранение шара, (б) — теорема Грюнбаума. При N, равном (C.2), правая часть строго меньше левой. Это противоречие показывает, что хотя бы одна из точек обращения к оракулу имеет невязку не больше ε.

▷ *Одномерный случай.* Начнём с отрезка $[-R, R]$. На каждом шаге обращаемся к оракулу в середине текущего отрезка. Если производная в ней положительна, оставляем левую половину, если отрицательна — правую, а при нулевой производной найден точный минимум. Монотонность производной выпуклой функции гарантирует, что точка минимума остаётся в отрезке. После n обращений середина $\hat{x}$ оставшегося отрезка удовлетворяет неравенствам

$$\begin{aligned} |\hat{x} - x^*| \ &\le \ R\,2^{-n}, \\ f(\hat{x}) - f^* &\underset{\text{(C.4)}}{\le} \frac{L_0}{L_1^2}\big(e^{L_1 R 2^{-n}} - 1 - L_1 R\,2^{-n}\big). \end{aligned}$$

При n, равном (C.3), имеем $R2^{-n} \le \rho_\varepsilon$, и правая часть не больше ε. В выходной середине к оракулу могли не обращаться. Если выход должен совпадать с точкой обращения, нужно ещё одно обращение. □

Замечание C.2.
При фиксированных d и $L_1^2\varepsilon/L_0$ предложение C.1 даёт лишь $O(\log(2 + L_1 R))$ обращений. Поэтому нижняя оценка, линейная по $L_1 R$ с точностью до логарифмов, не может быть реализована семейством фиксированной размерности. Ей необходим механизм сокрытия информации в числе направлений, растущем вместе с числом обращений. Именно поэтому в теоремах B.3 и 4.10 используется размерность порядка длины цепочки.

D Сводная таблица известных оценок

В таблице 2 собраны известные верхние оценки для выпуклого детерминированного случая. Здесь $R = \|x^0 - x^*\|$, $F_0 = f(x^0) - f^*$, запись $O(\cdot)$ скрывает абсолютные константы, $\widetilde{O}(\cdot)$ — ещё и логарифмические множители. Условие гладкости в столбце «Гл.»: sym — симметричное (определение 2.1), asym — локальное несимметричное, ℓ — с общей функцией $\ell(\|\nabla f\|)$, (H_0, H_1) — $\|\nabla^2 f\| \le H_0 + H_1(f - f^*)$.

Таблица 2. Выпуклый детерминированный случай: число обращений до $f(\hat{x}) - f^* \le \varepsilon$.

Работа	Гл.	Метод	Сложность
Koloskova et al. (2023)	sym + L-гл.	clipped GD	$O\big(\frac{L_0 R^2}{\varepsilon} + L_1 R^2 \sqrt{\frac{L}{\varepsilon}}\big)^a$
Takezawa et al. (2024)	sym + L-гл.	шаг Поляка	$O\big(\frac{L_0 R^2}{\varepsilon} + L_1 R^2 \sqrt{\frac{L}{\varepsilon}}\big)^a$
Li et al. (2023)	ℓ	GD	$O\big(\frac{\ell(G) R^2}{\varepsilon}\big)$, $G = \|\nabla f(x^0)\|^f$
Li et al. (2023)	ℓ	быстрый градиентный метод	$O\big((1 + L_1^2 R^2 + \frac{L_1^2 F_0}{L_0}) \sqrt{\frac{F_0 + L_0 R^2}{\varepsilon}}\big)^g$
Gorbunov et al. (2025)	sym	(L_0, L_1)-GD, шаг Поляка	$O\big(\frac{L_0 R^2}{\varepsilon} + L_1^2 R^2\big)$
Gorbunov et al. (2025)	sym	(L_0, L_1)-STM	$O\big(\sqrt{(1 + L_1 R e^{L_1 R}) \frac{L_0 R^2}{\varepsilon}}\big)$
Vankov et al. (2025)	sym	GD (три правила шага), clipping	$O\big(\frac{L_0 R^2}{\varepsilon} + L_1 R \log \frac{F_0}{\varepsilon}\big)$
Vankov et al. (2025)	sym	нормированный GD, шаг Поляка	$O\big(\frac{L_0 R^2}{\varepsilon} + L_1^2 R^2\big)$
Vankov et al. (2025)	sym	AGMsDR^h	$O\big(\sqrt{\frac{L_0 R^2}{\varepsilon}} + (L_1 R)^{2/3} \log \frac{F_0}{\varepsilon}\big)$ итераций
Lobanov et al. (2025)	asym	GD, нормированный и clipped GD	$O\big(\frac{L_0 R^2}{\varepsilon} + L_1 R \log \frac{F_0}{\varepsilon}\big)$
Tyurin (2025)	ℓ	GD с шагом $\int_0^1 \frac{dv}{\ell(\|g\|(1+v))}$	$O\big(\frac{L_0 R^2}{\varepsilon} + \min\big\{L_1 R \sqrt{\frac{F_0}{\varepsilon}}, L_1^2 R^2, \frac{L_1 \|\nabla f(x^0)\| R^2}{\varepsilon}\big\}\big)$
Krivchenko (2026)	sym	GD, PEP	уточнение констант в оценке с $L_1 R \log \frac{F_0}{\varepsilon}$
Oikonomidis et al. (2025)	анизотропная	нелинейно предобусловленный GD	$O(\mathcal{D}_0/\varepsilon)$, $\mathcal{D}_0$ — супремум по подуровневому множеству
Kovalev and Stonyakin (2026)	sym	шаг Поляка с неточным нормированным градиентом	$O\big(\frac{L_0 R^2}{\varepsilon} + L_1^2 R^2\big)$
Tyurin (2026)	ℓ	ускоренный метод	$O\big(\sqrt{\frac{L_0 R^2}{\varepsilon}} + L_1 R \log_+ \min\big\{\frac{L_1^2 F_0}{L_0}, \frac{F_0}{\varepsilon}\big\}\big)^i$
Borodich and Kovalev (2026)	sym	GRAAL с ускорением	$O\big(1 + \sqrt{\frac{L_0 R^2}{\varepsilon}} + (L_1 R)^3\big)^j$
Lobanov (2026)	(H_0, H_1)	ускоренный, маломерная релаксация, рестарты	$\widetilde{O}\big(\sqrt{\frac{H_0 \tilde{R}^2}{\varepsilon}} + \sqrt{H_1 \tilde{R}^2} \log \frac{F_0}{\varepsilon}\big)$
Эта статья (теорема 3.7)	sym	ускоренный, конечный поиск	$5\sqrt{\frac{L_0 R^2}{\varepsilon}} + O\big((1 + L_1 R) \log(2 + L_1 R)\big)$

a: выведено нами из теоремы ($c = L_0/L_1$, дополнительно предполагается L-гладкость). f: при условии на радиус из определения (r, ℓ)-гладкости. g: пересчёт из Vankov et al. (2025). h: каждая итерация содержит точную одномерную минимизацию. i: плюс член, зависящий от инициализации. j: при начальном шаге $\eta_0 = e^{-L_1 R}/L_0$, полная оценка содержит ещё $(1 + (L_1 R)^2) \log \frac{1}{\eta_0 L_0}$.