«Спуск с Эвереста»
Оракульная сложность выпуклой оптимизации при (L_0, L_1)-гладкости

Михаил Рудоманов[♠▲] Иван Фомин[♣▲]
Александр Владимирович Гасников[†] Федор Сергеевич Стонякин[‡]

Аннотация. Для выпуклых (L_0, L_1)-гладких функций кривизна может расти вместе с нормой градиента. Поэтому даже при $\|x^0 - x^*\| \le R$ градиент и невязка по функции в начальной точке могут быть экспоненциально большими по $L_1 R$, и оценка $\sqrt{L_0 R^2/\varepsilon}$, известная для ускоренного метода на функциях с липшицевым градиентом, уже не описывает сложность задачи. Мы находим оракульную сложность этого класса для произвольных детерминированных методов первого порядка: при $L_0 R^2/\varepsilon \ge 1$ оптимальное число обращений к оракулу N удовлетворяет соотношению $1 + N = \widetilde{\Theta}\big(\sqrt{L_0 R^2/\varepsilon} + L_1 R\big)$. Верхняя оценка имеет вид $O\big(\sqrt{L_0 R^2/\varepsilon} + (1 + L_1 R)\log(2 + L_1 R)\big)$: метод сначала проходит режим больших градиентов за $O(1 + L_1 R)$ итераций с неточным одномерным поиском, а затем работает обычный ускоренный метод с постоянным шагом. Нижняя оценка получена с помощью цепочек и принципа ортогональной инвариантности на функциях, сопряжённых к сильно выпуклым функциям на многограннике. Если начальная невязка не больше 4ε, то оптимальная оценка принимает вид $1 + N = \widetilde{\Theta}\big(\sqrt{L_0 R^2/\varepsilon} + (L_1 R)^{2/3}\big)$.

Ключевые слова: (L_0, L_1)-гладкость, обобщённая гладкость, выпуклая оптимизация, оракульная сложность, нижние оценки, ускоренные методы, неточный одномерный поиск, методы первого порядка.

Использование языковых моделей. При получении теоретических результатов настоящей работы использовались модели *Codex Astra 6* и *Claude Opus 5.5*. Они также применялись при подготовке и вёрстке рукописи и для перевода исходного текста на английский язык. Однако каждая строка статьи, включая каждое утверждение, каждое доказательство и каждое вычисление, лично отредактирована и проверена авторами. Ответственность за корректность всех математических утверждений, доказательств и выводов несут исключительно авторы работы.

1 Введение

Мы рассматриваем задачу безусловной выпуклой оптимизации

$$f(x) \to \min_{x \in \mathbb{R}^d},$$

где $f : \mathbb{R}^d \to \mathbb{R}$ — выпуклая дифференцируемая (L_0, L_1)-гладкая функция, достигающая минимума f^* в некоторой точке[1] x^*. О начальной точке x^0 известна лишь верхняя оценка R её расстояния до точки минимума: $\|x^0 - x^*\| \le R$.

[♠]MIRIAI, Moscow Independent Research Institute of Artificial Intelligence, Москва, Россия. rudomanov.ma@phystech.edu.

[▲]Равный вклад.

[♣]Яндекс, Москва, Россия. ash-ivanfomin@yandex-team.ru.

[†]Университет Иннополис, Иннополис, Россия. gasnikov@yandex.ru.

[‡]КФУ им. В. И. Вернадского, Симферополь, Россия. fedyor@mail.ru.

[1]Точка минимума, вообще говоря, не единственна. Множество $X^* = \arg\min f$ выпукло и замкнуто, поэтому условие ниже равносильно $\operatorname{dist}(x^0, X^*) \le R$, и под x^* можно понимать ближайшую к x^0 точку минимума.

Для выпуклых задач с L-липшицевым градиентом расстояние R до точки минимума ограничивает начальную невязку по функции величиной $LR^2/2$ и задаёт сложность градиентных методов — классические оценки LR^2/ε и $\sqrt{LR^2/\varepsilon}$. При обобщённой гладкости это уже не так. Для дважды непрерывно дифференцируемых функций класс (L_0, L_1)-гладких выпуклых функций с параметрами $L_0, L_1 > 0$ задаётся условием

$$0 \preceq \nabla^2 f(x) \preceq \big(L_0 + L_1\|\nabla f(x)\|\big) I,$$

то есть кривизне разрешено расти вместе с нормой градиента. Эта модель была предложена для объяснения успеха методов с клиппингом градиента (Zhang et al., 2020b,a) и с тех пор стала одним из стандартных предположений в анализе методов первого порядка.

Условие (L_0, L_1)-гладкости было предложено на основе экспериментальных наблюдений при обучении нейронных сетей. В экспериментах с языковой моделью на основе LSTM была обнаружена положительная корреляция между локальной константой гладкости и нормой градиента, что послужило основанием для введения модели с зависимостью $L_0 + L_1\|\nabla f(x)\|$ (Zhang et al., 2020b). Аналогичная зависимость наблюдалась при обучении трансформеров (Crawshaw et al., 2022).

Условие (L_0, L_1)-гладкости не требует выпуклости функции. В частности, ему удовлетворяют многочлены одной переменной степени не ниже третьей при подходящем выборе констант L_0, L_1 (Zhang et al., 2020b). Кроме того, соответствующая оценка гессиана выполняется для некоторых задач распределённо-робастной оптимизации после перехода к двойственной переменной и введения штрафа, при определённых предположениях о функции потерь и дивергенции (Jin et al., 2021, Chen et al., 2023).

В отличие от функций с липшицевым градиентом, расстояние до точки минимума уже не ограничивает невязку по функции квадратичной величиной: в точке на расстоянии R от минимума невязка может достигать $(L_0/L_1^2)\big(e^{L_1 R} - L_1 R - 1\big)$, то есть быть экспоненциально большой по $L_1 R$, и эта оценка достигается (лемма A.2). Поэтому, прежде чем метод попадёт в область малых градиентов, где работает привычная теория задач с липшицевым градиентом, ему приходится пройти область больших градиентов. Сколько обращений к оракулу это стоит наилучшему методу первого порядка, если о начальной точке известна только верхняя оценка R её расстояния до точки минимума? В этой работе мы даём ответ: с точностью до логарифмических множителей эта цена равна $L_1 R$.

Обозначения. Через $\varepsilon > 0$ обозначается требуемая точность решения задачи по функции: метод должен выдать точку $\hat{x}$, для которой $f(\hat{x}) - f^* \le \varepsilon$. Знак $\|\cdot\|$ всюду означает евклидову норму вектора и спектральную норму матрицы, $[x, y]$ — отрезок с концами $x, y \in \mathbb{R}^d$, $B(x, r)$ — замкнутый шар радиуса r с центром x, КБШ — неравенство Коши–Буняковского–Шварца. Сумму первых k членов последовательности мы обозначаем соответствующей заглавной буквой: например, $A_k = a_1 + \cdots + a_k$ и $A_0 = 0$.

Основной результат. Мы рассматриваем произвольные детерминированные методы первого порядка: методу разрешено запрашивать градиент в любых точках и выдавать любую точку, а учитывается каждое обращение к оракулу. Мы доказываем, что наименьшее число обращений N, при котором существует детерминированный метод первого порядка, решающий задачу для всех функций класса во всех размерностях, удовлетворяет неравенствам[2]

$$1 + N \ge \frac{1}{29}\Big[1 + \sqrt{\frac{L_0 R^2}{\varepsilon}} + \frac{L_1 R}{\sqrt{\log(2 + L_1 R)}}\Big],$$

[2]Здесь и далее нижние оценки доказаны при $L_0 R^2 \ge \varepsilon$.

$$1 + N \leq 5\sqrt{\frac{L_0 R^2}{\varepsilon}} + C\,(1 + L_1 R)\log(2 + L_1 R)$$

с абсолютной константой C (теоремы 3.7 и 4.10). Таким образом, оптимальная сложность равна $\sqrt{L_0 R^2/\varepsilon} + L_1 R$ с точностью до логарифмических множителей, причём логарифмы стоят только при $L_1 R$. Метод верхней оценки использует только градиенты. Нижняя оценка остаётся верной и для методов, которые вместе с градиентом получают значение функции.

Верхняя и нижняя оценки. Верхняя оценка получена методом из двух этапов. На первом этапе метод SHERPA проходит режим больших градиентов за $O(1 + L_1 R)$ итераций. Это ускоренный метод с неточным одномерным поиском ICEPICK, построенный по схеме оценивающих последовательностей Нестерова (Nesterov, 2018). На втором этапе работает обычный ускоренный метод с постоянным шагом $1/(2L_0)$, анализ которого мы берём из работы Tyurin (2026). Используемый вариант этого метода мы называем CRUISE. Нижняя оценка получена по классической схеме: цепочка и принцип ортогональной инвариантности (Nemirovsky and Yudin, 1983, Nesterov, 2018, Carmon et al., 2020).

Ограниченная начальная невязка. Если дополнительно известно, что $f(x^0) - f^* \leq 4\varepsilon$, то сложность падает до

$$1 + N = \widetilde{\Theta}\Big(\sqrt{\frac{L_0 R^2}{\varepsilon}} + (L_1 R)^{2/3}\Big)$$

(приложение B). Противоречия с основным результатом нет: наихудшие функции, на которых получено слагаемое $L_1 R$, имеют огромную начальную невязку и в класс с ограниченной невязкой не входят. Этот режим может быть полезен для схем с рестартами: каждый следующий запуск метода начинается из точки, в которой невязка по функции уже ограничена постоянным кратным точности, требуемой от этого запуска, поэтому стоимость одного запуска определяется показателем $2/3$, а не 1.

Связанные работы. Обобщение, в котором $L_0 + L_1\|\nabla f(x)\|$ заменяется произвольной функцией $\ell(\|\nabla f(x)\|)$, изучалось в работах Li et al. (2023), Tyurin (2025). Мы ограничиваемся аффинным случаем. Гарантии сходимости градиентных методов в выпуклом случае получены в работах Gorbunov et al. (2025), Vankov et al. (2025), Lobanov et al. (2025), ускоренные методы рассматривались в работах Gorbunov et al. (2025), Vankov et al. (2025), Tyurin (2026), Borodich and Kovalev (2026). Нижние оценки для функций с липшицевым градиентом и произвольных методов первого порядка обсуждаются, например, в работе Guzmán and Nemirovski (2015). Сводная таблица известных верхних оценок для выпуклого случая приведена в приложении D.

Сравнение с известными результатами. Известные оценки для выпуклого детерминированного случая, не использующие оценку начальной невязки, содержат либо член $(L_1 R)^2$ или выше, либо множитель, равный логарифму отношения начальной невязки $f(x^0) - f^*$ к ε или к L_0/L_1^2 (таблица 2). На классе, заданном только радиусом, этот множитель может иметь порядок $L_1 R$. Например, при $L_1 R \geq 1$ для прохождения режима больших градиентов, то есть для достижения невязки $L_0/(128 L_1^2)$, известные оценки дают $O((L_1 R)^{5/3})$ итераций с точной одномерной минимизацией для метода AGMsDR (Vankov et al., 2025) и $O((L_1 R)^2)$ итераций для предварительного этапа метода из работы Tyurin (2026). Наш первый этап проходит этот режим за $O\big((1 + L_1 R)\log(2 + L_1 R)\big)$ обращений

к оракулу при неизвестной начальной невязке. После этого ускоренный метод из работы Tyurin (2026, теорема 3.2) даёт оценку $O\bigl(1+\sqrt{L_0R^2/\varepsilon}\bigr)$ без логарифмов, и мы используем его на втором этапе. Нижние оценки в обобщённой постановке ранее были известны лишь для конкретных методов, например для градиентного спуска с постоянным шагом (Zhang et al., 2020b, Crawshaw et al., 2022), вариантов AdaGrad (Crawshaw and Liu, 2025) и методов без знания параметров (Hübler et al., 2023), или переносились из подкласса $L_1 = 0$ (Nesterov, 2018). Насколько нам известно, теоремы 4.10 и B.3 — первые нижние оценки для произвольных детерминированных методов, в которых участвует L_1.

Организация. В разделе 2 заданы класс функций и оракульная сложность. В разделе 3 построен метод, дающий верхнюю оценку. В разделе 4 доказана нижняя оценка, совпадающая с верхней асимптотически с точностью до логарифмических множителей. Раздел 5 перечисляет открытые вопросы. Приложение A содержит общие неравенства для функций класса, описанного выше, и доказательства вспомогательных лемм. В приложения вынесены также класс с ограниченной начальной невязкой (приложение B), фиксированная размерность (приложение C) и сводная таблица известных оценок (приложение D).

Таблица 1. Результаты, полученные в нашей работе. Столбец «Условие» задаёт дополнительное ограничение на начальную невязку в определении класса.

Результат	Условие	Ниж.	Верх.	Сложность $1+N$
Теоремы 3.7, 4.10	нет	✓	✓	$\widetilde{\Theta}\Bigl(1+\sqrt{\dfrac{L_0R^2}{\varepsilon}}+L_1R\Bigr)$
Теоремы B.7(а), B.3	$f(x^0)-f^*\le 4\varepsilon$	✓	✓	$\widetilde{\Theta}\Bigl(1+\sqrt{\dfrac{L_0R^2}{\varepsilon}}+(L_1R)^{2/3}\Bigr)$
Теорема B.7(б)	$f(x^0)-f^*\le\Delta$	✗	✓	$O\Bigl(\log\Bigl(2+\dfrac{L_0R^2}{\varepsilon}+L_1R\Bigr)\times$ $\times\Bigl[1+\sqrt{\dfrac{L_0R^2}{\varepsilon}}+(L_1R)^{2/3}\log^{2/3}\dfrac{2\Delta}{\varepsilon}\Bigr]\Bigr)$

В третьей строке предполагается $\Delta > \varepsilon$. При $\Delta \le \varepsilon$ достаточно вернуть x^0 без обращений к оракулу.

2 Постановка задачи

В этом разделе вводятся класс функций и оракульная сложность.

Определение 2.1 (класс функций)**.**
Пусть $\ell : [0,\infty) \to (0,\infty)$ — непрерывная неубывающая функция. Через $\mathcal{F}_\ell^d$ обозначается класс выпуклых дифференцируемых функций $f : \mathbb{R}^d \to \mathbb{R}$, для которых при всех $x, y \in \mathbb{R}^d$

$$\|\nabla f(x) - \nabla f(y)\| \le \ell\Bigl(\sup_{u\in[x,y]} \|\nabla f(u)\|\Bigr)\|x-y\|. \tag{2.1}$$

Для $\ell(s) = L_0 + L_1 s$ мы пишем $\mathcal{F}^d_{L_0,L_1}$ и называем функции этого класса (L_0, L_1)-*гладкими.*

Неравенство (2.1) — это условие симметричной (L_0, L_1)-гладкости из работы Gorbunov et al. (2025, предположение 1.3), записанное для произвольной функции ℓ. Оно согласуется с определением ℓ-гладкости в работах Li et al. (2023), Tyurin (2025). При $\ell \equiv L$ получается класс выпуклых функций с L-липшицевым градиентом. Класс $\mathcal{F}_\ell^d$ инвариантен

относительно ортогональных преобразований координат, сдвигов аргумента и прибавления константы.

Проверять условие (2.1) непосредственно неудобно. Следующая лемма показывает, что его достаточно проверять вдоль прямых, а для дважды непрерывно дифференцируемых функций оно равносильно привычной оценке гессиана. Её доказательство приведено в приложении A.1.

Лемма 2.2 (характеризация класса)**.** ▼
Пусть функция $f : \mathbb{R}^d \to \mathbb{R}$ выпукла и дифференцируема.

(а) $f \in \mathcal{F}_\ell^d$ тогда и только тогда, когда для любых $x, v \in \mathbb{R}^d$ отображение $t \mapsto \nabla f(x + tv)$ локально абсолютно непрерывно на $\mathbb{R}$ и при почти всех t

$$\Big\| \frac{d}{dt} \nabla f(x + tv) \Big\| \le \ell\big(\|\nabla f(x + tv)\|\big)\|v\|. \tag{2.2}$$

(б) Если $f \in C^2(\mathbb{R}^d)$, то $f \in \mathcal{F}_\ell^d$ тогда и только тогда, когда при всех x

$$0 \preceq \nabla^2 f(x) \preceq \ell\big(\|\nabla f(x)\|\big) I. \tag{2.3}$$

Сдвигом аргумента можно добиться равенства $x^0 = 0$, что мы и предполагаем. Рассматриваются два класса задач.

- ▷ $\mathcal{P}_\mathrm{R}$ — все функции $f \in \mathcal{F}^d_{L_0,L_1}$, $d \ge 1$, имеющие точку минимума x^* с $\|x^*\| \le R$ (*класс, заданный только радиусом*).
- ▷ $\mathcal{P}_\Delta$ — функции из $\mathcal{P}_\mathrm{R}$, для которых дополнительно $f(0) - f^* \le \Delta$ (*класс с ограниченной начальной невязкой*).

Метод *решает* класс за N обращений к оракулу в размерности d, если на выходе $f(\hat{x}) - f^* \le \varepsilon$ для всех функций класса на $\mathbb{R}^d$. *Оракульная сложность* $\mathcal{N}(\mathcal{P})$ класса $\mathcal{P}$ — наименьшее N, при котором для каждой размерности d найдётся метод, решающий все задачи класса в этой размерности не более чем за N обращений. Точная модель детерминированного метода нужна для нижней оценки и приведена в разделе 4. Нас интересует прежде всего сложность $\mathcal{N}(\mathcal{P}_\mathrm{R})$, класс $\mathcal{P}_\Delta$ рассматривается в приложении B.

3 Верхняя оценка

В этом разделе построен метод, на котором достигается верхняя оценка сложности класса $\mathcal{P}_\mathrm{R}$. Метод состоит из двух этапов.

- ▷ *Первый этап* (метод SHERPA) проходит режим больших градиентов. Начиная из точки x^0, он находит точку x', для которой

$$\begin{aligned} f(x') - f^* &\le \frac{L_0}{128 L_1^2}, \\ \|x' - x^*\| &\le R. \end{aligned} \tag{3.1}$$

  Это ускоренный метод, построенный по схеме оценивающих последовательностей Нестерова (Nesterov, 2018, §2.2), с неточным одномерным поиском.
- ▷ *Второй этап* (метод CRUISE) запускается из точки x'. В окрестности такой точки функция класса ведёт себя как функция с $2L_0$-липшицевым градиентом, и работает обычный ускоренный метод с постоянным шагом $1/(2L_0)$, анализ которого мы берём из работы Tyurin (2026).

Подразделы 3.1–3.6 посвящены первому этапу, подраздел 3.7 — второму, в подразделе 3.8 доказана итоговая оценка. Всюду в разделе $f \in \mathcal{F}^d_{L_0,L_1}$, а x^* — точка минимума функции f. Доказательства вспомогательных лемм вынесены в приложение A.

3.1 Лемма о спуске

Первая лемма — аналог классической леммы о спуске (Nesterov, 2018, лемма 1.2.3). Шаг градиентного спуска делается с длиной, вычисленной по локальной константе гладкости $L_0 + L_1\|\nabla f(y)\|$.

Лемма 3.1 (лемма о спуске)**.** ▼
Для любой точки $y \in \mathbb{R}^d$ точка

$$y^+ = y - \frac{\nabla f(y)}{4\big(L_0 + L_1\|\nabla f(y)\|\big)}$$

удовлетворяет неравенствам

$$f(y^+) \le f(y) - \frac{5\|\nabla f(y)\|^2}{24\big(L_0 + L_1\|\nabla f(y)\|\big)},$$
$$\|y^+ - x^*\|^2 \le \|y - x^*\|^2 - \frac{\|\nabla f(y)\|^2}{24\big(L_0 + L_1\|\nabla f(y)\|\big)^2}.$$

Доказательство леммы 3.1 приведено в приложении A.3. Длина такого шага не больше $1/(4L_1)$. На таком расстоянии локальная константа гладкости меняется не более чем в $e^{1/4}$ раз (лемма A.1), поэтому функция ведёт себя как функция с липшицевым градиентом.

3.2 Неравенство в точке минимума

При $G \ge 0$ введём функцию

$$\Phi(G) = \frac{L_0}{L_1^2}\Big[\Big(1 + \frac{L_1 G}{L_0}\Big)\log\Big(1 + \frac{L_1 G}{L_0}\Big) - \frac{L_1 G}{L_0}\Big]. \tag{3.2}$$

Она выпукла, $\Phi(0) = 0$ и

$$\begin{aligned} \Phi'(G) &= \frac{1}{L_1}\log\Big(1 + \frac{L_1 G}{L_0}\Big), \\ \Phi''(G) &= \frac{1}{L_0 + L_1 G}. \end{aligned} \tag{3.3}$$

При малых G функция $\Phi(G)$ ведёт себя как $G^2/(2L_0)$, а при больших — как $(G/L_1)\log(L_1 G/L_0)$.

Обычное неравенство выпуклости в точке минимума утверждает, что касательная к графику функции, проведённая в точке y, проходит в точке x^* не выше значения f^*. В классе $\mathcal{F}^d_{L_0,L_1}$ касательная проходит ниже f^* по крайней мере на $\Phi(\|\nabla f(y)\|)$.

Лемма 3.2 (неравенство в точке минимума)**.** ▼
Для любой точки $y \in \mathbb{R}^d$

$$f(y) + \langle \nabla f(y), x^* - y\rangle + \Phi\big(\|\nabla f(y)\|\big) \le f^*.$$

Доказательство леммы 3.2 приведено в приложении A.4. Для дважды непрерывно дифференцируемых функций это частный случай неравенства из работы Vankov et al. (2025, лемма 2.7). Благодаря слагаемому $\Phi(\|\nabla f(y)\|)$ методу первого этапа не нужна оценка начальной невязки по функции.

3.3 Неточный одномерный поиск

Ускоренному методу на каждой итерации нужна точка y на отрезке $[v, x]$, в которой одновременно $f(y) \le f(x)$ и мала величина $\langle \nabla f(y), y - v\rangle$. Точная одномерная минимизация дала бы $\langle \nabla f(y), y - v\rangle \le 0$, но за конечное число обращений к оракулу она не гарантируется. Достаточно метода деления отрезка пополам с заранее известным числом шагов (алгоритм 1). Мы называем этот метод ICEPICK (Inexact Convex Edge Probing by Interval Cutting with Known Query Bound).

Алгоритм 1 ICEPICK: неточный одномерный поиск

Вход: точки $v, x \in \mathbb{R}^d$, числа $r, \delta > 0$, натуральное число m

Запросить $\nabla f(v)$ и $\nabla f(x)$
если $r\|\nabla f(v)\| \le \delta$ **то** ▷ критерий остановки
  вернуть $y = v$
иначе если $r\|\nabla f(x)\| \le \delta$ **то** ▷ критерий остановки
  вернуть $y = x$
иначе если $\langle \nabla f(v), x - v\rangle \ge 0$ **то**
  вернуть $y = v$
иначе если $\langle \nabla f(x), x - v\rangle \le 0$ **то**
  вернуть $y = x$
конец если
$t_- = 0$, $t_+ = 1$
для $j = 1, \dots, m$ **выполнять**
  $t = (t_- + t_+)/2$, запросить $\nabla f\big(v + t(x - v)\big)$
  если $r\|\nabla f(v + t(x - v))\| \le \delta$ **то** ▷ критерий остановки
    вернуть $y = v + t(x - v)$
  иначе если $\langle \nabla f(v + t(x - v)), x - v\rangle = 0$ **то**
    вернуть $y = v + t(x - v)$
  иначе если $\langle \nabla f(v + t(x - v)), x - v\rangle < 0$ **то**
    $t_- = t$
  иначе
    $t_+ = t$
  конец если
конец для
вернуть $y = v + t_+(x - v)$

Лемма 3.3 (неточный одномерный поиск)**.** ▼
Пусть $r, \delta > 0$, точки v и x лежат в шаре $B(x^*, r)$, а натуральное число m удовлетворяет условию

$$2^m \ge 128\Big(1 + \frac{L_0 r^2}{\delta} + L_1 r\Big)^2. \tag{3.4}$$

Тогда алгоритм 1 делает не более $m + 2$ обращений к оракулу в точках отрезка $[v, x]$ и возвращает точку $y \in [v, x]$, для которой выполнено одно из двух условий.

(a) Сработал критерий остановки. Тогда $f(y) - f^* \le \delta$.

(б) Выполнены неравенства

$$f(y) \le f(x),$$
$$\langle \nabla f(y), y - v\rangle \le \frac{\|\nabla f(y)\|^2}{16\big(L_0 + L_1\|\nabla f(y)\|\big)}. \tag{3.5}$$

Доказательство леммы 3.3 приведено в приложении A.5. Число шагов m логарифмически зависит от $L_0 r^2/\delta$ и $L_1 r$. Именно отсюда возникает логарифмический множитель в верхней оценке. Алгоритм 1 использует только градиенты: значения функции ему не нужны.

3.4 Метод первого этапа

Метод первого этапа SHERPA (Smoothness-aware High-gradient Escape with Radius-Preserving Acceleration, алгоритм 2) устроен как ускоренный метод с оценивающими последовательностями (Nesterov, 2018, §2.2) и близок к методу AGMsDR (Vankov et al., 2025, алгоритм 1). Он поддерживает две последовательности точек: x^k с убывающими значениями функции и v^k, по которой строится оценка функции снизу. Здесь и далее сумма первых k членов последовательности обозначается соответствующей заглавной буквой: $A_k = a_1 + \cdots + a_k$, $A_0 = 0$. Коэффициент $a_k > 0$ определяется уравнением

$$a_k^2 = \frac{A_{k-1} + a_k}{7\big(L_0 + L_1\|\nabla f(y^k)\|\big)} + \frac{a_k\,\Phi\big(\|\nabla f(y^k)\|\big)}{\|\nabla f(y^k)\|^2}. \tag{3.6}$$

Это квадратное уравнение относительно a_k с единственным положительным корнем. Без последнего слагаемого оно совпадает с обычным правилом выбора коэффициентов ускоренного метода, в котором константа Липшица градиента заменена на $7(L_0+L_1\|\nabla f(y^k)\|)$. Последнее слагаемое отвечает добавке Φ из леммы 3.2. Оно увеличивает коэффициент на итерациях с большим градиентом.

Алгоритм 2 SHERPA (первый этап): ускоренный метод с неточным одномерным поиском

Вход: начальная точка x^0, параметры L_0, L_1, R, причём $L_1 R \ge 1$

$m = \left\lceil \log_2\big(128(1 + 128L_1^2R^2 + L_1R)^2\big)\right\rceil$, $K = \lceil 60 L_1 R\rceil$
$v^0 = x^0$, $A_0 = 0$
для $k = 1, \dots, K$ **выполнять**
  y^k — результат алгоритма 1 на отрезке $[v^{k-1}, x^{k-1}]$ с $r = R$, $\delta = L_0/(128L_1^2)$ и m
  если сработал критерий остановки **то**
    вернуть y^k
  конец если
  a_k — положительный корень уравнения (3.6), $A_k = A_{k-1} + a_k$
  $x^k = y^k - \dfrac{\nabla f(y^k)}{4(L_0 + L_1\|\nabla f(y^k)\|)}$
  $v^k = v^{k-1} - a_k \nabla f(y^k)$
конец для
вернуть x^K

Из уравнения (3.6) и неравенства $A_{k-1} \geq 0$ следуют два свойства коэффициентов:

$$\begin{aligned} a_k &\leq A_k, \\ a_k^2 &\geq \frac{A_k}{7\bigl(L_0 + L_1\|\nabla f(y^k)\|\bigr)}. \end{aligned} \tag{3.7}$$

На каждой итерации алгоритм 1 делает не более $m+2$ обращений к оракулу, а точки x^k и v^k вычисляются без обращений. Поэтому K итераций стоят не более $K(m+2)$ обращений. Значения функции методу не нужны.

3.5 Невязка и расстояние до точки минимума

Следующая лемма одновременно ограничивает невязку по функции, сумму квадратов норм градиентов с весами и расстояние от точки v^k до точки минимума.

Лемма 3.4.
Пусть $\|x^0 - x^*\| \leq R$, а итерации $1, \ldots, k$ алгоритма 2 прошли без срабатывания критерия остановки. Тогда

$$A_k\bigl(f(x^k) - f^*\bigr) + \frac{1}{2}\sum_{i=1}^{k} a_i^2 \|\nabla f(y^i)\|^2 + \frac{1}{2}\|v^k - x^*\|^2 \leq \frac{R^2}{2}, \tag{3.8}$$

и все точки x^i, v^i, y^i, $i \leq k$, лежат в шаре $B(x^*, R)$.

Доказательство. Индукция по k. При $k = 0$ неравенство (3.8) совпадает с условием $\|x^0 - x^*\| \leq R$. Пусть утверждение верно для $k-1$.

▷ *Итерация корректна.* По предположению индукции точки v^{k-1} и x^{k-1} лежат в шаре $B(x^*, R)$. Шар выпукл, поэтому отрезок $[v^{k-1}, x^{k-1}]$ и точка y^k лежат в нём, и лемма 3.3 применима. Критерий остановки не сработал, поэтому выполнены неравенства (3.5). Вместе с леммой 3.1 они дают $x^k \in B(x^*, R)$ и

$$\begin{aligned} &f(y^k) \leq f(x^{k-1}), \\ &\langle \nabla f(y^k), y^k - v^{k-1}\rangle \leq \frac{\|\nabla f(y^k)\|^2}{16\bigl(L_0 + L_1\|\nabla f(y^k)\|\bigr)}, \\ &f(x^k) \leq f(y^k) - \frac{5\|\nabla f(y^k)\|^2}{24\bigl(L_0 + L_1\|\nabla f(y^k)\|\bigr)}. \end{aligned} \tag{3.9}$$

▷ *Расстояние.* Так как $v^k = v^{k-1} - a_k \nabla f(y^k)$,

$$\begin{aligned} &\frac{1}{2}\|v^k - x^*\|^2 - \frac{1}{2}\|v^{k-1} - x^*\|^2 \\ &\qquad = a_k\langle \nabla f(y^k), y^k - v^{k-1}\rangle - a_k\langle \nabla f(y^k), y^k - x^*\rangle + \frac{1}{2}a_k^2\|\nabla f(y^k)\|^2. \end{aligned} \tag{3.10}$$

Оценим первые два слагаемых справа:

$$\begin{aligned} a_k\langle \nabla f(y^k), y^k - v^{k-1}\rangle &\underset{(3.9)}{\leq} \frac{a_k\|\nabla f(y^k)\|^2}{16\bigl(L_0 + L_1\|\nabla f(y^k)\|\bigr)}, \\ -a_k\langle \nabla f(y^k), y^k - x^*\rangle &\underset{\text{лемма } 3.2}{\leq} -a_k\bigl(f(y^k) - f^*\bigr) - a_k\Phi\bigl(\|\nabla f(y^k)\|\bigr). \end{aligned}$$

▷ *Невязка.* Так как $A_k = A_{k-1} + a_k$,

$$\begin{aligned} & A_k\big(f(x^k) - f^*\big) - A_{k-1}\big(f(x^{k-1}) - f^*\big) \\ & \quad \underset{(3.9)}{\leq} A_k\big(f(y^k) - f^*\big) - \frac{5A_k\|\nabla f(y^k)\|^2}{24\big(L_0 + L_1\|\nabla f(y^k)\|\big)} - A_{k-1}\big(f(y^k) - f^*\big) \\ & \quad = a_k\big(f(y^k) - f^*\big) - \frac{5A_k\|\nabla f(y^k)\|^2}{24\big(L_0 + L_1\|\nabla f(y^k)\|\big)}. \end{aligned}$$

▷ *Сумма.* Умножив уравнение (3.6) на $\|\nabla f(y^k)\|^2$, получаем

$$a_k\Phi\big(\|\nabla f(y^k)\|\big) = a_k^2\|\nabla f(y^k)\|^2 - \frac{A_k\|\nabla f(y^k)\|^2}{7\big(L_0 + L_1\|\nabla f(y^k)\|\big)}.$$

Сложим (3.10), две оценки его слагаемых и оценку невязки, затем подставим это равенство:

$$\begin{aligned} & \Big[A_k\big(f(x^k) - f^*\big) + \frac{1}{2}\|v^k - x^*\|^2\Big] - \Big[A_{k-1}\big(f(x^{k-1}) - f^*\big) + \frac{1}{2}\|v^{k-1} - x^*\|^2\Big] \\ & \quad \leq \Big(\frac{a_k}{16} - \frac{5A_k}{24}\Big)\frac{\|\nabla f(y^k)\|^2}{L_0 + L_1\|\nabla f(y^k)\|} - a_k\Phi\big(\|\nabla f(y^k)\|\big) + \frac{1}{2}a_k^2\|\nabla f(y^k)\|^2 \\ & \quad = \Big(\frac{a_k}{16} - \frac{5A_k}{24} + \frac{A_k}{7}\Big)\frac{\|\nabla f(y^k)\|^2}{L_0 + L_1\|\nabla f(y^k)\|} - \frac{1}{2}a_k^2\|\nabla f(y^k)\|^2 \\ & \quad \underset{(3.7)}{\leq} -\frac{A_k\|\nabla f(y^k)\|^2}{336\big(L_0 + L_1\|\nabla f(y^k)\|\big)} - \frac{1}{2}a_k^2\|\nabla f(y^k)\|^2 \\ & \quad \leq -\frac{1}{2}a_k^2\|\nabla f(y^k)\|^2. \end{aligned}$$

Прибавив это неравенство к неравенству (3.8) для $k-1$, получаем (3.8) для k. Из него следует $\|v^k - x^*\| \leq R$, что замыкает индукцию. □

3.6 Число итераций первого этапа

Начальная невязка неизвестна и может быть экспоненциально большой по L_1R, поэтому оценка числа итераций через неё бесполезна. Вместо неё работают две суммы, которые ограничивает лемма 3.4: веса A_K и сумма квадратов $a_i^2\|\nabla f(y^i)\|^2$. Итерации с очень большим градиентом увеличивают вторую сумму, поэтому их мало. На остальных итерациях вес A_i не слишком мал, и число таких итераций оценивается так же, как в ускоренном методе для функций с липшицевым градиентом.

Лемма 3.5 (число итераций первого этапа)**.**
Пусть $\|x^0 - x^*\| \leq R$ и $L_1R \geq 1$. Если K итераций алгоритма 2 прошли без срабатывания критерия остановки и

$$f(x^K) - f^* > \frac{L_0}{128L_1^2},$$

то $K < 60L_1R$.

Доказательство.

▷ *Две суммы.* По лемме 3.4 и условию на невязку

$$\begin{aligned} &L_0 A_K < 64 L_1^2 R^2, \\ &\sum_{i=1}^{K} a_i^2 \|\nabla f(y^i)\|^2 \le R^2. \end{aligned} \tag{3.11}$$

▷ *Оценки для одной итерации.* Из неравенств (3.7)

$$\begin{aligned} \sqrt{L_0 A_i} - \sqrt{L_0 A_{i-1}} &= \frac{\sqrt{L_0}\, a_i}{\sqrt{A_i} + \sqrt{A_{i-1}}} \\ &\underset{\text{(a)}}{\ge} \frac{\sqrt{L_0}\, a_i}{2\sqrt{A_i}} \underset{(3.7)}{\ge} \frac{1}{2\sqrt{7}} \sqrt{\frac{L_0}{L_0 + L_1\|\nabla f(y^i)\|}}, \\ L_0 A_i = \frac{L_0 A_i^2}{A_i} &\underset{(3.7)}{\ge} \frac{L_0 a_i^2}{A_i} \underset{(3.7)}{\ge} \frac{L_0}{7\big(L_0 + L_1\|\nabla f(y^i)\|\big)}. \end{aligned} \tag{3.12}$$

Здесь (а) — неравенство $A_{i-1} \le A_i$. Разделим уравнение (3.6) на a_i и умножим на $L_1\|\nabla f(y^i)\|$:

$$L_1 a_i \|\nabla f(y^i)\| = \frac{L_1 \Phi(\|\nabla f(y^i)\|)}{\|\nabla f(y^i)\|} + \frac{A_i}{7a_i} \cdot \frac{L_1\|\nabla f(y^i)\|}{L_0 + L_1\|\nabla f(y^i)\|}. \tag{3.13}$$

Оба слагаемых справа неотрицательны. По определению (3.2)

$$\begin{aligned} \frac{L_1 \Phi(\|\nabla f(y^i)\|)}{\|\nabla f(y^i)\|} &= \Big(1 + \frac{L_0}{L_1\|\nabla f(y^i)\|}\Big) \log\Big(1 + \frac{L_1\|\nabla f(y^i)\|}{L_0}\Big) - 1 \\ &\ge \log\Big(1 + \frac{L_1\|\nabla f(y^i)\|}{L_0}\Big) - 1. \end{aligned} \tag{3.14}$$

Умножив (3.13) на $7a_i/A_i$ и сложив с первым неравенством (3.12), получаем

$$\begin{aligned} &2\sqrt{7}\Big(\sqrt{L_0 A_i} - \sqrt{L_0 A_{i-1}}\Big) + \Big(\frac{7L_1 a_i^2 \|\nabla f(y^i)\|}{A_i}\Big)^{2/3} \\ &\quad \ge \Big(\frac{L_0}{L_0 + L_1\|\nabla f(y^i)\|}\Big)^{1/2} + \Big(\frac{L_1\|\nabla f(y^i)\|}{L_0 + L_1\|\nabla f(y^i)\|}\Big)^{2/3} \\ &\quad \underset{\text{(б)}}{\ge} \frac{L_0}{L_0 + L_1\|\nabla f(y^i)\|} + \frac{L_1\|\nabla f(y^i)\|}{L_0 + L_1\|\nabla f(y^i)\|} = 1. \end{aligned} \tag{3.15}$$

Здесь (б) — неравенства $t^{1/2} \ge t$ и $t^{2/3} \ge t$ при $0 \le t \le 1$.

▷ *Итерации с большим произведением* $L_1 a_i \|\nabla f(y^i)\|$. Пусть J — множество номеров $i \le K$, для которых $L_1 a_i \|\nabla f(y^i)\| \ge \sqrt{L_1 R}$. По второму неравенству (3.11)

$$|J|\, L_1 R \le \sum_{i \in J} L_1^2 a_i^2 \|\nabla f(y^i)\|^2 \le L_1^2 R^2,$$

то есть $|J| \le L_1 R$.

▷ *Остальные итерации.* Пусть I — множество остальных номеров. Если оно пусто, то $K = |J| \le L_1 R$. Иначе для $i \in I$ по (3.13) и (3.14)

$$\log\Big(1 + \frac{L_1\|\nabla f(y^i)\|}{L_0}\Big) - 1 \le L_1 a_i \|\nabla f(y^i)\| < \sqrt{L_1 R},$$

и второе неравенство (3.12) даёт

$$L_0 A_i \geq \frac{1}{7}\Bigl(1 + \frac{L_1\|\nabla f(y^i)\|}{L_0}\Bigr)^{-1} > \frac{1}{7}e^{-\sqrt{L_1 R}-1}.$$

Пусть j — наименьший номер из I. Веса A_i возрастают, поэтому при $i > j$ имеем $A_{i-1} > 0$ и

$$\frac{a_i}{A_i} \leq -\log\Bigl(1 - \frac{a_i}{A_i}\Bigr) = \log\frac{A_i}{A_{i-1}}.$$

Вместе с неравенством $a_j \leq A_j$ это даёт

$$\begin{aligned}\sum_{i\in I}\frac{a_i}{A_i} &\leq 1 + \log\frac{A_K}{A_j} \underset{(3.11)}{<} 1 + \log\bigl(448 L_1^2 R^2 e^{\sqrt{L_1 R}+1}\bigr)\\ &= \sqrt{L_1 R} + 2 + \log 448 + 2\log(L_1 R)\\ &\underset{(\text{в})}{<} 5\sqrt{L_1 R} + \frac{9}{2} \underset{L_1 R \geq 1}{\leq} \frac{19}{2}\sqrt{L_1 R}.\end{aligned}$$

Здесь (в) — неравенства $\log 448 < 13/2$ и $\log t \leq 2\sqrt{t} - 2$ при $t \geq 1$. Сложим неравенства (3.15) по $i \in I$. Первые слагаемые в сумме не больше $2\sqrt{7}\sqrt{L_0 A_K} < 16\sqrt{7} L_1 R$. Ко вторым применим неравенство Гёльдера с показателями 3 и 3/2:

$$\begin{aligned}|I| &< 16\sqrt{7} L_1 R + 7^{2/3}\sum_{i\in I}\bigl(L_1 a_i \|\nabla f(y^i)\|\bigr)^{2/3}\Bigl(\frac{a_i}{A_i}\Bigr)^{2/3}\\ &\leq 16\sqrt{7} L_1 R + 7^{2/3}\Bigl(\sum_{i\in I} L_1^2 a_i^2 \|\nabla f(y^i)\|^2\Bigr)^{1/3}\Bigl(\sum_{i\in I}\frac{a_i}{A_i}\Bigr)^{2/3}\\ &\underset{(3.11)}{<} 16\sqrt{7} L_1 R + 7^{2/3}(L_1 R)^{2/3}\Bigl(\frac{19}{2}\sqrt{L_1 R}\Bigr)^{2/3}\\ &= \Bigl(16\sqrt{7} + \Bigl(\frac{133}{2}\Bigr)^{2/3}\Bigr) L_1 R\\ &\underset{(\text{г})}{<} 59 L_1 R.\end{aligned}$$

Здесь (г) — неравенства $16\sqrt{7} < 42{,}4$ и $(133/2)^{2/3} < 16{,}5$, равносильные $1792 < 42{,}4^2$ и $133^2 < 4 \cdot 16{,}5^3$.

▷ *Итог.* Каждая итерация попадает ровно в одно из множеств J и I, поэтому

$$K = |J| + |I| < L_1 R + 59 L_1 R = 60 L_1 R. \qquad \square$$

3.7 Второй этап

На втором этапе работает ускоренный градиентный метод с постоянным шагом $1/(2L_0)$ (Tyurin, 2026, алгоритм 1) (алгоритм 3). По структуре он близок к методу подобных треугольников (Gasnikov and Nesterov, 2018). Используемый вариант мы называем CRUISE (Constant-step Refinement Using Inertia in Smooth Environments). Это название варианта ускоренного метода из работы Tyurin (2026) с начальной точкой, найденной на первом этапе, а не новый метод, разработанный авторами настоящей статьи. На каждой итерации вычисляется один новый градиент.

Алгоритм 3 CRUISE (второй этап): ускоренный метод с постоянным шагом из работы Tyurin (2026)

Вход: начальная точка x', параметры L_0, L_1, R, число итераций N

$y^0 = w^0 = x'$, $\Gamma_0 = L_0/(64L_1^2R^2)$

для $k = 0, \dots, N-1$ **выполнять**

  $\lambda_k = \sqrt{\Gamma_k/(2L_0)}$

  $y^{k+1} = \dfrac{1}{1+\lambda_k}\Big(y^k + \lambda_k w^k - \dfrac{\nabla f(y^k)}{2L_0}\Big)$

  $w^{k+1} = w^k - \dfrac{\lambda_k}{\Gamma_k}\nabla f(y^{k+1})$

  $\Gamma_{k+1} = \Gamma_k/(1+\lambda_k)$

конец для

вернуть y^N

Предложение 3.6 (второй этап)**.**
Пусть $L_1R \geq 1$, а точка x' удовлетворяет условиям

$$f(x') - f^* \leq \frac{L_0}{128L_1^2},$$
$$\|x' - x^*\| \leq R.$$

Тогда точки алгоритма 3 при всех $k \geq 1$ удовлетворяют неравенству

$$f(y^k) - f^* \leq \frac{18L_0R^2}{k^2}.$$

В частности, при

$$N = \left\lceil \sqrt{\frac{18L_0R^2}{\varepsilon}} \right\rceil \tag{3.16}$$

алгоритм находит точку с невязкой по функции не больше ε, сделав не более

$$5\sqrt{\frac{L_0R^2}{\varepsilon}} + 2$$

обращений к оракулу.

Доказательство. Это теорема 3.2 из работы Tyurin (2026) для $\ell(s) = L_0 + L_1 s$ с параметром точности, равным удвоенной правой части первого неравенства (3.1). Проверим её условия.

▷ Автор работы Tyurin (2026) формулирует результат для дважды дифференцируемых функций, но отмечает (там же, после леммы 2.2), что вместо оценки гессиана достаточно неравенства

$$\|\nabla f(z) - \nabla f(y)\| \leq \big(L_0 + L_1\|\nabla f(y)\|\big)\frac{e^{L_1\|z-y\|} - 1}{L_1}.$$

Для нашего класса это лемма A.1(б).

▷ Функция из условия теоремы 3.2 строго возрастает на $[0, \infty)$, поскольку при $t > 0$

$$\frac{d}{dt}\,\frac{t^2}{2(L_0 + 4L_1t)} = \frac{t(L_0 + 2L_1t)}{(L_0 + 4L_1t)^2} > 0.$$

▷ Условие теоремы 3.2 на параметр точности выполнено с равенством:

$$\ell\Big(8\sqrt{\ell(0)\,\frac{L_0}{64L_1^2}}\Big) = L_0 + 8L_1\sqrt{\frac{L_0^2}{64L_1^2}} = 2L_0 = 2\ell(0).$$

▷ В теореме 3.2 начальная точка ускоренного метода получена градиентным спуском, но в доказательстве (там же, приложение E.1, формула (32)) используются только два её свойства (3.1). Для точки x' они выполнены по условию.

▷ Число предварительных итераций в теореме 3.2 равно нулю:

$$\frac{\Gamma_0}{8L_0} = \frac{1}{512L_1^2R^2} \le \frac{4}{9},$$

поэтому

$$\max\Big\{1 + \frac{1}{2}\log_{3/2}\frac{\Gamma_0}{8L_0},\ 0\Big\} = 0.$$

Теорема 3.2 даёт оценку из формулировки предложения. При N из (3.16) её правая часть для $k = N$ не больше ε. Алгоритм вычисляет градиенты в точках $y^0, \dots, y^N$, поэтому число $N+1$ его обращений к оракулу удовлетворяет неравенству

$$N + 1 \le \sqrt{\frac{18L_0R^2}{\varepsilon}} + 2 \le 5\sqrt{\frac{L_0R^2}{\varepsilon}} + 2.$$

□

3.8 Итоговая оценка

Теорема 3.7 (верхняя оценка для класса, заданного только радиусом)**.**
Для любых $L_0, L_1, R, \varepsilon > 0$

$$\mathcal{N}(\mathcal{P}_{\mathrm{R}}) \le 5\sqrt{\frac{L_0R^2}{\varepsilon}} + 240\,(1 + L_1R)\log_2\big(64(1 + L_1R)\big) + 2.$$

Метод, на котором достигается эта оценка, использует только градиенты и числа L_0, L_1, R, ε. Значение f^*, оценка начальной невязки и значения функции ему не нужны.

Доказательство.

▷ *Сведение к случаю* $L_1R \ge 1$. Если $L_1R < 1$, то класс $\mathcal{F}^d_{L_0,L_1}$ содержится в классе $\mathcal{F}^d_{L_0,1/R}$. Тогда во всех параметрах обоих этапов заменим L_1 на $1/R$. После замены $K = 60$ и $m = 22$, поэтому первый этап делает не больше $60 \cdot 24 = 240\log_2 64$ обращений к оракулу, что не превосходит $240(1 + L_1R)\log_2\big(64(1 + L_1R)\big)$. Далее $L_1R \ge 1$.

▷ *Первый этап.* Запустим алгоритм 2. Число m в нём удовлетворяет условию (3.4) с $r = R$ и $\delta = L_0/(128L_1^2)$. Пусть x' — возвращённая точка. Докажем, что для неё выполнены неравенства (3.1). Если на итерации k сработал критерий остановки, то первое из них даёт лемма 3.3. Кроме того, x' лежит на отрезке $[v^{k-1}, x^{k-1}]$, концы которого по лемме 3.4 лежат в шаре $B(x^*, R)$. Иначе выполнены все $K \ge 60L_1R$ итераций, и первое неравенство даёт лемма 3.5, а второе — лемма 3.4.

▷ *Число обращений на первом этапе.* Оно не больше $K(m+2)$. При $L_1R \ge 1$

$$K \le 60L_1R + 1 \le 60(1 + L_1R),$$
$$m + 2 \underset{\text{(a)}}{\le} \log_2\big(2^{21}L_1^2R^2(1 + L_1R)^2\big) + 3 \le 4\log_2\big(64(1 + L_1R)\big).$$

Здесь (а) — неравенство $1 + 128L_1^2R^2 + L_1R \le 128L_1R(1 + L_1R)$. Значит, первый этап делает не больше $240(1 + L_1R)\log_2\bigl(64(1 + L_1R)\bigr)$ обращений к оракулу.

▷ *Второй этап.* Если ε не меньше правой части первого неравенства (3.1), возвращаем x'. Иначе запускаем из x' алгоритм 3 с числом итераций (3.16). По предложению 3.6 он находит точку с невязкой по функции не больше ε, и число его обращений к оракулу ограничено оценкой из этого предложения.

Складывая число обращений на двух этапах, получаем утверждение теоремы. Оба алгоритма используют только градиенты. □

Итак,

$$\mathcal{N}(\mathcal{P}_{\mathrm{R}}) = O\Bigl(\sqrt{\frac{L_0R^2}{\varepsilon}} + (1 + L_1R)\log(2 + L_1R)\Bigr).$$

Классическое слагаемое входит без логарифма и с константой 5, а логарифмический множитель стоит только при L_1R и возникает из одномерного поиска. В разделе 4 показано, что с точностью до логарифмических множителей эта оценка неулучшаема.

4 Нижняя оценка

Модель оракула. Мы пользуемся стандартной моделью чёрного ящика с оракулом первого порядка (Nemirovsky and Yudin, 1983), (Nesterov, 2018, §1.1.2). На запрос $z \in \mathbb{R}^d$ оракул возвращает пару $(f(z), \nabla f(z))$, другой информации о функции у метода нет. *Детерминированный метод*, делающий N обращений к оракулу в размерности d, задаётся двумя правилами: k-я точка запроса есть произвольная функция предыдущих точек запроса и ответов оракула в них, а выход $\hat{x}$ — произвольная функция всех точек запроса и ответов. Метод знает L_0, L_1, R, ε (и оценку начальной невязки Δ, если она задана), но не знает f^* и x^*. Значения функции в ответе оракула только расширяют возможности метода, поэтому нижние оценки этого раздела тем более верны для методов, получающих лишь градиенты.

Нижняя оценка означает, что для каждого детерминированного метода с меньшим числом обращений к оракулу найдётся функция класса, на выходе которой невязка по функции больше ε. Мы пользуемся классической схемой Nemirovsky and Yudin (1983) в форме, изложенной в работе Carmon et al. (2020). Схема состоит из двух шагов.

▷ *Цепочка.* Строится выпуклая функция на $\mathbb{R}^n$, у которой каждое обращение к оракулу открывает не больше одной новой координаты. Крыловский метод после $n-1$ обращений не выходит из подпространства, где последняя координата равна нулю, а там невязка больше ε.

▷ *Принцип ортогональной инвариантности.* Класс не меняется при ортогональных преобразованиях. Поэтому, поворачивая цепочку в пространстве размерности $2n$, оценку для крыловских методов можно перенести на произвольные детерминированные методы.

Оба шага — общий инструмент, он описан в подразделе 4.1. Там же построены цепочки, сопряжённые к сильно выпуклым функциям на многограннике. Конкретные цепочки различаются наклонами звеньев. В подразделе 4.2 наклоны убывают в геометрической прогрессии, и цепочка содержит почти L_1R звеньев. В приложении B наклоны равны, звеньев порядка $(L_1R)^{2/3}$, зато начальная невязка мала. Классическое слагаемое, не зависящее от L_1, даёт нижняя оценка для функций с L_0-липшицевым градиентом (Nesterov, 2018, теорема 2.1.7), мы её не передоказываем. Основной результат раздела, теорема 4.10, доказан в подразделе 4.3.

4.1 Цепочки и принцип ортогональной инвариантности

Пусть $e_1, \dots, e_n$ — стандартный базис $\mathbb{R}^n$. Положим $\mathcal{K}_0 = \{0\}$ и при $j = 1, \dots, n$

$$\mathcal{K}_j = \operatorname{span}\{e_1, \dots, e_j\}.$$

Определение 4.1 (цепочка)**.**
Дифференцируемая функция $\varphi : \mathbb{R}^n \to \mathbb{R}$ называется *цепочкой*, если при каждом $j = 1, \dots, n$

$$y \in \mathcal{K}_{j-1} \implies \nabla\varphi(y) \in \mathcal{K}_j. \tag{4.1}$$

Это нуль-цепочки первого порядка в терминологии работы Carmon et al. (2020), а $\mathcal{K}_j$ играют роль крыловских подпространств. Метод назовём *крыловским*, если каждая точка запроса и выход лежат в линейной оболочке уже полученных градиентов, то есть если выполнено предположение о линейной оболочке (Nesterov, 2018, предположение 2.1.4). Это расширенное употребление термина: обычно крыловские подпространства порождаются фиксированной матрицей. Такой метод после $n-1$ обращений к цепочке не выходит из $\mathcal{K}_{n-1}$.

Цепочки на многограннике. Квадратичная цепочка не использует L_1. Чтобы получить слагаемое с $L_1 R$, нужна цепочка, кривизна которой растёт вместе с нормой градиента. Мы строим её как функцию, сопряжённую к сильно выпуклой функции H на многограннике: чем меньше модуль сильной выпуклости H, тем больше кривизна сопряжённой функции. При постоянном модуле градиент сопряжённой функции липшицев с константой, обратной модулю (Nesterov, 2018, теорема 6.1.1). Следующая лемма разрешает модулю зависеть от точки.

Лемма 4.2 (гладкость сопряжённой функции)**.**
Пусть $K \subset \mathbb{R}^n$ — непустой выпуклый компакт, функция H непрерывна на K, и для любых $z, z' \in K$ её сужение на отрезок $[z, z']$ сильно выпукло с модулем

$$\frac{1}{L_0 + L_1 \max\{\|z\|, \|z'\|\}}.$$

Тогда при любом $\sigma \in \mathbb{R}^n$ функция

$$\varphi(y) = \max_{z \in K} \bigl\{ \langle y + \sigma, z \rangle - H(z) \bigr\}$$

выпукла и дифференцируема, её градиент $\nabla\varphi(y)$ — единственная точка максимума $z(y)$, и при всех y, y'

$$\|\nabla\varphi(y) - \nabla\varphi(y')\| \le \Bigl(L_0 + L_1 \max\bigl\{ \|\nabla\varphi(y)\|, \|\nabla\varphi(y')\| \bigr\} \Bigr) \|y - y'\|. \tag{4.2}$$

В частности, $\varphi \in \mathcal{F}^n_{L_0, L_1}$.

Модуль убывает с ростом норм концов отрезка. Именно поэтому кривизна φ может расти вместе с нормой градиента. Сам градиент лежит в K.

Доказательство.

▷ *Градиент.* Обозначим $\Psi_y(z) = \langle y + \sigma, z \rangle - H(z)$. Функция H строго выпукла на каждом отрезке, поэтому Ψ_y имеет на K единственную точку максимума $z(y)$. По теореме Данскина функция φ выпукла, дифференцируема и $\nabla\varphi(y) = z(y)$.

▷ *Рост вокруг точки максимума.* Пусть $z = z(y)$, $z' \in K$, $z_t = z + t(z' - z)$, а m — модуль из условия для отрезка $[z, z']$. По условию функция $\Psi_y(z_t)$ остаётся вогнутой по t после прибавления квадратичного слагаемого с модулем m, поэтому

$$\begin{aligned}\Psi_y(z) &\underset{z=z(y)}{\geq} \Psi_y(z_t) \\ &\underset{\text{(a)}}{\geq} (1-t)\Psi_y(z) + t\Psi_y(z') + \frac{m}{2}t(1-t)\|z' - z\|^2,\end{aligned}$$

где (a) — сильная вогнутость Ψ_y на отрезке $[z, z']$ с модулем m. Вычитая $(1-t)\Psi_y(z)$, деля на t и устремляя t к нулю, получаем

$$\Psi_y(z(y)) - \Psi_y(z') \geq \frac{m}{2}\|z' - z(y)\|^2. \tag{4.3}$$

▷ *Липшицевость градиента.* Пусть $z = z(y)$, $z' = z(y')$, а m — модуль для отрезка $[z, z']$. Сложим (4.3) для пары (y, z') с тем же неравенством для пары (y', z). Значения H сокращаются, и

$$\begin{aligned}m\|z - z'\|^2 &\leq \langle y - y', z - z'\rangle \\ &\underset{\text{КБШ}}{\leq} \|y - y'\|\,\|z - z'\|.\end{aligned}$$

При $z = z'$ неравенство (4.2) очевидно, иначе деление на $m\|z - z'\|$ даёт (4.2). Максимум нормы градиента по концам отрезка не больше его супремума по отрезку, поэтому $\varphi \in \mathcal{F}^n_{L_0,L_1}$. □

Принцип ортогональной инвариантности. Ограничение на метод снимается поворотом цепочки: класс не меняется при ортогональных преобразованиях.

Предложение 4.3 (принцип ортогональной инвариантности)**.**

(а) Пусть $\varphi : \mathbb{R}^n \to \mathbb{R}$ — выпуклая цепочка, $d \geq 2n$, и каждой матрице V размера $d \times n$ с ортонормированными столбцами $v_1, \ldots, v_n$ сопоставлена функция

$$F_V(x) = \varphi(V^\top x).$$

Пусть каждая функция F_V достигает минимума и при некотором $\mathrm{gap} > 0$

$$\langle v_n, x\rangle = 0 \implies F_V(x) - \min F_V \geq \mathrm{gap}. \tag{4.4}$$

Тогда для любого детерминированного метода с $n-1$ обращениями к оракулу в $\mathbb{R}^d$ найдётся V, для которого $F_V(\hat{x}) - \min F_V \geq \mathrm{gap}$.

(б) Пусть цепочка $\varphi \in \mathcal{F}^n_{L_0,L_1}$ имеет точку минимума нормы не больше R и при $y_n = 0$

$$\varphi(y) - \min\varphi \geq \mathrm{gap} > \varepsilon.$$

Тогда $\mathcal{N}(\mathcal{P}_{\mathrm{R}}) \geq n$. Если, кроме того, $\varphi(0) - \min\varphi \leq \Delta$, то $\mathcal{N}(\mathcal{P}_\Delta) \geq n$.

Пункт (а) — принцип ортогональной инвариантности, то есть сведение, основанное на инвариантности класса относительно ортогональных преобразований, в форме рассуждения с поворотами из работы Carmon et al. (2020, §3.3). Векторы v_k выбираются по ходу работы метода ортогонально уже сделанным запросам, поэтому ответы оракула,

включая значения функции, не зависят от ещё не выбранных векторов. Квадратичная цепочка для методов, точки которых лежат в линейной оболочке градиентов, разобрана, например, в Гасников (2021, упражнение 1.3). Переход к произвольным детерминированным методам восходит к Nemirovsky and Yudin (1983). Пункт (б) следует из (а) при $d = 2n$.

4.2 Цепочка с геометрически убывающими наклонами

Звенья этой цепочки — аффинные функции координат с наклонами G_i, убывающими в геометрической прогрессии. Благодаря этому сдвиги звеньев почти одинаковы, и в шар радиуса R помещается почти $L_1 R$ звеньев: теряется лишь множитель $\sqrt{\log(L_1 R)}$. Новыми здесь являются выбор функции H, модуль сильной выпуклости которой убывает ровно так, как требует условие (L_0, L_1)-гладкости, и выбор наклонов и сдвигов.

Наклоны и сдвиги. Зафиксируем $n \geq 1$ и при $i = 1, \dots, n$ положим

$$\begin{aligned} G_i &= \varepsilon L_1 \exp\Bigl((n-i)\sqrt{\frac{\log(4n)}{n}}\Bigr), \\ \sigma_i &= \frac{2}{L_1}\log\Bigl(1 + \frac{L_1 G_1}{L_0}\Bigr) + \frac{2}{L_1} + \frac{4\log(1+\sqrt{n})}{L_1 G_i}\sum_{k=i}^{n} G_k. \end{aligned} \tag{4.5}$$

Наклоны убывают от G_1 до $G_n = \varepsilon L_1$. Из определения сдвигов при $j < l$

$$\begin{aligned} G_j\sigma_j - G_l\sigma_l &= (G_j - G_l)\Bigl[\frac{2}{L_1}\log\Bigl(1 + \frac{L_1 G_1}{L_0}\Bigr) + \frac{2}{L_1}\Bigr] + \frac{4\log(1+\sqrt{n})}{L_1}\sum_{k=j}^{l-1} G_k \\ &\geq (G_j - G_l)\,\frac{2}{L_1}\log\Bigl(1 + \frac{L_1 G_1}{L_0}\Bigr) + \frac{4\log(1+\sqrt{n})}{L_1}\,G_j. \end{aligned} \tag{4.6}$$

Функция на многограннике. Определим многогранник

$$K = \Bigl\{ z \in \mathbb{R}^n : \; z \geq 0, \; \sum_{i=1}^{n} \frac{z_i}{G_i} \leq 1 \Bigr\}$$

и при $p \geq 0$ функцию

$$r(p) = \frac{4}{L_1}\Bigl[\Bigl(p + \frac{1}{\sqrt{n}}\Bigr)\log\bigl(1 + \sqrt{n}\,p\bigr) - p\Bigr].$$

Её производные равны

$$\begin{aligned} r'(p) &= \frac{4}{L_1}\log\bigl(1 + \sqrt{n}\,p\bigr), \\ r''(p) &= \frac{4\sqrt{n}}{L_1\bigl(1 + \sqrt{n}\,p\bigr)}, \end{aligned} \tag{4.7}$$

так что $r(0) = r'(0) = 0$. Для точки $z \in K$ обозначим $Z_n = z_1 + \dots + z_n$ и положим

$$H(z) = \begin{cases} 2\Phi(Z_n) + Z_n \displaystyle\sum_{i=1}^{n} r\Bigl(\frac{z_i}{Z_n}\Bigr), & Z_n > 0, \\ 0, & z = 0, \end{cases}$$

где Φ — функция (3.2) из раздела 3. Наконец, положим

$$\varphi(y) = \max_{z \in K}\bigl\{\langle y + \sigma, z\rangle - H(z)\bigr\}. \tag{4.8}$$

В вершине $G_i e_i$ многогранника выражение под максимумом равно $G_i(y_i+\sigma_i)-H(G_i e_i)$, то есть i-е звено — аффинная функция с наклоном G_i.

Первое слагаемое H зависит только от суммы координат z и отвечает за рост кривизны вместе с нормой градиента. Второе слагаемое отвечает за распределение этой суммы по координатам. Производная r в нуле конечна, поэтому далёкие звенья не включаются вовсе.

Лемма 4.4 (принадлежность классу)**.**
Функция H удовлетворяет условию леммы 4.2. Следовательно, $\varphi \in \mathcal{F}^n_{L_0,L_1}$ и её градиент удовлетворяет неравенству (4.2).

Доказательство.

▷ *Непрерывность.* Функция r выпукла и $r(0)=0$, поэтому на $[0,1]$

$$0 \le r(p) \le p\, r'(p) \le p\, r'(1).$$

Значит, второе слагаемое H не больше $Z_n r'(1)$ и стремится к нулю вместе с Z_n. В остальных точках K непрерывность очевидна.

▷ *Вторая производная вдоль отрезка.* Пусть $z, z' \in K$ различны, $u = z'-z$ и $w = z+tu$, $t \in [0,1]$. Обозначим $W_n = w_1 + \dots + w_n$ и $U_n = u_1 + \dots + u_n$, так что W_n зависит от t и его производная по t равна U_n. Положим

$$p = \frac{w}{W_n}.$$

Координаты, равные нулю в обеих точках, равны нулю на всём отрезке, остальные положительны при $0 < t < 1$. Поэтому на $(0,1)$ функция $t \mapsto H(w)$ дважды непрерывно дифференцируема. Второе слагаемое H — перспектива функции $r(p_1) + \dots + r(p_n)$. Вдоль отрезка

$$\frac{dp}{dt} = \frac{u - pU_n}{W_n},$$
$$\Phi''(W_n) \underset{(3.3)}{=} \frac{1}{L_0 + L_1 W_n},$$

и дифференцирование даёт

$$\frac{d^2}{dt^2} H(w) = \frac{2U_n^2}{L_0 + L_1 W_n} + \sum_{i=1}^{n} \frac{r''(p_i)}{W_n} (u_i - p_i U_n)^2. \tag{4.9}$$

Вектор p лежит в симплексе, поэтому каждая его координата не больше его нормы и

$$\frac{1}{\sqrt{n}} \le \|p\| \le 1. \tag{4.10}$$

Кроме того, $\|w\| = W_n \|p\|$. Оценим коэффициенты в (4.9):

$$\frac{r''(p_i)}{W_n} \underset{(4.7)}{=} \frac{4\sqrt{n}}{L_1 W_n \left(1 + \sqrt{n}\, p_i\right)} \underset{(4.10)}{\ge} \frac{2}{L_1 W_n \|p\|}$$
$$= \frac{2}{L_1 \|w\|} \ge \frac{2}{L_0 + L_1 \|w\|},$$
$$\frac{2}{L_0 + L_1 W_n} \underset{\|p\| \le 1}{\ge} \frac{2\|p\|^2}{L_0 + L_1 W_n \|p\|} = \frac{2\|p\|^2}{L_0 + L_1 \|w\|}.$$

Подставляя их в (4.9), получаем

$$\frac{d^2}{dt^2}H(w) \geq \frac{2}{L_0 + L_1\|w\|}\Big(\|p\|^2 U_n^2 + \|u - pU_n\|^2\Big)$$
$$\underset{\text{(а)}}{\geq} \frac{\|u\|^2}{L_0 + L_1\|w\|} \underset{\text{(б)}}{\geq} \frac{\|u\|^2}{L_0 + L_1 \max\{\|z\|, \|z'\|\}}.$$

Здесь (а) — неравенство $\|u\|^2 \leq 2\|pU_n\|^2 + 2\|u - pU_n\|^2$, (б) — выпуклость нормы.

▷ *Вывод.* Сужение H на отрезок минус квадратичное слагаемое из леммы 4.2 имеет на $(0, 1)$ неотрицательную вторую производную и непрерывно на $[0, 1]$. Значит, оно выпукло, и лемма 4.2 применима. □

Вторая производная слагаемого $2\Phi(Z_n)$ даёт множитель $L_0 + L_1\|z\|$ в модуле сильной выпуклости и, следовательно, рост кривизны φ вместе с нормой градиента. Множитель $\sqrt{n}$ в функции r согласует второе слагаемое с первым и определяет величину

$$r'(1) = \frac{4}{L_1}\log\big(1 + \sqrt{n}\big),$$

от которой зависит длина цепочки.

Лемма 4.5 (цепочка)**.**
Функция φ — цепочка: если $y \in \mathcal{K}_{j-1}$, то $\nabla\varphi(y) \in \mathcal{K}_j$.

Доказательство. Пусть $y \in \mathcal{K}_{j-1}$, то есть $y_i = 0$ при $i \geq j$, и $z = \nabla\varphi(y)$. Нужно доказать, что $z_l = 0$ при $l > j$. Если $z = 0$, доказывать нечего. Иначе $Z_n > 0$. Пусть p — вектор z, делённый на Z_n.

▷ *Условия оптимальности.* В окрестности z функция H дифференцируема и $\partial_i H(z) = \nu + r'(p_i)$, где

$$\nu = 2\Phi'(Z_n) + \sum_{k=1}^{n}\big[r(p_k) - p_k r'(p_k)\big].$$

Точка z максимизирует вогнутую функцию на многограннике K. По теореме Каруша–Куна–Таккера найдётся множитель $\lambda \geq 0$ линейного ограничения, задающего K, для которого

$$y_i + \sigma_i - \frac{\lambda}{G_i}\begin{cases} = \nu + r'(p_i), & z_i > 0, \\ \leq \nu, & z_i = 0. \end{cases} \tag{4.11}$$

▷ *Оценка сверху для ν.* Так как $r(p) \leq p\,r'(p)$, имеем $\nu \leq 2\Phi'(Z_n)$. Далее, $Z_n \leq G_1$, поскольку $z \in K$ и все наклоны не больше G_1. Функция Φ' возрастает, поэтому

$$\nu \leq 2\Phi'(G_1) \underset{(3.3)}{=} \frac{2}{L_1}\log\Big(1 + \frac{L_1 G_1}{L_0}\Big). \tag{4.12}$$

▷ *Оценка снизу для ν.* Так как $0 \leq r'(p_j) \leq r'(1)$ и $y_j = 0$, из (4.11) в обоих случаях

$$-\lambda \leq G_j\nu - G_j\sigma_j + G_j r'(1). \tag{4.13}$$

▷ *Координата l равна нулю.* Так как $y_l = 0$ и $G_j \ge G_l$,

$$G_l\Big(\sigma_l - \frac{\lambda}{G_l} - \nu\Big) \underset{(4.13)}{\le} G_l\sigma_l - G_j\sigma_j + G_j r'(1) + (G_j - G_l)\nu$$
$$\underset{(4.12)}{\le} G_l\sigma_l - G_j\sigma_j + G_j r'(1) + (G_j - G_l)\,\frac{2}{L_1}\log\Big(1 + \frac{L_1 G_1}{L_0}\Big)$$
$$\underset{(4.6)}{\le} 0.$$

Если бы $z_l > 0$, то по (4.11) левая часть равнялась бы $G_l r'(p_l) > 0$. Значит, $z_l = 0$. □

Лемма 4.6.

(а) $\min\varphi = 0$, и минимум достигается в точке $-\sigma$.
(б) Если $y_n = 0$, то $\varphi(y) \ge 2\varepsilon$.

Доказательство.

▷ *Утверждение (а).* Точка $z = 0$ допустима, поэтому $\varphi \ge -H(0) = 0$. С другой стороны, $H \ge 0$, и $\varphi(-\sigma) = \max_K\{-H\} = 0$.

▷ *Утверждение (б).* Подставим в (4.8) вершину $G_n e_n$. Функция Φ выпукла, $\Phi(0) = 0$ и Φ' возрастает, поэтому $\Phi(G_n) \le G_n\Phi'(G_n) \le G_n\Phi'(G_1)$. Кроме того, $r(1) \le r'(1)$. Значит,

$$\varphi(y) \ge G_n\sigma_n - 2\Phi(G_n) - G_n r(1)$$
$$\ge G_n\sigma_n - \frac{2G_n}{L_1}\log\Big(1 + \frac{L_1 G_1}{L_0}\Big) - G_n\,\frac{4}{L_1}\log\big(1 + \sqrt{n}\big) \underset{(4.5)}{=} \frac{2G_n}{L_1} = 2\varepsilon. \qquad \square$$

Лемма 4.7 (расстояние до точки минимума)**.**

$$L_1\|\sigma\| \le 2\sqrt{n}\,\log\Big(1 + \frac{L_1^2\varepsilon}{L_0}\Big) + 9\,n\sqrt{\log(4n)}.$$

Доказательство. Оценим три величины, из которых складываются сдвиги σ_i:

$$2\log\Big(1 + \frac{L_1 G_1}{L_0}\Big) \underset{(a)}{\le} 2\log\Big(1 + \frac{L_1^2\varepsilon}{L_0}\Big) + 2\sqrt{n\log(4n)},$$
$$4\log\big(1 + \sqrt{n}\big) \underset{(b)}{\le} 2\log(4n),$$
$$\sum_{k=i}^{n}\frac{G_k}{G_i} \underset{(c)}{\le} 1 + \sqrt{\frac{n}{\log(4n)}}.$$

Здесь (a) — неравенство $\log(1 + xe^v) \le \log(1 + x) + v$ при $x, v \ge 0$, (b) — неравенство $(1 + \sqrt{n})^2 \le 4n$, (c) — сумма геометрической прогрессии и неравенство $e^{-x}(1 + x) \le 1$. Складывая, получаем для каждой координаты

$$L_1\sigma_i \le 2\log\Big(1 + \frac{L_1^2\varepsilon}{L_0}\Big) + 4\sqrt{n\log(4n)} + 2\log(4n) + 2.$$

Все σ_i положительны, поэтому $\|\sigma\| \le \sqrt{n}\max_i \sigma_i$ и

$$L_1\|\sigma\| \le 2\sqrt{n}\log\Bigl(1+\frac{L_1^2\varepsilon}{L_0}\Bigr) + n\sqrt{\log(4n)}\,\Bigl[4+2\sqrt{\frac{\log(4n)}{n}}+\frac{2}{\sqrt{n\log(4n)}}\Bigr].$$

Отношение $\log(4n)$ к n убывает и потому не больше $\log 4 < 2$, а $n\log(4n) \ge \log 4 > 1$. Значит, скобка меньше $4+2\sqrt{2}+2<9$. □

Теорема 4.8 (нижняя оценка для цепочки с убывающими наклонами)**.**
Пусть натуральное число n удовлетворяет условию

$$2\sqrt{n}\,\log\Bigl(1+\frac{L_1^2\varepsilon}{L_0}\Bigr) + 9\,n\sqrt{\log(4n)} \le L_1 R. \tag{4.14}$$

Тогда для каждого детерминированного метода с $n-1$ обращениями к оракулу в $\mathbb{R}^{2n}$ найдётся функция $f \in \mathcal{P}_{\mathrm{R}}$ на $\mathbb{R}^{2n}$ с $\min f = 0$ и $f(\hat{x}) \ge 2\varepsilon$. В частности, $\mathcal{N}(\mathcal{P}_{\mathrm{R}}) \ge n$.

Доказательство. Функция φ — выпуклая цепочка из класса $\mathcal{F}^n_{L_0,L_1}$ (леммы 4.4 и 4.5). Её минимум равен нулю и достигается в точке $-\sigma$, а при $y_n = 0$ её значение не меньше 2ε (лемма 4.6). Из леммы 4.7 и условия (4.14) следует, что норма σ не больше R. Остаётся применить предложение 4.3(б) с $\mathrm{gap} = 2\varepsilon$. □

Начальная невязка этих функций не ограничена величиной 4ε. Подстановка вершины $G_1 e_1$ в (4.8), как в доказательстве леммы 4.6(б), даёт

$$\varphi(0) \ge \frac{2G_1}{L_1} = 2\varepsilon\exp\Bigl((n-1)\sqrt{\frac{\log(4n)}{n}}\Bigr),$$

то есть невязка экспоненциально велика по $\sqrt{n\log n}$. Поэтому теорема 4.8 не противоречит верхней оценке со слагаемым $(L_1R)^{2/3}$ на классе $\mathcal{P}_{4\varepsilon}$ (приложение B).

4.3 Основная нижняя оценка

Осталось выбрать длину цепочки, удовлетворяющую условию (4.14).

Лемма 4.9 (выбор длины цепочки)**.**
Если $L_0R^2 \ge \varepsilon$ и $L_1R \ge 16$, то

$$1+\mathcal{N}(\mathcal{P}_{\mathrm{R}}) \ge \frac{L_1R}{24\sqrt{\log(2+L_1R)}}.$$

Доказательство. Положим

$$n = \Bigl\lfloor \frac{L_1R}{24\sqrt{\log(2+L_1R)}} \Bigr\rfloor.$$

Если $n=0$, утверждение очевидно. Пусть $n \ge 1$. Проверим условие (4.14), оценив два его слагаемых.

▷ *Второе слагаемое.* Число $4n$ меньше $2+L_1R$, поэтому $\log(4n) \le \log(2+L_1R)$ и

$$9n\sqrt{\log(4n)} \le 9n\sqrt{\log(2+L_1R)} \underset{\text{опр. } n}{\le} \frac{3}{8}L_1R.$$

▷ *Первое слагаемое.* Отношение $\log^{3/2}(2+x)$ к x убывает при $x \geq 16$ и в точке 16 меньше трёх восьмых. Поэтому

$$2\sqrt{n}\log\Bigl(1+\frac{L_1^2\varepsilon}{L_0}\Bigr) \underset{L_0R^2\geq\varepsilon}{\leq} 2\sqrt{n}\log\bigl(1+(L_1R)^2\bigr) \underset{1+t^2\leq(2+t)^2}{\leq} 4\sqrt{n}\log(2+L_1R)$$
$$\underset{\text{опр. } n}{\leq} \frac{4}{\sqrt{24}}\,L_1R\sqrt{\frac{\log^{3/2}(2+L_1R)}{L_1R}}$$
$$\underset{L_1R\geq 16}{<} \frac{4}{\sqrt{24}}\sqrt{\frac{3}{8}}\,L_1R = \frac{L_1R}{2}.$$

Сумма слагаемых меньше L_1R, и теорема 4.8 даёт

$$1+\mathcal{N}(\mathcal{P}_{\mathrm{R}}) \geq 1+n \geq \frac{L_1R}{24\sqrt{\log(2+L_1R)}}.$$ □

Теорема 4.10 (нижняя оценка для класса, заданного только радиусом)**.** Если $L_0R^2 \geq \varepsilon$, то

$$1+\mathcal{N}(\mathcal{P}_{\mathrm{R}}) \geq \frac{1}{29}\Bigl[1+\sqrt{\frac{L_0R^2}{\varepsilon}}+\frac{L_1R}{\sqrt{\log(2+L_1R)}}\Bigr]. \tag{4.15}$$

Доказательство. Оценим каждое из трёх слагаемых в скобке через $1+\mathcal{N}(\mathcal{P}_{\mathrm{R}})$.

▷ *Первое.* Очевидно, $1 \leq 1+\mathcal{N}(\mathcal{P}_{\mathrm{R}})$.

▷ *Второе.* Функции с L_0-липшицевым градиентом лежат в классе. Классическая оценка (Nesterov, 2018, теорема 2.1.7) вместе с предложением 4.3 даёт

$$\sqrt{\frac{L_0R^2}{\varepsilon}} \leq 4\bigl(1+\mathcal{N}(\mathcal{P}_{\mathrm{R}})\bigr).$$

▷ *Третье.* При $L_1R \geq 16$ по лемме 4.9 оно не больше $24(1+\mathcal{N}(\mathcal{P}_{\mathrm{R}}))$. При $L_1R < 16$ оно меньше 10, поскольку возрастает по L_1R и

$$\frac{16}{\sqrt{\log 18}} \underset{\log 18>4\log 2}{<} \frac{16}{\sqrt{4\log 2}} \underset{\log 2>2/3}{<} \sqrt{96} < 10.$$

Складывая, получаем, что скобка в (4.15) не больше $29(1+\mathcal{N}(\mathcal{P}_{\mathrm{R}}))$. □

Вместе с теоремой 3.7 при $L_0R^2 \geq \varepsilon$ получаем

$$1+\mathcal{N}(\mathcal{P}_{\mathrm{R}}) = \widetilde{\Theta}\Bigl(1+\sqrt{\frac{L_0R^2}{\varepsilon}}+L_1R\Bigr).$$

Степени в нижней и верхней оценках совпадают, а расхождение сводится к логарифмическим множителям при L_1R.

5 Заключение и открытые вопросы

Большие градиенты и растущая вместе с ними кривизна создают режим, число обращений к оракулу в котором в худшем случае зависит от L_1R и не зависит от ε. Если, помимо L_0, L_1 и ε, методу известна только верхняя оценка R начального расстояния до

точки минимума, то при $L_0R^2 \geq \varepsilon$ оптимальная сложность среди детерминированных методов первого порядка N удовлетворяет соотношению

$$1 + N = \widetilde{\Theta}\Big(1 + \sqrt{\frac{L_0R^2}{\varepsilon}} + L_1R\Big).$$

Иначе говоря, цена прохождения области больших градиентов равна L_1R с точностью до логарифмических множителей. Если начальная невязка не больше 4ε, эта цена падает до $(L_1R)^{2/3}$ (приложение B). Открытыми остаются следующие вопросы.

- ▷ *Логарифмические множители.* Между нижней и верхней оценками остаётся множитель порядка $\log^{3/2}(2 + L_1R)$ при слагаемом L_1R. Множитель $\sqrt{\log(2 + L_1R)}$ теряется в нижней оценке из-за выбора наклонов и сдвигов цепочки, множитель $\log(2 + L_1R)$ — в верхней из-за одномерного поиска на первом этапе. Мы не знаем, можно ли пройти режим больших градиентов за $O(1 + L_1R)$ обращений без одномерного поиска.
- ▷ *Известная оценка невязки.* Для класса $\mathcal{P}_\Delta$, у которого Δ больше 4ε, но меньше правой части оценки (A.3), доказана только верхняя оценка теоремы B.7(б). Совпадающая с ней нижняя оценка по зависимости от Δ неизвестна. Точная зависимость сложности от Δ/ε при $\varepsilon < \Delta < 4\varepsilon$ также не установлена.
- ▷ *Размерность.* Нижние оценки для произвольных методов реализуются в размерности порядка числа обращений, а в фиксированной размерности при фиксированных L_0, L_1 и ε сложность растёт лишь логарифмически по R (приложение C). Промежуточный режим не изучен.
- ▷ *Рандомизированные методы и неточные градиенты.* Все нижние оценки получены для детерминированных методов и точного оракула.

Список литературы

Ekaterina Borodich and Dmitry Kovalev. Nesterov finds GRAAL: Optimal and adaptive gradient method for convex optimization. In *International Conference on Learning Representations*, 2026. URL https://openreview.net/forum?id=vPSiCA3CkD. arXiv:2507.09823v2.

Yair Carmon, John C. Duchi, Oliver Hinder, and Aaron Sidford. Lower bounds for finding stationary points I. *Mathematical Programming*, 184:71–120, 2020.

Ziyi Chen, Yi Zhou, Yingbin Liang, and Zhaosong Lu. Generalized-smooth nonconvex optimization is as efficient as smooth nonconvex optimization. In *Proceedings of the 40th International Conference on Machine Learning*, volume 202 of *PMLR*, pages 5396–5427, 2023.

Michael Crawshaw and Mingrui Liu. Complexity lower bounds of adaptive gradient algorithms for non-convex stochastic optimization under relaxed smoothness. arXiv:2505.04599, 2025.

Michael Crawshaw, Mingrui Liu, Francesco Orabona, Wei Zhang, and Zhenxun Zhuang. Robustness to unbounded smoothness of generalized SignSGD. arXiv:2208.11195, 2022.

A. V. Gasnikov and Yu. E. Nesterov. Universal method for stochastic composite optimization problems. *Computational Mathematics and Mathematical Physics*, 58(1):48–64, 2018.

Eduard Gorbunov, Nazarii Tupitsa, Sayantan Choudhury, Alen Aliev, Peter Richtárik, Samuel Horváth, and Martin Takáč. Methods for convex (L_0, L_1)-smooth optimization: Clipping, acceleration, and adaptivity. In *International Conference on Learning Representations*, 2025. arXiv:2409.14989.

Branko Grünbaum. Partitions of mass-distributions and of convex bodies by hyperplanes. *Pacific Journal of Mathematics*, 10(4):1257–1261, 1960.

Cristóbal Guzmán and Arkadi Nemirovski. On lower complexity bounds for large-scale smooth convex optimization. *Journal of Complexity*, 31(1):1–14, 2015. doi: 10.1016/j.jco.2014.08.003. URL https://arxiv.org/abs/1307.5001.

Florian Hübler, Junchi Yang, Xiang Li, and Niao He. Parameter-agnostic optimization under relaxed smoothness. arXiv:2311.03252, 2023.

Jikai Jin, Bohang Zhang, Haiyang Wang, and Liwei Wang. Non-convex distributionally robust optimization: Non-asymptotic analysis. In *Advances in Neural Information Processing Systems*, volume 34, pages 2771–2782, 2021.

Anastasia Koloskova, Hadrien Hendrikx, and Sebastian U. Stich. Revisiting gradient clipping: Stochastic bias and tight convergence guarantees. In *Proceedings of the 40th International Conference on Machine Learning*, volume 202 of *PMLR*, pages 17343–17363, 2023.

Evgeniy Kovalev and Fedor Stonyakin. Normalized first-order methods for convex (L_0, L_1)-smooth optimization with inexact gradients. arXiv:2607.26969, 2026.

V. O. Krivchenko. Computer-aided analysis of gradient descent under generalized smoothness. *Doklady Rossiiskoi Akademii Nauk. Matematika, Informatika, Protsessy Upravleniya*, 530 (1):5–13, 2026. doi: 10.7868/S3034504926030011. URL https://journals.rcsi.science/2686-9543/article/view/444931. In Russian.

Haochuan Li, Jian Qian, Yi Tian, Alexander Rakhlin, and Ali Jadbabaie. Convex and non-convex optimization under generalized smoothness. In *Advances in Neural Information Processing Systems*, volume 36, 2023.

Aleksandr Lobanov. A few accelerated algorithms for convex optimization under (H_0, H_1)-smoothness. arXiv:2608.04884, 2026.

Aleksandr Lobanov, Alexander Gasnikov, Eduard Gorbunov, and Martin Takáč. Linear convergence rate in convex setup is possible! Gradient descent method variants under (L_0, L_1)-smoothness. *arXiv preprint arXiv:2412.17050*, 2025. doi: 10.48550/arXiv.2412.17050. URL https://arxiv.org/abs/2412.17050v2.

A. S. Nemirovsky and D. B. Yudin. *Problem Complexity and Method Efficiency in Optimization*. Wiley-Interscience, New York, 1983.

Yurii Nesterov. *Lectures on Convex Optimization*, volume 137 of *Springer Optimization and Its Applications*. Springer, 2018.

Konstantinos Oikonomidis, Jan Quan, Emanuel Laude, and Panagiotis Patrinos. Nonlinearly preconditioned gradient methods under generalized smoothness. arXiv:2502.08532, 2025.

R. Tyrrell Rockafellar. *Convex Analysis*. Princeton University Press, 1970.

Yuki Takezawa, Han Bao, Ryoma Sato, Kenta Niwa, and Makoto Yamada. Parameter-free clipped gradient descent meets Polyak. In *Advances in Neural Information Processing Systems*, volume 37, 2024. arXiv:2405.15010.

Alexander Tyurin. Toward a unified theory of gradient descent under generalized smoothness. In *Proceedings of the 42nd International Conference on Machine Learning*, volume 267 of *Proceedings of Machine Learning Research*, pages 60493–60514, 2025. URL https://proceedings.mlr.press/v267/tyurin25a.html.

Alexander Tyurin. Near-optimal convergence of accelerated gradient methods under generalized and (L_0, L_1)-smoothness. In *Proceedings of the 43rd International Conference on Machine Learning*, 2026. arXiv:2508.06884.

Daniil Vankov, Anton Rodomanov, Angelia Nedić, Lalitha Sankar, and Sebastian U. Stich. Optimizing (L_0, L_1)-smooth functions by gradient methods. In *International Conference on Learning Representations*, 2025. arXiv:2410.10800.

Bohang Zhang, Jikai Jin, Cong Fang, and Liwei Wang. Improved analysis of clipping algorithms for non-convex optimization. *Advances in Neural Information Processing Systems*, 33, 2020a.

Jingzhao Zhang, Tianxing He, Suvrit Sra, and Ali Jadbabaie. Why gradient clipping accelerates training: A theoretical justification for adaptivity. In *International Conference on Learning Representations*, 2020b. arXiv:1905.11881.

А. В. Гасников. *Современные численные методы оптимизации. Метод универсального градиентного спуска: учебное пособие. 2-е изд., испр.* МЦНМО, Москва, 2021. ISBN 978-5-4439-4199-8.

A Вспомогательные неравенства

В этом приложении доказаны лемма 2.2 и вспомогательные леммы раздела 3. В подразделе A.1 функция ℓ произвольна, как в определении 2.1. Начиная с подраздела A.2, $f \in \mathcal{F}^d_{L_0,L_1}$, а x^* — точка минимума функции f.

A.1 Характеризация класса

Доказательство леммы 2.2 ▲.

▷ *Необходимость в (а).* Градиент выпуклой дифференцируемой функции непрерывен (Rockafellar, 1970, теорема 25.5), поэтому на каждом шаре он ограничен некоторым числом M. Если отрезок $[x, y]$ лежит в таком шаре, то по (2.1)

$$\|\nabla f(x) - \nabla f(y)\| \le \ell(M)\|x - y\|.$$

Значит, отображение $t \mapsto \nabla f(x + tv)$ липшицево на каждом отрезке, а потому локально абсолютно непрерывно и дифференцируемо при почти всех t. В такой точке t применим (2.1) к точкам $x + tv$ и $x + (t + h)v$, разделим на $|h|$ и устремим h к нулю. В силу непрерывности ∇f и ℓ получим (2.2).

▷ *Достаточность в (а).* Пусть $v = y - x$. По формуле Ньютона–Лейбница и монотонности ℓ

$$\begin{aligned}\|\nabla f(y) - \nabla f(x)\| &\le \int_0^1 \ell\big(\|\nabla f(x + tv)\|\big)\|v\|\,dt \\ &\le \ell\Big(\sup_{u\in[x,y]} \|\nabla f(u)\|\Big)\|x - y\|.\end{aligned}$$

▷ *Утверждение (б).* Для $f \in C^2$ производная отображения $t \mapsto \nabla f(x + tv)$ равна $\nabla^2 f(x+tv)v$ и непрерывна по t. Поэтому условие (2.2) при почти всех t равносильно неравенству

$$\|\nabla^2 f(x)v\| \le \ell\big(\|\nabla f(x)\|\big)\|v\|$$

при всех x и v. Гессиан выпуклой функции класса C^2 — симметричная неотрицательно определённая матрица, и для неё это неравенство равносильно (2.3). Остаётся применить (а). □

A.2 Скорость изменения градиента

Следующая лемма показывает, что локальная константа гладкости $L_0 + L_1\|\nabla f(y)\|$ при переходе от точки y к точке z меняется не более чем в $e^{L_1\|z-y\|}$ раз. Остальные оценки приложения выводятся из этого факта.

Лемма A.1 (следствия леммы Гронуолла)**.**
Для любых точек $y, z \in \mathbb{R}^d$ выполнены неравенства

(а) $$L_0 + L_1\|\nabla f(z)\| \le \big(L_0 + L_1\|\nabla f(y)\|\big)e^{L_1\|z-y\|},$$

(б) $$\|\nabla f(z) - \nabla f(y)\| \le \big(L_0 + L_1\|\nabla f(y)\|\big)\frac{e^{L_1\|z-y\|} - 1}{L_1},$$

(в) $$0 \le f(z) - f(y) - \langle\nabla f(y), z - y\rangle \le \big(L_0 + L_1\|\nabla f(y)\|\big)\frac{e^{L_1\|z-y\|} - 1 - L_1\|z - y\|}{L_1^2}.$$

Доказательство. Будем следить за градиентом в точках $y + t(z-y)$, $t \in [0,1]$.

▷ *Интегральное неравенство.* По лемме 2.2(а) отображение $t \mapsto \nabla f(y + t(z-y))$ абсолютно непрерывно, и при почти всех t норма его производной не больше $(L_0 + L_1\|\nabla f(y + t(z-y))\|)\|z-y\|$. Поэтому при всех $t \in [0,1]$

$$\|\nabla f\big(y + t(z-y)\big) - \nabla f(y)\| \le \|z-y\| \int_0^t \Big(L_0 + L_1\|\nabla f\big(y + \tau(z-y)\big)\|\Big) d\tau. \quad \text{(A.1)}$$

По неравенству треугольника отсюда следует

$$\begin{aligned} &L_0 + L_1\|\nabla f\big(y + t(z-y)\big)\| \\ &\quad \le L_0 + L_1\|\nabla f(y)\| + L_1\|z-y\| \int_0^t \Big(L_0 + L_1\|\nabla f\big(y + \tau(z-y)\big)\|\Big) d\tau. \end{aligned}$$

▷ *Лемма Гронуолла.* Левая часть последнего неравенства непрерывна по t, и по лемме Гронуолла в интегральной форме

$$L_0 + L_1\|\nabla f\big(y + t(z-y)\big)\| \le \big(L_0 + L_1\|\nabla f(y)\|\big) e^{L_1\|z-y\|t}.$$

При $t = 1$ это утверждение (а).

▷ *Приращение градиента.* Подставим эту оценку в (A.1):

$$\begin{aligned} \|\nabla f\big(y + t(z-y)\big) - \nabla f(y)\| &\le \big(L_0 + L_1\|\nabla f(y)\|\big)\|z-y\| \int_0^t e^{L_1\|z-y\|\tau} d\tau \\ &= \big(L_0 + L_1\|\nabla f(y)\|\big) \frac{e^{L_1\|z-y\|t} - 1}{L_1}. \end{aligned}$$

При $t = 1$ это утверждение (б).

▷ *Приращение функции.* Левое неравенство в (в) — это выпуклость функции f. Для правого

$$\begin{aligned} f(z) - f(y) - \langle \nabla f(y), z-y\rangle &= \int_0^1 \langle \nabla f\big(y + t(z-y)\big) - \nabla f(y), z-y\rangle \, dt \\ &\underset{\text{(б)}}{\le} \big(L_0 + L_1\|\nabla f(y)\|\big)\|z-y\| \int_0^1 \frac{e^{L_1\|z-y\|t} - 1}{L_1} \, dt \\ &= \big(L_0 + L_1\|\nabla f(y)\|\big) \frac{e^{L_1\|z-y\|} - 1 - L_1\|z-y\|}{L_1^2}. \end{aligned}$$

Во втором переходе использованы неравенство КБШ и утверждение (б). □

Для дважды непрерывно дифференцируемых функций неравенства (б) и (в) получены в работе Vankov et al. (2025, лемма 2.5). Из неравенства $e^x - 1 - x \le x^2 e^x/2$ при $x \ge 0$ и утверждения (в) следует

$$f(z) \le f(y) + \langle \nabla f(y), z-y\rangle + \frac{\big(L_0 + L_1\|\nabla f(y)\|\big) e^{L_1\|z-y\|}}{2} \|z-y\|^2. \quad \text{(A.2)}$$

На расстояниях порядка $1/L_1$ это обычное неравенство для функций с липшицевым градиентом (Nesterov, 2018, лемма 1.2.3) с константой, пропорциональной $L_0 + L_1\|\nabla f(y)\|$.

A.3 Лемма о спуске

Доказательство леммы 3.1 ▲.

▷ *Убывание функции.* Так как $L_0 + L_1\|\nabla f(y)\| \geq L_1\|\nabla f(y)\|$, длина шага

$$\|y^+ - y\| = \frac{\|\nabla f(y)\|}{4\big(L_0 + L_1\|\nabla f(y)\|\big)}$$

не больше $1/(4L_1)$, и множитель $e^{L_1\|y^+-y\|}$ в (A.2) не больше $e^{1/4}$. Поэтому

$$\begin{aligned} f(y^+) &\underset{\text{(A.2)}}{\leq} f(y) - \frac{\|\nabla f(y)\|^2}{4\big(L_0 + L_1\|\nabla f(y)\|\big)} + \frac{e^{1/4}\|\nabla f(y)\|^2}{32\big(L_0 + L_1\|\nabla f(y)\|\big)} \\ &= f(y) - \Big(\frac{1}{4} - \frac{e^{1/4}}{32}\Big)\frac{\|\nabla f(y)\|^2}{L_0 + L_1\|\nabla f(y)\|} \\ &\underset{\text{(а)}}{\leq} f(y) - \frac{5\|\nabla f(y)\|^2}{24\big(L_0 + L_1\|\nabla f(y)\|\big)}. \end{aligned}$$

Здесь (а) — неравенство $e^{1/4} < 4/3$, которое следует из $e^t \leq 1/(1-t)$ при $0 \leq t < 1$.

▷ *Убывание расстояния до точки минимума.* Имеем

$$\begin{aligned} \langle \nabla f(y), y - x^*\rangle &\underset{\text{(б)}}{\geq} f(y) - f^* \underset{\text{(в)}}{\geq} f(y) - f(y^+) \\ &\underset{\text{(г)}}{\geq} \frac{5\|\nabla f(y)\|^2}{24\big(L_0 + L_1\|\nabla f(y)\|\big)}, \end{aligned}$$

где (б) — выпуклость, (в) — неравенство $f(y^+) \geq f^*$, (г) — уже доказанное убывание функции. Раскрывая квадрат нормы и подставляя эту оценку, получаем

$$\begin{aligned} \|y^+ - x^*\|^2 &= \|y - x^*\|^2 - \frac{\langle \nabla f(y), y - x^*\rangle}{2\big(L_0 + L_1\|\nabla f(y)\|\big)} + \frac{\|\nabla f(y)\|^2}{16\big(L_0 + L_1\|\nabla f(y)\|\big)^2} \\ &\leq \|y - x^*\|^2 - \frac{5\|\nabla f(y)\|^2}{48\big(L_0 + L_1\|\nabla f(y)\|\big)^2} + \frac{3\|\nabla f(y)\|^2}{48\big(L_0 + L_1\|\nabla f(y)\|\big)^2}. \end{aligned}$$

□

A.4 Оценки в окрестности точки минимума

В точке минимума градиент равен нулю, поэтому лемма A.1 при $y = x^*$ даёт оценку роста функции при удалении от точки минимума.

Лемма A.2 (рост вокруг точки минимума)**.**
Для любой точки $x \in \mathbb{R}^d$

$$\begin{aligned} \|\nabla f(x)\| &\leq \frac{L_0}{L_1}\big(e^{L_1\|x-x^*\|} - 1\big), \\ f(x) - f^* &\leq \frac{L_0}{L_1^2}\big(e^{L_1\|x-x^*\|} - 1 - L_1\|x - x^*\|\big). \end{aligned}$$

В частности, если $\|x^0 - x^*\| \leq R$, то

$$f(x^0) - f^* \leq \frac{L_0}{L_1^2}\big(e^{L_1 R} - 1 - L_1 R\big). \tag{A.3}$$

Доказательство. Обе оценки — утверждения (б) и (в) леммы A.1 при $y = x^*$ и $z = x$, поскольку $\nabla f(x^*) = 0$. Правая часть второй оценки возрастает по $\|x - x^*\|$, что даёт (A.3). □

Оценка (A.3) точна. Функция

$$f(x) = \frac{L_0}{L_1^2}\bigl(e^{L_1\|x\|} - 1 - L_1\|x\|\bigr)$$

дважды непрерывно дифференцируема, и

$$\|\nabla f(x)\| = \frac{L_0}{L_1}\bigl(e^{L_1\|x\|} - 1\bigr).$$

При $x \neq 0$ её кривизна вдоль радиуса равна

$$L_0 e^{L_1\|x\|} = L_0 + L_1\|\nabla f(x)\|,$$

а в касательных направлениях кривизна равна

$$\frac{\|\nabla f(x)\|}{\|x\|} = \frac{L_0\bigl(e^{L_1\|x\|} - 1\bigr)}{L_1\|x\|} \leq L_0 e^{L_1\|x\|},$$

поскольку $e^s - 1 \leq se^s$. В нуле гессиан равен $L_0 I$, и обе кривизны стремятся к L_0. По лемме 2.2(б) функция лежит в классе $\mathcal{F}^d_{L_0,L_1}$, а при $\|x^0\| = R$ в (A.3) достигается равенство. Таким образом, начальная невязка по функции может быть экспоненциально большой по $L_1 R$.

Доказательство леммы 3.2 ▲. При $\nabla f(y) = 0$ утверждение совпадает с неравенством выпуклости. Пусть $\nabla f(y) \neq 0$. Сравним касательную в точке y с оценкой роста леммы A.2 в точках луча

$$z_t = x^* + \frac{t\,\nabla f(y)}{\|\nabla f(y)\|},$$

где $t \geq 0$.

▷ *Оценка при фиксированном t.* Так как $\langle \nabla f(y), z_t - x^* \rangle = t\|\nabla f(y)\|$,

$$\begin{aligned} f(y) + \langle \nabla f(y), x^* - y\rangle + t\|\nabla f(y)\| &= f(y) + \langle \nabla f(y), z_t - y\rangle \\ &\underset{\text{(а)}}{\leq} f(z_t) \underset{\text{(б)}}{\leq} f^* + \frac{L_0}{L_1^2}\bigl(e^{L_1 t} - 1 - L_1 t\bigr), \end{aligned}$$

где (а) — выпуклость, (б) — лемма A.2.

▷ *Выбор t.* Положим

$$t = \frac{1}{L_1}\log\Bigl(1 + \frac{L_1\|\nabla f(y)\|}{L_0}\Bigr).$$

Тогда

$$e^{L_1 t} = 1 + \frac{L_1\|\nabla f(y)\|}{L_0},$$

и прямое вычисление по формуле (3.2) даёт

$$t\|\nabla f(y)\| - \frac{L_0}{L_1^2}\bigl(e^{L_1 t} - 1 - L_1 t\bigr) = \Phi\bigl(\|\nabla f(y)\|\bigr).$$

Подставляя это в предыдущую оценку, получаем утверждение леммы. □

Выбранное t максимизирует левую часть последнего равенства, то есть Φ — функция, сопряжённая к функции роста из леммы A.2. Неравенство леммы 3.2 утверждается только в точке x^*: аффинная функция с добавкой Φ не обязана быть минорантой функции f всюду.

A.5 Неточный одномерный поиск

Доказательство леммы 3.3 ▲. Обозначим через $z(t) = v + t(x - v)$ точки отрезка $[v, x]$. Функция $t \mapsto f(z(t))$ выпукла на $[0, 1]$, а её производная $\langle \nabla f(z(t)), x - v\rangle$ не убывает. Для точки $y = z(t)$

$$\langle \nabla f(y), y - v\rangle = t\,\langle \nabla f(z(t)), x - v\rangle.$$

▷ *Критерий остановки.* Если он сработал в точке $z \in [v, x]$, то z лежит в шаре $B(x^*, r)$, и по выпуклости

$$f(z) - f^* \le \langle \nabla f(z), z - x^*\rangle \le r\|\nabla f(z)\| \le \delta.$$

Далее считаем, что критерий остановки не сработал.

▷ *Возврат в концах отрезка.* Если $\langle \nabla f(v), x - v\rangle \ge 0$, то производная неотрицательна на $[0, 1]$. Значит, $f(v) \le f(x)$, а для $y = v$ левая часть второго неравенства (3.5) равна нулю. Если $\langle \nabla f(x), x - v\rangle \le 0$, то для $y = x$ первое неравенство (3.5) очевидно, а левая часть второго неположительна.

▷ *Деление отрезка пополам.* Алгоритм поддерживает неравенства

$$\langle \nabla f(z(t_-)), x - v\rangle < 0 < \langle \nabla f(z(t_+)), x - v\rangle.$$

Если в середине производная равна нулю, то эта середина — точка минимума функции на отрезке, и для неё выполнены оба неравенства (3.5). Иначе после m шагов $t_+ - t_- = 2^{-m}$.

▷ *Убывание для $y = z(t_+)$.* Производная в точке t_+ положительна, поэтому функция не убывает на $[t_+, 1]$, и $f(y) \le f(x)$.

▷ *Погрешность для $y = z(t_+)$.* Расстояние между точками $z(t_+)$ и $z(t_-)$ равно $2^{-m}\|x - v\|$, причём $\|x - v\| \le 2r$. По условию (3.4)

$$L_1\|z(t_+) - z(t_-)\| \le 2^{1-m} L_1 r \le \frac{2L_1 r}{128\big(1 + L_1 r\big)^2} \le \frac{1}{32}.$$

По лемме A.1(б) с базовой точкой $z(t_+)$ и неравенству $e^s - 1 \le se^s$

$$\|\nabla f(z(t_+)) - \nabla f(z(t_-))\| \le 2\big(L_0 + L_1\|\nabla f(y)\|\big)\|z(t_+) - z(t_-)\|.$$

Так как $\langle \nabla f(z(t_-)), x - v\rangle < 0$ и $t_+ \le 1$,

$$\begin{aligned}
\langle \nabla f(y), y - v\rangle &\le t_+ \langle \nabla f(z(t_+)) - \nabla f(z(t_-)), x - v\rangle \\
&\underset{\text{(a)}}{\le} 2r\|\nabla f(z(t_+)) - \nabla f(z(t_-))\| \\
&\le 2^{3-m} r^2 \big(L_0 + L_1\|\nabla f(y)\|\big) \\
&\underset{(3.4)}{\le} \frac{r^2\big(L_0 + L_1\|\nabla f(y)\|\big)}{16\big(1 + L_0 r^2/\delta + L_1 r\big)^2},
\end{aligned}$$

где (a) — неравенства $t_+ \le 1$ и $\|x - v\| \le 2r$.

▷ *Связь с градиентом.* В точке y критерий остановки не выполнен, то есть $r\|\nabla f(y)\| > \delta$. Поэтому

$$\begin{aligned}
\frac{r\big(L_0 + L_1\|\nabla f(y)\|\big)}{\|\nabla f(y)\|} &= \frac{L_0 r}{\|\nabla f(y)\|} + L_1 r \\
&\underset{\text{(б)}}{<} \frac{L_0 r^2}{\delta} + L_1 r < 1 + \frac{L_0 r^2}{\delta} + L_1 r,
\end{aligned}$$

где (б) — неравенство $r\|\nabla f(y)\| > \delta$. Возводя в квадрат и деля на $16(L_0 + L_1\|\nabla f(y)\|)$, получаем

$$\frac{r^2\big(L_0 + L_1\|\nabla f(y)\|\big)}{16\big(1 + L_0 r^2/\delta + L_1 r\big)^2} < \frac{\|\nabla f(y)\|^2}{16\big(L_0 + L_1\|\nabla f(y)\|\big)},$$

и второе неравенство (3.5) выполнено.

▷ *Число обращений.* Алгоритм делает два обращения в концах отрезка и не более m обращений в серединах. □

B Класс с ограниченной начальной невязкой

В основном тексте о начальной точке известна только верхняя оценка R её расстояния до точки минимума, и начальная невязка по функции может быть экспоненциально большой по $L_1 R$. В этом приложении рассмотрен класс $\mathcal{P}_\Delta$ из раздела 2, в котором начальная невязка ограничена известным числом Δ, и прежде всего случай $\Delta = 4\varepsilon$. Показатель степени при $L_1 R$ в оценке сложности падает при этом с единицы до $2/3$.

Условие $f(x^0) - f^* \le 4\varepsilon$ естественно в схемах с рестартами: каждая фаза стартует из точки, где невязка уже ограничена постоянным кратным точности, требуемой от этой фазы.

Нижняя оценка доказана в подразделе B.1 на цепочке с равными наклонами звеньев. Верхние оценки получены вариантом ускоренного метода раздела 3 с другими способами подсчёта итераций (подразделы B.2–B.4). Итоговые утверждения сформулированы в конце соответствующих подразделов.

B.1 Нижняя оценка: цепочка с равными наклонами

Как и в подразделе 4.2, построим цепочку сопряжением на многограннике и применим лемму 4.2. Здесь наклоны всех звеньев равны, а сдвиги образуют арифметическую прогрессию с разностью $-b$.

Наклон и сдвиги. Зафиксируем $n \ge 1$ и положим

$$\begin{aligned} b &= R\Big(\sum_{k=n+1}^{2n} k^2\Big)^{-1/2}, \\ \sigma_i &= (2n - i)\, b, \\ G &= \frac{2\varepsilon}{nb}. \end{aligned} \tag{B.1}$$

где $i = 1, \dots, n$. Сумма в определении b лежит между n^3 и $4n^3$.

Функция на многограннике. Пусть функция $r \in C^1([0,1])$ сильно выпукла с некоторым положительным модулем, $r(0) = r'(0) = 0$ и $r'(1) = b$. Рассмотрим многогранник

$$K = \big\{z \in \mathbb{R}^n :\ z \ge 0,\ Z_n \le G\big\},$$

где $Z_n = z_1 + \dots + z_n$. Для $z \in K$ положим

$$\begin{aligned} p_i &= \frac{z_i}{G}, \\ p_0 &= 1 - \frac{Z_n}{G}, \end{aligned}$$

где $i = 1, \dots, n$. Координата p_0 — нормированный остаток до ограничения $Z_n \le G$, благодаря ей у ψ есть целая область точек минимума. Определим функцию на K и сопряжённую к ней:

$$\begin{aligned} H(z) &= G\Big[\sum_{i=0}^{n} r(p_i) - r(1)\Big], \\ \psi(y) &= \max_{z \in K} \big\{ \langle y + \sigma, z \rangle - H(z) \big\}. \end{aligned} \tag{B.2}$$

Здесь $H(0) = H(Ge_i) = 0$.

Лемма B.1 (свойства цепочки с равными наклонами)**.**
Функция ψ выпукла, непрерывно дифференцируема, и

(а) её минимум равен нулю, а множество точек минимума равно

$$\big\{ y \in \mathbb{R}^n : \ y_i \le -(\sigma_i + b) \text{ при } i = 1, \dots, n \big\}.$$

Ближайшая к нулю точка минимума $-b\,(2n, 2n-1, \dots, n+1)$ имеет норму R,

(б) $\psi(0) = (4 - 2/n)\varepsilon$,

(в) при $y_n = 0$ имеем $\psi(y) \ge 2\varepsilon$,

(г) ψ — цепочка,

(д) $\nabla\psi(y) = z(y) = G\,(p_1, \dots, p_n)$, где $z(y)$ — единственная точка максимума в (B.2).

Доказательство.

▷ *Градиент.* Сильная выпуклость r даёт сильную выпуклость H на K с постоянным модулем. Поэтому точка максимума единственна, и, как в доказательстве леммы 4.2, $\nabla\psi(y) = z(y)$ и градиент непрерывен. Это утверждение (д).

▷ *Условия оптимальности.* Положим $\theta_0 = 0$ и $\theta_i = y_i + \sigma_i$ при $i \ge 1$. Задача максимизации в (B.2) равносильна максимизации

$$\sum_{i=0}^{n} \theta_i p_i - \sum_{i=0}^{n} r(p_i)$$

на симплексе. Перенос веса между двумя положительными координатами и из положительной координаты в нулевую даёт число ν, для которого при $0 \le i \le n$

$$\theta_i \ \begin{cases} = \nu + r'(p_i), & p_i > 0, \\ \le \nu, & p_i = 0. \end{cases} \tag{B.3}$$

Эти условия также достаточны по выпуклости r. Так как $0 \le r'(p_i) \le b$, всегда $\nu \ge \theta_i - b$.

▷ *Утверждение (а).* Точка $z = 0$ допустима, поэтому $\psi \ge 0$. Равенство достигается ровно тогда, когда оптимален вектор $p = e_0$. По (B.3) это равносильно $\nu = -b$ и $\theta_i \le -b$ при $i \ge 1$. Формулы для множества точек минимума и ближайшей к нулю точки следуют из (B.1).

▷ *Утверждение (б).* При $y = 0$ условия (B.3) выполнены для $p = e_1$ и $\nu = \sigma_1 - b = (2n-2)b$: все остальные θ_i, включая $\theta_0 = 0$, не больше ν. Поэтому $\psi(0) = G\sigma_1 = (4 - 2/n)\varepsilon$.

▷ *Утверждение (в).* Подставляя $z = Ge_n$, получаем $\psi(y) \ge G\sigma_n = 2\varepsilon$.

▷ *Утверждение (г).* Если $y_i = 0$ при $i \geq j$, то при $l > j$

$$\theta_l = \sigma_l \leq \sigma_j - b = \theta_j - b \leq \nu.$$

Положительное p_l противоречило бы (B.3), поскольку $r'(p_l) > 0$. Значит, l-я координата градиента Gp_l равна нулю. □

Для проверки условия класса достаточно одномерной оценки кривизны функции r.

Лемма B.2 (условие класса для равных наклонов)**.**
Если r дважды непрерывно дифференцируема на $(0, 1)$ и при $0 < p < 1$

$$r''(p) \geq \frac{G}{L_0 + L_1 G p}, \tag{B.4}$$

то $\psi \in \mathcal{F}^n_{L_0,L_1}$.

Доказательство. Пусть $z, z' \in K$ различны и $u = z' - z$. На интервале $0 < t < 1$ координаты p_i точки $z+tu$ либо положительны, либо тождественно равны нулю. Поэтому

$$\begin{aligned}\frac{d^2}{dt^2} H(z + tu) &= \frac{1}{G}\sum_{i=1}^{n} r''(p_i)u_i^2 + \frac{1}{G} r''(p_0)U_n^2 \\ &\underset{\text{(B.4)}}{\geq} \frac{\|u\|^2}{L_0 + L_1\|z + tu\|} \geq \frac{\|u\|^2}{L_0 + L_1 \max\{\|z\|, \|z'\|\}},\end{aligned}$$

где $U_n = u_1 + \cdots + u_n$. Слагаемые с тождественно нулевыми координатами пропущены. Если $p_0 \equiv 0$, то $U_n = 0$ и последнее слагаемое также отсутствует. Во втором переходе использовано неравенство $Gp_i = (z + tu)_i \leq \|z + tu\|$, в третьем — выпуклость нормы. Интегрирование и непрерывность на концах дают условие леммы 4.2, которая завершает доказательство. □

Квадратичная функция r. Возьмём $r(p) = bp^2/2$. Тогда $r'' = b$. Пусть

$$4n \leq \sqrt{\frac{L_0 R^2}{\varepsilon}}. \tag{B.5}$$

Тогда

$$\begin{aligned}\frac{G}{b} &\underset{\text{(B.1)}}{=} \frac{2\varepsilon}{nR^2} \sum_{k=n+1}^{2n} k^2 \leq \frac{8\varepsilon n^2}{R^2} \\ &\underset{\text{(B.5)}}{\leq} \frac{L_0}{2}.\end{aligned}$$

Следовательно, условие (B.4) выполнено, и градиент функции ψ даже липшицев с константой не больше $L_0/2$.

Логарифмическая функция r. Положим

$$\begin{aligned} r(p) &= \frac{1}{L_1}\Big[(p + \chi)\log\Big(1 + \frac{p}{\chi}\Big) - p\Big], \\ \chi &= \frac{1}{e^{L_1 b} - 1}. \end{aligned} \tag{B.6}$$

Тогда

$$r'(p) = \frac{1}{L_1}\log\Big(1 + \frac{p}{\chi}\Big),$$
$$r''(p) = \frac{1}{L_1(p+\chi)},$$

и $r'(1) = b$. Условие (B.4) выполнено, если $GL_1\chi \le L_0$, поскольку тогда $GL_1(p+\chi) \le L_0 + L_1 G p$. Проверим это при условиях

$$\begin{aligned} &L_1^2\varepsilon \ge L_0, \\ &n \le \Big(\frac{L_1 R}{8\log(2 + L_1^2\varepsilon/L_0)}\Big)^{2/3}. \end{aligned} \tag{B.7}$$

Из (B.1) и (B.7)

$$\begin{aligned} L_1 b &\underset{\text{(B.1)}}{\ge} \frac{L_1 R}{2n^{3/2}} \underset{\text{(B.7)}}{\ge} 4\log\Big(2 + \frac{L_1^2\varepsilon}{L_0}\Big) \\ &\underset{\text{(B.7)}}{\ge} 4\log 3 > 4. \end{aligned}$$

В последнем переходе использовано первое условие (B.7). Поэтому $e^{L_1 b} \ge 2$ и

$$\chi \le 2e^{-L_1 b} \le 2\Big(2 + \frac{L_1^2\varepsilon}{L_0}\Big)^{-2},$$

и

$$\begin{aligned} \frac{GL_1\chi}{L_0} &= \frac{2L_1^2\varepsilon}{nL_1 b\, L_0}\chi \le \frac{4}{nL_1 b}\cdot\frac{L_1^2\varepsilon/L_0}{\big(2 + L_1^2\varepsilon/L_0\big)^2} \\ &\underset{\text{(a)}}{\le} \frac{1}{2nL_1 b} < \frac{1}{2}. \end{aligned}$$

Здесь (a) — неравенство $t/(2+t)^2 \le 1/8$ при $t \ge 0$, равносильное $(t-2)^2 \ge 0$.

Теорема B.3 (нижняя оценка на классе с ограниченной начальной невязкой)**.** Пусть натуральное число n удовлетворяет условию (B.5) или условию (B.7). Тогда для каждого детерминированного метода с $n-1$ обращениями к оракулу в $\mathbb{R}^{2n}$ найдётся функция $f \in \mathcal{P}_{4\varepsilon}$ на $\mathbb{R}^{2n}$, для которой $f^* = 0$, расстояние от нуля до множества точек минимума равно R, $f(0) = (4 - 2/n)\varepsilon$ и $f(\hat{x}) \ge 2\varepsilon$. В частности, $\mathcal{N}(\mathcal{P}_{4\varepsilon}) \ge n$, и при $L_0 R^2 \ge \varepsilon$

$$1 + \mathcal{N}(\mathcal{P}_{4\varepsilon}) \ge \frac{1}{12}\Big[1 + \sqrt{\frac{L_0 R^2}{\varepsilon}} + \Big(\frac{L_1 R}{\log(2 + L_1^2\varepsilon/L_0)}\Big)^{2/3}\Big]. \tag{B.8}$$

Доказательство.

▷ *Наихудшие функции.* Если выполнено условие (B.5), возьмём квадратичную функцию r, иначе — логарифмическую (B.6). В обоих случаях $\psi \in \mathcal{F}^n_{L_0,L_1}$ по лемме B.2, а лемма B.1 даёт остальные условия предложения 4.3(б) с $\mathrm{gap} = 2\varepsilon$ и $\Delta = 4\varepsilon$. По этому предложению для каждого метода найдётся матрица V с ортонормированными столбцами, для которой функция $f(x) = \psi(V^\top x)$ лежит в $\mathcal{P}_{4\varepsilon}$ и $f(\hat{x}) \ge 2\varepsilon$. Остальные свойства f дают утверждения (а) и (б) леммы B.1.

▷ *Случай* $L_1^2\varepsilon \ge L_0$. Для каждого из условий (B.5) и (B.7) возьмём в качестве n целую часть наибольшей допустимой правой части. Если она положительна, первая часть теоремы даёт $\mathcal{N}(\mathcal{P}_{4\varepsilon}) \ge n$, а если равна нулю, это неравенство очевидно. Вместе с неравенством $1 + \lfloor x \rfloor \ge x$ получаем

$$\begin{aligned} 1 + \mathcal{N}(\mathcal{P}_{4\varepsilon}) &\ge 1, \\ 1 + \mathcal{N}(\mathcal{P}_{4\varepsilon}) &\ge \frac{1}{4}\sqrt{\frac{L_0 R^2}{\varepsilon}}, \\ 1 + \mathcal{N}(\mathcal{P}_{4\varepsilon}) &\ge \Big(\frac{L_1 R}{8\log(2 + L_1^2\varepsilon/L_0)}\Big)^{2/3} \\ &= \frac{1}{4}\Big(\frac{L_1 R}{\log(2 + L_1^2\varepsilon/L_0)}\Big)^{2/3}. \end{aligned}$$

Складывая эти неравенства с множителями 1, 4 и 4, получаем, что скобка в (B.8) не больше $9\big(1 + \mathcal{N}(\mathcal{P}_{4\varepsilon})\big)$.

▷ *Случай* $L_1^2\varepsilon < L_0$. Тогда $(L_1 R)^2 < L_0 R^2/\varepsilon$, и при $L_0 R^2 \ge \varepsilon$

$$\begin{aligned} \Big(\frac{L_1 R}{\log(2 + L_1^2\varepsilon/L_0)}\Big)^{2/3} &\underset{\text{(а)}}{\le} (\log 2)^{-2/3}(L_1 R)^{2/3} \underset{\text{(б)}}{<} \frac{3}{2}\Big(\frac{L_0 R^2}{\varepsilon}\Big)^{1/3} \\ &\underset{\text{(в)}}{\le} \frac{3}{2}\sqrt{\frac{L_0 R^2}{\varepsilon}}, \end{aligned}$$

где (а) — неравенство $\log(2 + t) \ge \log 2$, (б) — неравенства $(\log 2)^{-2/3} < 3/2$ и $(L_1 R)^2 < L_0 R^2/\varepsilon$, (в) — условие $L_0 R^2 \ge \varepsilon$. Значит, скобка в (B.8) не больше

$$\begin{aligned} 1 + \frac{5}{2}\sqrt{\frac{L_0 R^2}{\varepsilon}} &\le \big(1 + \mathcal{N}(\mathcal{P}_{4\varepsilon})\big) + 10\big(1 + \mathcal{N}(\mathcal{P}_{4\varepsilon})\big) \\ &= 11\big(1 + \mathcal{N}(\mathcal{P}_{4\varepsilon})\big). \end{aligned}$$

Здесь использованы первые два неравенства из предыдущего случая: они получены без условия на знак $L_1^2\varepsilon - L_0$.

В обоих случаях подходит константа $1/12$. □

Показатель $2/3$ возникает так. Сдвиги $\sigma_i = (2n - i)b$ образуют арифметическую прогрессию с разностью $-b$, поэтому R^2 имеет порядок $b^2 n^3$. Условие класса для логарифмической функции r требует, чтобы $L_1 b$ было не меньше логарифма, как в условии (B.7). Эти две оценки дают длину цепочки порядка $(L_1 R)^{2/3}$ с точностью до логарифма. Начальная невязка меньше 4ε, и теорема B.7(а) ниже показывает, что показатель $2/3$ точен с точностью до логарифмических множителей. Начальная невязка функций теоремы 4.8, напротив, не ограничена равномерно величиной 4ε (см. замечание после неё).

B.2 Вариант метода без слагаемого Φ

В этом подразделе и далее $f \in \mathcal{F}^d_{L_0,L_1}$, а x^* — точка минимума функции f. Используется вариант алгоритма 2 без добавки Φ, и с начальным весом $a_0 \ge 0$ (алгоритм 4). Положим $A_k = a_0 + a_1 + \dots + a_k$. Коэффициент $a_k > 0$ определяется уравнением

$$32\big(L_0 + L_1\|\nabla f(y^k)\|\big)a_k^2 = A_{k-1} + a_k, \tag{B.9}$$

а число шагов одномерного поиска — условием (3.4).

Алгоритм 4 Вариант метода SHERPA без слагаемого Φ

Вход: начальная точка x^0, начальный вес $a_0 \geq 0$, числа $r, \delta > 0$, натуральное число m с условием (3.4), число итераций K

$v^0 = x^0$, $A_0 = a_0$
для $k = 1, \ldots, K$ **выполнять**
  y^k — результат алгоритма 1 на отрезке $[v^{k-1}, x^{k-1}]$ с числами r, δ, m
  если сработал критерий остановки **то**
    вернуть y^k
  конец если
  a_k — положительный корень уравнения (B.9), $A_k = A_{k-1} + a_k$
  $x^k = y^k - \dfrac{\nabla f(y^k)}{4(L_0 + L_1\|\nabla f(y^k)\|)}$
  $v^k = v^{k-1} - a_k \nabla f(y^k)$
конец для
вернуть x^K

Лемма B.4.
Пусть $\|x^0 - x^*\| \leq R_0$, начальная невязка $f(x^0) - f^*$ не больше Δ_0 и

$$r^2 \geq R_0^2 + 2a_0\Delta_0.$$

Если первые k итераций алгоритма 4 прошли без срабатывания критерия остановки, то

$$A_k\big(f(x^k) - f^*\big) + \frac{1}{2}\sum_{i=1}^{k} a_i^2\|\nabla f(y^i)\|^2 + \frac{1}{2}\|v^k - x^*\|^2 \leq \frac{1}{2}R_0^2 + a_0\Delta_0, \tag{B.10}$$

и все точки метода и одномерного поиска лежат в шаре $B(x^*, r)$. Кроме того, при всех $i \leq k$

$$\begin{aligned} f(x^{i-1}) &\geq f(y^i), \\ f(y^i) &\geq f(x^i) + \frac{\|\nabla f(y^i)\|^2}{8\big(L_0 + L_1\|\nabla f(y^i)\|\big)}. \end{aligned} \tag{B.11}$$

Доказательство. Доказательство повторяет доказательство леммы 3.4. При $k = 0$ неравенство (B.10) следует из условий на x^0. Шаг индукции отличается в трёх местах.

- ▷ *Замены.* Вместо леммы 3.2 используется неравенство выпуклости $\langle \nabla f(y^k), y^k - x^* \rangle \geq f(y^k) - f^*$, а лемма 3.3 используется так же. Неравенства (B.11) следуют из неё и леммы 3.1.
- ▷ *Приращение.* С этими заменами оценки расстояния и невязки из доказательства леммы 3.4 дают

$$\begin{aligned} &\Big[A_k\big(f(x^k) - f^*\big) + \frac{1}{2}\|v^k - x^*\|^2\Big] - \Big[A_{k-1}\big(f(x^{k-1}) - f^*\big) + \frac{1}{2}\|v^{k-1} - x^*\|^2\Big] \\ &\quad\leq \Big(\frac{a_k}{16} - \frac{5A_k}{24}\Big)\frac{\|\nabla f(y^k)\|^2}{L_0 + L_1\|\nabla f(y^k)\|} + \frac{1}{2}a_k^2\|\nabla f(y^k)\|^2 \\ &\quad\underset{\text{(B.9)}}{=} \Big(\frac{a_k}{16} - \frac{5A_k}{24} + \frac{A_k}{32}\Big)\frac{\|\nabla f(y^k)\|^2}{L_0 + L_1\|\nabla f(y^k)\|} - \frac{1}{2}a_k^2\|\nabla f(y^k)\|^2 \\ &\quad\underset{\text{(a)}}{\leq} -\frac{1}{2}a_k^2\|\nabla f(y^k)\|^2, \end{aligned}$$

где (a) — неравенства $a_k \le A_k$ и $1/16 - 5/24 + 1/32 < 0$.

▷ *Шар радиуса r.* По неравенству (B.10) и условию леммы

$$\|v^k - x^*\|^2 \le R_0^2 + 2a_0\Delta_0 \le r^2,$$

а точка x^k лежит в шаре по лемме 3.1. □

Из уравнения (B.9) и равенства $A_k = A_{k-1} + a_k$ при каждом $i \ge 1$ следуют соотношения

$$\begin{aligned} a_i^2 &= \frac{A_i}{32\big(L_0 + L_1\|\nabla f(y^i)\|\big)}, \\ \sqrt{A_i} - \sqrt{A_{i-1}} &= \frac{a_i}{\sqrt{A_i} + \sqrt{A_{i-1}}} \underset{A_{i-1}\le A_i}{\ge} \frac{a_i}{2\sqrt{A_i}} \\ &= \frac{1}{2\sqrt{32\big(L_0 + L_1\|\nabla f(y^i)\|\big)}}. \end{aligned} \tag{B.12}$$

Кроме того, при $A_{i-1} > 0$

$$\frac{a_i}{A_i} \le -\log\Big(1 - \frac{a_i}{A_i}\Big) = \log\frac{A_i}{A_{i-1}}. \tag{B.13}$$

B.3 Невязка не больше 4ε: оценка по блокам

Первый способ подсчёта оценивает невязку после блока из N последовательных итераций через невязку в начале блока.

Лемма B.5 (оценка по блокам)**.**
Пусть $\|x^0 - x^*\| \le R$, алгоритм 4 запущен с $a_0 = 0$ и $r = R$, и итерации $k+1, \dots, k+N$, $N \ge 1$, прошли без срабатывания критерия остановки. Тогда

$$f(x^{k+N}) - f^* \le \frac{96L_0R^2}{N^2} + \frac{3072\,L_1^2R^2}{N^3}\big(f(x^k) - f^*\big). \tag{B.14}$$

Доказательство. Все суммы в доказательстве берутся по $i = k+1, \dots, k+N$.

▷ *Невязка через веса.* Имеем

$$\begin{aligned} f(x^{k+N}) - f^* &\underset{\text{(B.10)}}{\le} \frac{R^2}{2A_{k+N}} \le \frac{R^2}{2\big(\sqrt{A_{k+N}} - \sqrt{A_k}\big)^2} \\ &\underset{\text{(B.12)}}{\le} \frac{64R^2}{\Big(\sum_i \big(L_0 + L_1\|\nabla f(y^i)\|\big)^{-1/2}\Big)^2}. \end{aligned}$$

▷ *Неравенство Гёльдера.* С показателями 3/2 и 3

$$\begin{aligned} N &= \sum_i \big(L_0 + L_1\|\nabla f(y^i)\|\big)^{-1/3}\big(L_0 + L_1\|\nabla f(y^i)\|\big)^{1/3} \\ &\le \Big(\sum_i \big(L_0 + L_1\|\nabla f(y^i)\|\big)^{-1/2}\Big)^{2/3}\Big(\sum_i \big(L_0 + L_1\|\nabla f(y^i)\|\big)\Big)^{1/3}. \end{aligned}$$

Подставляя в предыдущую оценку, получаем

$$\begin{aligned} f(x^{k+N}) - f^* &\le \frac{64R^2}{N^3}\sum_i \big(L_0 + L_1\|\nabla f(y^i)\|\big) \\ &= \frac{64L_0R^2}{N^2} + \frac{64L_1R^2}{N^3}\sum_i \|\nabla f(y^i)\|. \end{aligned} \tag{B.15}$$

▷ *Сумма норм градиентов мала, если мала невязка.* Суммируя неравенства (B.11) по блоку, получаем

$$\sum_i \frac{\|\nabla f(y^i)\|^2}{L_0 + L_1\|\nabla f(y^i)\|} \le 8\big(f(x^k) - f^*\big).$$

По неравенству КБШ

$$\begin{aligned}\Big(\sum_i \|\nabla f(y^i)\|\Big)^2 &\le \sum_i \frac{\|\nabla f(y^i)\|^2}{L_0 + L_1\|\nabla f(y^i)\|} \cdot \sum_i \big(L_0 + L_1\|\nabla f(y^i)\|\big) \\ &\le 8\big(f(x^k) - f^*\big)\Big(NL_0 + L_1 \sum_i \|\nabla f(y^i)\|\Big).\end{aligned}$$

Если бы сумма $\sum_i \|\nabla f(y^i)\|$ превышала $\sqrt{8NL_0(f(x^k) - f^*)} + 8L_1(f(x^k) - f^*)$, то её квадрат превышал бы произведение этой величины на саму сумму, которое не меньше правой части последнего неравенства. Поэтому

$$\sum_i \|\nabla f(y^i)\| \le \sqrt{8NL_0\big(f(x^k) - f^*\big)} + 8L_1\big(f(x^k) - f^*\big).$$

▷ *Подстановка.* Подставим эту оценку в (B.15). Второе слагаемое в (B.15) станет не больше

$$\frac{64L_1R^2}{N^3}\sqrt{8NL_0\big(f(x^k) - f^*\big)} + \frac{512\,L_1^2R^2\big(f(x^k) - f^*\big)}{N^3}.$$

По неравенству между средним арифметическим и средним геометрическим первое из этих слагаемых не больше

$$\frac{32L_0R^2}{N^2} + \frac{256\,L_1^2R^2\big(f(x^k) - f^*\big)}{N^3}.$$

Поэтому

$$f(x^{k+N}) - f^* \le \frac{96L_0R^2}{N^2} + \frac{768\,L_1^2R^2\big(f(x^k) - f^*\big)}{N^3}.$$

Так как $768 \le 3072$, получаем (B.14). □

Оценка (B.14) объясняет, откуда берутся два слагаемых: первое — обычная скорость ускоренного метода, второе — цена нелинейности кривизны, пропорциональная невязке в начале блока. Если начальная невязка неизвестна и может быть экспоненциально большой, второе слагаемое бесполезно. Это препятствие обходится двумя способами: добавкой Ф, если известен только радиус (раздел 3), и положительным начальным весом, если известна оценка невязки (следующий подраздел).

B.4 Известная оценка невязки: положительный начальный вес

Пусть $\|x^0 - x^*\| \le R$ и известно число $\Delta > \varepsilon$, для которого $f(x^0) - f^* \le \Delta$. Запустим алгоритм 4 с параметрами

$$\begin{aligned} a_0 &= \frac{R^2}{2\Delta}, \\ r &= \sqrt{2}R, \\ \delta &= \varepsilon. \end{aligned} \tag{B.16}$$

Условие леммы B.4 с $R_0 = R$ и $\Delta_0 = \Delta$ выполнено, поскольку $R^2 + 2a_0\Delta = 2R^2 = r^2$.

Лемма B.6 (подсчёт при положительном начальном весе)**.**
Если K итераций алгоритма 4 с параметрами (B.16) прошли без срабатывания критерия остановки и $f(x^K) - f^* > \varepsilon$, то

$$K < 16\sqrt{\frac{L_0 R^2}{\varepsilon}} + 21\,(L_1 R)^{2/3} \log^{2/3} \frac{2\Delta}{\varepsilon}.$$

Доказательство. Правая часть (B.10) не больше $R^2/2 + R^2/2 = R^2$. Так как $f(x^K) - f^* > \varepsilon$, отсюда

$$\begin{gathered} A_K < \frac{R^2}{\varepsilon}, \\ \sum_{i=1}^{K} a_i^2 \|\nabla f(y^i)\|^2 \le 2R^2. \end{gathered} \tag{B.17}$$

Разделим итерации на две группы: с малым градиентом, $L_1\|\nabla f(y^i)\| \le L_0$, и с большим, $L_1\|\nabla f(y^i)\| > L_0$.

▷ *Итерации с малым градиентом.* Для них $L_0 + L_1\|\nabla f(y^i)\| \le 2L_0$, и по (B.12) каждая такая итерация увеличивает $\sqrt{L_0 A_i}$ не менее чем на $1/16$. Значит, их число не больше

$$16\sqrt{L_0 A_K} \underset{\text{(B.17)}}{<} 16\sqrt{\frac{L_0 R^2}{\varepsilon}}.$$

▷ *Итерации с большим градиентом.* Для них $L_0 + L_1\|\nabla f(y^i)\| < 2L_1\|\nabla f(y^i)\|$, поэтому

$$\begin{aligned} a_i\|\nabla f(y^i)\| &\underset{\text{(B.12)}}{=} \frac{A_i\|\nabla f(y^i)\|}{32\big(L_0 + L_1\|\nabla f(y^i)\|\big)a_i} \\ &> \frac{A_i}{64 L_1 a_i}. \end{aligned}$$

Отсюда и из (B.17)

$$\sum_{L_1\|\nabla f(y^i)\| > L_0} \Big(\frac{A_i}{a_i}\Big)^2 < (64L_1)^2 \cdot 2R^2 = 8192\, L_1^2 R^2.$$

Так как $A_{i-1} \ge a_0 > 0$, по (B.13)

$$\sum_{L_1\|\nabla f(y^i)\| > L_0} \frac{a_i}{A_i} \le \log \frac{A_K}{a_0} \underset{\text{(B.17), (B.16)}}{<} \log \frac{2\Delta}{\varepsilon}.$$

По неравенству Гёльдера с показателями 3 и 3/2 число итераций с большим градиентом равно

$$\begin{aligned} \sum_{L_1\|\nabla f(y^i)\| > L_0} \Big(\frac{A_i}{a_i}\Big)^{2/3} \Big(\frac{a_i}{A_i}\Big)^{2/3} &\le \Big(\sum \Big(\frac{A_i}{a_i}\Big)^2\Big)^{1/3} \Big(\sum \frac{a_i}{A_i}\Big)^{2/3} \\ &< (8192\, L_1^2 R^2)^{1/3} \log^{2/3} \frac{2\Delta}{\varepsilon} \\ &< 21\,(L_1 R)^{2/3} \log^{2/3} \frac{2\Delta}{\varepsilon}. \end{aligned}$$

□

B.5 Итоговые верхние оценки

Теорема B.7 (верхние оценки при ограниченной начальной невязке)**.**
Пусть $f \in \mathcal{F}^d_{L_0,L_1}$, $\|x^0 - x^*\| \le R$ и $\varepsilon > 0$.

(а) Если $f(x^0) - f^* \le 4\varepsilon$, то алгоритм 4 с $a_0 = 0$, $r = R$, $\delta = \varepsilon$,

$$m = \left\lceil \log_2\Big(128\Big(1 + \frac{L_0R^2}{\varepsilon} + L_1R\Big)^2\Big)\right\rceil$$

и числом итераций

$$\begin{aligned} K &= \max\Big\{1, \Big\lceil\sqrt{\frac{192L_0R^2}{\varepsilon}}\Big\rceil, \lceil(24576\,L_1^2R^2)^{1/3}\rceil\Big\} \\ &\le 3 + 14\sqrt{\frac{L_0R^2}{\varepsilon}} + 30(L_1R)^{2/3} \end{aligned}$$

выдаёт точку с невязкой по функции не больше ε, сделав не более $K(m+2)$ обращений к оракулу.

(б) Если известно число $\Delta > \varepsilon$ с $f(x^0) - f^* \le \Delta$, то алгоритм 4 с параметрами (B.16),

$$m = \left\lceil \log_2\Big(128\Big(1 + \frac{2L_0R^2}{\varepsilon} + \sqrt{2}L_1R\Big)^2\Big)\right\rceil$$

и числом итераций

$$K = \left\lceil 16\sqrt{\frac{L_0R^2}{\varepsilon}} + 21\,(L_1R)^{2/3}\log^{2/3}\frac{2\Delta}{\varepsilon}\right\rceil$$

выдаёт такую точку, сделав не более $K(m+2)$ обращений к оракулу. При $\Delta \le \varepsilon$ достаточно вернуть x^0.

В обоих случаях метод использует только градиенты и не использует значение f^*. В случае (а) он не использует и оценку начальной невязки.

Доказательство.

▷ *Пункт (а).* Если сработал критерий остановки, выход корректен по лемме 3.3. Иначе оценка (B.14) с $k = 0$ и $f(x^0) - f^* \le 4\varepsilon$ даёт

$$f(x^K) - f^* \le \frac{96L_0R^2}{K^2} + \frac{3072\,L_1^2R^2\cdot 4\varepsilon}{K^3} \underset{\text{(а)}}{\le} \frac{\varepsilon}{2} + \frac{\varepsilon}{2},$$

где (а) — выбор K. Оценка для K следует из неравенств $\sqrt{192} < 14$ и $24576^{1/3} < 30$.

▷ *Пункт (б).* При $\Delta \le \varepsilon$ возвращаем x^0. Иначе по лемме B.6 после K итераций либо сработал критерий остановки и выход корректен по лемме 3.3, либо $f(x^K) - f^* \le \varepsilon$.

В обоих пунктах число обращений не больше $K(m+2)$. □

Число шагов поиска $m + 2$ растёт лишь логарифмически по L_0R^2/ε и L_1R, поэтому теорема даёт для класса с начальной невязкой не больше 4ε и для класса с известной оценкой начальной невязки Δ соответственно оценки

$$O\Big(\Big[1 + \sqrt{\frac{L_0R^2}{\varepsilon}} + (L_1R)^{2/3}\Big]\log\Big(2 + \frac{L_0R^2}{\varepsilon} + L_1R\Big)\Big),$$
$$O\Big(\Big[1 + \sqrt{\frac{L_0R^2}{\varepsilon}} + (L_1R)^{2/3}\log^{2/3}\frac{2\Delta}{\varepsilon}\Big]\log\Big(2 + \frac{L_0R^2}{\varepsilon} + L_1R\Big)\Big).$$

В случае (б) перед запуском Δ можно заменить на минимум из Δ и правой части (A.3). Вместе с теоремой B.3 первая оценка даёт при $L_0 R^2 \geq \varepsilon$

$$1 + \mathcal{N}(\mathcal{P}_{4\varepsilon}) = \widetilde{\Theta}\Big(1 + \sqrt{\frac{L_0 R^2}{\varepsilon}} + (L_1 R)^{2/3}\Big).$$

Совпадающая с (б) нижняя оценка при Δ между 4ε и правой частью (A.3) неизвестна.

C Фиксированная размерность

Нижние оценки раздела 4 используют растущую размерность. Покажем, что это существенно: в фиксированной размерности метод центров тяжести решает задачу при фиксированной нормированной точности $L_1^2\varepsilon/L_0$ за число обращений, логарифмическое по $L_1 R$.

Функция $t \mapsto e^t - 1 - t$ строго возрастает на $[0, \infty)$ от 0 до $+\infty$. Поэтому однозначно определено число $\rho_\varepsilon > 0$ — радиус шара вокруг точки минимума, в котором оценка роста леммы A.2 не превосходит ε:

$$\frac{L_0}{L_1^2}\big(e^{L_1\rho_\varepsilon} - 1 - L_1\rho_\varepsilon\big) = \varepsilon. \tag{C.1}$$

Предложение C.1 (метод центров тяжести)**.**
Пусть $L_0, L_1, R, \varepsilon > 0$ и размерность d фиксирована. Класс $\mathcal{P}_{\mathrm{R}}$ в размерности d решается методом центров тяжести за

$$1 + \Big\lfloor \frac{d \log\big(2\sqrt{d}\, R/\min\{R, \rho_\varepsilon\}\big)}{-\log(1 - 1/e)} \Big\rfloor \tag{C.2}$$

обращений к оракулу, то есть за

$$O\Big(d \log\Big(2\sqrt{d} \max\Big\{1, \frac{R}{\rho_\varepsilon}\Big\}\Big)\Big)$$

обращений. В размерности $d = 1$ метод деления отрезка пополам использует не более

$$\Big\lceil \max\Big\{\log_2 \frac{R}{\rho_\varepsilon},\, 0\Big\} \Big\rceil \tag{C.3}$$

обращений. Если выход обязан совпадать с точкой обращения к оракулу, достаточно добавить одно обращение.

При фиксированных d и $L_1^2\varepsilon/L_0$ величина $L_1\rho_\varepsilon$ постоянна, и оценка (C.2) имеет порядок $\log(2 + L_1 R)$. Многомерный метод центров тяжести выбирает выход по значениям функции. Метод деления отрезка пополам использует только знаки производной.

Доказательство.

▷ *Шар точек с малой невязкой.* По лемме A.2 для каждого x

$$f(x) - f^* \leq \frac{L_0}{L_1^2}\big(e^{L_1\|x - x^*\|} - 1 - L_1\|x - x^*\|\big). \tag{C.4}$$

Следовательно, в шаре $B(x^*, \min\{R, \rho_\varepsilon\})$ невязка по функции не больше ε.

▷ *Метод центров тяжести.* Без ограничения общности $x^0 = 0$. Начнём с куба $K_0 = [-2R, 2R]^d$. Он содержит шар $B(x^*, \min\{R, \rho_\varepsilon\})$, поскольку $\|x^*\| \leq R$. На

шаге k вычислим центр тяжести c_k многогранника K_{k-1} и обратимся к оракулу в этой точке. Если $\nabla f(c_k) = 0$, то c_k — точка минимума. Иначе положим

$$K_k = K_{k-1} \cap \{z : \ \langle \nabla f(c_k), z - c_k \rangle \le 0\}.$$

После заданного числа шагов вернём точку обращения с наименьшим значением функции. Вычисления центров тяжести между обращениями к оракулу не учитываются.

▷ *Шар сохраняется.* Пусть во всех первых N точках обращения невязка по функции больше ε. Для всякой точки z шара $B(x^*, \min\{R, \rho_\varepsilon\})$ из выпуклости и (C.4)

$$\langle \nabla f(c_k), z - c_k \rangle \le f(z) - f(c_k) < 0.$$

Значит, весь шар сохраняется после каждого отсечения.

▷ *Сравнение объёмов.* По теореме Грюнбаума (Grünbaum, 1960) всякая гиперплоскость, проходящая через центр тяжести выпуклого тела, оставляет в каждом из двух полупространств не менее $1/e$ его объёма. Единичный шар содержит куб $[-1/\sqrt{d}, 1/\sqrt{d}]^d$, поэтому его объём не меньше $(2/\sqrt{d})^d$. Следовательно,

$$\begin{aligned} \Big(\frac{2\min\{R, \rho_\varepsilon\}}{\sqrt{d}}\Big)^d &\underset{\text{(а)}}{\le} \operatorname{vol}(K_N) \\ &\underset{\text{(б)}}{\le} \Big(1 - \frac{1}{e}\Big)^N (4R)^d, \end{aligned}$$

где (а) — сохранение шара, (б) — теорема Грюнбаума. При N, равном (C.2), правая часть строго меньше левой. Это противоречие показывает, что хотя бы одна из точек обращения к оракулу имеет невязку не больше ε.

▷ *Одномерный случай.* Начнём с отрезка $[-R, R]$. На каждом шаге обращаемся к оракулу в середине текущего отрезка. Если производная в ней положительна, оставляем левую половину, если отрицательна — правую, а при нулевой производной найден точный минимум. Монотонность производной выпуклой функции гарантирует, что точка минимума остаётся в отрезке. После n обращений середина $\hat{x}$ оставшегося отрезка удовлетворяет неравенствам

$$\begin{aligned} |\hat{x} - x^*| \ &\le \ R\,2^{-n}, \\ f(\hat{x}) - f^* &\underset{\text{(C.4)}}{\le} \frac{L_0}{L_1^2}\big(e^{L_1 R 2^{-n}} - 1 - L_1 R\,2^{-n}\big). \end{aligned}$$

При n, равном (C.3), имеем $R2^{-n} \le \rho_\varepsilon$, и правая часть не больше ε. В выходной середине к оракулу могли не обращаться. Если выход должен совпадать с точкой обращения, нужно ещё одно обращение. □

Замечание C.2.
При фиксированных d и $L_1^2\varepsilon/L_0$ предложение C.1 даёт лишь $O(\log(2 + L_1 R))$ обращений. Поэтому нижняя оценка, линейная по $L_1 R$ с точностью до логарифмов, не может быть реализована семейством фиксированной размерности. Ей необходим механизм сокрытия информации в числе направлений, растущем вместе с числом обращений. Именно поэтому в теоремах B.3 и 4.10 используется размерность порядка длины цепочки.

D Сводная таблица известных оценок

В таблице 2 собраны известные верхние оценки для выпуклого детерминированного случая. Здесь $R = \|x^0 - x^*\|$, $F_0 = f(x^0) - f^*$, запись $O(\cdot)$ скрывает абсолютные константы, $\widetilde{O}(\cdot)$ — ещё и логарифмические множители. В столбце «Гл.» sym обозначает симметричную (L_0, L_1)-гладкость (определение 2.1), asym — локальную несимметричную гладкость, ℓ — гладкость с общей функцией $\ell(\|\nabla f\|)$, (H_0, H_1) — условие $\|\nabla^2 f\| \le H_0 + H_1(f - f^*)$.

Таблица 2. Выпуклый детерминированный случай: число обращений до $f(\hat{x}) - f^* \le \varepsilon$.

Работа	Гл.	Метод	Сложность
Koloskova et al. (2023)	sym + L-гл.	clipped GD	$O\big(\frac{L_0R^2}{\varepsilon} + L_1R^2\sqrt{\frac{L}{\varepsilon}}\big)^a$
Takezawa et al. (2024)	sym + L-гл.	GD с шагом Поляка	$O\big(\frac{L_0R^2}{\varepsilon} + L_1R^2\sqrt{\frac{L}{\varepsilon}}\big)^a$
Li et al. (2023)	ℓ	GD	$O\big(\frac{\ell(G)R^2}{\varepsilon}\big)$, $G = \|\nabla f(x^0)\|^f$
Li et al. (2023)	ℓ	быстрый градиентный метод	$O\big((1 + L_1^2R^2 + \frac{L_1^2F_0}{L_0})\sqrt{\frac{F_0+L_0R^2}{\varepsilon}}\big)^g$
Gorbunov et al. (2025)	sym	(L_0, L_1)-GD, GD с шагом Поляка	$O\big(\frac{L_0R^2}{\varepsilon} + L_1^2R^2\big)$
Gorbunov et al. (2025)	sym	(L_0, L_1)-STM	$O\Big(\sqrt{(1 + L_1Re^{L_1R})\frac{L_0R^2}{\varepsilon}}\Big)$
Vankov et al. (2025)	sym	GD (три правила шага), clipping	$O\big(\frac{L_0R^2}{\varepsilon} + L_1R\log\frac{F_0}{\varepsilon}\big)$
Vankov et al. (2025)	sym	нормированный GD, GD с шагом Поляка	$O\big(\frac{L_0R^2}{\varepsilon} + L_1^2R^2\big)$
Vankov et al. (2025)	sym	AGMsDR^h	$O\Big(\sqrt{\frac{L_0R^2}{\varepsilon}} + (L_1R)^{2/3}\log\frac{F_0}{\varepsilon}\Big)$ итераций
Lobanov et al. (2025)	asym	GD, clipped GD	$O\big(\frac{L_0R^2}{\varepsilon} + L_1R\log\frac{F_0}{\varepsilon}\big)$
Lobanov et al. (2025)	asym	нормированный GD	$O\big(\big(\frac{L_0R^2}{\varepsilon} + L_1R\big)\log\frac{F_0}{\varepsilon}\big)$
Tyurin (2025)	ℓ	GD с шагом $\int_0^1 \frac{dv}{\ell(\|\nabla f(x^k)\|(1+v))}$	$O\big(\frac{L_0R^2}{\varepsilon} + \min\big\{L_1R\sqrt{\frac{F_0}{\varepsilon}}, L_1^2R^2, \frac{L_1\|\nabla f(x^0)\|R^2}{\varepsilon}\big\}\big)$
Krivchenko (2026)	sym	GD, PEP	уточнение констант в оценке с $L_1R\log\frac{F_0}{\varepsilon}$
Oikonomidis et al. (2025)	анизотропная	нелинейно предобусловленный GD	$O(\mathcal{D}_0/\varepsilon)$, $\mathcal{D}_0$ — супремум по подуровневому множеству
Kovalev and Stonyakin (2026)	sym	GD с шагом Поляка и неточным нормированным градиентом	$O\big(\frac{ML_0R^2}{\varepsilon} + \frac{ML_1^2R^2}{c}\big)^k$
Tyurin (2026)	ℓ	ускоренный метод	$O\Big(\sqrt{\frac{L_0R^2}{\varepsilon}} + L_1R\log_+\min\big\{\frac{L_1^2F_0}{L_0}, \frac{F_0}{\varepsilon}\big\}\Big)^i$
Borodich and Kovalev (2026)	sym	GRAAL с ускорением	$O\big(1 + \sqrt{\frac{L_0R^2}{\varepsilon}} + (L_1R)^3\big)^j$
Lobanov (2026)	(H_0, H_1)	ускоренный, маломерная релаксация, рестарты	$\widetilde{O}\Big(\sqrt{\frac{H_0\tilde{R}^2}{\varepsilon}} + \sqrt{H_1\tilde{R}^2}\log\frac{F_0}{\varepsilon}\Big)^l$
Эта статья (теорема 3.7)	sym	ускоренный, неточный одномерный поиск	$5\sqrt{\frac{L_0R^2}{\varepsilon}} + O\big((1 + L_1R)\log(2 + L_1R)\big)$

a: выведено нами из теоремы ($c = L_0/L_1$, дополнительно предполагается L-гладкость). f: при условии на радиус из определения (r, ℓ)-гладкости. g: пересчёт из Vankov et al. (2025). h: каждая итерация содержит точную одномерную минимизацию. i: плюс член, зависящий от инициализации. j: при начальном шаге $\eta_0 = e^{-L_1R}/L_0$, полная оценка содержит ещё $(1 + (L_1R)^2)\log(1/(\eta_0L_0))$. k: M — оценка нормы градиента на траектории, $0 < c < \min\{\varepsilon/R, L_0/L_1\}$, ошибка градиента достаточно мала. l: $\tilde{R}$ — радиус начального подуровневого множества вокруг x^*.