«Спуск с Эвереста», часть II
Оракульная сложность минимизации суммы выпуклых (L_0, L_1)-гладких функций*

Михаил Рудоманов♠▲ Иван Фомин♣▲
Александр Владимирович Гасников† Федор Сергеевич Стонякин‡

Аннотация. Рассматривается минимизация среднего n выпуклых (L_0, L_1)-гладких функций: норма гессиана каждой из них ограничена аффинной функцией нормы её градиента. Предполагаются известными верхняя граница R расстояния от начальной точки до точки минимума и верхняя граница δ разности между минимумом среднего и средним значением инфимумов слагаемых. Получены верхняя и нижняя оценки оракульной сложности достижения точности ε по функции в среднем. С точностью до логарифмических множителей обе оценки имеют порядок

$$n\big(1 + (L_1 R)^{2/3}\big) + \sqrt{\frac{n(L_0 + L_1^2\delta)R^2}{\varepsilon} + n(L_1 R)^2}.$$

Верхняя оценка достигается предложенным методом YETI. Метод использует идеи ускоренных проксимальных методов и методов уменьшения дисперсии, а также эвристику для выбора дополнительных точек. Число обращений эвристики к оракулу ограничено, что позволяет сохранить верхнюю оценку общего числа запросов до достижения нужной точности. В экспериментах YETI сравнивается с методами первого порядка на синтетических задачах и задачах пуассоновской регрессии. Отдельно проверяются критерий остановки и влияние эвристики. Нижняя оценка получена явным построением семейств задач, трудных для любого метода первого порядка.

Ключевые слова: (L_0, L_1)-гладкость, обобщённая гладкость, минимизация суммы функций, оракульная сложность, нижние оценки, ускоренные методы, уменьшение дисперсии.

Использование языковых моделей. При получении теоретических результатов настоящей работы использовались модели *Codex Astra 6* и *Claude Opus 5.5*. Они также применялись при подготовке и вёрстке рукописи и для перевода исходного текста на английский язык. Однако каждая строка статьи, включая каждое утверждение, каждое доказательство и каждое вычисление, лично отредактирована и проверена авторами. Ответственность за корректность всех математических утверждений, доказательств и выводов несут исключительно авторы работы.

1 Введение

Мы рассматриваем задачу минимизации суммы функций

$$f(x) = \frac{1}{n}\sum_{i=1}^{n} f_i(x) \to \min_{x\in\mathbb{R}^d}.$$

*Английская версия статьи: https://arxiv.org/abs/2611.04171.

♠MIRIAI, Moscow Independent Research Institute of Artificial Intelligence, Москва, Россия. rudomanov.ma@phystech.edu.
▲Равный вклад.
♣Яндекс, Москва, Россия. ash-ivanfomin@yandex-team.ru.
†Университет Иннополис, Иннополис, Россия. gasnikov@yandex.ru.
‡КФУ им. В. И. Вернадского, Симферополь, Россия. fedyor@mail.ru.

Задачи такого вида возникают при минимизации эмпирического риска в машинном обучении, где f_i — функция потерь на i-м объекте обучающей выборки (Shalev-Shwartz and Ben-David, 2014, Bottou et al., 2018). В федеративном и распределённом обучении слагаемое f_i — это функция потерь на данных i-го устройства или вычислительного узла (McMahan et al., 2017). Градиент одного слагаемого часто вычисляется существенно дешевле полного градиента. Поэтому сложность методов мы измеряем числом обращений к оракулу, который возвращает значение и градиент одного слагаемого.

Для суммы L-гладких функций число обращений к оракулу позволяют сократить методы уменьшения дисперсии (Johnson and Zhang, 2013, Xiao and Zhang, 2014). Они периодически вычисляют полный градиент f, а на остальных шагах используют градиенты отдельных слагаемых f_i. Нижние оценки для произвольных рандомизированных методов показывают, какие зависимости от числа слагаемых и точности улучшить нельзя (Woodworth and Srebro, 2016).

Однако условие L-гладкости не выполняется, например, для экспоненциальных функций потерь. Условие (L_0, L_1)-гладкости введено в работе Zhang et al. (2020), чтобы объяснить успех методов с клиппированием градиента. При обучении языковой модели на основе LSTM авторы заметили, что локальная константа гладкости растёт вместе с нормой градиента. Аналогичная зависимость обнаружена и при обучении трансформеров (Crawshaw et al., 2022). Условие (L_0, L_1)-гладкости как раз допускает такой рост кривизны. Его обобщения и методы первого порядка для таких функций изучались в работах Li et al. (2023), Gorbunov et al. (2025), Vankov et al. (2025), Tyurin (2025). Для конечных сумм нужно учитывать одновременно и число слагаемых, и рост кривизны. Например, в пуассоновской регрессии с логарифмической функцией связи (Stan Development Team) $f_i(x) = \exp(a_i^\top x) - b_i a_i^\top x$, где $b_i \geq 0$, гессиан не ограничен на всём пространстве, но

$$\|\nabla^2 f_i(x)\| \leq b_i \|a_i\|^2 + \|a_i\| \|\nabla f_i(x)\|.$$

В задаче восстановления фазы по измерениям интенсивности используются потери $f_i(x) = (\langle a_i, x\rangle^2 - b_i)^2$ (Candès et al., 2015). Здесь также приходится минимизировать конечную сумму слагаемых с неограниченной кривизной. Ещё один пример — экспоненциальные потери в задаче классификации (Gorbunov et al., 2025, пример 1.5). Во всех этих задачах при большом числе наблюдений вычислять полный градиент может быть дорого, а сам градиент не является глобально липшицевым. Поэтому нужны методы, которые учитывают рост кривизны и не вычисляют градиенты всех слагаемых на каждом шаге. Ниже предполагается, что функция f достигает минимума, а расстояние до точки минимума, начальная невязка и неоднородность слагаемых ограничены.

Особенность суммы функций. В рассматриваемой задаче каждое слагаемое удовлетворяет неравенству

$$0 \preceq \nabla^2 f_i(x) \preceq \big(L_{0,i} + L_1 \|\nabla f_i(x)\|\big) I.$$

Даже в точке минимума среднего градиенты отдельных слагаемых могут быть большими: равенство $\nabla f(x^*) = 0$ означает лишь, что их сумма равна нулю. Поэтому малость нормы полного градиента не влечёт малости констант гладкости слагаемых, от которых зависят оценки методов уменьшения дисперсии. Какова оракульная сложность минимизации суммы в этой ситуации? Мы отвечаем на этот вопрос в настоящей работе.

Обозначения. Через $\varepsilon > 0$ обозначается требуемая точность решения задачи по функции: метод должен выдать точку $\hat{x}$, для которой $f(\hat{x}) - f^* \leq \varepsilon$. Знак $\|\cdot\|$ всюду означает

евклидову норму вектора и спектральную норму матрицы, $[x, y]$ — отрезок с концами $x, y \in \mathbb{R}^d$, $B(x, r)$ — замкнутый шар радиуса r с центром x. Сумму первых k членов последовательности мы обозначаем соответствующей заглавной буквой: например, $A_k = a_1 + \cdots + a_k$ и $A_0 = 0$.

Для рандомизированных методов указанная точность требуется в математическом ожидании. Все проекции евклидовы; через Π_C обозначается проекция на непустое замкнутое выпуклое множество C.

Основной результат. Пусть слагаемые выпуклы, дважды непрерывно дифференцируемы и ограничены снизу, а $n^{-1}\sum_i L_{0,i} \le L_0$. Начальную точку x_0 будем считать нулевой: этого можно добиться сдвигом, относительно которого класс задач инвариантен. Предполагается, что f достигает минимума в точке x^*, причём $\|x^*\| \le R$ и $f(0) - f^* \le \Delta$. При условиях теоремы 2.9 верхняя и нижняя оценки сложности имеют, с точностью до логарифмических множителей, порядок

$$n\bigl(1 + (L_1 R)^{2/3}\bigr) + \sqrt{\frac{n(L_0 + L_1^2\delta)R^2}{\varepsilon} + n(L_1 R)^2}.$$

Здесь под сложностью понимается математическое ожидание числа запросов значений и градиентов отдельных слагаемых в худшем случае, достаточного для выполнения $\mathbb{E}[f(\hat{x}) - f^*] \le \varepsilon$. Нижняя оценка справедлива для произвольных рандомизированных методов; размерность задачи при этом не ограничена. Точное определение класса и логарифмические множители приведены в разделе 2.

Замечание о логарифмических множителях. В верхней оценке скрыт множитель $\log^2 N$, где N из (2.5) растёт линейно по Δ/ε. В худшем случае, когда Δ экспоненциально велико по $L_1 R$, этот логарифм может иметь порядок $L_1 R$, так что множитель $\log^2 N$ может иметь порядок $(L_1 R)^2$, то есть давать дополнительный полиномиальный множитель.

Слагаемое $\sqrt{nL_0R^2/\varepsilon}$ известно из теории минимизации суммы L-гладких функций (Woodworth and Srebro, 2016). Слагаемое $n(L_1R)^{2/3}$ отражает число обращений к оракулу, необходимое, чтобы приблизиться к минимуму из области, где градиенты экспоненциально велики. Слагаемое

$$\sqrt{\frac{nL_1^2R^2\delta}{\varepsilon} + n(L_1R)^2}$$

возникает из-за того, что кривизна слагаемых вблизи минимума определяется их градиентами, которые могут оставаться большими даже в точке минимума среднего.

Метод и эксперименты. Верхнюю оценку достигает метод YETI. При малой локальной кривизне он выполняет ускоренный шаг, решая вспомогательную задачу методом SVRG, а при большой — проецирует вспомогательную точку на полупространство, содержащее точку минимума. Кроме того, YETI использует эвристику с ограниченным числом запросов к оракулу: она позволяет воспользоваться удачными предложенными точками, не ухудшая теоретическую оценку. В экспериментах YETI сравнивается с другими методами и проверяется его критерий остановки.

Связь с известными методами. YETI использует ускоренную проксимальную схему Монтейро–Свайтера (Monteiro and Svaiter, 2013) и идею адаптивного выбора регуляризации без решения неявного уравнения на каждом шаге (Carmon et al., 2022). Локальная

задача решается проекционным вариантом SVRG. Ускорение за счёт приближённого решения регуляризованных задач изучалось также в схеме Catalyst (Lin et al., 2015, 2018) и в работе Frostig et al. (2015). В YETI выбор шага зависит от вычисляемой оценки кривизны суммы: если эта оценка слишком велика, метод вместо шага строит отделяющее полупространство. Оценка сложности учитывает запросы и локального решателя, и эвристики.

Нижняя оценка опирается на принцип Яо (Yao, 1977): трудная задача выбирается случайно из конечного семейства, после чего проводится усреднение по случайным величинам алгоритма. Скрытые координаты и распределение информации по разным слагаемым продолжают известный подход к построению нижних оценок для задач минимизации суммы (Woodworth and Srebro, 2016). Для рассматриваемого класса мы применяем экспоненциальные преобразования выпуклых цепочек и выбираем их параметры так, чтобы выполнялись ограничения на L_1, δ и начальную невязку.

Настоящая статья продолжает нашу предыдущую работу Rudomanov et al. (2026), в которой оракульная сложность этого класса найдена для одной функции ($n = 1$): её порядок равен $\sqrt{L_0R^2/\varepsilon} + L_1R$, а при малой начальной невязке — $\sqrt{L_0R^2/\varepsilon} + (L_1R)^{2/3}$. Здесь рассматривается сумма функций, а оракул возвращает значение и градиент лишь одного слагаемого, поэтому для получения верхней оценки мы используем уменьшение дисперсии. Результаты для одной функции (Vankov et al., 2025, Tyurin, 2026) относятся к оракулу, вычисляющему полный градиент. В частности, оптимальность метода Tyurin (2026) при достаточно малых ε основана на классической нижней оценке для гладкого подкласса и касается только ведущего члена $\sqrt{L_0R^2/\varepsilon}$. Оптимальность слагаемого $n(L_1R)^{2/3}$ для оракула, возвращающего градиент одного слагаемого, из неё не вытекает. Аналогично, оценки для стохастических методов в случае общей точки минимума всех слагаемых (Gorbunov et al., 2025) не охватывают произвольную положительную неоднородность δ.

Организация работы. Постановка задачи и основной результат приведены в разделе 2, метод YETI и его анализ — в разделах 3–5, основные эксперименты — в разделе 6 (дополнительные эксперименты и их детали — в приложении I), нижняя оценка — в разделе 7. В основном тексте приведены результаты и схема доказательства нижней оценки, а вспомогательные доказательства и варианты метода вынесены в приложения. Сводная таблица известных оценок приведена в приложении J.

2 Постановка задачи и основные оценки

Рассматривается функция $f = n^{-1}\sum_{i=1}^n f_i$ на $\mathbb{R}^d$. Заданы $n \geq 2$, $L_0, \delta \geq 0$ и $L_1, R, \Delta, \varepsilon > 0$. Начальную точку считаем нулевой; этого можно добиться сдвигом координат. Все общие предположения собраны ниже.

Предположение 2.1 (компоненты).
Функции $f_i : \mathbb{R}^d \to \mathbb{R}$, $1 \leq i \leq n$, выпуклы, дважды непрерывно дифференцируемы и ограничены снизу.

Предположение 2.2 (обобщённая гладкость).
Известны числа $L_{0,i} \geq 0$, для которых

$$\|\nabla^2 f_i(x)\| \leq L_{0,i} + L_1\|\nabla f_i(x)\| \quad (x \in \mathbb{R}^d,\ 1 \leq i \leq n),$$
$$\frac{1}{n}\sum_{i=1}^{n} L_{0,i} \leq L_0. \tag{2.1}$$

Предположение 2.3 (точка минимума).
Существует точка минимума $x^* \in \arg\min f$, для которой $\|x^*\| \leq R$. Обозначим $f^* = f(x^*)$.

Предположение 2.4 (начальная невязка).
Выполнено $f(0) - f^* \leq \Delta$, причём $\Delta \geq 2\varepsilon$.

Предположение 2.5 (неоднородность).

$$f^* - \frac{1}{n}\sum_{i=1}^{n} \inf_{x\in\mathbb{R}^d} f_i(x) \leq \delta. \tag{2.2}$$

Предположение 2.6 (диапазон точностей).

$$\frac{L_1^2 R^2 \delta}{\varepsilon} \geq 3. \tag{2.3}$$

Определение 2.7 (класс задач).
Через $\mathcal{P}_d$ обозначим множество наборов функций $f_1, \ldots, f_n : \mathbb{R}^d \to \mathbb{R}$ и известных чисел $L_{0,1}, \ldots, L_{0,n}$, удовлетворяющих предположениям 2.1–2.5.

Предположение 2.2 ограничивает только среднее чисел $L_{0,i}$; отдельные $L_{0,i}$ могут превышать L_0. Нижнюю оценку достаточно построить на подклассе $L_{0,i} = L_0$. Для C^2-функций ограничение на гессиан из предположения 2.2 эквивалентно симметричной $(L_{0,i}, L_1)$-гладкости (Gorbunov et al., 2025, предположение 1.3, формула (5)):

$$\|\nabla f_i(x) - \nabla f_i(y)\| \leq \Big(L_{0,i} + L_1 \sup_{z\in[x,y]} \|\nabla f_i(z)\|\Big)\|x - y\|.$$

Предположение 2.5 не требует знать ни f^*, ни инфимумы компонент. Предположение 2.6 гарантирует, что в трудной задаче со скрытой парой функций из раздела 7 начальная невязка больше требуемой точности (лемма D.5).

Модель оракула. Алгоритму известны параметры задачи и числа $L_{0,i}$. Информацию о функциях он получает только от оракула, возвращающего $(f_i(x), \nabla f_i(x))$ на запрос (i, x). Запросы разрешены во всём $\mathbb{R}^d$. Точки запросов, момент остановки и выдаваемый ответ являются измеримыми функциями от полученных ответов оракула и случайных величин алгоритма. Сложность измеряется числом обращений к оракулу (Nesterov, 2018,

раздел 1.1). Вычисление значения функции и полного градиента в одной точке требует n запросов.

Определение 2.8 (оракульная сложность).
Пусть $\tau_{\mathsf{M}}(p)$ — число обращений алгоритма M к оракулу на входе p, а $\hat{x}_{\mathsf{M}}(p)$ — его ответ. Алгоритм называется корректным, если для любых d и $p \in \mathcal{P}_d$ он почти наверное останавливается и

$$\mathbb{E}\big[f(\hat{x}_{\mathsf{M}}(p)) - f^*\big] \le \varepsilon.$$

Сложность алгоритма на классе и минимаксная сложность определяются как

$$\begin{aligned} \mathcal{T}(\mathsf{M}) &= \sup_{d \ge 1} \sup_{p \in \mathcal{P}_d} \mathbb{E}\tau_{\mathsf{M}}(p), \\ \mathcal{T}^* &= \inf_{\mathsf{M}\ \text{корректный}} \mathcal{T}(\mathsf{M}). \end{aligned} \tag{2.4}$$

Для оценки числа запросов положим

$$N_0 = 4 + n + \frac{(L_0 + L_1^2\delta)R^2}{\varepsilon} + (L_1 R)^2, \qquad N = N_0 - 2 + \frac{\Delta}{\varepsilon}. \tag{2.5}$$

Для неотрицательных величин запись $a \lesssim b$ означает $a \le Cb$ с абсолютной постоянной C, не зависящей от параметров задачи, размерности и алгоритма. Пишем $a \sim b$, если $a \lesssim b \lesssim a$. Обозначения O и Ω используются в том же равномерном смысле, а $\widetilde{\Theta}$ скрывает также степени $\log N$. В нижней оценке используется величина N_0, не зависящая от Δ, а в верхней — величина N, которая по предположению 2.4 не меньше N_0. Положим

$$T_0 = n\big(1 + (L_1 R)^{2/3}\big) + \sqrt{\frac{n(L_0 + L_1^2\delta)R^2}{\varepsilon} + n(L_1 R)^2}. \tag{2.6}$$

Теорема 2.9 (двусторонняя оценка сложности).
При предположениях 2.1–2.6 выполнено

$$\frac{T_0}{\log^2 N_0} \lesssim \mathcal{T}^* \lesssim T_0 \log^2 N. \tag{2.7}$$

Верхняя оценка достигается методом YETI, в том числе при различных $L_{0,i}$. Нижняя оценка верна уже при $L_{0,i} = L_0$.

Верхняя оценка доказана в теореме 5.1, нижняя — в теореме 7.1. Доказательства приведены в приложениях C и E. Вопрос об устранении разрыва в логарифмических множителях остаётся открытым.

3 Метод YETI

YETI сочетает ускоренный проксимальный метод с эвристикой. Эвристика предлагает точку $z \in B(0, R)$, опираясь на историю запросов. Метод принимает её, если $f(z) \le f(x)$. В одном эвристическом блоке допускается не более $n\lceil \log N \rceil$ запросов к оракулу, включая проверку предложенных точек. Если блок не завершил работу метода, выполняется основная итерация (рис. 1).



Рис. 1. Схема метода YETI.

Ускоренный шаг и отсечение. По градиентам компонент в точке y вычислим оценку кривизны

$$\ell(y) = \frac{1}{n}\sum_i \big(L_{0,i} + L_1\|\nabla f_i(y)\|\big).$$

По лемме G.2 выполнены неравенства

$$\|\nabla^2 f(y)\| \le \ell(y) \le \tfrac{3}{2}L_0 + 2L_1^2\big(\delta + f(y) - f^*\big), \qquad \ell(z) \le e^{L_1\|z-y\|}\ell(y).$$

Если величина $\ell(y)$ мала, то в шаре радиуса $r = \min\{R, 1/(2L_1)\}$ можно решить регуляризованную задачу методом SVRG и выполнить ускоренный шаг. Если же проверка кривизны не пройдена, то из верхней границы для $\ell(y)$ следует нижняя оценка невязки $f(y) - f^*$. В силу выпуклости (предположение 2.1) $\langle \nabla f(y), x^* - y\rangle \le -(f(y) - f^*)$, поэтому эта оценка задаёт полупространство $\mathcal{H}_y$, содержащее точку минимума. Проекция вспомогательной точки v на это полупространство приближает её к x^*.

Остановка. В силу предположений 2.1 и 2.3 каждое вычисление $f(p)$ и $\nabla f(p)$ даёт нижнюю оценку

$$\widetilde{f}(p) = f(p) - \langle \nabla f(p), p\rangle - R\|\nabla f(p)\| \le f^*.$$

Подпрограмма Оценка хранит максимум $\widetilde{f}_{\text{best}}$ таких оценок и лучшую найденную точку $w_{\text{best}} \in B(0,R)$. Если $f(w_{\text{best}}) - \widetilde{f}_{\text{best}} \le \varepsilon/2$, метод останавливается и возвращает w_{best}. Уже полученные ответы компонент повторно не запрашиваются.

Алгоритм 1 хранит точки x, v, вес $\mathcal{A}$ и параметр h, по которому выбирается регуляризация. Границы $\lambda_\downarrow(\mathcal{A})$ и $\lambda_\uparrow$ — нижнее и верхнее ограничения проксимального параметра: на каждой итерации метод берёт $\lambda = \min\{\max\{h, \lambda_\downarrow(\mathcal{A})\}, \lambda_\uparrow\}$. Нижнее ограничение удерживает вес ускоренного шага ограниченным, делает локальную задачу хорошо обусловленной и обеспечивает остановку; оно не возрастает при росте веса $\mathcal{A}$. Верхнее ограничение $\lambda_\uparrow$ равно значению нижнего при начальном весе $\mathcal{A} = R^2/(2\Delta)$. Явные формулы приведены в (G.7). Подпрограммы Оценка и Блок, включая правила учёта запросов, приведены в приложении G. Требования к ответу Решателя сформулированы в следующем разделе.

Алгоритм 1 YETI

Вход: n, R, Δ, δ, ε, L_0, L_1, константы $L_{0,i}$, эвристика

задать r, $\lambda_\downarrow$ и $\lambda_\uparrow$ по (G.7)
$x = v = 0$
$\mathcal{A} = R^2/(2\Delta)$
$h = \lambda_\uparrow$
история запросов пуста
повторять
  $x \leftarrow$ Блок(x) ▷ эвристический блок
  $\lambda = \min\{\max\{h, \lambda_\downarrow(\mathcal{A})\}, \lambda_\uparrow\}$
  $a_\lambda = \big(1 + \sqrt{1 + 4\lambda\mathcal{A}}\big)/(2\lambda)$
  $\alpha = a_\lambda/(\mathcal{A} + a_\lambda)$
  $y = (1-\alpha)x + \alpha v$
  Оценка(y)
  $\ell(y) = \frac{1}{n}\sum_i \big(L_{0,i} + L_1\|\nabla f_i(y)\|\big)$
  если $\ell(y) > e^{L_1 r}\big(\frac{3}{2}L_0 + 2L_1^2(\delta + R^2/\mathcal{A})\big)$ **то** ▷ отсечение
    $\mathcal{H}_y = \Big\{w : \ \langle \nabla f(y), w - y\rangle \le -\dfrac{\ell(y) - \frac{3}{2}L_0 - 2L_1^2\delta}{2L_1^2}\Big\}$
    $v \leftarrow \Pi_{B(0,R)}\Pi_{\mathcal{H}_y} v$
    $h \leftarrow 2\lambda$
  иначе ▷ шаг по решению локальной задачи
    $(z, g, \beta) \leftarrow$ Решатель(y, λ)
    если $\|g\| \le \varepsilon/(4R)$ **то**
      вернуть z
    конец если
    $\gamma = \lambda/(\lambda + \beta)$
    $x \leftarrow \dfrac{(1-\gamma)\mathcal{A}x + \gamma(\mathcal{A} + a_\lambda)z}{\mathcal{A} + \gamma a_\lambda}$
    $v \leftarrow \Pi_{B(0,R)}(v - \gamma a_\lambda g)$
    $\mathcal{A} \leftarrow \mathcal{A} + \gamma a_\lambda$
    $h \leftarrow \begin{cases} 2\lambda, & \beta > 0, \\ \lambda/2, & \beta = 0 \end{cases}$
    если $\mathcal{A} \ge 2R^2/\varepsilon$ **то**
      вернуть x
    конец если
  конец если
конец повторять

4 Локальная задача

В точке y решается задача

$$\min_{z \in B(0,R) \cap B(y,r)} \left\{ f(z) + \frac{\lambda}{2}\|z - y\|^2 \right\}.$$

Решатель возвращает $z \in B(0,R) \cap B(y,r)$, $g \in \partial(f + I_{B(0,R)})(z)$ и $\beta \geq 0$, причём $\beta > 0$ возможно лишь при $\|y - z\| = r$. Здесь $I_{B(0,R)}$ — индикаторная функция шара $B(0,R)$. Ответ решателя должен удовлетворять одному из двух условий:

$$\|g\| \leq \frac{\varepsilon}{4R} \quad \text{или} \quad \|g - (\lambda + \beta)(y - z)\| \leq \frac{4}{5}(\lambda + \beta)\|y - z\|.$$

Первое позволяет остановить YETI, второе обеспечивает точность ускоренного обновления. При $\beta = 0$ вес этого обновления не меняется, а при $\beta > 0$ умножается на коэффициент $\gamma = \lambda/(\lambda + \beta) < 1$.

Для решения используется SVRG с вероятностями выбора компонент, пропорциональными их локальным константам гладкости. После каждой эпохи проверяются указанные условия. Решатель почти наверное завершает работу (лемма H.2), а математическое ожидание числа его запросов на итерации YETI при фиксированной истории равно $O(n \log(n+2))$ (приложение C.3). Полностью алгоритм решателя приведён в приложении H.

5 Оценка сложности YETI

В анализе используется функция Ляпунова

$$\Phi = \mathcal{A}\big(f(x) - f^*\big) + \tfrac{1}{2}\|v - x^*\|^2 \leq R^2.$$

Принятие точки, предложенной эвристикой, не увеличивает первое слагаемое. Проекция на $\mathcal{H}_y$ уменьшает второе. При ускоренном обновлении Φ не возрастает благодаря условию точности локального решателя. Отсюда $f(x) - f^* \leq R^2/\mathcal{A}$.

Число итераций, на которых регуляризация увеличивается, ограничено благодаря убыванию Φ. На остальных итерациях регуляризация уменьшается вдвое или растёт вес $\mathcal{A}$. Отсюда следует оценка числа итераций до выполнения условия $\mathcal{A} \geq 2R^2/\varepsilon$. Соответствующие оценки доказаны в леммах B.3 и B.4 приложения B. Каждая итерация вместе с предшествующим ей эвристическим блоком требует в среднем $O(n \log N)$ запросов при фиксированной истории предыдущих итераций.

Теорема 5.1 (верхняя оценка).
При предположениях 2.1–2.6 алгоритм 1 почти наверное останавливается и возвращает точку $\hat{x}$, для которой

$$\mathbb{E}[f(\hat{x}) - f^*] \leq \varepsilon, \tag{5.1}$$

а математическое ожидание общего числа T обращений к оракулу удовлетворяет

$$\mathbb{E}T \lesssim T_0 \log^2 N. \tag{5.2}$$

В T включены все обращения к оракулу в эвристических блоках, основных итерациях и проверках.

Доказательство приведено в приложении C.3. Вариант, в котором допустимое число запросов эвристики зависит от уже выполненной работы, рассмотрен в приложении F.4.

6 Численные эксперименты

Мы сравниваем методы по числу обращений к оракулу на цепочках S и X (трудных семействах из раздела 7.1), на пуассоновских моделях и на 65 задачах из 13 семейств (по пять экземпляров каждого), включая суммы квартических функций и логистическую регрессию. Число запросов делится на n, то есть измеряется в проходах по данным; учитываются и запросы, потраченные на неудачные пробные точки при подборе шага. Относительная невязка равна $(f - f_{\mathrm{ref}})/\widehat{\Delta}$, где $\widehat{\Delta} = f(0) - f_{\mathrm{ref}}$, а f_{ref} — эталонное значение минимума. На цепочках оно совпадает с f^*, известным из построения. На остальных задачах f^* неизвестно, и f_{ref} — его приближение, найденное численно заранее; поэтому мы обозначаем его f_{ref}, а не f^*. Запросы, потраченные на вычисление эталона, в сравнении не учитываются. Постановки задач, настройки методов и подробные результаты приведены в приложении I.

На цепочках YETI работает примерно так же, как L-BFGS. На пяти пуассоновских задачах он достигает относительной точности 10^{-4} за 4–9 проходов; на freMTPL2freq методу SAGA требуется меньше проходов: 5 против 7 (табл. 2, 4).

Остановка. Критерий остановки по истории запросов (G.2) не использует эталонное значение. При $\varepsilon = 10^{-6}\widehat{\Delta}$ он срабатывает на всех 65 задачах, и все возвращённые точки удовлетворяют допуску относительно эталона. Медиана числа проходов до остановки равна 15, максимум — 273. Критерий может срабатывать позже, чем допуск фактически достигнут (рис. 4).

Тестовые задачи. Цепочки S и X — численные варианты трудных семейств из раздела 7.1. Пуассоновские модели — это синтетические задачи и задачи на данных Bike Sharing и freMTPL2freq. Тринадцать семейств, из которых составлены 65 задач (их названия указаны на рис. 2 и в табл. 1), устроены следующим образом.

- ▷ *Поворот, κ*: пуассоновская регрессия, в которой ковариационная матрица признаков имеет число обусловленности $\kappa \in \{10^4, 10^8\}$ и не диагональна в исходном базисе (её собственные векторы повёрнуты относительно координатных осей).
- ▷ *Большая размерность*: пуассоновская регрессия с большим числом признаков: $n = 600$, $d = 160$, $\kappa = 10^4$.
- ▷ *Сильная нелинейность*: пуассоновская регрессия, в которой истинный вектор параметров, по которому генерируются отклики, в три раза длиннее, чем в остальных пуассоновских семействах; это увеличивает разброс линейных предикторов $a_i^\top x$ и значений экспоненты.
- ▷ *Редкие признаки* и *Редкие, $n = 5 \cdot 10^4$*: пуассоновская регрессия с разреженными признаками; во втором семействе число слагаемых равно $5 \cdot 10^4$.
- ▷ $n = 5 \cdot 10^4$, $\kappa = 10^8$: плохо обусловленная пуассоновская регрессия с $5 \cdot 10^4$ слагаемыми.
- ▷ *Квартики*: суммы квартических функций $f_i(x) = \frac{1}{2}(x - c_i)^\top H_i (x - c_i) + \frac{\nu}{4}\|x - c_i\|^4$, где $H_i \succ 0$, а c_i — случайные центры. В названиях семейств 32×48 и 256×32 указаны число слагаемых n и размерность d; ν — вес слагаемого четвёртой степени (в этих двух семействах $\nu = 10^{-6}$).
- ▷ *Логистика, поворот* и *Логистика, редкие*: регуляризованная логистическая регрессия с повёрнутыми и с разреженными признаками соответственно.

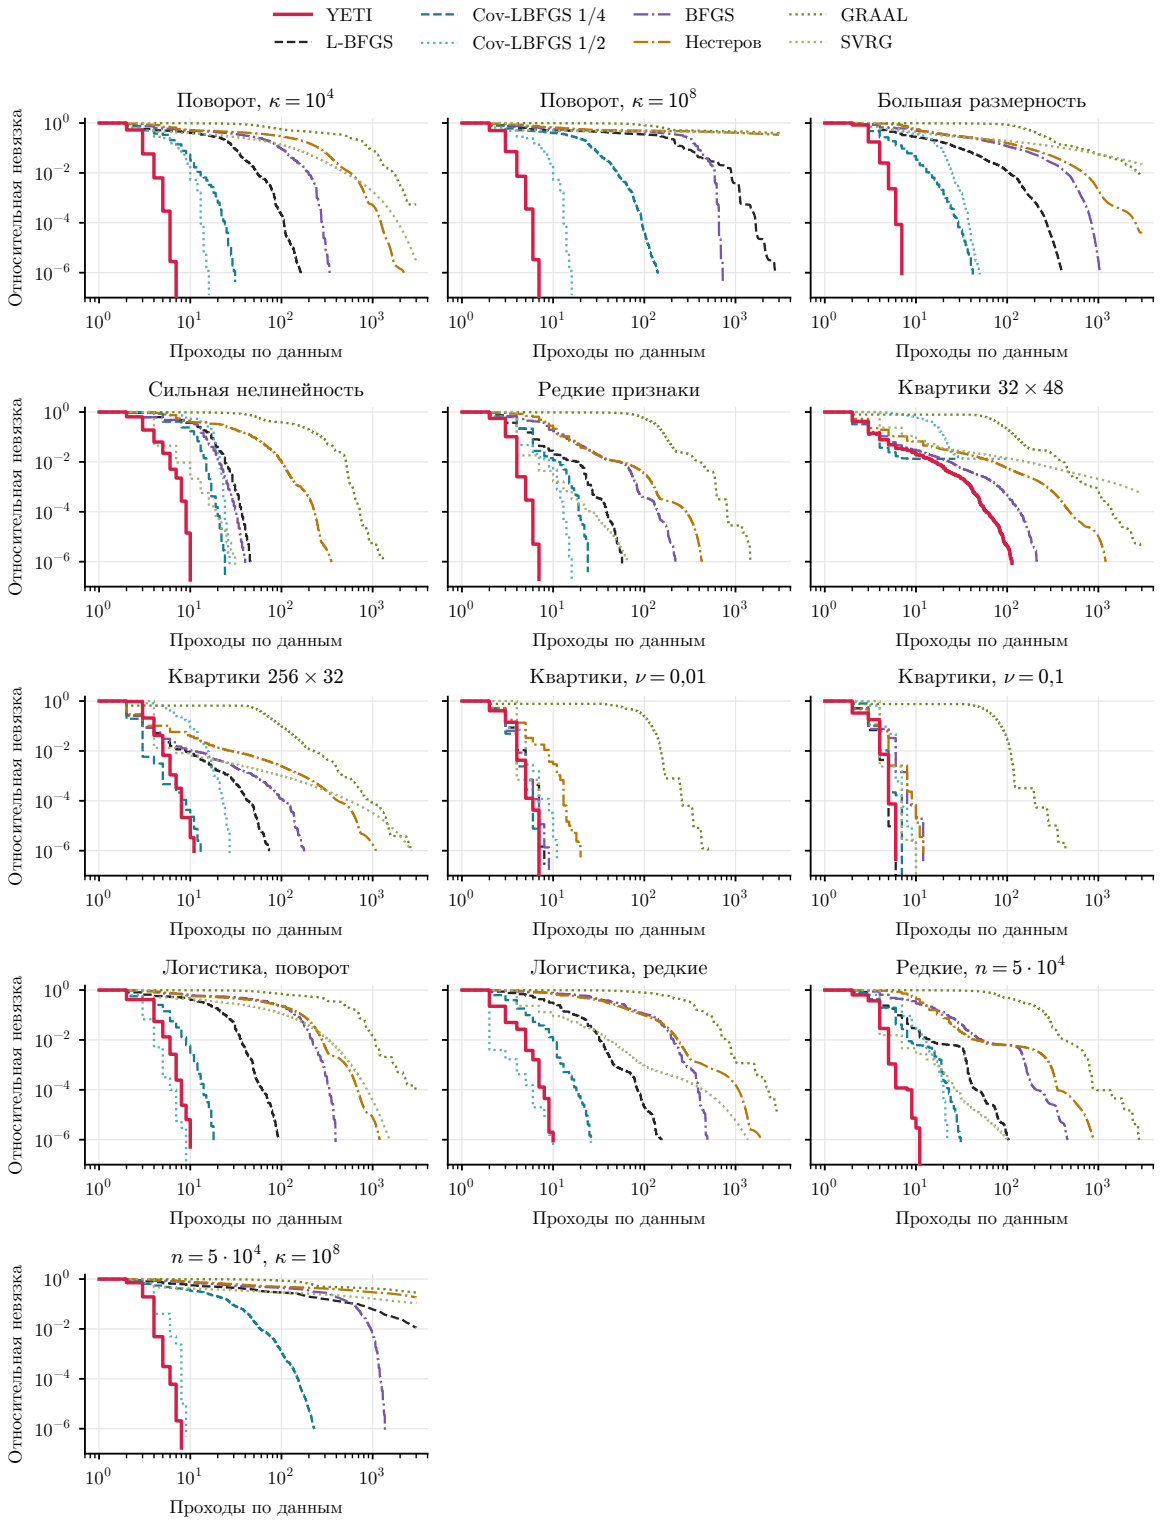


Рис. 2. Наименьшая достигнутая к данному моменту относительная невязка на первом экземпляре каждого семейства (обе шкалы логарифмические; YETI выделен красным; κ — число обусловленности ковариационной матрицы признаков).

7 Нижняя оценка для произвольных запросов

Оценим снизу число запросов, необходимое любому методу, который решает все задачи рассматриваемого класса.

7.1 Происхождение четырёх слагаемых

Нижнюю оценку докажем отдельно для каждого из четырёх слагаемых. Обозначим

$$\begin{aligned} B_n &= n, \\ B_S &= \sqrt{\frac{nL_0R^2}{\varepsilon}}, \\ B_Q &= n(L_1R)^{2/3}, \\ B_X &= \sqrt{\frac{nL_1^2R^2\delta}{\varepsilon} + n(L_1R)^2}. \end{aligned} \tag{7.1}$$

Поскольку $\sqrt{a^2+b^2} \sim a+b$ при $a, b \geq 0$, имеем $T_0 \sim B_n + B_S + B_X + B_Q$.

Член	Что затрудняет решение	Трудное семейство
B_n	Поиск информативной компоненты	Скрытая пара функций
B_S	Последовательное раскрытие гладких цепочек	Независимые цепочки S
B_X	Неоднородность компонент при обобщённой гладкости	Экспоненциальные цепочки X
B_Q	Повторный поиск компоненты для следующего шага	Цепочка Q со скрытым размещением звеньев

Для каждого слагаемого построим своё семейство задач. Поскольку метод должен решать задачи всех четырёх семейств, его сложность не меньше максимума полученных оценок. Ниже зависимости обсуждаются с точностью до числовых и логарифмических множителей. Точные условия конструкций приведены в приложении; если отдельная конструкция неприменима, соответствующий член оценивается через остальные.

Поиск информативной компоненты: $B_n = n$. Среди n компонент случайно выбираются две ненулевые, остальные равны нулю. До первого обращения к одной из них алгоритм получает только нулевые ответы. Эти ответы не позволяют различить две задачи с точками минимума по разные стороны от начальной точки. Чтобы ожидаемая ошибка была мала, нужно с достаточной вероятностью найти скрытую пару функций, а для этого требуется порядка n обращений к оракулу (лемма D.5).

Независимые гладкие цепочки: B_S. В каждую компоненту помещается своя цепочка координат. Под цепочкой понимается функция, у которой очередная координата влияет на ответ оракула только после достаточного продвижения по предыдущим координатам. В идеализированной модели один запрос раскрывает не более одного нового звена одной цепочки. Как это свойство переносится на произвольные запросы, объяснено ниже.

В семействе S число звеньев одной цепочки имеет порядок $\sqrt{L_0R^2/(n\varepsilon)}$. Чтобы достичь точности ε, нужно раскрыть достаточную долю от общего числа звеньев всех цепочек. Поэтому число запросов имеет порядок

$$n\sqrt{\frac{L_0R^2}{n\varepsilon}} = \sqrt{\frac{nL_0R^2}{\varepsilon}} = B_S.$$

Задачи этого семейства гладкие: $\|\nabla^2 f_i\| \le L_0$ (лемма D.6). Если условия построения цепочки не выполнены, то $B_S \lesssim B_n$ и достаточно оценки для B_n.

Экспоненциальные цепочки: B_X. При обобщённой гладкости кривизна компоненты может расти вместе с её градиентом. Даже в точке минимума среднего, где $\nabla f(x^*) = 0$, отдельные градиенты $\nabla f_i(x^*)$ могут быть ненулевыми и компенсировать друг друга. Поэтому малость нормы градиента среднего не влечёт малости констант гладкости компонент. Параметр δ ограничивает расхождение между минимумом среднего и средним значением инфимумов компонент.

В семействе X цепочки входят в показатели экспонент у компонент, объединённых в пары. Конструкция сохраняет последовательное раскрытие звеньев и задаёт неоднородность, равную δ. Оценка для этого семейства вместе с оценкой для скрытой пары функций даёт B_X (леммы D.8 и D.5). Поскольку $B_X = \sqrt{n}\, L_1 R\sqrt{1+\delta/\varepsilon}$, имеем

$$B_X \sim \sqrt{n}\, L_1 R \max\left\{1, \sqrt{\frac{\delta}{\varepsilon}}\right\}.$$

Поиск следующего звена: B_Q. В семействе Q используется одна цепочка, но её звенья случайно размещены по парам компонент. После раскрытия очередной координаты недостаточно знать, в каком направлении продолжать: нужно ещё найти пару, в которой находится следующее звено. Компонента, которая уже была запрошена, может стать информативной лишь на следующем уровне цепочки, поэтому однократное вычисление всех компонент не избавляет от этих поисков.

При условиях леммы D.10 длина цепочки имеет порядок $(L_1R)^{2/3}$, а поиск пары на очередном уровне требует порядка n запросов в среднем. Отсюда с точностью до логарифмических множителей

$$\underbrace{(L_1R)^{2/3}}_{\text{число уровней}} \underbrace{n}_{\text{поиск на уровне}} = B_Q.$$

Показатель $2/3$ объясняется выбором длины цепочки T. В точке минимума её T активных координат равны $R/\sqrt{T}$, так что норма этой точки равна R. Оценка невязки через число раскрытых звеньев (D.20) показывает, что для достижения точности нужно пройти порядка $L_1R/\sqrt{T}$ уровней (с точностью до логарифмических множителей), а всего уровней T. Длина цепочки выбирается так, чтобы величины T и $L_1R/\sqrt{T}$ совпадали с точностью до абсолютных постоянных. Из равенства $T = L_1R/\sqrt{T}$ получаем $T^{3/2} = L_1R$, то есть $T = (L_1R)^{2/3}$; в лемме D.10 выбрано целое T этого порядка. Точные условия этого выбора учитывают также начальную невязку и неоднородность. Число обращений к оракулу, необходимое для поиска следующего звена, оценивается в леммах D.9 и D.3.

7.2 Нижняя оценка

Пусть выполнены предположения 2.1–2.6. Число N_0 задано в (2.5).

Теорема 7.1. ▼доказательство в приложении E
Для оракула, возвращающего $(f_i(x), \nabla f_i(x))$, выполнено

$$\mathcal{T}^* \gtrsim \frac{T_0}{\log^2 N_0}.$$

Правая часть не зависит от Δ при $\Delta \ge 2\varepsilon$. Оценка относится к наихудшей задаче класса в произвольной размерности. Метод может быть рандомизированным и выбирать

точки запросов во всём пространстве, а не только в линейной оболочке ранее полученных градиентов.

Вместе с верхней оценкой для YETI (теорема 5.1) эта теорема показывает, что в данной постановке показатели степеней при n, L_0, L_1, R, δ и ε улучшить нельзя (с точностью до логарифмических множителей). Логарифмический разрыв между верхней и нижней оценками здесь не устраняется. Предположение 2.6 существенно для области применимости результата: эту нижнюю оценку нельзя автоматически переносить, например, на подкласс с $\delta = 0$. Равенство $\delta = 0$ означает, что точка x^* минимизирует каждую компоненту, то есть у всех f_i есть общая точка минимума. Для этого случая оценки сходимости стохастических методов (L_0, L_1)-SGD и SGD-PS получены в работе Gorbunov et al. (2025, раздел 7).

7.3 Доказательство нижней оценки

Схема доказательства теоремы 7.1. Задача со скрытой парой функций даёт оценку для B_n. Семейство S даёт оценку для B_S, а если его условия нарушены, используется $B_S \lesssim B_n$. Семейство X вместе со скрытой парой функций даёт оценку для B_X с точностью до логарифмического множителя. Семейство Q даёт оценку для B_Q. Когда условия (D.17) не выполнены, этот член оценивается через уже полученные оценки.

Следовательно,

$$T_0 \sim \max\{B_n, B_S, B_X, B_Q\} \lesssim \mathcal{T}^* \log^2 N_0.$$

Леммы D.1–D.3 позволяют применить эти оценки к произвольным рандомизированным методам. Разбор всех режимов параметров приведён в приложении E. □

8 Заключение

Для минимизации суммы выпуклых (L_0, L_1)-гладких функций метод YETI достигает верхней оценки $O(T_0 \log^2 N)$, а для любого корректного метода доказана нижняя оценка $\Omega(T_0/\log^2 N_0)$. Если $\Delta/\varepsilon \le N_0^c$ при некотором фиксированном $c \ge 1$, то эти оценки совпадают с точностью до степеней $\log N_0$. Без ограничения на рост начальной невязки Δ оптимальность верхней оценки не установлена.

На 65 задачах при относительной точности 10^{-4} испытанный вариант YETI занял первое место (в том числе разделив его с другими методами) в 46 случаях, а его критерий остановки по истории запросов сработал на всех 65 задачах. Основной выигрыш в этих опытах даёт эвристика (приложение I). Однако её матричные операции могут быть дорогими, поэтому выигрыш в числе запросов не обязательно означает такой же выигрыш во времени.

8.1 Открытые вопросы

1. *Большая начальная невязка.* Какова оптимальная зависимость сложности от Δ? Если $\log(\Delta/\varepsilon)$ имеет порядок $L_1 R$, то полученные верхняя и нижняя оценки могут различаться полиномиально по $L_1 R$. Нужно либо улучшить верхнюю оценку, либо доказать нижнюю оценку, учитывающую Δ. При умеренных Δ остаётся устранить логарифмический разрыв.
2. *Индивидуальные константы гладкости.* Можно ли получить более точную оценку сложности для заданного набора $(L_{0,i}, L_{1,i})$, не заменяя все $L_{1,i}$ их максимумом? Неравномерный выбор компонент уже позволяет обойтись средним значением $L_{0,i}$ (приложение F). Чтобы улучшить общую оценку, нужно учесть связь между $L_{1,i}$ и невязками отдельных слагаемых и построить соответствующую нижнюю оценку: наша нижняя оценка получена на подклассе с одинаковыми $L_{0,i}$.

3. *Ограничения и неевклидова геометрия.* Как перенести результат на минимизацию по выпуклому множеству и на методы с расстоянием Брэгмана? Зеркальный спуск при обобщённой гладкости изучен в работе Yu et al. (2026). Здесь дополнительно потребуются анализ уменьшения дисперсии, замена евклидова потенциала и оценка числа отсечений.
4. *Негладкие слагаемые.* Можно ли получить аналогичные двусторонние оценки для конечных сумм, у которых нормы субградиентов ограничены через невязку? Такая негладкая стохастическая постановка рассматривается в работе Kovalev (2026). Для конечной суммы нужно отдельно определить модель оракула и выяснить, какой выигрыш даёт уменьшение дисперсии.
5. *Методы второго и более высоких порядков.* Можно ли совместить уменьшение дисперсии для конечных сумм (Tsedenov and Kovalev, 2026) с ускорением при обобщённой гладкости гессиана (Agafonov et al., 2026)? Для этого нужны оценки ошибок стохастических производных и новый локальный решатель. Условия на старшие производные не следуют из предположения 2.2.
6. *Двойственная задача.* Можно ли интерпретировать YETI как покоординатный метод для двойственной задачи и связать его со схемой из работы Podlipnova et al. (2026)? Помимо преобразования задачи, потребуется сопоставить доступные оракулы и стоимость одного шага: запрос компоненты f_i и запрос координаты двойственного градиента в общем случае не эквивалентны.

Отдельно остаётся найти сложность вне области действия предположения 2.6, в частности при $\delta = 0$. Этот вопрос касается неоднородности слагаемых и не совпадает с вопросом о большой начальной невязке Δ.

Литература

Artem Agafonov, Aslan Ashabokov, Alexander D'yakonov, Martin Takáč, Alexander Gasnikov, and Dmitry Kamzolov. Optimal parameter-free second-order acceleration with inexact hessians under generalized smoothness. arXiv:2609.32977, 2026. URL https://arxiv.org/abs/2609.32977.

Zeyuan Allen-Zhu. Katyusha: The first direct acceleration of stochastic gradient methods. *Journal of Machine Learning Research*, 18(221):1–51, 2018. URL https://www.jmlr.org/papers/v18/16-410.html.

Jean-Bernard Baillon and Georges Haddad. Quelques propriétés des opérateurs angle-bornés et n-cycliquement monotones. *Israel Journal of Mathematics*, 26(2):137–150, 1977. doi: 10.1007/BF03007664.

Heinz H. Bauschke and Patrick L. Combettes. The Baillon–Haddad theorem revisited. *Journal of Convex Analysis*, 17(3–4):781–787, 2010. URL https://pcombet.math.ncsu.edu/jca3.pdf.

Ekaterina Borodich and Dmitry Kovalev. Nesterov finds GRAAL: Optimal and adaptive gradient method for convex optimization. In *International Conference on Learning Representations*, 2026. URL https://openreview.net/forum?id=vPSiCA3CkD.

Léon Bottou, Frank E. Curtis, and Jorge Nocedal. Optimization methods for large-scale machine learning. *SIAM Review*, 60(2):223–311, 2018.

Emmanuel J. Candès, Xiaodong Li, and Mahdi Soltanolkotabi. Phase retrieval via wirtinger flow: Theory and algorithms. *IEEE Transactions on Information Theory*, 61(4):1985–2007, 2015. doi: 10.1109/TIT.2015.2399924.

Yair Carmon, John C. Duchi, Oliver Hinder, and Aaron Sidford. Lower bounds for finding stationary points I. *Mathematical Programming*, 184:71–120, 2020. URL https://arxiv.org/abs/1710.11606.

Yair Carmon, Danielle Hausler, Arun Jambulapati, Yujia Jin, and Aaron Sidford. Optimal and adaptive Monteiro–Svaiter acceleration. In *Advances in Neural Information Processing Systems*, volume 35, 2022. URL https://arxiv.org/abs/2205.15371.

Michael Crawshaw, Mingrui Liu, Francesco Orabona, Wei Zhang, and Zhenxun Zhuang. Robustness to unbounded smoothness of generalized SignSGD. arXiv:2208.11195, 2022.

Aaron Defazio, Francis Bach, and Simon Lacoste-Julien. SAGA: A fast incremental gradient method with support for non-strongly convex composite objectives. In *Advances in Neural Information Processing Systems*, volume 27, 2014. URL https://proceedings.nips.cc/paper_files/paper/2014/hash/937964195d6fb3a55cd7cc578165f058-Abstract.html.

Elizabeth D. Dolan and Jorge J. Moré. Benchmarking optimization software with performance profiles. *Mathematical Programming*, 91(2):201–213, 2002. doi: 10.1007/s101070100263.

Roy Frostig, Rong Ge, Sham Kakade, and Aaron Sidford. Un-regularizing: Approximate proximal point and faster stochastic algorithms for empirical risk minimization. In *Proceedings of the 32nd International Conference on Machine Learning*, volume 37 of *Proceedings of Machine Learning Research*, pages 2540–2548, 2015. URL https://proceedings.mlr.press/v37/frostig15.html.

Eduard Gorbunov, Nazarii Tupitsa, Sayantan Choudhury, Alen Aliev, Peter Richtárik, Samuel Horváth, and Martin Takáč. Methods for convex (L_0, L_1)-smooth optimization: Clipping, acceleration, and adaptivity. In *International Conference on Learning Representations*, 2025. arXiv:2409.14989.

Martin Jaggi. Revisiting Frank–Wolfe: Projection-free sparse convex optimization. In *Proceedings of the 30th International Conference on Machine Learning*, volume 28 of *Proceedings of Machine Learning Research*, pages 427–435, 2013. URL https://proceedings.mlr.press/v28/jaggi13.html.

Rie Johnson and Tong Zhang. Accelerating stochastic gradient descent using predictive variance reduction. In *Advances in Neural Information Processing Systems*, volume 26, pages 315–323, 2013. URL https://proceedings.neurips.cc/paper/2013/hash/ac1dd209cbcc5e5d1c6e28598e8cbbe8-Abstract.html.

Dmitry Kovalev. Stochastic non-smooth convex optimization with unbounded gradients. arXiv:2605.15522, 2026. URL https://arxiv.org/abs/2605.15522.

Guanghui Lan, Zhize Li, and Yi Zhou. A unified variance-reduced accelerated gradient method for convex optimization. In *Advances in Neural Information Processing Systems*, volume 32, 2019. URL https://arxiv.org/abs/1905.12412.

Haochuan Li, Jian Qian, Yi Tian, Alexander Rakhlin, and Ali Jadbabaie. Convex and non-convex optimization under generalized smoothness. In *Advances in Neural Information Processing Systems*, volume 36, 2023.

Hongzhou Lin, Julien Mairal, and Zaid Harchaoui. A universal catalyst for first-order optimization. In *Advances in Neural Information Processing Systems*, volume 28, 2015. URL https://proceedings.neurips.cc/paper_files/paper/2015/hash/c164bbc9d6c72a52c599bbb43d8db8e1-Abstract.html.

Hongzhou Lin, Julien Mairal, and Zaid Harchaoui. Catalyst acceleration for first-order convex optimization: from theory to practice. *Journal of Machine Learning Research*, 18(212):1–54, 2018. URL https://arxiv.org/abs/1712.05654.

Dong C. Liu and Jorge Nocedal. On the limited memory BFGS method for large scale optimization. *Mathematical Programming*, 45:503–528, 1989. doi: 10.1007/BF01589116.

Yura Malitsky and Konstantin Mishchenko. Adaptive gradient descent without descent. In *Proceedings of the 37th International Conference on Machine Learning*, volume 119 of *Proceedings of Machine Learning Research*, pages 6702–6712, 2020. URL https://proceedings.mlr.press/v119/malitsky20a.html.

H. Brendan McMahan, Eider Moore, Daniel Ramage, Seth Hampson, and Blaise Agüera y Arcas. Communication-efficient learning of deep networks from decentralized data. In *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics*, volume 54 of *Proceedings of Machine Learning Research*, pages 1273–1282, 2017.

Renato D. C. Monteiro and Benar F. Svaiter. An accelerated hybrid proximal extragradient method for convex optimization and its implications to second-order methods. *SIAM Journal on Optimization*, 23(2):1092–1125, 2013. doi: 10.1137/110833786. URL https://w3.impa.br/~benar/docs/SIAM/AccHPE_Optim.pdf.

Yurii Nesterov. *Lectures on Convex Optimization*, volume 137 of *Springer Optimization and Its Applications*. Springer, 2018.

Jorge Nocedal and Stephen J. Wright. *Numerical Optimization*. Springer, 2 edition, 2006. doi: 10.1007/978-0-387-40065-5.

Irina Podlipnova, Maxim Mashtaler, Artem Agafonov, Yuriy Dorn, and Alexander Gasnikov. Smooth or separable? sparse block acceleration for entropy-regularized linear programs. arXiv:2609.32558, 2026. URL https://arxiv.org/abs/2609.32558.

Amirhossein Reisizadeh, Haochuan Li, Subhro Das, and Ali Jadbabaie. Variance-reduced clipping for non-convex optimization. arXiv:2303.00883, 2023.

M. Rudomanov, I. Fomin, A. V. Gasnikov, and F. S. Stonyakin. Descending Everest with first-order oracles: Oracle complexity of convex optimization under (l_0, l_1)-smoothness. arXiv:2610.21461, 2026. URL https://arxiv.org/abs/2610.21461.

Shai Shalev-Shwartz and Shai Ben-David. *Understanding Machine Learning: From Theory to Algorithms*. Cambridge University Press, 2014.

Stan Development Team. Poisson-log generalized linear model (poisson regression). Stan Functions Reference, version 2.30, section 17.7. URL https://mc-stan.org/docs/2_30/functions-reference/poisson-log-glm.html.

Artem Tsedenov and Dmitry Kovalev. An optimal second-order algorithm for finite-sum optimization under average smoothness and convexity. arXiv:2610.10495, 2026. URL https://arxiv.org/abs/2610.10495.

Alexander Tyurin. Toward a unified theory of gradient descent under generalized smoothness. In *Proceedings of the 42nd International Conference on Machine Learning*, volume 267 of *Proceedings of Machine Learning Research*, pages 60493–60514, 2025. URL https://proceedings.mlr.press/v267/tyurin25a.html.

Alexander Tyurin. Near-optimal convergence of accelerated gradient methods under generalized and (L_0, L_1)-smoothness. In *Proceedings of the 43rd International Conference on Machine Learning*, volume 306 of *Proceedings of Machine Learning Research*, pages 122876–122905, 2026. URL https://proceedings.mlr.press/v306/tyurin26b.html.

Daniil Vankov, Anton Rodomanov, Angelia Nedić, Lalitha Sankar, and Sebastian U. Stich. Optimizing (L_0, L_1)-smooth functions by gradient methods. In *International Conference on Learning Representations*, 2025. arXiv:2410.10800.

Blake Woodworth and Nathan Srebro. Tight complexity bounds for optimizing composite objectives. In *Advances in Neural Information Processing Systems*, volume 29, 2016. URL https://arxiv.org/abs/1605.08003.

Lin Xiao and Tong Zhang. A proximal stochastic gradient method with progressive variance reduction. *SIAM Journal on Optimization*, 24(4):2057–2075, 2014. doi: 10.1137/140961791. URL https://arxiv.org/abs/1403.4699.

Andrew Chi-Chih Yao. Probabilistic computations: Toward a unified measure of complexity. In *18th Annual Symposium on Foundations of Computer Science*, pages 222–227, 1977. doi: 10.1109/SFCS.1977.24. URL https://doi.org/10.1109/SFCS.1977.24.

Dingzhi Yu, Wei Jiang, Hongyi Tao, Yuanyu Wan, and Lijun Zhang. Mirror descent under generalized smoothness. In *Proceedings of the 43rd International Conference on Machine Learning*, 2026. URL https://arxiv.org/abs/2502.00753. arXiv:2502.00753v4.

Jingzhao Zhang, Tianxing He, Suvrit Sra, and Ali Jadbabaie. Why gradient clipping accelerates training: A theoretical justification for adaptivity. In *International Conference on Learning Representations*, 2020. arXiv:1905.11881.

A Аналитические свойства класса

Вспомогательные леммы сформулированы для произвольной функции φ. К компонентам f_i они применяются в силу предположений 2.1 и 2.2 с константой $L_{0,i}$ вместо L_0.

A.1 Локальная гладкость

См. также Rudomanov et al. (2026, лемма A.1) и Vankov et al. (2025, лемма 2.5).

Лемма A.1 (рост градиента вдоль отрезка).
Пусть $\varphi \in C^2(\mathbb{R}^d)$ и $\|\nabla^2\varphi(x)\| \le L_0 + L_1\|\nabla\varphi(x)\|$ для всех x. Тогда для любых x, y выполняется

$$L_0 + L_1\|\nabla\varphi(x)\| \le e^{L_1\|x-y\|}\big(L_0 + L_1\|\nabla\varphi(y)\|\big). \tag{A.1}$$

В частности, на шаре $B(y, r)$ градиент φ липшицев с константой $e^{L_1 r}(L_0 + L_1\|\nabla\varphi(y)\|)$.

Доказательство. По формуле Ньютона–Лейбница

$$\nabla\varphi(y + t(x-y)) - \nabla\varphi(y) = \int_0^t \nabla^2\varphi(y + u(x-y))(x-y)\,du.$$

Взяв норму и применив условие на гессиан, для $t \in [0,1]$ получаем

$$L_0 + L_1\|\nabla\varphi(y + t(x-y))\| \le L_0 + L_1\|\nabla\varphi(y)\| + L_1\|x-y\|\int_0^t \big(L_0 + L_1\|\nabla\varphi(y + u(x-y))\|\big)\,du.$$

По неравенству Гронуолла

$$L_0 + L_1\|\nabla\varphi(y + t(x-y))\| \le e^{L_1\|x-y\|t}\big(L_0 + L_1\|\nabla\varphi(y)\|\big).$$

При $t = 1$ получаем первое утверждение. Для $x \in B(y, r)$ оно даёт оценку нормы гессиана на всём шаре, а интегрирование гессиана по отрезкам внутри выпуклого шара доказывает липшицевость градиента. □

(Теорема Байона–Хаддада, Bauschke and Combettes, 2010)

Лемма A.2 (кокоэрцитивность на выпуклой области).
Пусть φ выпукла и дважды непрерывно дифференцируема в окрестности выпуклого множества $\mathcal{D}$. Если $\|\nabla^2\varphi\| \le L$ на $\mathcal{D}$, где $L > 0$, то для всех $x, z \in \mathcal{D}$

$$\|\nabla\varphi(x) - \nabla\varphi(z)\|^2 \le L\langle\nabla\varphi(x) - \nabla\varphi(z), x - z\rangle.$$

Доказательство. Средний гессиан

$$H = \int_0^1 \nabla^2\varphi(z + t(x-z))\,dt$$

удовлетворяет $0 \preceq H \preceq LI$ по выпуклости, поэтому $H^2 \preceq LH$ и

$$\|\nabla\varphi(x) - \nabla\varphi(z)\|^2 = \langle x - z, H^2(x-z)\rangle \le L\langle x - z, H(x-z)\rangle = L\langle\nabla\varphi(x) - \nabla\varphi(z), x - z\rangle.$$

□

Лемма A.3 (оценка разности градиентов).
Пусть φ выпукла, $\varphi \in C^2(\mathbb{R}^d)$ и $\|\nabla^2\varphi\| \le L$ на $B(y, 3r)$, где $L > 0$. Тогда для $x, w \in B(y, r)$ выполнено

$$\|\nabla\varphi(x) - \nabla\varphi(w)\|^2 \le 2L\big(\varphi(x) - \varphi(w) - \langle\nabla\varphi(w), x - w\rangle\big).$$

Доказательство. Так как градиент функции φ является L-липшицевым на $B(y,r)$ и $x, w \in B(y,r)$, имеем

$$\|\nabla\varphi(x) - \nabla\varphi(w)\| \le L\|x - w\| \le 2Lr.$$

Поэтому точка

$$q = x - \frac{1}{L}\big(\nabla\varphi(x) - \nabla\varphi(w)\big)$$

лежит в $B(y,3r)$, а значит, и весь отрезок $[x,q]$ содержится в $B(y,3r)$. Функция

$$z \mapsto \varphi(z) - \varphi(w) - \langle\nabla\varphi(w), z - w\rangle$$

выпукла, неотрицательна во всём пространстве и имеет на $B(y,3r)$ L-липшицев градиент $\nabla\varphi(z) - \nabla\varphi(w)$. Квадратичная оценка сверху на отрезке $[x,q]$ даёт

$$\begin{aligned} 0 &\le \varphi(q) - \varphi(w) - \langle\nabla\varphi(w), q - w\rangle \\ &\le \varphi(x) - \varphi(w) - \langle\nabla\varphi(w), x - w\rangle + \langle\nabla\varphi(x) - \nabla\varphi(w), q - x\rangle + \frac{L}{2}\|q - x\|^2 \\ &= \varphi(x) - \varphi(w) - \langle\nabla\varphi(w), x - w\rangle - \frac{1}{2L}\|\nabla\varphi(x) - \nabla\varphi(w)\|^2. \end{aligned}$$

Остаётся перенести последнее слагаемое в левую часть. □

A.2 Оценка нормы градиента через невязку

Ср. Li et al. (2023) и Yu et al. (2026, лемма 3.4).

Лемма A.4 (интегральная оценка нормы градиента).
Пусть φ выпукла, ограничена снизу, принадлежит $C^2(\mathbb{R}^d)$ и удовлетворяет условию леммы A.1. Тогда для любого x

$$\begin{gathered} \int_0^{\|\nabla\varphi(x)\|} \frac{t}{L_0 + L_1 t}\, dt \le \varphi(x) - \inf\varphi, \\ \|\nabla\varphi(x)\| \le L_1\big(\varphi(x) - \inf\varphi\big) + \sqrt{2L_0\big(\varphi(x) - \inf\varphi\big)}. \end{gathered} \tag{A.2}$$

При $L_0 = 0$ подынтегральная функция доопределяется в нуле по непрерывности. Достижимость инфимума не предполагается.

Доказательство. При $\nabla\varphi(x) = 0$ утверждение очевидно. Иначе выберем $h > 0$ так, чтобы

$$\begin{gathered} L_1 h\|\nabla\varphi(x)\| \le \tfrac{1}{2}, \\ h\big(L_0 + L_1\|\nabla\varphi(x)\|\big) \le \tfrac{1}{2}, \end{gathered}$$

и рассмотрим градиентный спуск из точки $x_0 = x$:

$$x_{j+1} = x_j - h\nabla\varphi(x_j).$$

▷ Норма градиента не возрастает. Пусть $\|\nabla\varphi(x_j)\| \le \|\nabla\varphi(x)\|$. Отрезок $[x_j, x_{j+1}]$ имеет длину $h\|\nabla\varphi(x_j)\|$, поэтому по лемме A.1 норма гессиана на нём не превосходит

$$e^{L_1 h\|\nabla\varphi(x_j)\|}\big(L_0 + L_1\|\nabla\varphi(x_j)\|\big) \le 2\big(L_0 + L_1\|\nabla\varphi(x)\|\big) \le \frac{1}{h}. \tag{A.3}$$

Значит, средний гессиан H_j на этом отрезке удовлетворяет $0 \preceq hH_j \preceq I$, и

$$\begin{gathered} \nabla\varphi(x_{j+1}) = (I - hH_j)\nabla\varphi(x_j), \\ \|\nabla\varphi(x_{j+1})\| \underset{(a)}{\le} \|\nabla\varphi(x_j)\|. \end{gathered}$$

Здесь (a) следует из $0 \preceq I - hH_j \preceq I$. По индукции эти оценки верны для всех j.

▷ Оценим две телескопические суммы. Квадратичная оценка сверху вместе с оценкой кривизны (A.3) даёт

$$\varphi(x_j)-\varphi(x_{j+1})\ge h\|\nabla\varphi(x_j)\|^2-\frac{h^2}{2}e^{L_1h\|\nabla\varphi(x_j)\|}\bigl(L_0+L_1\|\nabla\varphi(x_j)\|\bigr)\|\nabla\varphi(x_j)\|^2\ge\frac{h}{2}\|\nabla\varphi(x_j)\|^2.$$

Подынтегральная функция $t/(L_0+L_1t)$ не убывает, а

$$\|\nabla\varphi(x_j)\|-\|\nabla\varphi(x_{j+1})\|\le\|hH_j\nabla\varphi(x_j)\|.$$

Поэтому

$$\int_{\|\nabla\varphi(x_{j+1})\|}^{\|\nabla\varphi(x_j)\|}\frac{t\,dt}{L_0+L_1t}\le\frac{\|\nabla\varphi(x_j)\|}{L_0+L_1\|\nabla\varphi(x_j)\|}\|hH_j\nabla\varphi(x_j)\|\underset{(a)}{\le}he^{L_1h\|\nabla\varphi(x_j)\|}\|\nabla\varphi(x_j)\|^2.$$

Здесь (a) следует из оценки (A.3) для $\|H_j\|$. Так как $e^s-1\le2s$ и $e^s\le2$ при $0\le s\le1/2$, из оценки убывания функции и последней оценки интеграла получаем

$$\int_{\|\nabla\varphi(x_{j+1})\|}^{\|\nabla\varphi(x_j)\|}\frac{t\,dt}{L_0+L_1t}\le\varphi(x_j)-\varphi(x_{j+1})+h^2\bigl(L_0+3L_1\|\nabla\varphi(x)\|\bigr)\|\nabla\varphi(x_j)\|^2.$$

Суммируя неравенство

$$\varphi(x_i)-\varphi(x_{i+1})\ge\frac{h}{2}\|\nabla\varphi(x_i)\|^2$$

по $i=0,\dots,m-1$, получаем

$$h\sum_{i<m}\|\nabla\varphi(x_i)\|^2\le2\bigl(\varphi(x)-\inf\varphi\bigr).$$

Суммируя оценку разности интегралов по $i=0,\dots,j-1$, где $0\le j<m$, и используя полученную оценку суммы квадратов норм градиентов, получаем

$$\int_0^{\|\nabla\varphi(x)\|}\frac{t\,dt}{L_0+L_1t}\le\bigl(\varphi(x)-\inf\varphi\bigr)\Bigl(1+2h\bigl(L_0+3L_1\|\nabla\varphi(x)\|\bigr)\Bigr)+\int_0^{\|\nabla\varphi(x_j)\|}\frac{t\,dt}{L_0+L_1t}.$$

Возьмём $m=\lceil h^{-2}\rceil$ и индекс $j<m$ с наименьшей нормой $\|\nabla\varphi(x_j)\|$. Тогда

$$\|\nabla\varphi(x_j)\|^2\le\frac{2(\varphi(x)-\inf\varphi)}{mh}\to0\quad\text{при }h\downarrow0.$$

Последний интеграл не превосходит $\|\nabla\varphi(x_j)\|/L_1$, поэтому, переходя к пределу, получаем первое неравенство (A.2).

▷ При $L_0=0$ интеграл равен $\|\nabla\varphi(x)\|/L_1$, что сразу даёт второе неравенство. При $L_0>0$ после замены $t=L_0s/L_1$ интегральная оценка принимает вид

$$\frac{L_1\|\nabla\varphi(x)\|}{L_0}-\log\Bigl(1+\frac{L_1\|\nabla\varphi(x)\|}{L_0}\Bigr)\le\frac{L_1^2(\varphi(x)-\inf\varphi)}{L_0}.$$

Функция $s\mapsto s-\log(1+s)$ возрастает при $s\ge0$. Для $v\ge0$ из разложения экспоненты в ряд следует $e^{\sqrt{2v}}\ge1+\sqrt{2v}+v$, поэтому

$$(v+\sqrt{2v})-\log(1+v+\sqrt{2v})\ge v.$$

Применив это неравенство при $v=L_1^2(\varphi(x)-\inf\varphi)/L_0$, получаем

$$\frac{L_1\|\nabla\varphi(x)\|}{L_0}\le\frac{L_1^2(\varphi(x)-\inf\varphi)}{L_0}+\sqrt{\frac{2L_1^2(\varphi(x)-\inf\varphi)}{L_0}},$$

что и требовалось.

□

A.3 Оценка локальной кривизны суммы

Доказательство леммы G.2 ▲. Для среднего неотрицательных величин $f_i(y) - \inf f_i$ имеем

$$\frac{1}{n}\sum_i \big(f_i(y) - \inf f_i\big) = f(y) - f^* + f^* - \frac{1}{n}\sum_i \inf f_i \underset{2.5}{\leq} \delta + f(y) - f^*.$$

По лемме A.4, применимой в силу предположений 2.1 и 2.2,

$$\begin{aligned}
\frac{1}{n}\sum_i \|\nabla f_i(y)\| &\leq \frac{L_1}{n}\sum_i \big(f_i(y) - \inf f_i\big) + \frac{1}{n}\sum_i \sqrt{2L_{0,i}\big(f_i(y) - \inf f_i\big)} \\
&\underset{(a)}{\leq} L_1\big(\delta + f(y) - f^*\big) + \sqrt{2L_0\big(\delta + f(y) - f^*\big)}, \\
\ell(y) &\leq L_0 + L_1^2\big(\delta + f(y) - f^*\big) + L_1\sqrt{2L_0\big(\delta + f(y) - f^*\big)} \\
&\underset{(b)}{\leq} \tfrac{3}{2}L_0 + 2L_1^2\big(\delta + f(y) - f^*\big).
\end{aligned}$$

В (a) использованы неравенство Коши–Буняковского–Шварца и ограничение на среднее значение $L_{0,i}$ из предположения 2.2; (b) следует из $2ab \leq a^2 + b^2$. Неравенство треугольника даёт обе оценки для $\|\nabla f(y)\|$. Остальные утверждения получаются суммированием оценок леммы A.1 с учётом предположения 2.2. □

A.4 Вырожденный класс

Предложение A.5.
При предположениях 2.1–2.3 и 2.5, если $L_0 = \delta = 0$, то все компоненты постоянны. Следовательно, минимаксная оракульная сложность такого класса равна нулю.

Доказательство. В силу предположения 2.2 из $L_0 = 0$ следует $L_{0,i} = 0$. В точке x^* из предположения 2.3 имеем

$$0 \leq \frac{1}{n}\sum_i \big(f_i(x^*) - \inf f_i\big) = f^* - \frac{1}{n}\sum_i \inf f_i \underset{2.5}{\leq} \delta = 0.$$

Значит, каждое слагаемое равно нулю, откуда $\nabla f_i(x^*) = 0$. Лемма A.1 при $L_{0,i} = 0$ даёт

$$\|\nabla f_i(x)\| \leq e^{L_1\|x - x^*\|}\|\nabla f_i(x^*)\| = 0$$

для любого x. Следовательно, все компоненты постоянны, и ответ 0 можно выдать без единого запроса к оракулу. □

B Доказательства утверждений о методе YETI

B.1 Нижние оценки по истории

Доказательство леммы G.1 ▲. Выберем точку $w \in B(0, R)$, минимизирующую линейную функцию $u \mapsto \langle \nabla f(z), u\rangle$. По определению нормального конуса $\langle v_z, w - z\rangle \leq 0$. Поэтому

$$f(z) - \widetilde{f}(z) = \langle \nabla f(z), z - w\rangle \leq \langle g, z - w\rangle \underset{(a)}{\leq} \|g\|\|z - w\| \leq 2R\|g\|,$$

где (a) следует из неравенства Коши–Буняковского–Шварца. После записи z в историю имеем $f(w_{\text{best}}) \leq f(z)$ и $\widetilde{f}_{\text{best}} \geq \widetilde{f}(z)$, что завершает доказательство. □

B.2 Нижняя оценка по ответам отдельных компонент

Критерий остановки (G.2) использует нижние оценки (G.1), а каждая из них требует ответов всех n компонент в одной и той же точке. Эвристика в экспериментах (приложение I) запрашивает отдельные компоненты в разных точках. Покажем, что и такие ответы можно объединить в нижнюю оценку f^*, не делая новых запросов. Этот подраздел нужен только для экспериментов: в доказательстве оценки сложности YETI он не используется.

Выберем для каждого индекса i один из уже полученных ответов этой компоненты; пусть он получен в точке p_i. Положим

$$\widetilde{f}_{\text{mix}} = \frac{1}{n}\sum_{i=1}^{n}\bigl(f_i(p_i) - \langle \nabla f_i(p_i), p_i\rangle\bigr) - R\Bigl\|\frac{1}{n}\sum_{i=1}^{n}\nabla f_i(p_i)\Bigr\|. \tag{B.1}$$

Если все точки p_i совпадают с некоторой точкой p, то $\widetilde{f}_{\text{mix}} = \widetilde{f}(p)$, то есть (B.1) обобщает (G.1).

Предложение B.1.
Выполнено $\widetilde{f}_{\text{mix}} \le f^*$. Поэтому величину $\widetilde{f}_{\text{mix}}$ можно учитывать в максимуме $\widetilde{f}_{\text{best}}$ наравне с оценками (G.1). При замене одного выбранного ответа пересчёт обеих сумм в (B.1) требует $O(d)$ арифметических операций и не требует новых запросов к оракулу.

Доказательство. В силу выпуклости компонент (предположение 2.1) для любого w

$$f(w) \ge \frac{1}{n}\sum_{i}\bigl(f_i(p_i) + \langle \nabla f_i(p_i), w - p_i\rangle\bigr).$$

При $w = x^*$ предположение 2.3 и неравенство Коши–Буняковского–Шварца дают $f^* \ge \widetilde{f}_{\text{mix}}$. Замена ответа с индексом i меняет только одно слагаемое скалярной суммы и одно слагаемое векторной суммы. □

Оценку (B.1) можно вычислить только после того, как для каждой компоненты получен хотя бы один ответ. Никаких условий на точки p_i или на порядок, в котором они получены, не требуется. При последующих заменах ответов значение $\widetilde{f}_{\text{mix}}$ может уменьшиться, поэтому в $\widetilde{f}_{\text{best}}$ хранится максимум всех уже полученных нижних оценок. Для пересчёта $\widetilde{f}_{\text{mix}}$ нужно хранить по одному выбранному ответу каждой компоненты; это дополнительная память по сравнению с хранением только лучшей нижней оценки и лучшей точки.

B.3 Локальный решатель

Доказательство леммы H.1 ▲.

▷ Для $\zeta \ge 0$ рассмотрим точку

$$z_\zeta = \Pi_{B(0,R)}\Bigl(\frac{b + \zeta y}{1 + \zeta}\Bigr).$$

Она непрерывно зависит от ζ и стремится к y при $\zeta \to \infty$. Если $\|z_0 - y\| \le r$, достаточно взять $\zeta = 0$. Иначе существует $\zeta > 0$, для которого $\|z_\zeta - y\| = r$. Вид нормального конуса к шару $B(0, R)$ даёт (H.3). Для любого $t \in \mathcal{K}$ получаем

$$\langle b - z, t - z\rangle = \xi\langle z, t - z\rangle + \zeta\langle z - y, t - z\rangle \underset{(a)}{\le} 0.$$

Здесь (a) следует из того, что ξz и $\zeta(z - y)$ — нормали к шарам $B(0, R)$ и $B(y, r)$ в точке z. Это неравенство характеризует проекцию на $\mathcal{K}$ и доказывает утверждение, в том числе когда шары совпадают или один из них вложен в другой.

▷ Неравенство (H.4) следует из леммы A.3 для $\varphi = P_i$ и $L = L_i$. В шаре радиуса $3r$ лежит и вспомогательная точка из доказательства этой леммы, поэтому к ней применима оценка гладкости. Из выпуклости P_i, следующей из предположения 2.1, получаем неотрицательность её отклонения от касательной. Кокоэрцитивность P следует из леммы A.2: на выпуклом шаре $B(y, r)$ средний гессиан P лежит между 0 и $\overline{L}I$. Это локальный вариант классического свойства кокоэрцитивности (Baillon and Haddad, 1977).

□

Для локальной задачи и эпохи SVRG сохраняем обозначения u, w, s, h_s, M и $\overline{L}$ из раздела 4.

Лемма B.2 (уменьшение функции Ляпунова за эпоху).
Положим

$$\Psi(w,s) = \|w-u\|^2 + 4h_s^2 \sum_{j=0}^{M-1}(1-h_s\lambda)^j \sum_{i=1}^{n} \frac{\|\nabla P_i(s) - \nabla P_i(u)\|^2}{nL_i/\overline{L}}. \tag{B.2}$$

Тогда условно относительно всей истории до начала эпохи

$$\begin{aligned} \mathbb{E}\Psi(w^+, s^+) &\le \tfrac{1}{2}\Psi(w,s), \\ \Psi(y,y) &\le \left(1 + \frac{2\overline{L}}{3\lambda}\right)\|y-u\|^2. \end{aligned} \tag{B.3}$$

Доказательство.

▷ Пусть случайный индекс I принимает значение i с вероятностью $L_i/(n\overline{L})$. Тогда

$$v_I - \nabla P(u) = \frac{\nabla P_I(x) - \nabla P_I(u)}{L_I/\overline{L}} + \Big(\nabla P(s) - \nabla P(u) - \frac{\nabla P_I(s) - \nabla P_I(u)}{L_I/\overline{L}}\Big).$$

Второе слагаемое центрировано, а математическое ожидание квадрата его нормы не превосходит суммы из (B.2). Для любой точки $t \in B(y,r)$

$$\sum_{i=1}^{n} \frac{\|\nabla P_i(t) - \nabla P_i(u)\|^2}{nL_i/\overline{L}} \underset{(a)}{\le} 2\overline{L}\big(P(t) - P(u) - \langle \nabla P(u), t-u\rangle\big), \tag{B.4}$$

где (a) следует из выбора вероятностей $L_i/(n\overline{L})$, оценки (H.4) и равенства $P = \frac{1}{n}\sum_i P_i$. Поэтому

$$\begin{aligned} \mathbb{E}\|v_I - \nabla P(u)\|^2 &\underset{(a)}{\le} 2\sum_{i=1}^{n} \frac{\|\nabla P_i(x) - \nabla P_i(u)\|^2}{nL_i/\overline{L}} + 2\sum_{i=1}^{n} \frac{\|\nabla P_i(s) - \nabla P_i(u)\|^2}{nL_i/\overline{L}} \\ &\underset{(b)}{\le} 4\overline{L}\big(P(x) - P(u) - \langle \nabla P(u), x-u\rangle\big) + 2\sum_{i=1}^{n} \frac{\|\nabla P_i(s) - \nabla P_i(u)\|^2}{nL_i/\overline{L}}. \end{aligned}$$

Здесь (a) следует из неравенства

$$\|a+b\|^2 \le 2\|a\|^2 + 2\|b\|^2,$$

(b) — из (B.4) при $t = x$.

▷ Оптимальность u означает $u = \Pi_{\mathcal{K}}(u - h_s\nabla P(u))$. Поэтому

$$\begin{aligned} \mathbb{E}\|x^+ - u\|^2 &\underset{(a)}{\le} \|x-u\|^2 - 2h_s\langle \nabla P(x) - \nabla P(u), x-u\rangle + h_s^2\mathbb{E}\|v_I - \nabla P(u)\|^2 \\ &\underset{(b)}{\le} (1-h_s\lambda)\|x-u\|^2 - \frac{4}{3}h_s\big(P(x) - P(u) - \langle \nabla P(u), x-u\rangle\big) \\ &\quad + 2h_s^2\sum_{i=1}^{n} \frac{\|\nabla P_i(s) - \nabla P_i(u)\|^2}{nL_i/\overline{L}}. \end{aligned}$$

Здесь (a) следует из нерастяжимости проекции и несмещённости v_I, (b) — из сильной выпуклости P, предыдущего пункта и равенства $2h_s - 4h_s^2\overline{L} = \frac{4}{3}h_s$.

▷ По (H.5) имеем $0 < h_s\lambda \le 1/6$ и $h_s\lambda M \ge 7/10$. Развернём полученное рекуррентное неравенство на всю эпоху. Так как $8h_s^2\overline{L} = \frac{4}{3}h_s$, слагаемые с остатками линеаризации в точках x_j сокращаются, и

$$\mathbb{E}\Psi(w^+, s^+) \underset{(a)}{\le} (1-h_s\lambda)^M\|w-u\|^2 + 2h_s^2\sum_{j=0}^{M-1}(1-h_s\lambda)^j \sum_{i=1}^{n} \frac{\|\nabla P_i(s) - \nabla P_i(u)\|^2}{nL_i/\overline{L}} \underset{(b)}{\le} \tfrac{1}{2}\Psi(w,s).$$

Здесь (a) следует из рекуррентного неравенства предыдущего пункта, оценки (B.4) при $t = s^+$ и неравенства Йенсена для выпуклой функции $t \mapsto P(t) - P(u) - \langle \nabla P(u), t - u\rangle$, (b) — из $(1 - h_s\lambda)^M \le e^{-7/10} < 1/2$. Наконец, локальная гладкость даёт

$$P(y) - P(u) - \langle \nabla P(u), y - u\rangle \le \frac{\overline{L}}{2}\|y - u\|^2,$$

поэтому по (B.4) сумма из (B.2) при $s = y$ не превосходит $\overline{L}^2\|y - u\|^2$. Вместе с

$$\sum_{j=0}^{M-1} (1 - h_s\lambda)^j \le \frac{1}{h_s\lambda}$$

это даёт

$$\Psi(y, y) \le \left(1 + \frac{4h_s\overline{L}^2}{\lambda}\right)\|y - u\|^2 = \left(1 + \frac{2\overline{L}}{3\lambda}\right)\|y - u\|^2.$$

□

Доказательство леммы H.2 ▲.

▷ По лемме H.1 отображение $I - \nabla P/\overline{L}$ нерастяжимо на $\mathcal{K}$. Сравнивая проекции точек $w - \nabla P(w)/\overline{L}$ и $u - \nabla P(u)/\overline{L}$, получаем первую оценку в (H.11). Для второй оценки имеем

$$\begin{aligned}\|e\|^2 &= \overline{L}^2\|w - z\|^2 - 2\overline{L}\langle \nabla P(w) - \nabla P(z), w - z\rangle + \|\nabla P(w) - \nabla P(z)\|^2 \\ &\underset{(a)}{\le} \overline{L}\langle e, w - z\rangle \underset{(b)}{\le} \overline{L}\langle e, w - u\rangle \underset{(c)}{\le} \overline{L}\|e\|\|w - u\|.\end{aligned}$$

Здесь (a) следует из кокоэрцитивности ∇P, (b) — из неравенства

$$\langle e, z - u\rangle \ge P(z) - P(u) \ge 0,$$

которое верно, поскольку $e \in \nabla P(z) + N_{\mathcal{K}}(z)$ по определению проекции, (c) — из неравенства Коши–Буняковского–Шварца.

▷ Если $\|w - u\|$ удовлетворяет условию леммы, то

$$\|e\| \le \overline{L}\|w - u\| \le \frac{4}{5}\lambda\big(\|y - u\| - \|w - u\|\big) \le \frac{4}{5}\lambda\|y - z\| \le \frac{4}{5}(\lambda + \beta)\|y - z\|.$$

Предпоследний переход следует из $\|z - u\| \le \|w - u\|$ и неравенства треугольника. Значит, выполнено второе условие (H.10). Если $y = u$, то $\Psi(y, y) = 0$, после первой эпохи почти наверное $w = u$, и набор принимается. При $y \ne u$ после j эпох лемма B.2 и неравенство Маркова дают

$$\begin{aligned}\Pr(T_{\text{ep}} > j) &\le \Pr\left(\|w_j - u\| > \frac{4\lambda}{5\overline{L} + 4\lambda}\|y - u\|\right) \\ &\le \left(1 + \frac{5\overline{L}}{4\lambda}\right)^2 \frac{\mathbb{E}\Psi(w_j, s_j)}{\|y - u\|^2} \le \Gamma 2^{-j}.\end{aligned}$$

При выводе этой оценки эпохи можно мысленно продолжить и после первого принятия, используя независимые выборки. Сумма правых частей конечна, что доказывает оба утверждения о времени остановки.

□

B.4 Убывание функции Ляпунова

Лемма B.3 (убывание функции Ляпунова).
Во всех состояниях метода выполнены условия

$$\begin{gathered} x, v \in B(0, R), \\ \mathcal{A} \geq R^2/(2\Delta), \\ h \geq \tfrac{1}{2}\lambda_{\downarrow}(\mathcal{A}), \\ \mathcal{A}\big(f(x) - f^*\big) + \tfrac{1}{2}\|v - x^*\|^2 \leq R^2. \end{gathered} \tag{B.5}$$

Обозначим левую часть последнего неравенства через Φ (функция Ляпунова). Всегда $\alpha \leq \frac{1}{2}(r/R)^{2/3} \leq \frac{1}{2}$ и $\lambda \leq 2h$. Принятие точки, предложенной эвристическим блоком, не меняет $v, \mathcal{A}, h$ и не увеличивает Φ. При нарушении (G.9) полупространство $\mathcal{H}_y$ содержит x^* и

$$\Phi^+ \leq \Phi - \frac{9r^2}{128\alpha^2}. \tag{B.6}$$

Пусть $y = (1-\alpha)x + \alpha v$ — центр локальной задачи из (G.8), а z — точка, возвращённая решателем. Если набор (z, g, β) принят по второму условию (H.10), то

$$\Phi^+ \leq \Phi - \frac{9}{50}\frac{\|y - z\|^2}{\alpha^2}. \tag{B.7}$$

При любом способе остановки невязка ответа не превосходит $\varepsilon/2$.

Доказательство.

▷ В начальный момент

$$\Phi_0 = \frac{R^2}{2\Delta}\big(f(0) - f^*\big) + \tfrac{1}{2}\|x^*\|^2 \underset{2.3,\,2.4}{\leq} R^2.$$

Функция $\lambda_{\downarrow}$ не возрастает, поэтому $\lambda_{\downarrow}(\mathcal{A}) \leq \lambda_{\uparrow}$ и $\lambda \geq \lambda_{\downarrow}(\mathcal{A})$. Равенство $\lambda\mathcal{A}\alpha^2 = 1-\alpha$ влечёт $\alpha \leq \frac{1}{2}(r/R)^{2/3}$, поскольку функция $t \mapsto (1-t)/t^2$ убывает. Неравенство $h \geq \lambda_{\downarrow}(\mathcal{A})/2$ влечёт $\lambda \leq 2h$.

▷ По правилу принятия эвристической точки $z \in B(0, R)$ и $f(z) \leq f(x)$. Замена x на z меняет функцию Ляпунова на $\mathcal{A}(f(z) - f(x)) \leq 0$, а $v, \mathcal{A}, h$ не меняются. Поэтому условия (B.5) сохраняются.

▷ Из предположения 2.1 и следствия G.3 получаем

$$\langle \nabla f(y), x^* - y\rangle \leq f^* - f(y) \leq -\frac{\ell(y) - \frac{3}{2}L_0 - 2L_1^2\delta}{2L_1^2},$$

то есть $x^* \in \mathcal{H}_y$. Пусть условие (G.9) нарушено. Так как $L_1 r \leq 1/2$,

$$\frac{\ell(y) - \frac{3}{2}L_0 - 2L_1^2(\delta + R^2/\mathcal{A})}{2L_1^2} \underset{(a)}{>} \frac{(1 - e^{-L_1 r})\ell(y)}{2L_1^2} \underset{(b)}{\geq} \frac{3r\ell(y)}{8L_1} > 0.$$

Здесь (a) следует из нарушения (G.9), (b) — из $1 - e^{-s} \geq 3s/4$ при $0 \leq s \leq 1/2$. Так как $f(x) - f^* \leq \Phi/\mathcal{A} \leq R^2/\mathcal{A}$,

$$\langle \nabla f(y), y - x\rangle \underset{2.1}{\geq} f(y) - f(x) \geq f(y) - f^* - \frac{R^2}{\mathcal{A}} \underset{(b)}{\geq} \frac{\ell(y) - \frac{3}{2}L_0 - 2L_1^2(\delta + R^2/\mathcal{A})}{2L_1^2}.$$

Переход (b) вытекает из следствия G.3. Правая часть положительна, следовательно, $\nabla f(y) \neq 0$. Используя $v - y = (1-\alpha)(y - x)/\alpha$ и $\|\nabla f(y)\| \leq \ell(y)/L_1$, получаем

$$\begin{aligned} \operatorname{dist}(v, \mathcal{H}_y) &= \frac{1}{\|\nabla f(y)\|}\left(\langle \nabla f(y), v - y\rangle + \frac{\ell(y) - \frac{3}{2}L_0 - 2L_1^2\delta}{2L_1^2}\right) \\ &\geq \frac{\ell(y) - \frac{3}{2}L_0 - 2L_1^2(\delta + R^2/\mathcal{A})}{2L_1^2\,\alpha\|\nabla f(y)\|} \geq \frac{3r}{8\alpha}. \end{aligned}$$

Проекция на $\mathcal{H}_y$ уменьшает квадрат расстояния до x^* не менее чем на квадрат расстояния от v до $\mathcal{H}_y$, а проекция на $B(0,R)$ его не увеличивает по предположению 2.3. Это даёт (B.6). Принадлежность x полупространству для рассуждения не нужна.

▷ Пусть набор принят по второму условию (H.10). Тогда g является субградиентом $f+I_{B(0,R)}$ в точке z, и

$$\Phi^+ - \Phi \underset{(a)}{\le} \gamma\mathcal{A}\langle g, z-x\rangle + \gamma a_\lambda\langle g, z-v\rangle + \tfrac12\gamma^2 a_\lambda^2\|g\|^2 = -\gamma(\mathcal{A}+a_\lambda)\langle g, y-z\rangle + \tfrac12\gamma^2a_\lambda^2\|g\|^2$$
$$= \tfrac12\gamma^2a_\lambda^2\big(\|e\|^2 - (\lambda+\beta)^2\|y-z\|^2\big) \underset{(b)}{\le} -\frac{9}{50}\gamma^2a_\lambda^2(\lambda+\beta)^2\|y-z\|^2 = -\frac{9}{50\alpha^2}\|y-z\|^2.$$

В (a) использованы выпуклость f (предположение 2.1), комбинация (G.11) и нерастяжимость проекции, сохраняющей x^* по предположению 2.3; (b) следует из $\|e\| \le \frac45(\lambda+\beta)\|y-z\|$. В последнем равенстве использованы равенства $\gamma(\lambda+\beta)=\lambda$ и $\lambda a_\lambda = 1/\alpha$. При $\beta>0$ смещение равно r. Все новые точки принадлежат $B(0,R)$, а $\mathcal{A}$ не убывает. На повышающем шаге $h^+ = 2\lambda \ge \lambda_\downarrow(\mathcal{A}^+)/2$, на понижающем — $h^+ = \lambda/2 \ge \lambda_\downarrow(\mathcal{A}^+)/2$. Поэтому условия (B.5) сохраняются.

▷ Если принят набор с $\|g\| \le \varepsilon/(4R)$, то для $z, x^* \in B(0,R)$

$$f(z) - f^* \underset{(a)}{\le} \langle g, z-x^*\rangle \underset{(b)}{\le} 2R\|g\| \le \varepsilon/2,$$

где (a) следует из $g \in \partial(f+I_{B(0,R)})(z)$, (b) — из неравенства Коши–Буняковского–Шварца и предположения 2.3. Остановка по росту $\mathcal{A}$ даёт $f(x) - f^* \le R^2/\mathcal{A} \le \varepsilon/2$. По (G.1) и предложению B.1 имеем $\widetilde{f}_{\text{best}} \le f^*$. Поэтому при остановке по критерию (G.2)

$$f(w_{\text{best}}) - f^* \le f(w_{\text{best}}) - \widetilde{f}_{\text{best}} \le \varepsilon/2.$$

Наконец, набор, принятый по второму условию при $\beta=0$ и $\lambda = \varepsilon/(8rR)$, уже удовлетворяет

$$\|g\| \le \frac95 \cdot \frac{\varepsilon}{8rR}\, r = \frac{9\varepsilon}{40R} < \frac{\varepsilon}{4R}.$$

Поэтому отдельное правило остановки при $\lambda = \varepsilon/(8rR)$ не требуется.

□

B.5 Число основных итераций

Лемма B.4 (число основных итераций).
При любом выборе эвристики в алгоритме 1 метод почти наверное останавливается не позже чем через K_{out} основных итераций, где K_{out} — детерминированная величина, удовлетворяющая оценке

$$K_{\text{out}} \lesssim \left(\frac{R}{r}\right)^{2/3}\left(1+\log\frac{\Delta}{\varepsilon}\right) + \log\left(2+\frac{rR\lambda_\uparrow}{\varepsilon}\right) + \frac{L_1R}{\sqrt{n}}\log\frac{\Delta}{\varepsilon} + \sqrt{\frac{(L_0+L_1^2\delta)R^2}{n\varepsilon}}. \tag{B.8}$$

Доказательство. Будем учитывать только итерации, после которых метод ещё не остановился; на них $\mathcal{A} < 2R^2/\varepsilon$. Принятие результата эвристики не меняет $\mathcal{A}, h$ и не увеличивает функцию Ляпунова Φ.

▷ Пусть n_U — число итераций, повышающих регуляризацию. По лемме B.3 на каждой из них

$$\Phi - \Phi^+ \ge \frac{9r^2}{128\alpha^2} \ge \frac{9}{32}R^2\left(\frac{r}{R}\right)^{2/3}, \qquad \alpha \le \frac12\left(\frac{r}{R}\right)^{2/3}.$$

Так как $0 \le \Phi \le R^2$, имеем $n_U \le \frac{32}{9}(R/r)^{2/3}$. Каждая такая итерация увеличивает h не более чем в четыре раза. Итерация с $\beta=0$ и $\lambda > \lambda_\downarrow(\mathcal{A})$ уменьшает h не менее чем вдвое,

а при $\lambda = \lambda_\downarrow(\mathcal{A})$ не увеличивает его. Из $h \ge \lambda_\downarrow(\mathcal{A})/2 \ge \varepsilon/(16rR)$ следует, что число n_D итераций с $\beta = 0$ и $\lambda > \lambda_\downarrow(\mathcal{A})$ удовлетворяет

$$h\,2^{n_D} \le \lambda_\uparrow 4^{n_U}, \qquad n_D \le 2n_U + \log_2 \frac{16rR\lambda_\uparrow}{\varepsilon}.$$

▷ Рассмотрим оставшиеся итерации с $\beta = 0$ и $\lambda = \lambda_\downarrow(\mathcal{A})$. На них $\mathcal{A}^+ = \mathcal{A} + a_\lambda$. Если максимум в (G.7) достигается на первом члене, то $\alpha = \frac{1}{2}(r/R)^{2/3}$ и

$$\log \frac{\mathcal{A}^+}{\mathcal{A}} = -\log(1-\alpha) \ge \alpha = \frac{1}{2}(r/R)^{2/3}.$$

Поскольку $\mathcal{A}_0 = R^2/(2\Delta)$, а до остановки $\mathcal{A} < 2R^2/\varepsilon$, суммарный рост $\log \mathcal{A}$ меньше $\log(4\Delta/\varepsilon)$. Поэтому таких итераций не больше $2(R/r)^{2/3}\log(4\Delta/\varepsilon)$.

▷ Если максимум достигается на втором члене, то

$$\lambda = \frac{1}{n}\left(\frac{3}{2}L_0 + 2L_1^2\delta + \frac{2L_1^2R^2}{\mathcal{A}}\right).$$

Если $\frac{3}{2}L_0 + 2L_1^2\delta \ge 2L_1^2R^2/\mathcal{A}$, то $\lambda \le (3L_0 + 4L_1^2\delta)/n$. Из $a_\lambda \ge \sqrt{\mathcal{A}/\lambda}$ и $\mathcal{A}^+ \le 2\mathcal{A}$ получаем

$$\begin{aligned}\sqrt{\mathcal{A}^+} - \sqrt{\mathcal{A}} &= \frac{a_\lambda}{\sqrt{\mathcal{A} + a_\lambda} + \sqrt{\mathcal{A}}} \\ &\ge \frac{1}{(1+\sqrt{2})\sqrt{\lambda}} \ge \frac{\sqrt{n}}{(1+\sqrt{2})\sqrt{3L_0 + 4L_1^2\delta}}.\end{aligned}$$

Так как $\sqrt{\mathcal{A}} < \sqrt{2R^2/\varepsilon}$, число этих итераций не превосходит

$$(1+\sqrt{2})\sqrt{\frac{2(3L_0 + 4L_1^2\delta)R^2}{n\varepsilon}}.$$

В противоположном случае $\lambda\mathcal{A} < 4(L_1R)^2/n$. Так как $\alpha \le 1/2$, имеем

$$\alpha^2 = \frac{1-\alpha}{\lambda\mathcal{A}} \ge \frac{n}{8(L_1R)^2}, \qquad \log\frac{\mathcal{A}^+}{\mathcal{A}} \ge \alpha \ge \frac{\sqrt{n}}{2\sqrt{2}\,L_1R}.$$

Поэтому число таких итераций есть $O((L_1R/\sqrt{n})\log(\Delta/\varepsilon))$.

▷ Если максимум достигается на последнем члене, то есть $\lambda = \varepsilon/(8rR)$, то метод останавливается по лемме B.3. Если несколько членов равны, итерацию относим к любому из них.

Суммируя полученные оценки и учитывая последнюю итерацию, получаем (B.8). Каждый вызов решателя почти наверное завершается за конечное число шагов, а каждый эвристический блок конечен по определению (раздел G.5). Следовательно, метод почти наверное останавливается. □

B.6 Число запросов эвристики

Доказательство теоремы F.3 ▲.

▷ В начальный момент $G = H = 0$. Из неравенства $H \le B_0 + \omega G$ следует неотрицательность числа разрешённых запросов в (F.4). Один блок расходует не больше $B_0 + \omega G - H$ запросов, поэтому после блока неравенство сохраняется. За основную итерацию увеличивается только G, так что неравенство также сохраняется. Лимит каждого блока не больше B_0, что доказывает вторую оценку $H \le kB_0$.

▷ Блоки с лимитом $B_k \le B_0$ удовлетворяют требованиям раздела G.5, поэтому к ним применимы леммы B.3 и B.4. Все условные оценки основных итераций и оценка числа обращений к оракулу в каждом эвристическом блоке остаются верными. Следовательно, оценка теоремы 5.1 сохраняется. Наконец, при каждом запуске

$$T = G + H \underset{(a)}{\le} B_0 + (1+\omega)G,$$

где (a) следует из (F.5). Переходя к математическому ожиданию, получаем (F.6).

□

C Доказательство верхней оценки

Используем N и T_0 из раздела 2. Все оценки ниже равномерны по параметрам задачи и истории метода.

C.1 Число основных итераций

По выбору радиуса r имеем

$$\frac{R}{r} = \max\{1, 2L_1 R\} \le 2\sqrt{N}.$$

Из (G.7) следует

$$\frac{\lambda_\uparrow r R}{\varepsilon} \lesssim \frac{\Delta}{\varepsilon}\left(\frac{R}{r}\right)^{1/3} + \frac{(L_0 + L_1^2\delta)R^2}{n\varepsilon} + \frac{\Delta}{\varepsilon}\frac{L_1 R}{n} + 1 \lesssim N^{3/2}. \tag{C.1}$$

Поэтому логарифмы в (B.8) имеют порядок $O(\log N)$.

Лемма C.1.
Число основных итераций удовлетворяет

$$nK_{\text{out}} \lesssim T_0 \log N. \tag{C.2}$$

Доказательство. Подставляя (C.1) в (B.8), получаем

$$nK_{\text{out}} \lesssim \log N \left[n\left(\frac{R}{r}\right)^{2/3} + \sqrt{n}\, L_1 R + \sqrt{\frac{n(L_0 + L_1^2\delta)R^2}{\varepsilon}} \right].$$

Остаётся использовать $(R/r)^{2/3} \sim 1 + (L_1 R)^{2/3}$ и $a + b \sim \sqrt{a^2 + b^2}$ для $a, b \ge 0$. □

C.2 Число запросов локального решателя

Проверка кривизны (G.9) и нижняя граница для λ дают

$$\kappa := \frac{\overline{L}}{\lambda} = 1 + \frac{e^{3L_1 r}\ell(y)}{\lambda} \le 1 + ne^{4L_1 r} \le 1 + ne^2 \le 8n, \tag{C.3}$$

поскольку $L_1 r \le 1/2$ и $n \ge 2$. Здесь использовано, что одна и та же величина $\frac{3}{2}L_0 + 2L_1^2(\delta + R^2/\mathcal{A})$ входит и в проверку кривизны, и в нижнюю границу для $n\lambda$.

Лемма C.2.
При любой истории, предшествующей локальному вызову,

$$\mathbb{E}[T_{\text{ep}} \mid \text{история}] \le 2 + \lceil \log_2 \Gamma \rceil, \qquad n + M \le 36n, \tag{C.4}$$

где Γ задано в лемме H.2 и $\Gamma \le 9(8n)^3$. В частности, условное математическое ожидание числа запросов локального решателя имеет порядок $O(n \log(n+2))$.

Доказательство. По (C.3) длина эпохи $M = \lceil 21\kappa/5 \rceil \le 1 + 168n/5 \le 35n$. Для величины Γ из (H.12) имеем

$$\Gamma = \left(1 + \frac{2\kappa}{3}\right)\left(1 + \frac{5\kappa}{4}\right)^2 \le \frac{5\kappa}{3}\left(\frac{9\kappa}{4}\right)^2 \le 9\kappa^3 \le 9(8n)^3,$$

так как $\kappa \ge 1$. Положим $j_0 = \lceil \log_2 \Gamma \rceil$. Суммируя хвостовую оценку (H.12), получаем

$$\mathbb{E}[T_{\text{ep}} \mid \text{история}] \le 1 + \sum_{j \ge 1} \min\{1, \Gamma 2^{-j}\} \le 1 + j_0 + \sum_{j > j_0} \Gamma 2^{-j} \le j_0 + 2.$$

Каждая эпоха вместе с проверкой результата требует $O(n + M) = O(n)$ запросов. □

C.3 Суммарное число запросов

Доказательство теоремы 5.1. По леммам B.3 и B.4 метод почти наверное останавливается с невязкой не более $\varepsilon/2$. Это доказывает (5.1).

Если проверка кривизны не пройдена, основная итерация требует n запросов. Иначе по лемме C.2 условное среднее число запросов равно $O(n\log(n+2))$. Эта оценка включает вычисления в центре, в опорных точках и при проверке результата решателя. Остановка по истории может лишь уменьшить число запросов: для сравнения работу решателя можно продолжить с новыми случайными индексами до выполнения его собственного критерия остановки. Каждый эвристический блок по определению из раздела G.5 делает $O(n\log N)$ запросов. Поскольку $n+2\le N$, эта же оценка применима и к основной итерации.

Число основных итераций и предшествующих им блоков не превосходит K_{out}. Суммируя условные оценки и используя (C.2), получаем

$$\mathbb{E}T \lesssim nK_{\text{out}}\log N \lesssim T_0\log^2 N.$$

Оценка равномерна по всем эвристикам, допустимым в блоке из раздела G.5. □

D Конструкции для нижней оценки

Всюду ниже считаем выполненными предположения 2.1–2.6.

D.1 Переход к рандомизированным методам

Лемма D.1 (усреднение по конечному семейству).
Пусть $\mathcal{F}$ — непустое конечное семейство допустимых входов, а $c_\tau>0$ и $c_{\mathcal{E}}\ge 0$ — весовые коэффициенты. Обозначим через τ_F число обращений алгоритма к оракулу на входе F, а через $\mathcal{E}_F$ — невязку его ответа на этом входе, то есть $f_F(\hat{x}_F)-f_F^*$. Если для каждого детерминированного алгоритма

$$\frac{1}{|\mathcal{F}|}\sum_{F\in\mathcal{F}}\bigl(c_\tau\tau_F+c_{\mathcal{E}}\mathcal{E}_F\bigr)\ge c,$$

то $\mathcal{T}^*\ge(c-c_{\mathcal{E}}\varepsilon)/c_\tau$. Входы в семействе могут повторяться: сумма берётся по конечному множеству параметров с равными весами.

Доказательство леммы D.1. Если зафиксировать все используемые алгоритмом случайные величины, он становится детерминированным. Измеримость правил выбора запросов в принятой модели оракула позволяет усреднить оценку по случайным величинам алгоритма. Пусть M — корректный алгоритм (то есть его ожидаемая невязка на каждом входе не превосходит ε) и $\mathcal{T}(\mathsf{M})<+\infty$. Тогда

$$c\underset{(a)}{\le}\mathbb{E}\left[\frac{1}{|\mathcal{F}|}\sum_{F\in\mathcal{F}}(c_\tau\tau_F+c_{\mathcal{E}}\mathcal{E}_F)\right]=\frac{1}{|\mathcal{F}|}\sum_{F\in\mathcal{F}}\bigl(c_\tau\mathbb{E}\tau_F+c_{\mathcal{E}}\mathbb{E}\mathcal{E}_F\bigr)\underset{(b)}{\le}c_\tau\mathcal{T}(\mathsf{M})+c_{\mathcal{E}}\varepsilon.$$

Здесь неравенство (a) следует из условия леммы, применённого при любых значениях случайных величин алгоритма, а в (b) использованы неравенства $\mathbb{E}\tau_F\le\mathcal{T}(\mathsf{M})$ и $\mathbb{E}\mathcal{E}_F\le\varepsilon$. Значит, $\mathcal{T}(\mathsf{M})\ge(c-c_{\mathcal{E}}\varepsilon)/c_\tau$; при $\mathcal{T}(\mathsf{M})=+\infty$ это неравенство очевидно. Переходя к инфимуму по корректным алгоритмам, получаем утверждение для $\mathcal{T}^*$. Это вариант принципа Яо (Yao, 1977) для конечного семейства. □

Пусть $c:\{1,\dots,s\}\to\{1,\dots,d\}$ выбрано равномерно, а координата 0 в $\mathbb{R}^{d+1}$ выделена. Раскрытие координат и ответы оракула зависят только от текущего запроса и уже раскрытых значений, а запросы и возвращённая точка — от истории ответов. При оценке вероятности раскрытия координат учитываем также возвращённую точку; число запросов при этом не увеличивается.

Лемма D.2 (усреднение по скрытой координате).
Пусть $\alpha, L > 0$, а $N_{\text{qry}} \geq 1$ — произвольное целое число. Доля отображений c, для которых среди первых N_{qry} точек запроса и точки, возвращённой до этого срока, найдётся точка x с $\|x\| \leq L$ и $|x_{c(j)}| \geq \alpha$ для некоторой ещё не раскрытой координаты $c(j)$, не превосходит $(N_{\text{qry}}+1)sL^2/(d\alpha^2)$. С учётом неинъективных отображений доля исключений не превосходит

$$\frac{s^2 + (N_{\text{qry}}+1)sL^2/\alpha^2}{d}. \tag{D.1}$$

Оценка (D.1) относится к равномерному распределению на множестве всех отображений, а не к условному распределению инъекций. Каждому неинъективному отображению приписываем вход, соответствующий одной фиксированной инъекции. Таким образом, каждый вход конечного распределения допустим. На исключениях используется лишь неотрицательность числа запросов и невязки; никаких свойств недопустимой конструкции там не требуется. Размерность выбирается после $N_{\text{qry}}, L, \alpha$, но до выбора алгоритма. Поэтому одна и та же размерность обеспечивает нужную оценку для любого алгоритма и любых значений используемых им случайных величин.

Доказательство леммы D.2. Зафиксируем позицию j и все значения c, кроме $c(j)$. До раскрытия j все соответствующие запуски имеют одну и ту же историю: это проверяется индукцией по времени, поскольку ответы до раскрытия не зависят от $c(j)$. Поэтому на любом шаге до раскрытия точка запроса или возвращённая точка одна и та же для всех d значений $c(j)$. Если её норма не больше L, то

$$\alpha^2 \#\{v : |x_v| \geq \alpha\} \leq \sum_{v:|x_v|\geq\alpha} |x_v|^2 \leq \|x\|^2 \leq L^2.$$

Доля значений $c(j)$, для которых $|x_{c(j)}| \geq \alpha$, не больше $L^2/(d\alpha^2)$. Остаётся усреднить по значениям на остальных позициях и просуммировать по s позициям и $N_{\text{qry}}+1$ точкам. Вероятность того, что c принимает одинаковые значения на двух различных позициях, не больше $\binom{s}{2}/d \leq s^2/d$. □

Лемма D.3 (нижняя оценка по числу раскрытых звеньев).
Пусть для конечного распределения допустимых входов задан идеальный процесс раскрытия s звеньев. Для любого детерминированного алгоритма и любого срока N_{qry} обозначим через Q число запросов в этом процессе до остановки или до указанного срока, а через P — число раскрытых звеньев. Предположим, что $\mathbb{E}Q \geq c_\tau \mathbb{E}P$ при некотором $c_\tau > 0$.

Пусть, кроме того, вне исключительного множества реальные и идеальные истории совпадают, а невязка возвращённой до этого срока точки не меньше $A - BP$, где

$$A \geq 7\varepsilon/4, \qquad B > 0, \qquad sB \geq A.$$

Если доля исключений ограничена величиной (D.1) с фиксированными $L, \alpha > 0$, не зависящими от алгоритма и размерности, то в некоторой конечной размерности

$$\mathcal{T}^* \geq \frac{c_\tau A}{4B}.$$

Доказательство. Положим $N_{\text{qry}} = \lceil 16Ac_\tau/B \rceil$, $q = BN_{\text{qry}}/(Ac_\tau) \geq 16$ и

$$Z = \frac{BQ}{Ac_\tau} + 1 - \frac{B}{A}P.$$

По предположению $\mathbb{E}Z \geq 1$, а из $Q \leq N_{\text{qry}}$ следует $Z \leq q+1$. По (D.1) выбор

$$d \geq 16q\big(s^2 + (N_{\text{qry}}+1)sL^2/\alpha^2\big)$$

обеспечивает $q\Pr(\text{bad}) \leq 1/16$ одновременно для всех алгоритмов.

Пусть τ — фактическое число запросов, $\mathcal{E}$ — невязка. Вне исключений при $\tau < N_{\mathrm{qry}}$ имеем $Q \le \tau$ и $\mathcal{E} \ge \max\{0, A - BP\}$; при $\tau \ge N_{\mathrm{qry}}$ используем $Z \le q+1$. Во всех случаях

$$\frac{B\tau}{Ac_\tau} + \frac{\mathcal{E}}{A} \ge \frac{q}{q+1} Z - q\mathbf{1}_{\mathrm{bad}}.$$

Действительно, при $Z < 0$ достаточно неотрицательности левой части, а на исключениях правая часть неположительна. Усредняя по входам и по случайным величинам корректного алгоритма, как в лемме D.1, получаем

$$\frac{B\mathcal{T}(\mathsf{M})}{Ac_\tau} \ge \frac{q}{q+1} - \frac{1}{16} - \frac{\varepsilon}{A} \ge \frac{16}{17} - \frac{1}{16} - \frac{4}{7} > \frac{1}{4}.$$

Остаётся перейти к инфимуму по корректным алгоритмам. □

D.2 Построение цепочки

Определим симметричную C^1-ступеньку

$$h(t) = \begin{cases} 0, & t \le 0, \\ 3t^2 - 2t^3, & 0 \le t \le 1, \\ 1, & t \ge 1. \end{cases}$$

Она принадлежит C^1, не убывает и удовлетворяет $h(1-t) = 1 - h(t)$. На $[0,1]$ имеем $h'(t) = 6t(1-t)$, поэтому $0 \le h' \le M = 3/2$. Положим

$$\begin{aligned} p(t) &= h(4|t| - 1)\bigl(1 - h(|t| - 2)\bigr), \\ \widehat{\psi}'(t) &= \int_0^t p(u)\,du, \\ \widehat{\psi}(t) &= \int_0^t \widehat{\psi}'(u)\,du, \\ G_H &= \widehat{\psi}'(1), \\ c_H &= G_H - \widehat{\psi}(1). \end{aligned} \tag{D.2}$$

На $[1/4, 1/2]$ подстановка $u = 4t - 1$ и интегрирование многочлена h дают

$$G_H = \frac{5}{8}, \qquad \widehat{\psi}(1) = \frac{63}{320}, \qquad c_H = \frac{137}{320}. \tag{D.3}$$

Функция p чётна, $0 \le p \le 1$, равна нулю при $|t| \le 1/4$ и $|t| \ge 3$, а на $[1/2, 2]$ равна единице. Следовательно, функция $\widehat{\psi}$ принадлежит C^2, выпукла, неотрицательна, равна нулю на $[-1/4, 1/4]$ и удовлетворяет оценкам

$$\begin{aligned} |\widehat{\psi}'| &\le 3, \\ 0 \le \widehat{\psi}'' &\le 1, \\ \widehat{\psi}(v) &\ge \tfrac{3}{2}(v - 2). \end{aligned} \tag{D.4}$$

Последняя оценка при $v \ge 2$ следует из касательной в точке 2:

$$\widehat{\psi}'(2) \ge \int_{1/2}^{2} p = 3/2.$$

Для произвольных $c_\psi, \sigma > 0$ рассмотрим семейство одномерных функций

$$\psi(u) = c_\psi \widehat{\psi}(u/\sigma).$$

Параметры c_ψ и σ будут выбраны отдельно для каждого семейства.

При $w > 0$ для точного сглаживания максимума зададим

$$S'_w(u) = 2h\big((u+w)/(2w)\big) - 1,$$
$$S_w(u) = w - \int_0^w S'_w(v)\,dv + \int_0^u S'_w(v)\,dv,$$
$$\operatorname{smax}_w(a,b) = (a+b)/2 + S_w((a-b)/2).$$

Из симметрии h следует чётность S_w; кроме того, $S_w(w) = w$. Из $|S'_w| \le 1$ и $0 \le S''_w \le M/w$ следует $S_w \ge |\cdot|$, причём равенство достигается при $|u| \ge w$. Поэтому функция smax_w принадлежит C^2, выпукла, не убывает по каждому аргументу, не меньше максимума своих аргументов и совпадает с ним при $|a-b| \ge 2w$. Для выпуклых C^2-функций $a(x), b(x)$

$$\begin{aligned} \nabla \operatorname{smax}_w(a,b) &= \frac{\nabla a + \nabla b}{2} + \frac{1}{2} S'_w((a-b)/2)(\nabla a - \nabla b), \\ \|\nabla^2 \operatorname{smax}_w(a,b)\| &\le \|\nabla^2 a\| + \|\nabla^2 b\| + \frac{M}{4w}\|\nabla a - \nabla b\|^2. \end{aligned} \tag{D.5}$$

Формулы получаются двукратным дифференцированием; дополнительное слагаемое в гессиане равно $\frac{1}{4} S''_w((a-b)/2)(\nabla a - \nabla b)(\nabla a - \nabla b)^\top$.

Для произвольного целого $T \ge 1$ положим $y_j = x_{c(j)}$ при $j < T$ и $y_T = 0$. Определим цепочку

$$C(x) = -\frac{c_\psi G_H}{\sigma} y_0 + \sum_{j=0}^{T-1} \psi(y_j - y_{j+1}). \tag{D.6}$$

Выпуклость функции ψ и касательная в σ дают для $0 \le p \le T$

$$C(x) \underset{(a)}{\ge} -\frac{c_\psi G_H}{\sigma} y_0 + \sum_{j=0}^{p-1} \Big(\frac{c_\psi G_H}{\sigma}(y_j - y_{j+1}) - c_\psi c_H \Big) \underset{(b)}{=} -\frac{c_\psi G_H}{\sigma} y_p - p c_\psi c_H. \tag{D.7}$$

Здесь в (a) использована касательная к функции ψ в точке σ, а в (b) учтено сокращение соседних слагаемых.

При $p = T$ получаем $C \ge -T c_\psi c_H$, причём равенство достигается при $y_j = (T-j)\sigma$. Для инъективного c оператор $y \mapsto (y_j - y_{j+1})_{j<T}$ имеет норму не больше 2:

$$\sum_{j<T} (y_j - y_{j+1})^2 \le 2 \sum_{j<T} (y_j^2 + y_{j+1}^2) \le 4 \sum_{j<T} y_j^2.$$

Отсюда для полной цепочки и для любой суммы её звеньев

$$\begin{aligned} \|\nabla C\| &\le \frac{c_\psi}{\sigma}(G_H + 6\sqrt{T}), \\ \|\nabla^2 C\| &\le \frac{4 c_\psi}{\sigma^2}. \end{aligned} \tag{D.8}$$

Если $|y_j| < \alpha \le \sigma/8$ для всех $j \ge p$, то звенья с $j \ge p$ равны нулю в некоторой окрестности x. Поэтому значение и градиент цепочки в точке x совпадают с ответом для функции

$$C^{[p]}(x) = -\frac{c_\psi G_H}{\sigma} y_0 + \sum_{0 \le j < \min(p,T)} \psi(y_j - y_{j+1}).$$

Ответ для $C^{[p]}$ зависит лишь от координат с номерами не больше p; до запроса некоторые из них ещё могут быть скрыты, но после этого запроса раскрывается не более одной новой координаты.

Чтобы обрабатывать удалённые запросы, введём радиальное продолжение. Оно не меняет функцию в шаре, содержащем её точку минимума, и скрывает координаты цепочки вне большего шара.

Лемма D.4 (радиальное продолжение).
Пусть $r, G, L_{\text{aux}} > 0$, а выпуклая C^2-функция C достигает минимума C_* в $B(0,r)$ и удовлетворяет

$$\|\nabla C\| \le G, \qquad \|\nabla^2 C\| \le L_{\text{aux}}/3, \qquad 4G/r \le L_{\text{aux}}/3.$$

Положим

$$\begin{aligned} w &= \frac{27MG^2}{4L_{\text{aux}}}, \\ \rho(x) &= 2G\sqrt{\|x\|^2 + r^2} - 4Gr + C_* - 2w, \\ H(x) &= \operatorname{smax}_w(C(x), \rho(x)). \end{aligned} \tag{D.9}$$

Тогда H выпукла, принадлежит C^2, совпадает с C на $B(0,r)$, имеет тот же минимум и удовлетворяет

$$\|\nabla H\| \le 2G, \qquad \|\nabla^2 H\| \le L_{\text{aux}}.$$

При $\|x\| \ge 4r + (C(0) - C_* + 4w)/G$ имеем $H(x) = \rho(x) \ge C(0)$.

Доказательство. На $B(0,r)$ выполнено $\rho \le C_* - 2w \le C - 2w$, поэтому $H = C$. Всюду $H \ge C \ge C_*$, поэтому минимум сохраняется. Для точек x из последнего утверждения используем $C(x) \le C(0) + G\|x\|$:

$$\rho(x) \ge 2G\|x\| - 4Gr + C_* - 2w \ge C(0) + G\|x\| + 2w \ge C(x) + 2w.$$

Значит, там $H = \rho \ge C(0)$.

Имеем $\|\nabla\rho\| \le 2G$ и $\|\nabla^2\rho\| \le 2G/r$. Градиент H — выпуклая комбинация градиентов C и ρ. По (D.5)

$$\|\nabla^2 H\| \le \frac{L_{\text{aux}}}{3} + \frac{2G}{r} + \frac{9MG^2}{4w} \le L_{\text{aux}}.$$

□

Для цепочки (D.6) берём $G = c_\psi(G_H + 6\sqrt{T})/\sigma$ и $C_* = -Tc_\psi c_H$. Условия леммы D.4 принимают вид

$$\frac{4c_\psi}{\sigma^2} \le \frac{L_{\text{aux}}}{3}, \qquad \frac{4c_\psi(G_H + 6\sqrt{T})}{\sigma r} \le \frac{L_{\text{aux}}}{3}. \tag{D.10}$$

Усечённые цепочки $C^{[p]}$ имеют ту же оценку градиента и равны нулю в начале координат. Продолжаем их с помощью той же функции ρ: вне указанного шара все ответы совпадают с ρ. Если полная и усечённая цепочки совпадают в окрестности точки, применение одного и того же сглаженного максимума сохраняет это свойство. Идея скрывать информацию от удалённых запросов с помощью радиального продолжения применяется в нижних оценках оракульной сложности (Carmon et al., 2020).

D.3 Поиск скрытой пары: член n

Выберем различные индексы a, b и знак $s \in \{-1, 1\}$ равномерно среди всех упорядоченных троек. В одномерном пространстве зададим

$$\begin{aligned} f_a(u) &= \frac{n \min\left\{\delta, \frac{\Delta}{\cosh(L_1 R) - 1}\right\}}{2} e^{L_1(u - sR)}, \\ f_b(u) &= \frac{n \min\left\{\delta, \frac{\Delta}{\cosh(L_1 R) - 1}\right\}}{2} e^{-L_1(u - sR)}, \\ f_i &= 0 \ (i \ne a, b). \end{aligned}$$

Лемма D.5.
При предположении 2.6 выполнено $\mathcal{T}^* \ge (n+1)/9$.

Доказательство леммы D.5.

▷ Компоненты скрытой пары удовлетворяют предположениям 2.1 и 2.2: они выпуклы, гладки, ограничены снизу и $|f_i''| = L_1|f_i'|$. Их среднее равно

$$f(u) = \min\left\{\delta, \frac{\Delta}{\cosh(L_1 R) - 1}\right\} \cosh(L_1(u - sR)),$$

минимум достигается в sR, так что предположение 2.3 выполнено. Начальная невязка равна $\min\{\Delta, (\cosh(L_1 R) - 1)\delta\} \le \Delta$ (предположение 2.4), а предположение 2.5 следует из

$$f^* = \min\left\{\delta, \frac{\Delta}{\cosh(L_1 R) - 1}\right\},$$
$$f^* - n^{-1}\sum_i \inf f_i = \min\left\{\delta, \frac{\Delta}{\cosh(L_1 R) - 1}\right\} \le \delta.$$

▷ Зафиксируем алгоритм и проследим его запуск на нулевом входе. До первого запроса к a или b все ответы совпадают с ответами на нулевом входе. Если до остановки эта пара не затронута, возвращённая точка u не зависит от s и

$$\frac{1}{2}\sum_{s=\pm 1}(f(u) - f^*) = \min\left\{\delta, \frac{\Delta}{\cosh(L_1 R) - 1}\right\}\big(\cosh(L_1 u)\cosh(L_1 R) - 1\big)$$
$$\underset{(a)}{\ge} \min\{\Delta, (\cosh(L_1 R) - 1)\delta\}.$$

Здесь в (a) использовано неравенство $\cosh(L_1 u) \ge 1$.

▷ Пусть при запуске на нулевом входе просмотрено $r \le n - 1$ различных индексов (после $n - 1$ просмотренных индексов любая пара уже затронута). Повторные запросы лишь увеличивают число запросов. Вероятность затронуть пару равна

$$1 - \frac{(n - r)(n - r - 1)}{n(n - 1)}.$$

Среднее число запросов до первого попадания или остановки не меньше

$$\sum_{j=0}^{r-1} \frac{(n - j)(n - j - 1)}{n(n - 1)} = \frac{n(n^2 - 1) - (n - r)((n - r)^2 - 1)}{3n(n - 1)},$$

$$\sum_{j=0}^{r-1} \frac{(n - j)(n - j - 1)}{n(n - 1)} - \frac{n + 1}{3}\left(1 - \frac{(n - r)(n - r - 1)}{n(n - 1)}\right) = \frac{(n - r)(n - r - 1)r}{3n(n - 1)} \ge 0.$$

В первом равенстве использовано тождество $\sum_{u=1}^{v} u(u - 1) = v(v^2 - 1)/3$.
Если при запуске на нулевом входе алгоритм делает бесконечно много запросов, но обращается менее чем к $n - 1$ различным индексам, то на некотором входе семейства число запросов бесконечно, и требуемая усреднённая оценка также выполнена. Обозначим число запросов на выбранном входе через τ, а невязку ответа через $\mathcal{E}$. Тогда

$$\frac{\mathbb{E}_{a,b,s}\tau}{(n + 1)/3} + \frac{\mathbb{E}_{a,b,s}\mathcal{E}}{\min\{\Delta, (\cosh(L_1 R) - 1)\delta\}} \ge 1.$$

▷ По лемме D.1

$$\mathcal{T}^* \ge \frac{n + 1}{3}\left(1 - \frac{\varepsilon}{\min\{\Delta, (\cosh(L_1 R) - 1)\delta\}}\right).$$

Из $\cosh u - 1 \ge u^2/2$ и предположения 2.6 следует $(\cosh(L_1 R) - 1)\delta \ge 3\varepsilon/2$. По предположению 2.4, $\Delta \ge 2\varepsilon$, поэтому выражение в скобках не меньше $1/3$. Следовательно, $\mathcal{T}^* \ge (n + 1)/9$.

□

D.4 Семейство S: независимые гладкие цепочки

При условиях следующей леммы зададим n цепочек (D.6) в непересекающихся координатах $c(i,j)$, $1 \le i \le n$, $0 \le j < T$, где

$$T = \left\lfloor \sqrt{\frac{c_H L_0 R^2}{24 n \varepsilon}} \right\rfloor, \qquad c_\psi = \frac{2\varepsilon}{T c_H}, \qquad \sigma = \sqrt{\frac{24\varepsilon}{T c_H L_0}}.$$

Положим $f_i = H_i$, где H_i — продолжение цепочки C_i по лемме D.4 с радиусом R и оценкой гессиана L_0. Точка общего минимума имеет координаты $x^*_{c(i,j)} = (T-j)\sigma$.

После q_i запросов к компоненте i считаем раскрытыми $p_i = \min\{q_i, T\}$ позиций её цепочки. Следующий идеальный ответ задаётся продолжением $C_i^{[p_i]}$ и раскрывает не больше одной позиции. Для скрытых координат используем порог

$$\alpha = \sigma \min\{1/8, c_H/(8G_H)\}.$$

Размерность выбираем по лемме D.3 с $s = nT$.

Лемма D.6.
Если

$$\frac{L_0 R^2}{\varepsilon} \ge \frac{24(G_H+6)^2}{c_H}\, n, \tag{D.11}$$

то

$$\mathcal{T}^* \gtrsim \sqrt{\frac{n L_0 R^2}{\varepsilon}}. \tag{D.12}$$

Доказательство. Условие (D.11) обеспечивает $T \ge 1$ и оставляет достаточный запас гладкости для радиального продолжения. Проверим предположение 2.3:

$$\|x^*\|^2 = n\sigma^2 \sum_{j=1}^{T} j^2 \le \frac{24 n \varepsilon}{c_H L_0} T^2 \le R^2.$$

По (D.8) имеем

$$\|\nabla^2 C_i\| \le \frac{4c_\psi}{\sigma^2} = \frac{L_0}{3}, \qquad G^2 = \frac{L_0 \varepsilon}{6 c_H}\left(\frac{G_H}{\sqrt{T}} + 6\right)^2 \le \frac{L_0 \varepsilon (G_H+6)^2}{6 c_H} \le \left(\frac{L_0 R}{12}\right)^2.$$

Последнее неравенство следует из (D.11). Значит, $4G/R \le L_0/3$, и лемма D.4 даёт выпуклые ограниченные снизу L_0-гладкие компоненты, то есть выполнены предположения 2.1 и 2.2. Имеем $f(0) = 0$, $f^* = -2\varepsilon$; начальная невязка равна $2\varepsilon \le \Delta$, неоднородность — нулю. Тем самым выполнены предположения 2.4 и 2.5.

Вне исключительного множества реальные и идеальные истории совпадают: для внутренних запросов это следует из наличия у ψ плоского участка, для внешних — из леммы D.4. То же верно для возвращённой точки $\hat{x}$. Внутри шара продолжения по (D.7)

$$f_i(\hat{x}) \ge -\frac{2\varepsilon}{T}\left(p_i + \frac{1}{8}\right).$$

При $p_i = T$ достаточно $f_i \ge -2\varepsilon$. Поэтому при $P = \sum_i p_i$ невязка удовлетворяет

$$\mathcal{E} \ge 2\varepsilon - \frac{\varepsilon}{4T} - \frac{2\varepsilon}{nT} P \ge \frac{7\varepsilon}{4} - \frac{2\varepsilon}{nT} P.$$

Вне шара она не меньше 2ε. Каждый запрос раскрывает не больше одного звена. Применяем лемму D.3 с $c_\tau = 1$, $A = 7\varepsilon/4$, $B = 2\varepsilon/(nT)$. Условие $sB \ge A$ выполнено, и

$$\mathcal{T}^* \ge \frac{7nT}{32} \ge \frac{7}{64}\sqrt{\frac{c_H n L_0 R^2}{24\varepsilon}}.$$

Здесь использовано неравенство $\lfloor u \rfloor \ge u/2$ при $u \ge 1$. □

D.5 Семейство X: экспоненциальное преобразование цепочек

Лемма D.7 (экспоненциальное преобразование).
Пусть функция $m \geq 0$ выпукла, принадлежит C^2 и удовлетворяет $\|\nabla m\| \leq L_1/7$, $\|\nabla^2 m\| \leq 4L_1^2/49$. Тогда при $\delta' > 0$ обе функции

$$v(x) = \delta'\big(e^{\pm 2L_1 x_0/7 + m(x)} - 1\big)$$

выпуклы, принадлежат C^2, имеют инфимум $-\delta'$ и удовлетворяют $\|\nabla^2 v\| \leq L_1\|\nabla v\|$.

Доказательство. Положим $u = \pm 2L_1 x_0/7 + m(x)$. Функция m может зависеть от x_0. Имеем

$$\begin{aligned} L_1/7 \leq \|\nabla u\| &\leq 3L_1/7, \\ \|\nabla^2 u\| + \|\nabla u\|^2 &\leq \left(\frac{4L_1}{7} + \frac{3L_1}{7}\right)\|\nabla u\| = L_1\|\nabla u\|, \\ \|\nabla^2 v\| &\leq \delta' e^u\big(\|\nabla^2 u\| + \|\nabla u\|^2\big) \leq L_1\|\nabla v\|. \end{aligned} \tag{D.13}$$

Выпуклость v следует из выпуклости u. Вдоль $x = \mp t e_0$ имеем $u(x) \leq m(0) - L_1 t/7 \to -\infty$, поэтому $\inf v = -\delta'$. □

Таким образом, v принадлежит требуемому классу при любом $L_0 \geq 0$. Проверка принадлежности классу через оценку гессиана соответствует характеризации из первой части (Rudomanov et al., 2026, лемма 2.2).

Положим

$$\begin{aligned} \eta &= \log\left(1 + \frac{2\varepsilon}{\delta}\right), \qquad \rho = \left(1 + \frac{\delta}{2\varepsilon}\right)\eta, \\ D_\delta &= \max\left\{\sqrt{\frac{12\eta}{c_H}}, \frac{4(G_H + 6)\eta}{c_H}\right\}, \qquad U = \frac{2L_1 R}{7D_\delta}. \end{aligned} \tag{D.14}$$

Здесь $D_\delta \sim \max\{\sqrt{\eta}, \eta\}$. Сначала рассмотрим произвольные целые $g, T \geq 1$ с $2g \leq n$. Построим g цепочек (D.6) в непересекающихся координатах $c(b, j)$, $1 \leq b \leq g$, $0 \leq j < T$, с параметрами

$$c_\psi = \frac{\eta}{T c_H}, \qquad \sigma = \frac{7}{2L_1}\max\left\{\sqrt{\frac{12\eta}{T c_H}}, \frac{4(G_H + 6\sqrt{T})\eta}{T c_H}\right\}.$$

Обозначим через σ_1 значение σ при $T = 1$. Тогда $\sigma \leq \sigma_1/\sqrt{T}$ и $U = R/\sigma_1$. Продолжаем каждую цепочку по лемме D.4 с радиусом $r_X = \max\{R, 21/(2L_1)\}$ и оценкой гессиана $4L_1^2/49$. Полученные функции обозначим через H_b. Их общий минимум достигается в точке $x^*_{c(b,j)} = (T - j)\sigma$.

Определим $2g$ активных компонент:

$$\begin{aligned} m_b(x) &= \eta + H_b(x), \\ f_{b,\pm}(x) &= \frac{n\delta}{2g}\big(e^{\pm 2L_1 x_0/7 + m_b(x)} - 1\big). \end{aligned}$$

Остальные компоненты равны нулю. Скрытые координаты отличны от 0, поэтому $x^*_0 = 0$.

Запрос к любой компоненте пары раскрывает не больше одного звена её цепочки. Для скрытых координат используем порог

$$\alpha = \sigma\min\{1/8, c_H/(8G_H\rho)\}.$$

Размерность выбираем по лемме D.3 с $s = gT$. При $U \geq 1$ берём

$$g = \min\{\lfloor n/2\rfloor, \lfloor U^2\rfloor\}, \qquad T = \lfloor U/\sqrt{g}\rfloor.$$

Оба числа положительны, и $2g \leq n$.

Лемма D.8.
Если $U \ge 1$, то

$$\mathcal{T}^* \gtrsim \frac{U \min\{\sqrt{n}, U\}}{\rho}. \tag{D.15}$$

Доказательство. Из выбора σ и (D.8) получаем

$$\|\nabla C_b\| \le L_1/14, \qquad \|\nabla^2 C_b\| \le 4L_1^2/147.$$

Вместе с $r_X \ge 21/(2L_1)$ это означает, что условия леммы D.4 выполнены. Кроме того,

$$\|x^*\|^2 = g\sigma^2 \sum_{j=1}^{T} j^2 \le g\sigma_1^2 T^2 \le R^2.$$

Следовательно, $m_b \ge 0$, $\|\nabla m_b\| \le L_1/7$ и $\|\nabla^2 m_b\| \le 4L_1^2/49$. По лемме D.7 выполнены предположения 2.1 и 2.2, причём

$$f(x) = \frac{\delta}{g} \sum_{b=1}^{g} \bigl(\cosh(2L_1 x_0/7) e^{m_b(x)} - 1\bigr) \ge 0.$$

В точке x^* все $m_b = 0$, поэтому $f(x^*) = f^* = 0$ и выполнено предположение 2.3. В нуле $m_b = \eta$, откуда $f(0) = 2\varepsilon \le \Delta$ (предположение 2.4). Поскольку $\inf f_{b,\pm} = -n\delta/(2g)$, неоднородность равна δ (предположение 2.5).

Совпадение реальных и идеальных историй доказывается так же, как для семейства S: экспоненциальное преобразование сохраняет локальное равенство функций. Пусть $p_b \le T$ — число раскрытых звеньев пары b и $P = \sum_b p_b$. Внутри шара продолжения вне исключительного множества оценка (D.7) даёт

$$m_b(\hat{x}) \ge \eta \left(1 - \frac{p_b}{T}\right) - \frac{\eta}{8T\rho}.$$

При $p_b = T$ достаточно $m_b \ge 0$. Касательная к экспоненте в η и равенство $e^\eta \eta\delta = 2\varepsilon\rho$ дают

$$\frac{\mathcal{E}}{2\varepsilon} \ge 1 - \frac{\rho}{gT} P - \frac{1}{8T}.$$

Вне шара невязка не меньше 2ε. Применяем лемму D.3 с $c_\tau = 1$, $A = 7\varepsilon/4$, $B = 2\varepsilon\rho/(gT)$. Неравенство $(1 + 1/z)\log(1+z) \ge 1$ при $z > 0$ даёт $\rho \ge 1$, поэтому $sB \ge A$. Получаем $\mathcal{T}^* \ge 7gT/(32\rho)$. Из $n \ge 2$, $U \ge 1$ и определения g, T следует

$$g \ge \frac{1}{3}\min\{n, U^2\}, \qquad T \ge \frac{U}{2\sqrt{g}}, \qquad gT \ge \frac{U\min\{\sqrt{n}, U\}}{2\sqrt{3}}.$$

Из этих неравенств следует (D.15). □

D.6 Число запросов при поиске звена

Лемма D.9 (число запросов для поиска звена).
Пусть T звеньев размещены инъекцией $\pi : \{0, \dots, T-1\} \to \{1, \dots, m\}$, $T \le m$. На уровне j идеальный ответ содержит лишь звенья с номерами не больше j, а уровень увеличивается на единицу только при запросе к паре $\pi(j)$. Пусть Q_j — число запросов на уровне j до остановки или до момента N_{qry}, а R_j — индикатор того, что этот уровень пройден к моменту N_{qry}. Тогда для каждого фиксированного отображения координат

$$\mathbb{E}_\pi Q_j \ge \frac{m - T + 2}{2} \mathbb{E}_\pi R_j. \tag{D.16}$$

Доказательство леммы D.9.

- ▷ Зафиксируем размещение всех звеньев, кроме j. Для размещения звена j остаётся $m-T+1$ свободных пар. До уровня j история не зависит от размещения этого звена. На самом уровне j сравним её с виртуальной историей, в которой звено j не помещено ни в одну пару. Запуски совпадают до первого запроса к выбранной свободной паре. Пусть в виртуальной истории до остановки или до момента N_{qry} запрашиваются r различных свободных пар.
- ▷ Ровно r вариантов размещения приводят к прохождению уровня; для k-го из них на данном уровне сделано не меньше k запросов, а для каждого из $(m-T+1)-r$ остальных — не меньше r. Поэтому

$$\sum_{v=1}^{(m-T+1)} Q_j(v) \underset{(a)}{\geq} \sum_{k=1}^{r} k + ((m-T+1)-r)r = r\left((m-T+1)+\frac{1-r}{2}\right)$$
$$\underset{(b)}{\geq} \frac{(m-T+1)+1}{2} \sum_{v=1}^{(m-T+1)} R_j(v).$$

  Здесь в (a) учтён порядок первого посещения свободных пар, а в (b) использованы соотношения $r \leq (m-T+1)$, $\sum_v R_j(v) = r$.
- ▷ Если уровень вообще не достигнут, обе правые величины равны нулю. Повторные запросы и запросы к занятым парам лишь увеличивают левую часть. Суммируя по всем фиксированным размещениям остальных звеньев, получаем (D.16). Это и есть усреднение по всем инъекциям: каждая из них входит ровно в один слой с весом $1/(m-T+1)$.

□

D.7 Семейство Q: поиск пары со следующим звеном

Показатель $2/3$ уже возникал в первой части в нижней оценке для одной функции с ограниченной начальной невязкой (Rudomanov et al., 2026, теорема B.3). Используемое здесь семейство Q задаётся экспонентами от вспомогательных функций и случайным размещением звеньев по парам компонент.

Сначала построим семейство для произвольных целых $m, T \geq 1$, таких что $2m \leq n$, $T \leq m/2$ и

$$2L_1R/7 \geq 3,$$
$$(2L_1R/7)^{2/3} \leq T \leq 2(2L_1R/7)^{2/3},$$
$$24\log\left(1+\frac{2\varepsilon m}{\delta}\right) \leq \widehat{\psi}(1)(2L_1R/7)^{2/3}.$$

Конкретные числа пар и звеньев зададим ниже.

Определим вспомогательные функции:

$$\Psi_0(u) = \frac{\log\left(1+\frac{2\varepsilon m}{\delta}\right)}{\widehat{\psi}(1)}\widehat{\psi}(u\sqrt{T}/R),$$
$$\Psi(u) = \frac{1}{48}\widehat{\psi}(4L_1u/7).$$

Звенья имеют вид $\Psi_0(R/\sqrt{T} - x_{c(0)})$ и $\Psi(x_{c(j-1)} - x_{c(j)})$, $1 \leq j < T$. Координаты $c(j)$ попарно различны и отличны от 0. Звенья размещаются по m парам с помощью равномерно выбранной инъекции π, так что каждая пара содержит не больше одного звена. Обозначим через Ψ_b сумму звеньев пары b и положим

$$\rho(x) = \frac{L_1}{7}\sqrt{\|x\|^2+R^2} - \frac{2L_1R}{7} - \frac{27M}{32},$$
$$m_b(x) = \operatorname{smax}_{27M/64}(\Psi_b(x), \rho(x)).$$

Зададим точку

$$x^* = \frac{R}{\sqrt{T}}\sum_{j<T} e_{c(j)}.$$

Определим компоненты

$$f_{b,\pm}(x) = \frac{n\delta}{2m}\left(e^{\pm 2L_1 x_0/7 + m_b(x)} - 1\right).$$

Остальные компоненты равны нулю. Определим функции

$$\phi_0(u) = e^{\Psi_0(u)} - 1,$$
$$\phi(u) = e^{\Psi(u)} - 1.$$

Идеальный оракул на уровне p оставляет только звенья $j \le p$ и увеличивает уровень после запроса к паре $\pi(p)$. До запроса раскрыты координаты с номерами $j < p$, а после него раскрывается не больше одной новой координаты. Для скрытых координат используем порог

$$\min\left\{\frac{7}{32L_1}, \frac{\varepsilon m}{4\phi_0'(R/\sqrt{T})\delta}\right\}.$$

Для следующей леммы положим

$$t = (2L_1R/7)^{2/3}, \qquad m = \lfloor n/2 \rfloor, \qquad T = \lceil t \rceil, \qquad \eta_m = \log(1 + 2\varepsilon m/\delta).$$

Лемма D.10.
Если

$$L_1R \ge \frac{21}{2}, \qquad 4t \le m, \qquad 24\eta_m \le \widehat{\psi}(1)t, \tag{D.17}$$

то

$$\mathcal{T}^* \gtrsim \frac{n(L_1R)^{2/3}}{(1+\eta_m)^2}. \tag{D.18}$$

Доказательство леммы D.10. Первое условие (D.17) позволяет продолжить звенья за пределы шара $B(0,R)$. Второе даёт $t \le T \le 2t \le m/2$: при поиске очередного звена свободными остаются не меньше половины пар. Третье ограничивает кривизну первого звена.

▷ Для обычного звена из (D.4) следуют оценки $L_1/14$ для нормы градиента и $4L_1^2/147$ для нормы гессиана. Для первого звена те же оценки следуют из

$$\frac{3\sqrt{T}\,\eta_m}{\widehat{\psi}(1)R} \le \frac{6\sqrt{t}\,\eta_m}{\widehat{\psi}(1)R} \le \frac{t^{3/2}}{4R} = \frac{L_1}{14},$$
$$\frac{T\eta_m}{\widehat{\psi}(1)R^2} \le \frac{t^2}{12R^2} \le \frac{4L_1^2}{147}.$$

При $2L_1R/7 \ge 3$ применима лемма D.4 с $G = L_1/14$, $L_{\text{aux}} = 4L_1^2/49$, $r = R$, $C_* = 0$. Поэтому

$$\|\nabla m_b\| \le L_1/7,$$
$$\|\nabla^2 m_b\| \le 4L_1^2/49.$$

Все потенциалы неотрицательны. Точка x^* имеет норму R, и в ней все звенья и потенциалы равны нулю. В нуле отличен от нуля лишь потенциал пары, содержащей звено 0; он равен η_m. Как и для семейства X, минимум средней функции равен нулю, неоднородность равна δ, а

$$f(0) = 2\varepsilon \le \Delta.$$

Тем самым выполнены предположения 2.3–2.5. Предположения 2.1 и 2.2 следуют из леммы D.7.

▷ Докажем нижнюю оценку невязки. Имеем

$$\phi_0(R/\sqrt{T}) = e^{\eta_m} - 1 = \frac{2\varepsilon m}{\delta},$$
$$\phi_0'(R/\sqrt{T}) = \frac{G_H\sqrt{T}}{R\widehat{\psi}(1)}e^{\eta_m}\eta_m.$$

Обозначим $s_0 = \phi_0'(R/\sqrt{T}) > 0$, $\log_+ u = \max\{0, \log u\}$ и

$$J = 1 + 16 \log_+(56 s_0 / L_1), \qquad K = \frac{7 s_0}{2 L_1} J.$$

Величина K ограничивает потерю в нижней оценке при добавлении одного звена:

$$\sup_{u \in \mathbb{R}} \{ s_0 u - \phi(u) \} \le K. \tag{D.19}$$

При $u \le 7/(2L_1)$ достаточно $\phi \ge 0$. При $u > 7/(2L_1)$ положим $v = 4L_1 u/7 - 2 > 0$. По (D.4), $\Psi(u) \ge v/32$. Для произвольных $\mu \ge 0$, $a > 0$, $v \ge 0$ касательная к экспоненте в $\log(\mu/a)$ при $\mu > a$ и $e^{av} \ge 1 + av$ при $\mu \le a$ дают

$$\mu v - (e^{av} - 1) \le \frac{\mu}{a} \max\{0, \log(\mu/a)\}.$$

Подставляя $\mu = 7 s_0/(4L_1)$ и $a = 1/32$, получаем

$$s_0 u - \phi(u) \le \frac{7 s_0}{2 L_1} + \frac{56 s_0}{L_1} \log_+(56 s_0 / L_1) = K.$$

Если раскрыты первые $p < T$ координат и модуль следующей координаты меньше выбранного порога, то сумма разностей $R/\sqrt{T} - x_{c(0)}$ и $x_{c(j-1)} - x_{c(j)}$, $1 \le j \le p$, равна $R/\sqrt{T} - x_{c(p)}$. Касательная к ϕ_0 и (D.19) дают

$$\begin{aligned} &\phi_0(R/\sqrt{T} - x_{c(0)}) + \sum_{j=1}^{p} \phi(x_{c(j-1)} - x_{c(j)}) \\ &\qquad \ge \frac{2\varepsilon m}{\delta} - s_0 x_{c(p)} - pK. \end{aligned} \tag{D.20}$$

Инъективность π позволяет оценить среднюю функцию снизу суммой этих экспоненциальных звеньев: пустая пара даёт неотрицательный вклад, а пара со звеном j даёт не меньше $(\delta/m)\phi(x_{c(j-1)} - x_{c(j)})$.

▷ Порог для скрытых координат, выбранный в построении Q, не превосходит $7/(32L_1)$, поэтому удалённые звенья равны нулю в окрестности точки запроса. При

$$\|x\| \ge 4R + \frac{14}{L_1} \log\!\left(1 + \frac{2\varepsilon m}{\delta}\right) + \frac{189 M}{8 L_1},$$

по лемме D.4 полные и усечённые компоненты определяются только радиальным продолжением и координатой x_0. Все потенциалы не меньше $\log\bigl(1 + \frac{2\varepsilon m}{\delta}\bigr)$, а невязка не меньше начальной. Таким образом, истории совпадают и для произвольных удалённых запросов. По (D.20) и выбору порога невязка после прохождения p уровней не меньше $A - Bp$, где можно взять

$$A = 7\varepsilon/4, \qquad B = \frac{K\delta}{m} = \frac{7 s_0 \delta}{2 m L_1} J.$$

Действительно, после умножения на δ/m слагаемое со скрытой координатой в (D.20) даёт потерю не больше $\varepsilon/4$. Для применения леммы D.3 проверим два соотношения. Из

$$s_0 = \frac{G_H}{\widehat{\psi}(1)} \frac{\sqrt{T}}{R} e^{\eta_m} \eta_m, \qquad \frac{\delta}{m} = \frac{2\varepsilon}{e^{\eta_m} - 1}$$

и $\sqrt{T} \le 2\sqrt{t}$ следует

$$\frac{A}{B} = \frac{\widehat{\psi}(1)}{4 G_H} \frac{L_1 R}{\sqrt{T}} \frac{1 - e^{-\eta_m}}{\eta_m J} \ge \frac{7 \widehat{\psi}(1)}{16 G_H} \frac{t}{(1 + \eta_m) J}. \tag{D.21}$$

Здесь использованы равенство $L_1 R = 7 t^{3/2}/2$ и неравенство $1 - e^{-u} \ge u/(1+u)$ при $u \ge 0$. Кроме того, $T^{3/2} \ge 2 L_1 R/7$, $J \ge 1$ и $G_H/\widehat{\psi}(1) \ge 1$ дают

$$TB = \frac{7\delta}{2 m L_1} \frac{G_H}{\widehat{\psi}(1)} \frac{T^{3/2}}{R} e^{\eta_m} \eta_m J \ge \frac{\delta}{m} e^{\eta_m} \eta_m \ge 2\varepsilon > A.$$

При $p = T$ оценка невязки следует из $f \ge 0$.

▷ Суммируя (D.16) по уровням, получаем $\mathbb{E}Q \geq c_\tau \mathbb{E}P$ с $c_\tau = (m - T + 2)/2 \geq m/4$. Лемма D.3 при $s = T$ даёт $\mathcal{T}^* \geq mA/(16B)$. Остаётся оценить J. По третьему условию (D.17)

$$\frac{56 s_0}{L_1} \leq \frac{32 G_H}{\widehat{\psi}(1)} \frac{e^{\eta_m} \eta_m}{t} \leq \frac{4 G_H}{3} e^{\eta_m} = \frac{5}{6} e^{\eta_m}.$$

Следовательно, $J \leq 1 + 16\eta_m$. Подставляя эту оценку в (D.21) и используя $m \geq n/3$ и $t = (2/7)^{2/3}(L_1 R)^{2/3}$, получаем (D.18).

□

E Доказательство нижней оценки

Доказательство теоремы 7.1 ▲. Достаточно оценить четыре слагаемых B_n, B_S, B_X, B_Q из (7.1): их сумма имеет порядок T_0. Положим $a = L_1 R$ и будем использовать величину N_0 из (2.5). Числа G_H, $\widehat{\psi}(1)$ и c_H вычислены в (D.3).

E.1 Член с L_0

По лемме D.5

$$B_n = n \leq 9\mathcal{T}^*. \tag{E.1}$$

Если выполнено (D.11), применима лемма D.6. Иначе

$$B_S < \sqrt{24/c_H}\,(G_H + 6)n < 50n.$$

В обоих случаях

$$B_S = \sqrt{\frac{nL_0R^2}{\varepsilon}} \lesssim \mathcal{T}^*. \tag{E.2}$$

E.2 Члены, получаемые из семейства X

Используем обозначения η, ρ, D_δ, U из (D.14). По предположению 2.6 $\varepsilon/\delta \leq a^2/3$, откуда

$$\eta \leq \log(1 + 2a^2/3) \leq \log N_0, \qquad 1 \leq \rho \leq 1 + \eta \leq 1 + \log N_0. \tag{E.3}$$

Для второй оценки достаточно неравенств $z/(1+z) \leq \log(1+z) \leq z$ при $z = 2\varepsilon/\delta$. Кроме того,

$$D_\delta \sqrt{1 + \delta/\varepsilon} \lesssim \log N_0. \tag{E.4}$$

Действительно, $\eta\delta/\varepsilon \leq 2$ по неравенству $\log(1+z) \leq z$, а $\sqrt{1+\delta/\varepsilon} \leq 1 + \delta/(2\varepsilon)$. Поэтому

$$D_\delta \sqrt{1 + \delta/\varepsilon} \leq \max\left\{ \sqrt{\frac{12(\eta+2)}{c_H}}, \frac{4(G_H+6)}{c_H}\rho \right\} \lesssim \log N_0.$$

Покажем, что

$$\sqrt{n}\,U \lesssim \log N_0\, \mathcal{T}^*. \tag{E.5}$$

При $U \geq \sqrt{n}$ это следует из леммы D.8 и (E.3). При $1 \leq U < \sqrt{n}$ та же лемма даёт $U^2 \lesssim \rho \mathcal{T}^*$. Перемножая это неравенство и (E.1), получаем $\sqrt{n}\,U \lesssim \sqrt{\rho}\,\mathcal{T}^* \lesssim \log N_0\, \mathcal{T}^*$. Наконец, при $U < 1$ достаточно $\sqrt{n}\,U \leq n$. Из $a = 7UD_\delta/2$, (E.4) и (E.5) следует

$$B_X = \sqrt{n}\, a \sqrt{1 + \delta/\varepsilon} \lesssim \log^2 N_0\, \mathcal{T}^*. \tag{E.6}$$

E.3 Член с показателем $2/3$

Положим $t = (2a/7)^{2/3}$, $m = \lfloor n/2 \rfloor$ и $\eta_m = \log(1 + 2\varepsilon m/\delta)$. По предположению 2.6

$$\eta_m \le \log(1 + na^2/3) \le 2 \log N_0.$$

Если выполнены условия (D.17), лемма D.10 даёт

$$B_Q = na^{2/3} \lesssim (1 + \eta_m)^2 \mathcal{T}^* \lesssim \log^2 N_0 \, \mathcal{T}^*. \tag{E.7}$$

Если хотя бы одно условие нарушено, оценка получается из уже доказанных:

- ▷ При $a < 21/2$ имеем $B_Q < 5n$.
- ▷ Если $a \ge 21/2$, но $m < 4t$, то $t > 1$ и $n \le 2m + 1 < 9t$. Поэтому

$$\frac{B_Q}{\sqrt{n}\, a} = \frac{\sqrt{n}}{a^{1/3}} < 3(2/7)^{1/3} < 2, \qquad B_Q < 2B_X.$$

- ▷ Если $24\eta_m > \widehat{\psi}(1)t$, то

$$B_Q < (7/2)^{2/3} \frac{24}{\widehat{\psi}(1)} n\eta_m \lesssim n \log N_0.$$

Таким образом, оценка (E.7) верна во всех случаях. Складывая оценки для четырёх слагаемых, получаем

$$T_0 \sim B_n + B_S + B_X + B_Q \lesssim \log^2 N_0 \, \mathcal{T}^*.$$

□

F Варианты YETI

F.1 Почему требуется ограничивать локальную кривизну

Само по себе условие $\|y - x^*\| \le R$ не даёт полиномиальной по $L_1 R$ оценки отношения локальных констант гладкости. Рассмотрим одномерную функцию

$$\varphi(t) = \cosh(L_1 t).$$

Она выпукла, имеет минимум в нуле и удовлетворяет

$$\varphi''(t) = L_1^2 \cosh(L_1 t) \le L_1^2 + L_1 |\varphi'(t)|.$$

Однако

$$\frac{\varphi''(R)}{\varphi''(0)} = \cosh(L_1 R)$$

растёт экспоненциально. Поэтому одной принадлежности центров шару недостаточно, чтобы убрать проверку кривизны и сохранить прежнюю оценку числа обращений к оракулу при локальном вызове. Этот пример касается только используемого решателя и не исключает существования других алгоритмов.

F.2 Выбор стохастического градиента

Пусть функции φ_i имеют локальные константы гладкости $L_i > 0$ на увеличенном шаре, а точки x, w лежат в исходном шаре. Для случайного индекса I с вероятностями $q_i > 0$ лемма A.3 даёт

$$\begin{aligned} \mathbb{E}\left\| \frac{\nabla\varphi_I(x) - \nabla\varphi_I(w)}{nq_I} \right\|^2 &= \frac{1}{n^2} \sum_i \frac{\|\nabla\varphi_i(x) - \nabla\varphi_i(w)\|^2}{q_i} \\ &\le \frac{2}{n^2} \sum_i \frac{L_i}{q_i} \big(\varphi_i(x) - \varphi_i(w) - \langle \nabla\varphi_i(w), x - w \rangle\big). \end{aligned} \tag{F.1}$$

Если

$$q_i = \frac{L_i}{\sum_j L_j},$$

то последняя строка равна

$$\left(\frac{2}{n}\sum_i L_i\right)\frac{1}{n}\sum_i\bigl(\varphi_i(x)-\varphi_i(w)-\langle\nabla\varphi_i(w),x-w\rangle\bigr).$$

При равномерной выборке стандартная верхняя оценка содержит $2\max_i L_i$ вместо $2n^{-1}\sum_i L_i$.

Отношение этих величин может иметь порядок n даже в рассматриваемом классе. В одномерном случае при $L_0>0$ возьмём

$$f_1(t)=\frac{L_0}{2}(t-R)^2,$$
$$f_i(t)=0\quad(i>1).$$

Зададим известные верхние оценки $L_{0,i}=L_0$ для всех i. Выберем параметры

$$y=0,$$
$$L_1R=n,$$
$$r=\frac{1}{2L_1},$$
$$\lambda=L_0.$$

Тогда константы из (H.2), то есть

$$L_i=e^{3L_1r}\bigl(L_{0,i}+L_1\|\nabla f_i(y)\|\bigr)+\lambda,$$

удовлетворяют

$$\frac{\max_i L_i}{n^{-1}\sum_i L_i}=\frac{1+e^{3/2}(1+n)}{1+2e^{3/2}}.$$

Это отношение растёт линейно по n. Тем самым для данной оценки внутреннего решателя неравномерная выборка существенна. Отсюда не следует, что любой метод с равномерной выборкой обязательно проигрывает.

В решателе YETI используются вероятности

$$q_i=\frac{L_i}{\sum_j L_j}.$$

Если другое распределение обеспечивает лишь

$$\frac{L_i}{nq_i}\le\frac{c}{n}\sum_j L_j,$$

то в правой части оценки (F.1) появляется множитель c. Его влияние на оценку сложности следует учитывать вместе с выбором параметров эпохи.

Сохранение опорного градиента также существенно. При $a>0$ для функций

$$f_1(t)=\frac{(t-a)^2}{2},$$
$$f_2(t)=\frac{(t+a)^2}{2}$$

минимум их среднего достигается в нуле, но

$$\frac{1}{2}\sum_{i=1}^{2}|f_i'(0)|^2=a^2>0.$$

Поэтому градиент случайно выбранной компоненты имеет в решении ненулевую дисперсию. В оценке же (F.1) разности градиентов обращаются в ноль при $x=w$. Без поправки с помощью сохранённых градиентов дисперсия в решении может оставаться положительной, и приведённое доказательство геометрической сходимости неприменимо.

F.3 Покомпонентные секущие для обобщённых линейных моделей

Пусть

$$f_i(x) = \phi_i(a_i^\top x),$$

где ϕ_i выпукла и дважды непрерывно дифференцируема. По уже вычисленным градиентам в точках x_0, x_1 определим

$$s = x_1 - x_0,$$
$$\Delta g_i = \nabla f_i(x_1) - \nabla f_i(x_0).$$

Предложение F.1 (восстановление среднего гессиана).
Если $\langle \Delta g_i, s\rangle > 0$, то

$$\frac{\Delta g_i \Delta g_i^\top}{\langle \Delta g_i, s\rangle} = \int_0^1 \nabla^2 f_i(x_0 + ts)\, dt. \tag{F.2}$$

Если $a_i^\top s = 0$, то нулевая секущая может соответствовать ненулевой матрице в правой части. Если же средняя скалярная кривизна равна нулю, а секущая явно определена как нулевая матрица (без деления на ноль), то обе части равенства равны нулю.

Доказательство. По формуле Ньютона–Лейбница

$$\Delta g_i = (a_i^\top s) a_i \int_0^1 \phi_i''(a_i^\top (x_0 + ts))\, dt,$$
$$\langle \Delta g_i, s\rangle = (a_i^\top s)^2 \int_0^1 \phi_i''(a_i^\top (x_0 + ts))\, dt,$$
$$\int_0^1 \nabla^2 f_i(x_0 + ts)\, dt = a_i a_i^\top \int_0^1 \phi_i''(a_i^\top (x_0 + ts))\, dt.$$

При положительном знаменателе сокращение скалярных множителей даёт (F.2). При $a_i^\top s = 0$ равенство $\Delta g_i = 0$ не определяет интеграл от ϕ_i''. Если же этот интеграл равен нулю, то средний гессиан и разность градиентов нулевые. □

Таким образом, положительная компонентная секущая восстанавливает средний гессиан вдоль отрезка. Чтобы получить гессиан в конце отрезка, нужно дополнительное предположение.

Предложение F.2 (приближение гессиана пуассоновской модели).
Пусть

$$f_i(x) = e^{a_i^\top x} - y_i a_i^\top x,$$

где $y_i \geq 0$ и $\|a_i\| \leq L_1$. Эти компоненты удовлетворяют условию класса при

$$L_{0,i} = y_i \|a_i\|^2.$$

Если для каждого ненулевого a_i выполнено $a_i^\top s \neq 0$, то матрица M, полученная усреднением секущих (F.2), удовлетворяет

$$e^{-L_1\|s\|} \nabla^2 f(x_1) \preceq M \preceq e^{L_1\|s\|} \nabla^2 f(x_1). \tag{F.3}$$

Нулевым a_i в сумме соответствуют нулевые матрицы.

Доказательство. Непосредственно из вида компоненты получаем

$$\|\nabla^2 f_i(x)\| = e^{a_i^\top x}\|a_i\|^2 \leq y_i \|a_i\|^2 + |e^{a_i^\top x} - y_i| \|a_i\|^2 \leq L_{0,i} + L_1 \|\nabla f_i(x)\|.$$

Кроме того, для $0 \leq t \leq 1$ по неравенству Коши–Буняковского–Шварца

$$|a_i^\top (x_0 + ts - x_1)| \leq L_1 \|s\|.$$

Поэтому

$$e^{-L_1\|s\|}e^{a_i^\top x_1} \le e^{a_i^\top(x_0+ts)} \le e^{L_1\|s\|}e^{a_i^\top x_1}.$$

Умножив на положительно полуопределённую матрицу $a_i a_i^\top$, проинтегрировав и усреднив по i, получаем (F.3). □

Для применения основной теоремы нужны также предположения 2.3–2.5. Условие отсутствия пропущенных ненулевых направлений существенно: если $a_i^\top s = 0$ при $a_i \neq 0$, то градиентная секущая нулевая, а гессиан пуассоновской компоненты ненулевой. Кроме того, две наблюдаемые параллельные производные не доказывают, что компонента глобально представима в виде $\phi_i(a_i^\top x)$. Поэтому восстановленную матрицу можно использовать для выбора эвристического предложения YETI: проверки и основные итерации метода сохраняют оценку его сложности. Замена полной суммы секущих выборкой фиксированного числа компонент потребовала бы отдельной теоремы о спектральном приближении.

F.4 Ограничение числа запросов эвристики к оракулу

Пусть $B_0 = n\lceil \log N \rceil$, G — суммарное число запросов к оракулу в основных итерациях, H — в эвристических блоках. Выберем $\omega \ge 0$. Перед очередным эвристическим блоком разрешим

$$B_k = n\left\lfloor \frac{\min\{B_0, B_0 + \omega G - H\}}{n} \right\rfloor \tag{F.4}$$

запросов. Если $B_k < n$, блок пропускается. Перед каждым вычислением функции и полного градиента оставляют n запросов. Все обращения эвристики к оракулу, включая проверки предложенных точек, учитываются в счётчике H.

Доказательство следующей теоремы сводится к пошаговой проверке инварианта и приведено в приложении B.6.

Теорема F.3 (число запросов эвристики). ▼ доказательство в приложении B.6
Если к некоторому моменту работы начато k эвристических блоков, то в этот момент выполнено

$$H \le \min\{kB_0, B_0 + \omega G\}. \tag{F.5}$$

Правило (F.4) сохраняет верхнюю оценку теоремы 5.1. Кроме того,

$$\mathbb{E}T \le B_0 + (1+\omega)\mathbb{E}G. \tag{F.6}$$

Здесь все заключительные вычисления функции и полного градиента включены в G или H.

При $\omega = 1$ эвристика сверх первых B_0 запросов не может сделать больше обращений к оракулу, чем уже сделали основные итерации. Первому блоку доступны все B_0 запросов, поэтому при одинаковых значениях случайных величин он выполняет те же запросы, что и блок с постоянным ограничением B_0. Это не требует предположения о полезности эвристики. Ограничение числа запросов существенно: повторение одной и той же точки без остановки и без перехода к основной итерации может сделать число обращений к оракулу бесконечным, даже если значение функции не возрастает.

G Подробное описание YETI

G.1 Критерий остановки по истории запросов

Вычисление функции и полного градиента в точке $p \in \mathbb{R}^d$ даёт аффинную миноранту $u \mapsto f(p) + \langle \nabla f(p), u - p\rangle$. Её минимум по $u \in B(0,R)$ равен

$$\widetilde{f}(p) = f(p) - \langle \nabla f(p), p\rangle - R\|\nabla f(p)\|. \tag{G.1}$$

Это нижняя оценка оптимального значения:

$$f^* \underset{2.1}{\geq} f(p) + \langle \nabla f(p), x^* - p\rangle \underset{2.3}{\geq} f(p) - \langle \nabla f(p), p\rangle - R\|\nabla f(p)\|.$$

Во втором переходе использовано также неравенство Коши–Буняковского–Шварца. Если $p \in B(0,R)$, то разность $f(p) - \widetilde{f}(p)$ является зазором Франка–Вульфа (Jaggi, 2013); оценка $\widetilde{f}(p) \leq f^*$ верна и при $p \notin B(0,R)$. Обозначим через $\widetilde{f}_{\text{best}}$ максимум всех сохранённых нижних оценок, а через w_{best} — лучшую из точек шара $B(0,R)$, в которых известно значение функции. Метод останавливается и возвращает w_{best}, если

$$f(w_{\text{best}}) - \widetilde{f}_{\text{best}} \leq \varepsilon/2. \tag{G.2}$$

Точка w_{best} хранится отдельно от x: при ускоренном обновлении x значение функции не обязательно убывает монотонно. Все вычисления функции и полного градиента выполняются подпрограммой Оценка (алгоритм 2): в предложенных эвристикой точках, в центрах, в опорных и проверочных точках решателя. Если значения и градиенты всех компонент в данной точке уже известны, повторные запросы не нужны. Для проверки (G.2) достаточно хранить $\widetilde{f}_{\text{best}}$, w_{best} и $f(w_{\text{best}})$; эвристика может хранить и дополнительные данные для выбора точек.

Алгоритм 2 Оценка(p): вычисление функции, градиента и проверка точности

Вход: точка p

запросить $\big(f_i(p), \nabla f_i(p)\big)$ для всех i, для которых ответы в точке p ещё не получены
$\widetilde{f}_{\text{best}} \leftarrow \max\big\{\widetilde{f}_{\text{best}},\ f(p) - \langle \nabla f(p), p\rangle - R\|\nabla f(p)\|\big\}$
если $\|p\| \leq R$ и $f(p) < f(w_{\text{best}})$ **то** ▷ до первой такой точки $f(w_{\text{best}}) = +\infty$
    $w_{\text{best}} \leftarrow p$
конец если
если $f(w_{\text{best}}) - \widetilde{f}_{\text{best}} \leq \varepsilon/2$ **то**
    завершить YETI с ответом w_{best}
конец если

Лемма G.1 (остановка при малом субградиенте). ▼доказательство в приложении B.1
Пусть $z \in B(0,R)$, функция и полный градиент в z уже вычислены и $g = \nabla f(z) + v_z$, где $v_z \in N_{B(0,R)}(z)$. Тогда

$$f(z) - \widetilde{f}(z) \leq 2R\|g\|.$$

В частности, при $\|g\| \leq \varepsilon/(4R)$ после записи z в историю выполнено (G.2).

Для проверки остановки можно использовать и ответы компонент, полученные в разных точках. Соответствующая нижняя оценка и способ её пересчёта без новых запросов приведены в приложении B.2. Эта возможность используется эвристикой в экспериментах, но для оценки сложности YETI не нужна.

G.2 Оценка локальной кривизны

После вычисления функции и полного градиента в y известна величина

$$\ell(y) = \frac{1}{n}\sum_{i=1}^{n}\bigl(L_{0,i} + L_1\|\nabla f_i(y)\|\bigr). \tag{G.3}$$

Лемма G.2 (оценка кривизны через невязку). ▼доказательство в приложении A.3
При предположениях 2.1–2.3 и 2.5 для любой точки y

$$\begin{gathered}\|\nabla f(y)\| \le L_1\bigl(\delta + f(y) - f^*\bigr) + \sqrt{2L_0\bigl(\delta + f(y) - f^*\bigr)},\\ L_1\|\nabla f(y)\| \le \ell(y),\\ \ell(y) \le \tfrac{3}{2}L_0 + 2L_1^2\bigl(\delta + f(y) - f^*\bigr).\end{gathered} \tag{G.4}$$

Кроме того, для любых x, y

$$\begin{gathered}\ell(x) \le e^{L_1\|x-y\|}\ell(y),\\ \|\nabla^2 f(x)\| \le \ell(x).\end{gathered} \tag{G.5}$$

В частности, для любого $r > 0$ на $B(y, 3r)$ норма гессиана компоненты f_i не превосходит

$$e^{3L_1 r}\bigl(L_{0,i} + L_1\|\nabla f_i(y)\|\bigr). \tag{G.6}$$

Следствие G.3 (нижняя оценка невязки по кривизне).
Вычисление функции и полного градиента в y даёт нижнюю оценку невязки по функции

$$f(y) - f^* \ge \frac{\ell(y) - \frac{3}{2}L_0 - 2L_1^2\delta}{2L_1^2}.$$

Если правая часть отрицательна, оценка тривиальна.

G.3 Параметры YETI

Состояние метода состоит из точек $x, v \in B(0, R)$, числа $\mathcal{A} > 0$ и параметра $h > 0$. Число $\mathcal{A}$ играет ту же роль, что и сумма коэффициентов A_k в ускоренных методах с оценочными последовательностями: ниже доказано, что всегда $f(x) - f^* \le R^2/\mathcal{A}$, а число $\mathcal{A}$ не убывает и увеличивается при обновлении (G.11). В отличие от введённой в обозначениях суммы A_k, начальное значение $\mathcal{A}$ положительно. Радиус r выбирается так, чтобы на малом шаре кривизна менялась не более чем в постоянное число раз. Проксимальный параметр ограничивается снизу по трём причинам, связанным с коэффициентом ускоренного шага, обусловленностью локальной задачи и остановкой. Используем следующие значения:

$$\begin{aligned}r &= \min\left\{R, \frac{1}{2L_1}\right\},\\ \lambda_\downarrow(\mathcal{A}) &= \max\left\{\frac{1 - \frac{1}{2}(r/R)^{2/3}}{\frac{1}{4}(r/R)^{4/3}\mathcal{A}},\ \frac{1}{n}\Bigl(\frac{3}{2}L_0 + 2L_1^2\Bigl(\delta + \frac{R^2}{\mathcal{A}}\Bigr)\Bigr),\ \frac{\varepsilon}{8rR}\right\},\\ \lambda_\uparrow &= \lambda_\downarrow\Bigl(\frac{R^2}{2\Delta}\Bigr).\end{aligned} \tag{G.7}$$

Здесь r — радиус малого шара, $\lambda_\downarrow(\mathcal{A})$ — нижняя граница проксимального параметра, $\lambda_\uparrow$ — верхняя. Три выражения под знаком максимума отвечают этим причинам: первое не даёт коэффициенту α ускоренного шага превысить $\frac{1}{2}(r/R)^{2/3}$, второе делает локальную задачу хорошо обусловленной, третье нужно для остановки.

Метод начинает работу с $x = v = 0$, $\mathcal{A} = R^2/(2\Delta)$, $h = \lambda_\uparrow$ и пустой историей запросов.

G.4 Основная итерация YETI

В состоянии $(x, v, \mathcal{A}, h)$ вычисляются

$$\begin{aligned} \lambda &= \min\bigl\{\max\{h, \lambda_{\downarrow}(\mathcal{A})\}, \lambda_{\uparrow}\bigr\}, \\ a_\lambda &= \frac{1+\sqrt{1+4\lambda\mathcal{A}}}{2\lambda}, \\ \alpha &= \frac{a_\lambda}{\mathcal{A}+a_\lambda}, \\ y &= (1-\alpha)x + \alpha v. \end{aligned} \tag{G.8}$$

Число a_λ — положительный корень уравнения $\lambda a_\lambda^2 = \mathcal{A} + a_\lambda$, поэтому

$$\begin{aligned} \lambda\mathcal{A}\alpha^2 &= 1-\alpha, \\ \lambda a_\lambda &= 1/\alpha. \end{aligned}$$

По значениям градиентов компонент в y проверяется условие на кривизну:

$$\ell(y) \le e^{L_1 r}\Bigl(\frac{3}{2}L_0 + 2L_1^2\Bigl(\delta + \frac{R^2}{\mathcal{A}}\Bigr)\Bigr). \tag{G.9}$$

Если это условие нарушено, то по следствию G.3 невязка в y велика, и полупространство

$$\mathcal{H}_y = \left\{w : \ \langle \nabla f(y), w - y\rangle \le -\frac{\ell(y) - \frac{3}{2}L_0 - 2L_1^2\delta}{2L_1^2}\right\} \tag{G.10}$$

содержит точку минимума. В этом случае выполняется обновление

$$\begin{aligned} v^+ &= \Pi_{B(0,R)}\Pi_{\mathcal{H}_y} v, \\ h^+ &= 2\lambda, \end{aligned}$$

при котором x и $\mathcal{A}$ не меняются. Такой шаг называется повышающим.

Если условие (G.9) выполнено, запускается локальный решатель (алгоритм 5), использующий уже полученные значения и градиенты компонент в y. Он возвращает точку z, субградиент g задачи на шаре $B(0,R)$ в точке z и число $\beta \ge 0$. Если g мал, метод возвращает z. Иначе, положив $\gamma = \lambda/(\lambda+\beta)$, уменьшаем вес ускоренного обновления, умножая его на γ, по схеме из (Carmon et al., 2022):

$$\begin{aligned} \mathcal{A}^+ &= \mathcal{A} + \gamma a_\lambda, \\ x^+ &= \frac{(1-\gamma)\mathcal{A}x + \gamma(\mathcal{A}+a_\lambda)z}{\mathcal{A}^+}, \\ v^+ &= \Pi_{B(0,R)}(v - \gamma a_\lambda g), \\ h^+ &= \begin{cases} 2\lambda, & \beta > 0, \\ \lambda/2, & \beta = 0. \end{cases} \end{aligned} \tag{G.11}$$

Шаг при $\beta > 0$ также называется повышающим, при $\beta = 0$ — понижающим. При $\mathcal{A}^+ \ge 2R^2/\varepsilon$ метод возвращает x^+.

G.5 Эвристический блок

Эвристика использует известные параметры задачи, историю ответов оракула и собственные случайные величины. Каждый блок возвращает управление за конечное число вычислений. Ограничение $n\lceil\log N\rceil$ распространяется на все запросы, включая запросы в отвергнутых точках и начальное вычисление функции и полного градиента в x. Перед вызовом эвристики резервируются n запросов для проверки предложения.

Точка z принимается, если $z \in B(0,R)$ и $f(z) \le f(x)$; при этом меняется только x. Остановка возможна по критерию (G.2). Решения, принимаемые эвристикой, измеримы. Для индексов локального решателя используются новые независимые случайные величины; при заданной истории индексы имеют распределение из раздела 4.

Алгоритм 3 Блок(x): эвристический блок

Вход: точка $x \in B(0,R)$, эвристика

$b = n\lceil \log N \rceil$ ▷ каждый запрос уменьшает b на единицу
Оценка(x)
пока $b \geq n$ и эвристика не завершила блок **выполнять**
    эвристика делает не более $b - n$ запросов и предлагает $z \in B(0,R)$
    Оценка(z)
    если $f(z) \leq f(x)$ **то**
        $x \leftarrow z$
    конец если
конец пока
вернуть x

H Локальное решение методом SVRG

H.1 Локальная задача

Пусть $y \in B(0,R)$, $\lambda > 0$ и $r > 0$. Рассмотрим функции

$$\begin{aligned} P(z) &= f(z) + \frac{\lambda}{2}\|z-y\|^2, \\ P_i(z) &= f_i(z) + \frac{\lambda}{2}\|z-y\|^2, \end{aligned} \tag{H.1}$$

множество $\mathcal{K} = B(0,R) \cap B(y,r)$ и точку

$$u = \arg\min\nolimits_{z\in\mathcal{K}} P(z).$$

Множество $\mathcal{K}$ компактно и выпукло, а P сильно выпукла с параметром λ, поэтому u существует и единственна. Вычисление функции и полного градиента в y позволяет найти числа

$$L_i = e^{3L_1 r}\big(L_{0,i} + L_1\|\nabla f_i(y)\|\big) + \lambda \tag{H.2}$$

и их среднее

$$\overline{L} = \frac{1}{n}\sum_i L_i = e^{3L_1 r}\ell(y) + \lambda.$$

По лемме G.2 норма гессиана P_i на $B(y,3r)$ не превосходит L_i.

Следующая лемма описывает проекцию на $\mathcal{K}$ и локальную кокоэрцитивность компонент; её доказательство приведено в приложении B.3.

Лемма H.1 (проекция на пересечение шаров). ▼доказательство в приложении B.3
Если $z = \Pi_{\mathcal{K}}(b)$, то существуют такие $\xi, \zeta \geq 0$, что

$$\begin{aligned} b - z &= \xi z + \zeta(z-y), \\ \xi > 0 &\Longrightarrow \|z\| = R, \\ \zeta > 0 &\Longrightarrow \|z-y\| = r. \end{aligned} \tag{H.3}$$

Для $x, t \in B(y,r)$ выполнено

$$\|\nabla P_i(x) - \nabla P_i(t)\|^2 \leq 2L_i\big(P_i(x) - P_i(t) - \langle \nabla P_i(t), x-t\rangle\big). \tag{H.4}$$

В частности, градиент P на $B(y,r)$ является $1/\overline{L}$-кокоэрцитивным.

H.2 Эпоха SVRG

В пределах одного вызова решателя величины λ, y и L_i не меняются. Индекс i выбирается с вероятностью $L_i/(n\overline{L})$. Шаг и длина эпохи равны

$$\begin{aligned} h_s &= \frac{1}{6\overline{L}}, \\ M &= \left\lceil \frac{21\overline{L}}{5\lambda} \right\rceil. \end{aligned} \tag{H.5}$$

Так как $L_i \geq \lambda > 0$, все вероятности $L_i/(n\overline{L})$ положительны и их сумма равна единице. В опорной точке $s \in \mathcal{K}$ известны значения и градиенты всех компонент. Из текущей точки x_j делается шаг с новым индексом i_j, условно независимым от предыдущих:

$$\begin{aligned} v_{i_j} &= \nabla P(s) + \frac{\nabla P_{i_j}(x_j) - \nabla P_{i_j}(s)}{L_{i_j}/\overline{L}}, \\ x_{j+1} &= \Pi_{\mathcal{K}}(x_j - h_s v_{i_j}). \end{aligned} \tag{H.6}$$

Следующая эпоха начинается в точке $w^+ = x_M$, а новая опорная точка равна

$$s^+ = \frac{\sum_{j=0}^{M-1}(1 - h_s\lambda)^{M-1-j} x_j}{\sum_{j=0}^{M-1}(1 - h_s\lambda)^j}. \tag{H.7}$$

Первая эпоха вызова начинается с $w = s = y$. Градиенты компонент в опорной точке сохраняются, поэтому один внутренний шаг требует одного запроса.

Алгоритм 4 Эпоха(w, s): эпоха SVRG для локальной задачи

Вход: точки $w, s \in \mathcal{K}$, ответы всех компонент в точке s, P_i, $\mathcal{K}$, L_i, $\overline{L}$, h_s, M из алгоритма 5

1: $x_0 = w$
2: **для** $j = 0, \ldots, M-1$ **выполнять**
3: выбрать индекс $i_j = i$ с вероятностью $L_i/(n\overline{L})$ независимо от прошлого
4: запросить $\nabla f_{i_j}(x_j)$
5: $v_j = \nabla P(s) + \dfrac{\overline{L}}{L_{i_j}}\big(\nabla P_{i_j}(x_j) - \nabla P_{i_j}(s)\big)$
6: $x_{j+1} = \Pi_{\mathcal{K}}(x_j - h_s v_j)$
7: **конец для**
8: **вернуть** $\left(x_M,\ \dfrac{\sum_{j=0}^{M-1}(1 - h_s\lambda)^{M-1-j} x_j}{\sum_{j=0}^{M-1}(1 - h_s\lambda)^j}\right)$

H.3 Остановка локального решателя

После эпохи вычисляется полный градиент в w. Сначала проверяется набор

$$\begin{aligned} z &= w, \\ \beta &= 0, \\ g &= \nabla f(w), \\ e &= \nabla P(w). \end{aligned}$$

Если он не принят, вычисляются точка и векторы

$$\begin{aligned} z &= \Pi_{\mathcal{K}}\big(w - \nabla P(w)/\overline{L}\big), \\ e &= \nabla P(z) - \nabla P(w) + \overline{L}(w - z), \\ g &= \nabla f(z) + \overline{L}\xi z, \end{aligned} \tag{H.8}$$

и число

$$\beta = \overline{L}\zeta,$$

где ξ, ζ — коэффициенты из (H.3) именно для проекции из первой строки. Для вычисления e и g нужен полный градиент в z. В обоих случаях

$$\begin{aligned} & g \in \partial(f + I_{B(0,R)})(z), \\ & e = g - (\lambda + \beta)(y - z), \\ & \beta > 0 \Longrightarrow \|y - z\| = r, \end{aligned} \tag{H.9}$$

где $I_{B(0,R)}$ — индикаторная функция выпуклого множества; её субдифференциал есть нормальный конус. Набор принимается, если выполнено хотя бы одно из условий

$$\begin{aligned} \|g\| &\le \frac{\varepsilon}{4R}, \\ \|e\| &\le \frac{4}{5}(\lambda + \beta)\|y - z\|. \end{aligned} \tag{H.10}$$

Первое условие проверяется раньше второго.

Решатель целиком записан в алгоритме 5. Если после эпохи ни один набор не принят, то вычисляются функция и полный градиент в новой опорной точке и начинается следующая эпоха.

Алгоритм 5 Решатель(y, λ): приближённое решение локальной задачи

Вход: центр $y \in B(0, R)$, в котором известны ответы всех компонент, параметр $\lambda > 0$

$P_i(z) = f_i(z) + \frac{\lambda}{2}\|z - y\|^2$, $i = 1, \dots, n$
$P(z) = f(z) + \frac{\lambda}{2}\|z - y\|^2$
$\mathcal{K} = B(0, R) \cap B(y, r)$
$L_i = e^{3L_1 r}\big(L_{0,i} + L_1\|\nabla f_i(y)\|\big) + \lambda$, $i = 1, \dots, n$
$\overline{L} = \frac{1}{n}\sum_i L_i$
$h_s = 1/(6\overline{L})$
$M = \lceil 21\overline{L}/(5\lambda) \rceil$
набор (z, g, β) *принят*, если $\|g\| \le \dfrac{\varepsilon}{4R}$ или $\|g - (\lambda + \beta)(y - z)\| \le \dfrac{4}{5}(\lambda + \beta)\|y - z\|$
$w = s = y$
повторять
    $(w, s) \leftarrow$ Эпоха(w, s)
    Оценка(w)
    если набор $\big(w, \nabla f(w), 0\big)$ принят **то**
        вернуть $\big(w, \nabla f(w), 0\big)$
    конец если
    $z = \Pi_{\mathcal{K}}\big(w - \nabla P(w)/\overline{L}\big)$
    $\xi, \zeta \ge 0$ — множители нормалей к двум шарам в точке z:
      $w - \nabla P(w)/\overline{L} - z = \xi z + \zeta(z - y)$,
      $\xi > 0 \Longrightarrow \|z\| = R$,
      $\zeta > 0 \Longrightarrow \|z - y\| = r$
    Оценка(z)
    если набор $\big(z, \nabla f(z) + \overline{L}\xi z, \overline{L}\zeta\big)$ принят **то**
        вернуть $\big(z, \nabla f(z) + \overline{L}\xi z, \overline{L}\zeta\big)$
    конец если
    Оценка(s)
конец повторять

Лемма H.2 (число эпох до остановки решателя). ▼ доказательство в приложении B.3
Для набора (H.8) выполнены оценки

$$\begin{aligned} \|z-u\| &\le \|w-u\|, \\ \|e\| &\le \overline{L}\|w-u\|. \end{aligned} \tag{H.11}$$

Поэтому при $\|w-u\| \le \frac{4\lambda}{5\overline{L}+4\lambda}\|y-u\|$ набор принимается. Пусть T_{ep} — число эпох до первого принятого набора. Тогда при $j \ge 1$

$$\Pr(T_{\text{ep}} > j \mid \text{история вызова}) \le \min\{1, \Gamma 2^{-j}\}, \tag{H.12}$$

где

$$\Gamma = \left(1 + \frac{2\overline{L}}{3\lambda}\right)\left(1 + \frac{5\overline{L}}{4\lambda}\right)^2.$$

В частности, решатель почти наверное завершается и делает в среднем конечное число обращений к оракулу.

I Подробности экспериментов

I.1 Условия опытов

Задачи. Используются три группы задач:

- ▷ Цепочки S и X: $n = 16$, $T \in \{8, 16, 32, 64\}$. Это численные варианты семейств из раздела 7 с табулированными интегралами, без скрытия координат и радиального продолжения. Они позволяют сравнить методы при увеличении T; нижнюю оценку для произвольных методов эти опыты не проверяют.
- ▷ Пуассоновские модели $f_i(x) = w_i e^{a_i^\top x} - y_i a_i^\top x$, где $w_i > 0$, $y_i \geq 0$, $L_{0,i} = y_i \|a_i\|^2$, $L_1 = \max_i \|a_i\|$. В синтетических задачах $d = 50$, $n \in \{2000, 20000, 100000\}$, число обусловленности ковариации признаков равно 10^4. На данных Bike Sharing $n = 17379$, $d = 48$; на freMTPL2freq $n = 678013$, $d = 68$.
- ▷ 65 задач: 13 семейств по пять случайных экземпляров. Эта серия включает повёрнутые, плохо обусловленные (до 10^8), нелинейные и разреженные пуассоновские модели, задачи большой размерности, суммы квартических функций и регуляризованную логистическую регрессию. Настройки реализации зафиксированы до запуска этих опытов; задачи, использованные при её разработке, в серию не входят.

Метрика. Учитываются все запросы метода, в том числе запросы для построения начальной метрики, вычисления полных градиентов, стохастических поправок и поиска шага. Один проход равен n запросам. Минимум на цепочках известен из построения; на остальных задачах f_{ref} найдено численно. По эталонному решению вычислены также границы R, Δ, δ, передаваемые YETI как параметры задачи. Запросы для вычисления эталона и внешней диагностики не учитываются. Число запросов до достижения допуска определяется по первой проверенной точке, удовлетворяющей допуску; на 65 задачах рассматриваются все точки с полным набором ответов компонент, включая пробные точки поиска шага. На графиках показана наименьшая невязка, достигнутая к данному моменту. Срабатывание собственного критерия остановки измеряется отдельно.

Методы. На 65 задачах сравниваются YETI, L-BFGS с памятью 50, Cov-LBFGS 1/4 и 1/2, BFGS, метод Нестерова с поиском шага и рестартом, GRAAL со стабилизацией оценки кривизны и SVRG (Liu and Nocedal, 1989, Nocedal and Wright, 2006, Borodich and Kovalev, 2026, Johnson and Zhang, 2013). Cov-LBFGS использует преобразование координат $C^{-1/4}$ или $C^{-1/2}$, где C — центрированная ковариация начальных компонентных градиентов; на отсечённом подпространстве псевдообратная матрица равна нулю. На основном наборе дополнительно рассматриваются нелинейный CG, AdGD, клиппированный градиентный спуск, SAGA и Katyusha (Malitsky and Mishchenko, 2020, Zhang et al., 2020, Defazio et al., 2014, Allen-Zhu, 2018). Для методов уменьшения дисперсии локальные оценки гладкости обновляются по доступным компонентным градиентам.

Ограничения запусков. На цепочках работа методов сравнения ограничена 20000 проходами, на пуассоновских моделях — 1000, на 65 задачах — 3000 проходами и 1800 секундами. Основные таблицы содержат результаты для одного экземпляра каждой конфигурации задачи. В расширенной серии учитываются все запуски, включая неудачные; медиана семейства приводится только при успехе на всех пяти экземплярах.

Испытанный вариант YETI. Для коллинеарных компонентных градиентов эвристика использует секущие из предложения F.1; в остальных случаях — L-BFGS в ковариационной метрике с выбором степени по наблюдаемой секущей. При недостаточной истории применяется обычный L-BFGS. На больших выборках начальная матрица секущих строится по выборке до 4096 строк. После 32 вычислений полного градиента или после неудачного блока возможен переход к полной истории ответов компонент. Плотная ковариация требует $O(nd^2)$ операций, её спектральное разложение — $O(d^3)$. В реализации ограничены доля ускоренного шага и число внутренних вызовов, изменены настройки локального решателя. Теорема 2.9 доказана для алгоритма 1; эти изменения требуют отдельного анализа.

I.2 Результаты по семействам

Рисунок 3 сравнивает методы по всем 65 задачам, таблица 1 показывает медианы по пяти экземплярам каждого семейства. В частности, на квартических задачах с $n < d$ Cov-LBFGS достигает допуска не на всех экземплярах из-за потери направлений при обращении вырожденной ковариационной матрицы.

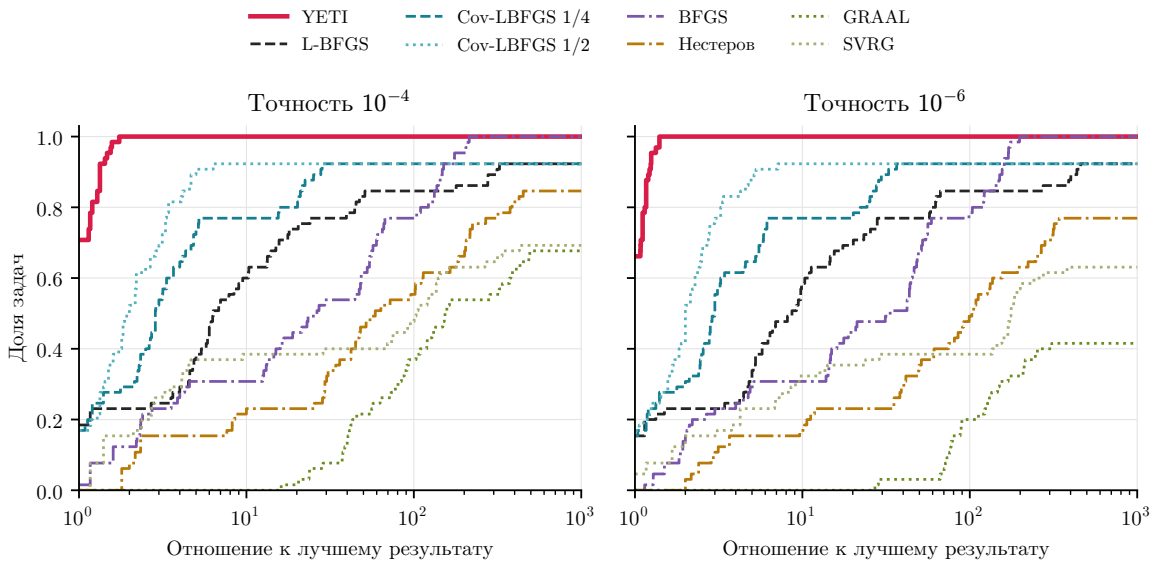


Рис. 3. Доля из 65 задач, на которых число запросов не превышает лучший результат более чем в τ раз (Dolan and Moré, 2002). При $\tau = 1$ учитываются все первые места, включая разделённые; неудачные запуски остаются в знаменателе.

Семейство	YETI	L-BFGS (50)	Cov-LBFGS 1/4	Cov-LBFGS 1/2	BFGS	Нестеров	GRAAL	SVRG
Поворот, 10^4	**6.0**	163	33	15	337	1969	—	—
Поворот, 10^8	**6.0**	2617	155	15	725	—	—	—
Большая размерность	**7.0**	440	42	37	1123	—	—	—
Сильная нелинейность	**8.0**	45	24	27	40	323	1080	34
Редкие признаки	**11**	57	27	19	229	670	1614	94
Редкие, $n = 5 \cdot 10^4$	27	104	30	**25**	464	1230	—	190
$n = 5 \cdot 10^4$, обусл. 10^8	**8.0**	—	237	10	1364	—	—	—
Квартики 32×48	**101**	**101**	—	—	211	1121	—	—
Квартики 256×32	13	73	**12**	29	177	1091	—	—
Квартики, $\nu = 0{,}01$	**7.0**	8.0	**7.0**	11	9.0	22	474	**7.0**
Квартики, $\nu = 0{,}1$	7.0	**6.0**	7.0	11	12	12	444	10
Логистика, поворот	10	88	20	**9.0**	392	1011	—	1519
Логистика, редкие	10	132	28	**9.0**	470	2403	—	1591

Таблица 1. Медиана числа проходов до относительной точности 10^{-6} по пяти экземплярам. «—» означает неудачу хотя бы на одном экземпляре, жирным выделен минимум до округления. κ — число обусловленности ковариации признаков, $n \times d$ — число компонент и размерность.

Результаты на основном наборе приведены в таблицах 2 и 4. В дополнительных запусках YETI на пяти синтетических пуассоновских экземплярах медианы числа проходов равны 4, 5 и 5 при $n = 2000$, 20000 и 100000; диапазоны — 4–5, 5–7 и 5–8 соответственно.

	S, длина T				X, длина T			
Метод	8	16	32	64	8	16	32	64
YETI	**22**	44	**80**	**158**	**21**	**39**	**81**	**151**
L-BFGS	**22**	**43**	87	181	**21**	41	88	175
BFGS	39	79	157	313	27	55	111	217
Katyusha	223	436	868	1726	265	514	1009	2005
Нестеров	82	182	377	763	159	416	873	1850
GRAAL	756	1472	2906	5814	496	1096	2610	5504
AdGD	149	156	1005	4640	392	1650	6538	—
SVRG	3658	13699	—	—	4222	15676	—	—

Таблица 2. Число проходов до относительной точности 10^{-2} на цепочках. Жирным выделен минимум до округления; «—» означает, что допуск не достигнут за отведённое число проходов.

		До $10^{-2}\widehat{\Delta}$			До собственного критерия		
Семейство	T	YETI	Без предложений	Случайные предложения	YETI	Без предложений	Случайные предложения
S	8	22	898	19290	27	2343	46145
S	16	44	2299	43590	47	6329	113107
X	8	21	1218	63896	33	3837	177593
X	16	39	1968	106768	55	7418	—

Таблица 3. Число проходов при трёх вариантах эвристики. Для собственного критерия используется $\varepsilon = 10^{-3}\widehat{\Delta}$. «—» означает, что он не выполнен за 200000 проходов.

	Синтетические задачи, n			Bike	freMTPL2
Метод	2000	20000	100000	Sharing	freq
YETI	**4.0**	**5.0**	**5.0**	**9.0**	7.0
L-BFGS	197	168	99	44	22
Cov-LBFGS 1/4	22	23	16	21	12
BFGS	353	325	253	26	116
Нелинейный CG	705	707	359	108	102
Нестеров	—	775	508	242	77
GRAAL	—	—	984	642	396
AdGD	—	—	—	937	86
Клиппированный GD	—	—	—	—	—
SVRG	—	145	16	10	10
SAGA	—	906	96	32	**5.0**
Katyusha	394	133	43	22	10

Таблица 4. Число проходов до относительной точности 10^{-4} на пуассоновских моделях. Обозначения как в табл. 2.

I.3 Проверка остановки

На 65 задачах при $\varepsilon = 10^{-6}\widehat{\Delta}$ не менее 90% запусков завершаются не позднее чем за 37 проходов. В 63 из 65 запусков YETI останавливается уже в первом эвристическом блоке. Основной проксимальный шаг понадобился только на двух экземплярах с редкими признаками при $n = 50000$: он выполнен 4 и 8 раз. На основном наборе все 45 запусков (24 на цепочках и 21 на регрессии) завершились до первого такого шага. Рисунок 4 показывает два дополнительных запуска с более строгим допуском.

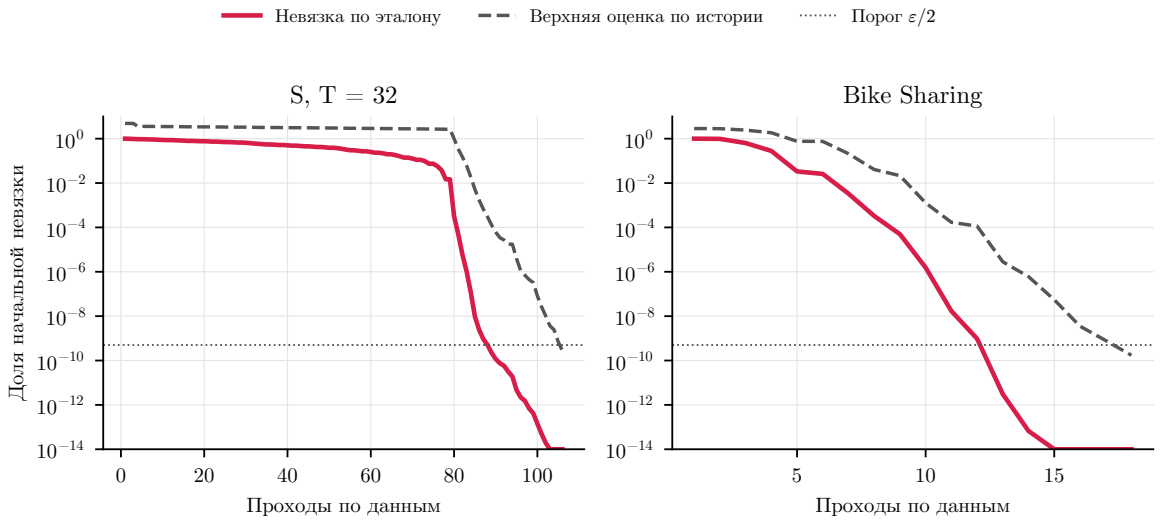


Рис. 4. Невязка относительно эталона и её верхняя оценка по истории при $\varepsilon = 10^{-9}\widehat{\Delta}$. Все величины делятся на $\widehat{\Delta}$; пунктир — порог $\varepsilon/2$. Значения ниже 10^{-14} показаны на нижней границе шкалы.

В таблице 3 сопоставлены обычная эвристика, блок из одного проверочного прохода без предложений и блок, предлагающий случайные точки допустимого шара. В последнем варианте каждый блок расходует весь разрешённый лимит: 243–264 прохода. Общее ограничение составляет 60000 проходов в режиме без предложений и 200000 — со случайными предложениями.

Допуск $10^{-2}\widehat{\Delta}$ достигнут во всех запусках. Отключение предложений эвристики увеличивает число проходов до допуска примерно в 41–58 раз, а случайные предложения — ещё примерно в 19–54 раза относительно режима без предложений. Таким образом, в этих опытах основной выигрыш даёт эвристика. Однако её матричные операции могут быть дорогими, поэтому выигрыш в числе запросов не обязательно означает такой же выигрыш во времени. На X при $T = 16$ собственный критерий не выполнен за отведённое число проходов. Ограничение длины блока не устраняет затрат на бесполезные предложения.

J Сводная таблица известных оценок

Таблица 5. Минимизация суммы: число обращений к оракулу одного слагаемого.

Метод и работа	Гладкость	Выпуклые	Критерий	Оценка
Сумма, L-гладкие слагаемые				
SAGA Defazio et al. (2014)	L	✓	$\mathbb{E}f(\hat{x}) - f^* \le \varepsilon$	$O\Big(n + \dfrac{nF_0 + LR^2}{\varepsilon}\Big)$
Katyusha с AdaptReg[†] Allen-Zhu (2018)	L	✓	$\mathbb{E}f(\hat{x}) - f^* \le \varepsilon$	$O\Big(n \log \dfrac{F_0}{\varepsilon} + \sqrt{\dfrac{nLR^2}{\varepsilon}}\Big)$
Varag[‡] Lan et al. (2019)	L	✓	$\mathbb{E}f(\hat{x}) - f^* \le \varepsilon$	$O\Big(n + n \log \min\Big\{n, \dfrac{D_0}{\varepsilon}\Big\} + \sqrt{\dfrac{nD_0}{\varepsilon}}\Big)$
Нижняя оценка[§] Woodworth and Srebro (2016)	L	✓	$\mathbb{E}f(\hat{x}) - f^* \le \varepsilon$	$\Omega\Big(n + \sqrt{\dfrac{nLR^2}{\varepsilon}}\Big)$
Одна функция ($n = 1$), обобщённая гладкость, оракул полного градиента				
Ускоренный метод[¶] Tyurin (2026)	sym. (L_0, L_1) функции f	✓	$f(\hat{x}) - f^* \le \varepsilon$	$O\Big(\sqrt{\dfrac{L_0R^2}{\varepsilon}} + L_1R \log_+ \min\Big\{\dfrac{2L_1^2F_0}{L_0^2}, \dfrac{2F_0}{\varepsilon}\Big\} + \log_+ \dfrac{2F_0}{L_0R^2}\Big)$
Верхняя и нижняя оценки[††] Rudomanov et al. (2026)	sym. (L_0, L_1) функции f	✓	$f(\hat{x}) - f^* \le \varepsilon$	$\widetilde{\Theta}\Big(\sqrt{\dfrac{L_0R^2}{\varepsilon}} + L_1R\Big)$; при $F_0 \le 4\varepsilon$: $\widetilde{\Theta}\Big(\sqrt{\dfrac{L_0R^2}{\varepsilon}} + (L_1R)^{2/3}\Big)$
Сумма, обобщённая гладкость				
(L_0, L_1)-SGD, SGD-PS[‡‡] Gorbunov et al. (2025)	sym. (L_0, L_1) каждого f_i	✓	см. прим. [‡‡]	$O\Big(\dfrac{L_0R^2}{\varepsilon}\Big)$ при $\delta = 0$ (у всех f_i общая точка минимума)
(L_0, L_1)-SPIDER[§§] Reisizadeh et al. (2023)	усредн. (L_0, L_1)	✗	$\|\nabla f(\hat{x})\| \le \varepsilon$ с вероятностью $\ge 1/2$	$O\Big(n + \dfrac{\sqrt{n}\, L_0F_0}{\varepsilon^2}\Big)$
YETI и нижняя оценка[¶¶] **Эта статья**, теорема 2.9	sym. $(L_{0,i}, L_1)$ каждого f_i	✓	$\mathbb{E}f(\hat{x}) - f^* \le \varepsilon$	$\widetilde{\Theta}\Big(n\big(1 + (L_1R)^{2/3}\big) + \sqrt{\dfrac{n(L_0 + L_1^2\delta)R^2}{\varepsilon} + n(L_1R)^2}\Big)$

Обозначения. $R = \|x_0 - x^*\|$, $F_0 = f(x_0) - f^*$, $\log_+ = \max\{\log, 0\}$; $O(\cdot)$ и $\Omega(\cdot)$ скрывают абсолютные константы, $\widetilde{\Theta}(\cdot)$ — ещё и логарифмические множители. Столбец «Выпуклые»: ✓ — результат получен для выпуклых f_i, ✗ — выпуклость не предполагается.

Гладкость. L: градиент каждого f_i липшицев с константой L. sym.: симметричная (L_0, L_1)-гладкость (Gorbunov et al., 2025, предположение 1.3), $\|\nabla g(x) - \nabla g(y)\| \le \big(L_0 + L_1 \sup_{u \in [x,y]} \|\nabla g(u)\|\big)\|x - y\|$ при всех x, y; для C^2 это равносильно $\|\nabla^2 g(x)\| \le L_0 + L_1\|\nabla g(x)\|$. Усредн.: усреднённая (L_0, L_1)-гладкость (Reisizadeh et al., 2023, предположение 1(ii)), $\big(\frac{1}{n}\sum_{i=1}^n \|\nabla f_i(x) - \nabla f_i(y)\|^2\big)^{1/2} \le \big(L_0 + L_1\|\nabla f(x)\|\big)\|x - y\|$ при $\|x - y\| \le 1/L_1$: слагаемые ограничены лишь в среднеквадратичном смысле, а справа стоит градиент суммы f, а не градиенты слагаемых.

[†] При $0 < \varepsilon \le F_0/2$. [‡] $D_0 = 2F_0 + \frac{3}{2}LR^2$; оценка записана при $D_0 \ge \varepsilon$. [††] Для детерминированных методов при $L_0R^2 \ge \varepsilon$.

[§] Для рандомизированных алгоритмов в достаточно большой размерности, на шаре $\|x\| \le R$.

[¶] Результат получен для ℓ-гладких функций, $\|\nabla^2 f(x)\| \le \ell(\|\nabla f(x)\|)$: для общей ℓ оценка равна $O\big(\sqrt{\ell(0)}\, R/\sqrt{\varepsilon} + T\big)$ с неявным T (Tyurin, 2026, следствие 5.3). Здесь она сведена к $\ell(s) = L_0 + L_1 s$ (Tyurin, 2026, теорема 4.3) при $\bar{R} = R$, $\Gamma_0 = 2F_0/R^2$.

[‡‡] Число стохастических градиентов до выполнения $\min_k \mathbb{E}\min\big\{\frac{\nu L_0}{4nL_1^2}, f(x_k) - f^*\big\} \le \varepsilon$, где $\nu = e^{-\nu}$ (Gorbunov et al., 2025, теоремы 7.2, 7.3); SGD-PS ещё требует знать все $\min f_i$.

[§§] При $\varepsilon < L_0/(20L_1)$; здесь $F_0 = f(x_0) - \inf f$ (Reisizadeh et al., 2023, теорема 4).

[¶¶] $L_{0,i}$ могут различаться, $\frac{1}{n}\sum_i L_{0,i} \le L_0$. Сложность в смысле определения 2.8; скрыты множители $\log^2 N_0$ (нижняя оценка) и $\log^2 N$ (верхняя). Предположения 2.1–2.6, в том числе $n \ge 2$, $\Delta \ge 2\varepsilon$, $L_1^2R^2\delta/\varepsilon \ge 3$; случай $\delta = 0$ не охватывается.